

中国科学院大学

《自然语言处理》实验报告

姓名 薛翼舟 专业 计算机科学与技术

1 实验题目

在这里我选择作业 1-C 进行实验,题目和具体要求如下



7. 习题

1. 利用北京大学标注的《人民日报》1998年1月份的分词和词性标注语料（见SEP平台课程附录03）完成如下工作：
 - ① 设计并实现算法，计算任意两个汉字之间的点式互信息和它们邻近同现的概率，分析两个邻近汉字构成词汇的概率与它们之间点式互信息情况。
 - ② 根据词性分类标记，计算任意两类词汇之间的互信息。
 - ③ 利用网络爬虫从《人民日报》官网(https://paper.people.com.cn/rmrb/pc/layout/202510/15/node_01.html)上爬取尽量多的语料（包括今年1月份的内容），对其进行处理，如清洗乱码等。
 - ④ 利用③中获取的今年1月份的语料与1998年1月的《人民日报》语料进行对比分析，分析词频差异，并抽取出所有的新词。
 - ⑤ 完成一份技术报告，在报告中写明上述各任务的计算结果分析情况，利用什么网络爬虫工具，如何进行的样本清洗等。结果分析有较大的伸缩空间。

2 设计讲解

在本次实验中,我的实验代码目录如下

作业一

```
├── data(存放数据集 ChinesCorpus1998)
├── out(存放输出的 csv 文件和爬取获得的 jsonl 文件)
├── src(存放代码)
│   ├── clean_2026.py(清洗爬取得到的数据集)
│   ├── compare_1998_2026.py(比较 1998 年和 2026 年的数据集)
│   ├── count_1998.py(统计 1998 年数据集的词频)
│   ├── count_2026.py(统计 2026 年数据集的词频)
│   ├── parse_1998.py(解析 1998 年数据集的文本文件)
│   ├── src_crawl_2026_peoplepaper.py(爬取 2026 年数据集的代码)
│   ├── stats_char.py(统计 1998 文本的词频)
│   └── stats_word_pmi.py(统计 1998 文本的词频和 PMI)
```

由于篇幅问题,在这里只对个别关键脚本进行简单讲解,具体代码请参见 src 目录下的文件。

2.1 parse_1998.py

该脚本的主要目标是解析 1998 年人民日报语料库的特定格式文本。它能够逐行读取文件,识别并提取出每个词语及其对应的词性标注,最终将这些词语序列按句子(以句号、问号、叹号为界)组织成列表。

这个脚本里的核心函数 parse_1998_line 主要负责处理单行文本,将这个文本当中的复合词合并成一个整体

2.2 stats_char.py

这个脚本的核心功能是对语料进行统计分析，内部的函数遍历预料中的句子，构建几个统计量，让偶感觉字符频率和字符对共现频率，计算两个汉字之间的 PMI，最后这个函数计算并筛选出整个物料中 PMI 值最高的若干个汉字对，保存到 csv 中

2.3 stats_word_pmi.py

这个脚本主要从词汇方面分析人民日报语料，找词汇之间的关联强度，主要是计算词汇之间的 PMI 值，找出 PMI 值最高的若干个词对。另外，这个脚本中有一些其他的操作，比如会对数据进行预处理，筛掉标点符号等无用的信息，最后这个脚本会产生很多 csv 文件为每种有意义的词性组合（例如 `n_v` 代表名词-动词）生成一个独立的 CSV 文件，其中包含该词性组合下 PMI 最高的词语对。（由于生成的 csv 太多了，所以在本次实验中，我只研究 `n-n`，`a-v` 等少数几种常见组合）

2.4 src_crawl_2026_peoplepaper.py

这是本次实验中最关键的脚本，主要功能是爬取 2026 年一月份人民日报语料库的数据。这个脚本主要使用了 requests 库进行网络请求，使用了 BeautifulSoup 库进行 HTML 解析，使用了 json 库进行数据处理。这个脚本会爬取人民日报网站上 2026 年一月份的所有文章，并将这些文章的标题、发布时间、正文内容等信息保存到一个 jsonl 文件中。在这个脚本中使用了正则表达式来识别文章页的 URL 这个脚本总体的运行流程如下：

1. **日期迭代**: 根据设定的起止日期（例如 2026 年 1 月 1 日到 1 月 31 日），逐日进行抓取。
2. **版面遍历**: 对于每一天，它会尝试从第 01 版遍历到第 30 版（一个预设的上限），构建版面页的 URL 并下载内容。
3. **链接汇总**: 调用链接提取函数，收集当天所有版面下的全部文章链接，并使用集合（Set）进行去重。
4. **文章抓取**: 遍历当天收集到的所有文章链接，下载文章页面，调用解析函数提取数据，并再次进行去重，确保每篇文章只被抓取一次。
5. **数据写入**: 所有文章抓取完毕后，将 `Article` 对象列表以 JSON Lines 的格式写入到指定的输出文件（如 `out/rmrb_2026_01.jsonl`）。JSONL 格式的优点是每行一个独立的 JSON 对象，便于流式处理。

在这里值得一提的是，一开始我是根据绝对路径去填入 URL 的，但是后来发现有些链接是相对路径，所以我改成了使用 `urljoin` 来处理相对路径和绝对路径的链接。

另外，这里还要注意的，我第一次爬取下来的 jsonl 得到的一大堆拉丁文乱码，这是因为 html 被错误编码成了 latin-1，是我的爬虫 requests 获取 `r.text` 时默认使用了 latin-1 编码导致的，所以我在爬取的时候指定了正确的编码 utf-8，最终成功获取了正确的文本内容。

2.5 compare_1998_2026.py

这个脚本是一个词频比较工具它的核心作用是读取两个不同年份（1998 年和 2026 年）的词频统计文件，然后通过计算和排序，找出在这两个时间点上词语使用频率发生了显著变化的词，以及在 2026 年出现的新词。总而言之，这个脚本做了如下三件事：

1. 找出 2026 年比 1998 年更“流行”的词：通过计算词频的对数比率，找到那些在 2026 年使用频率显著高于 1998 年的词。
2. 找出 2026 年比 1998 年更“流行”的词：通过计算词频的对数比率，找到那些在 2026 年使用频率显著高于 1998 年的词。

3. 找出 2026 年比 1998 年更“流行”的词：通过计算词频的对数比率，找到那些在 2026 年使用频率显著高于 1998 年的词。

3 实验结果分析

3.1 字符点互信息表

在 char_pmi_d1_top.csv 中,展示了相邻总次数,以下是这个数据的 top20:

char_x	char_y	f(x,y)	pmi
蜿	蜒	6	18.116826768900644
璀	璨	7	17.894434347564196
澎	湃	5	17.894434347564196
胳膊	膊	9	17.531864268179486
癩痢	痢	7	17.531864268179486
茸	朶	7	17.339219190237092
尴	尬	11	17.242357650984502
遐	迹	6	17.116826768900644
珊	瑚	6	17.019965229648054
貂蝉	蝉	8	16.894434347564193
鞠躬	躬	5	16.853792363066848
磅礴	礴	8	16.79489867401328
葫芦	芦	15	16.79489867401328
肺腑	腑	5	16.79489867401328
崩溃	溃	9	16.742431254119143
荟萃	萃	10	16.7017892696218
秸秆	秆	6	16.7017892696218
祈祷	祷	9	16.54978617617675
猖獗	獗	17	16.531864268179486
脂肪	肪	7	16.531864268179486

两个字的 pmi 值越高,说明它们在文本中越倾向于一起出现,具有更强的关联性。比如“蜿”和“蜒”这两个字的 pmi 值非常高,我发现都是一些相较而言不太常见的字对,这些字对是一些成语或者固定搭配,或者是一些特定领域的术语,这些词对在文本中具有较强的关联性,是一些常用的词组或者短语。

3.2 字符共现频率表

在 char_cooccur_d1_top.csv 中更为直接, 它直接展示了那些汉字对最常相邻出现, 以下是这个数据的 top20: (p_d1 表示相邻出现的概率, 另外, 我筛选掉了一些类似 19,00,99 之类的表示年代的数字, 因为它们的出现频率非常高, 可能会干扰分析结果)

char_x	char_y	f(x,y)	p_d1
中	国	3543	0.002173817009151751
经	济	3474	0.0021314818768820728
发	展	3318	0.002035767664794104
企	业	2610	0.0016013723945487075
工	作	2607	0.0015995317366239389
国	家	2337	0.0014338725233947623
记	者	2158	0.001324046600550234
人	民	2149	0.0013185246267759282
社	会	2072	0.0012712810733735334
一	个	2032	0.0012467389677099515
我	们	2027	0.0012436712045020039
市	场	1973	0.0012105393618561686
建	设	1824	0.0011191200182593267
问	题	1714	0.0010516292276844768
政	府	1626	0.0009976365952245971
全	国	1614	0.0009902739635255227
公	司	1612	0.0009890468582423434
北	京	1607	0.0009859790950343958
本	报	1467	0.0009000817252118597
领	导	1408	0.0008638821193580767

相比上一部分数据, 我发现这些词汇更加常用, 具有更强的普遍性, 这些词对在文本中具有较强的关联性, 是一些常用的词组或者短语。比如中国, 一个, 我们, 国家, 社会等等, 这些都是一些非常常见的词汇, 它们在文本中经常一起出现, 具有较强的关联性, 但是这些词汇的 pmi 值可能并不高, 因为这些字在文本中出现的频率非常高, 所以它们的 pmi 值可能会被稀释掉。

3.3 字符共现概率表

在 char_cooccur_d1_top.csv 中展示了当两个汉字相邻出现时,他们有多大概率是同一个词的,以下是这个数据的 top20:

char_x	char_y	f_inword	f_inword	p_same_word
经	济	3474	3474	1.0
发	展	3318	3318	1.0
企	业	2610	2610	1.0
记	者	2158	2158	1.0
社	会	2072	2072	1.0
我	们	2027	2027	1.0
市	场	1973	1973	1.0
1	月	1943	1943	1.0
问	题	1714	1714	1.0
政	府	1626	1626	1.0
全	国	1614	1614	1.0
公	司	1612	1612	1.0
北	京	1607	1607	1.0
本	报	1467	1467	1.0
领	导	1408	1408	1.0
他	们	1354	1354	1.0
改	革	1291	1291	1.0
中	央	1287	1287	1.0
世	界	1280	1280	1.0

不知 top 二十,将近 top500 的汉字对的 p_same_word 值都是 1.0,说明这些汉字对在文本中几乎总是作为一个词出现的,这些词对在文本中具有较强的关联性,是一些常用的词组或者短语。比如经济,发展,企业,记者,社会,我们等等,

3.4 1998,2026 词频统计

为了更好的比较 1998 和 2026, 我们还需要对这两年的词频进行统计分析, 由于这一步只是为了进行最后一步的比较, 在这里不多赘述

3.5 1998,2026 词频比较

这是本篇报告的最重要的部分, 在这里我人为对数据进行了一些处理, 比如删去了一些比如 copyright,reserved, rights 之类的词汇和 www,cn,com 等一些网址相关的词汇, 因为这些词汇在 2026 年出现的频率非常高, 对分析结果也没有什么意义。以下是这个数据的 top20:

word	f_2026	p_2026	f_1998	p_1998	log_ratio	delta_p
习近平	4137.0	0.0022508185536654	0.0	0.0	14.626804953932616	0.0022508185536654
人工智能	1240.0	0.0006746470888434	0.0	0.0	13.421946484042945	0.0006746470888434
日电	1176.0	0.0006398265939353	0.0	0.0	13.368954034569246	0.0006398265939353
精准	1026.0	0.0005582160589946	0.0	0.0	13.232503160338636	0.0005582160589946
引领	1000.0	0.0005440702329382	0.0	0.0	13.206835460166909	0.0005440702329382
一年	985.0	0.0005359091794441	0.0	0.0	13.191721850346577	0.0005359091794441
更好	944.0	0.0005136022998936	0.0	0.0	13.149206456363729	0.0005136022998936
本报记者	925.0	0.0005032649654678	0.0	0.0	13.128874067723707	0.0005032649654678
研发	819.0	0.0004455935207764	0.0	0.0	13.007164671236847	0.0004455935207764
经济社会	811.0	0.0004412409589129	0.0	0.0	12.997348663636739	0.0004412409589129
这是	748.0	0.0004069645342377	0.0	0.0	12.916483778376316	0.0004069645342377
亿元	718.0	0.0003906424272496	0.0	0.0	12.875550472119132	0.0003906424272496
新能源	688.0	0.0003743203202615	0.0	0.0	12.832869852627006	0.0003743203202615
赋能	656.0	0.0003569100728074	0.0	0.0	12.785241933954678	0.0003569100728074
十四五	646.0	0.000351469370478	0.0	0.0	12.769880692164937	0.000351469370478
最大	635.0	0.0003454845979157	0.0	0.0	12.752706236561838	0.0003454845979157
新质	623.0	0.0003389557551205	0.0	0.0	12.733627812209127	0.0003389557551205
助力	622.0	0.0003384116848875	0.0	0.0	12.732021390903803	0.0003384116848875
高水平	604.0	0.0003286184206946	0.0	0.0	12.702655584161471	0.0003286184206946
产业链	523.0	0.0002845487318266	0.0	0.0	12.558663321583452	0.0002845487318266

从这个数据中我们可以看出, 在 2026 年出现了很多新的词汇, 这些词汇在 1998 年是不存在的, 这些词汇的出现反映了社会的发展和变化, 主要表现在国家领导人, 高科技等方面比如习近平, 人工智能, 新能源等等, 这些词汇的出现反映了社会的发展和变化, 这些词汇的出现也反映了人们的关注点和兴趣的变化。

4 实验总结

通过本次实验, 我对自然语言处理中的一些基本概念和方法有了更深入的理解, 比如词频统计, PMI 计算, 文本清洗, 数据爬取等等, 这些都是自然语言处理中的重要技术和方法。通过对 1998 年和 2026 年人民日报语料库的比较分析, 我发现了一些有趣的现象, 比如一些词汇的出现频率发生了显著变化, 一些新的词汇的出现等等, 这些现象反映了社会的发展和变化, 也反