

中国科学院大学

《自然语言处理》实验报告

姓名 薛翼舟 专业 计算机科学与技术

1 实验题目

1 请下载调试FNN、RNN和LSTM模型的开源工具。利用北京大学标注的《人民日报》1998年1月份的分词语料，或者利用网络爬虫自己从互联网上收集足够多的英文文本语料，借助FNN 或者 RNN/ LSTM 开源工具，完成如下任务：

- (1) 获得汉语或英语词语的词向量。
- (2) 对于同一批词汇，对比分别用FNN, RNN 或 LSTM获得的词向量的差异。
- (3) 利用你认为最好的词向量结果，对于随机选取的20个词汇分别计算与其词向量最相似的前10个单词，按相似度大小排序，人工对比排序结果是否与你的判断一致。
- (4) 如果汉语和英语的词向量都学习到了，请对比同一个意思的汉语词汇和英语词汇，如“书”和‘book’，“工作”和‘work/ job’等，分析其向量距离。

[第(4)题选做]

课程作业-2

2 设计讲解

在本次实验中，我的实验代码目录如下，同样在这里不多赘述每部分代码的具体功能，只对关键部分和实验结果进行讲解

作业一

- ├ out(用于存放输出的比较结果和任务三的测试结果)
- └ src(存放代码)
 - ├ compare.py(用于比较三种模型的词向量)
 - ├ config.py (存放一些全局的配置参数)
 - ├ data.py(存放数据处理的代码)
 - ├ evaluate.py(存放评测代码)
 - ├ model.py(存放三种模型的训练代码)
 - └ train.py(存放训练代码)

在本次实验中，我使用了 PyTorch 框架来实现三种模型的训练和评测。

2.1 config.py

主要是进行一些配置参数的定义，包括数据路径、模型超参数等，以便在其他模块中调用和修改。

2.2 data.py

这个脚本主要负责数据处理和构建，他将原本的人民日报的文本数据进行处理，去掉 /n, /v 这样的词性标注和标点符号，把文本变成模型能看懂的数字 ID。并且根据上下文窗口的大小构建训练数据集

2.3 models.py

按照实验要求定义了三种基于 PyTorch 的神经网络模型架构类, 分别是 FNNModel(前馈神经网络)、RNN-Model(循环神经网络)和 LSTMMModel(长短期记忆网络), 它们均包含 Embedding 层用于后续提取词向量。

2.4 train.py

模型的主训练脚本。串联了数据处理、加载模型与数据集流水线。通过交叉熵计算损失、Adam 优化器进行参数更新。训练结束后会将三个模型的 Embedding 层权重与词表信息保存为.pt 文件。

2.5 compare.py

用于对比和可视化不同模型训练得到的词向量, 包括提取特定词的相似词对比。另外为了可视化差异, 我还使用了 PCA 算法将高维词向量降到二维空间, 并绘图来直观展示不同模型的词向量分布差异。

2.6 evaluate.py

用于词向量评估测试。支持加载训练保存的嵌入权重。我在这里使用余弦相似来计算词汇的相似度。这个脚本指定特定词汇或随机抽取词汇计算余弦相似度从而提取最相关的 top-K 相似词汇并将结果导出。

3 实验结果

3.1 任务 2

在运行 compare.py 脚本后, 我得到了三种模型的词向量相似度比较结果。

3.1.1 【中国】在三种模型下的相似词对比

模型 FNN_embeddings.pt:

全班 (相似度=0.5393)
各族 (相似度=0.5075)
毛 (相似度=0.4690)
政法委 (相似度=0.4687)
雪地 (相似度=0.4624)
朱 (相似度=0.4551)
南翼 (相似度=0.4538)
羁押 (相似度=0.4114)
宝贵 (相似度=0.4095)
尽管如此 (相似度=0.3730)

模型 RNN_embeddings.pt:

热农大 (相似度=0.3933)
近年 (相似度=0.3904)
蒙古 (相似度=0.3693)
南非 (相似度=0.3685)
中非共和国 (相似度=0.3673)
美丽 (相似度=0.3659)
乎 (相似度=0.3605)
体育界 (相似度=0.3499)
边疆 (相似度=0.3494)

置 (相似度=0.3423)

模型 LSTM_embeddings.pt:

杪楞 (相似度=0.3936)
大厦 (相似度=0.3834)
兼顾 (相似度=0.3776)
无私无畏 (相似度=0.3697)
旭东 (相似度=0.3655)
俄罗斯 (相似度=0.3641)
贝鲁特 (相似度=0.3617)
刚刚 (相似度=0.3553)
张北 (相似度=0.3544)
猖獗 (相似度=0.3502)

我们可以看到在三种模型下, 词“中国”的相似词对比结果差异较大, 这可能是由于不同模型的训练方式和结构导致的词向量空间的差异所致。但是经过比较我认为, LSTM 模型产生的相似词结果更好一些, 因为它包含了更多与“中国”相关的地理位置和政治相关词汇(如俄罗斯、贝鲁特等), 相比之下 FNN 和 RNN 模型的相似词更偏向于一些不太相关的词汇(如全班、热农大等)。这可能是因为 LSTM 模型能够更好地捕捉文本中的上下文信息, 从而生成更准确的词向量。

3.1.2 词向量 PCA 可视化对比




图 1: 三种模型的词向量 PCA 可视化对比

在这个图中, 两个点越靠近, 说明语义更相似, 结合坐标尺我们可以看到不同模型下词向量的分布差异。总体来说, LSTM 模型的词向量分布更为紧凑和有意义, 比如中国和美国, 发展和时长与建设靠的很近能够更好地捕捉词汇之间的语义关系, 而 FNN 和 RNN 模型的词向量分布相对较为分散, 可能无法很好地捕捉到词汇之间的语义关系。随着模型从 FNN $\rightarrow$ RNN $\rightarrow$ LSTM, 词向量的语义结构更清晰、聚类更稳定

3.2 任务 3

从任务 2 我们可以认为 LSTM 模型的效果最好, 所以我们根据 LSTM 来完成任务 3, 由于任务 3 最后的输出比较长, 于是我在这里只展示前 5 个词汇的输出结果

=== LSTM 模型测试结果 ===

【中国】的相似词:

杪楞 (相似度=0.3936)

大厦 (相似度=0.3834)
兼顾 (相似度=0.3776)
无私无畏 (相似度=0.3697)
旭东 (相似度=0.3655)
俄罗斯 (相似度=0.3641)
贝鲁特 (相似度=0.3617)
刚刚 (相似度=0.3553)
张北 (相似度=0.3544)
猖獗 (相似度=0.3502)

--- 随机测试 ---

【大西南】的相似词:

地板 (相似度=0.3899)
泳三 (相似度=0.3660)
引人入胜 (相似度=0.3556)
文盛 (相似度=0.3480)
千红 (相似度=0.3478)
曲线 (相似度=0.3477)
洁 (相似度=0.3422)
服装 (相似度=0.3420)
国立 (相似度=0.3396)
降 (相似度=0.3377)

【根本】的相似词:

对敌 (相似度=0.4200)
商业化 (相似度=0.3647)
详尽 (相似度=0.3575)
防护林 (相似度=0.3493)
演出 (相似度=0.3489)
足联 (相似度=0.3384)
善恶 (相似度=0.3330)
抓大放小 (相似度=0.3273)
斯大林 (相似度=0.3186)
工业 (相似度=0.3159)

【使用】的相似词:

消费 (相似度=0.4088)
覆盖 (相似度=0.3888)
雨祥 (相似度=0.3750)
创办 (相似度=0.3743)
外观 (相似度=0.3666)
支行 (相似度=0.3610)
自然环境 (相似度=0.3571)
七日 (相似度=0.3551)
剑 (相似度=0.3547)
击败 (相似度=0.3522)

【秧歌队】的相似词:

常委 (相似度=0.3977)

工作团 (相似度=0.3705)
慷慨 (相似度=0.3681)
足额 (相似度=0.3537)
信息量 (相似度=0.3510)
高位 (相似度=0.3482)
雪上加霜 (相似度=0.3442)
主办员 (相似度=0.3418)
助残 (相似度=0.3400)
亏损 (相似度=0.3326)

【中方】的相似词:

游船 (相似度=0.4037)
徒步 (相似度=0.3622)
囚犯 (相似度=0.3620)
泳三 (相似度=0.3557)
工商联 (相似度=0.3483)
资格 (相似度=0.3442)
商界 (相似度=0.3401)
后头 (相似度=0.3378)
人 (相似度=0.3346)
心愿 (相似度=0.3340)

我们通过这些数据,我觉得大体而言和人工判断的结果相似,比如中国和俄罗斯,使用和消费等。但是距离准确还是有相当的距离的。

1. 相似度绝对数值偏低:所有列出的 Top-10 相似词,其余弦相似度得分基本都在 0.33 到 0.42 之间
2. 语义相关性表现一般,存在大量“噪声”匹配:现象:大部分词的匹配结果显得比较随机。例如:【大西南】与“地板”、“曲线”、“服装”。【使用】与“外观”、“七日”、“剑”。且出现了一些低频词或专有名词

虽然对比可见 LSTM 提取的词向量相对另外两个模型更优,但从绝对相似度分数(普遍低于 0.45)和部分随机的相似词(如大西南-地板)可以看出,当前模型生成的词向量还未能达到比较理想的效果。可能是训练语料的规模有限,或者模型训练的参数设置不够优化,导致词向量质量不高,从而影响了相似度计算的准确性。