

2022—2023 学年春季学期《自然语言处理》B 卷 —— 参考解答

任课教师：宗成庆 | 考核方式：课堂开卷

说明：本解答给出一种完整、可落地的作答思路。分词、命名实体类型、语义角色标签等在学术界存在多套等价方案（如 ARGM-LOC / AM-LOC、UPenn 标注集 / 北大标注集），只要思路正确、自治即可得分。设计题给出的步骤越具体、给出计算公式者得分越高。

第 1 题 标注题 (10 分)

原文：

6 月 25 日是第 33 个全国土地日，今年的主题是“节约集约用地，严守耕地红线”。江苏在全国首创“责任+激励、行政+市场”耕地保护新机制，筑牢粮食“耕”基……守住用好每一寸土地的号角声愈发嘹亮，此次全国土地日主场活动前后，将组织策划“耕地保护进万村”“全国耕地保护全媒体创意作品征集”“在希望的田野上主题直播”等宣传活动，持续提升全社会保护耕地、节约集约和依法依规用地的意识。（文/冯唯歆 图/金裕）

(1) 词语切分（用 / 标注词边界）

6月25日 / 是 / 第 / 33 / 个 / 全国土地日 / ， / 今年 / 的 / 主题 / 是 / “ / 节约 / 集约 / 用地 / 、 / 严守 / 耕地 / 红线 / ” / 。 /
江苏 / 在 / 全国 / 首创 / “ / 责任 / + / 激励 / 、 / 行政 / + / 市场 / ” / 耕地 / 保护 / 新 / 机制 / ， / 筑牢 / 粮食 / “ / 耕 / ” / 基 / …… /
守住 / 用好 / 每 / 一 / 寸 / 土地 / 的 / 号角声 / 愈发 / 嘹亮 / ， /
此次 / 全国土地日 / 主场 / 活动 / 前后 / ， / 将 / 组织 / 策划 / “ / 耕地 / 保护 / 进 / 万村 / ” /
“ / 全国 / 耕地 / 保护 / 全媒体 / 创意 / 作品 / 征集 / ” /
“ / 在 / 希望 / 的 / 田野 / 上 / 主题 / 直播 / ” / 等 / 宣传 / 活动 / ， /
持续 / 提升 / 全社会 / 保护 / 耕地 / 、 / 节约 / 集约 / 和 / 依法依规 / 用地 / 的 / 意识 / 。 /
（ / 文 / / / 冯唯歆 / / 图 / / / 金裕 / ）

切分原则：

- **专有名词 / 主题词整体保留：**全国土地日、全媒体、号角声、全社会、依法依规 等作为一个词，避免切碎丢失专名语义（与 NER 一致）。
- **时间、数字：**6月25日、33 作为整体（时间/数量实体）。
- **标点、引号、分隔符（，、。“”……+ / ）** 独立成词。
- 存在歧义处（如 号角声 → 号角/声、主场活动 → 主场/活动）已采用更细粒度切分，等价切分同样正确。

(2) 命名实体 (NER) 及其类型

实体	类型
----	----

6月25日	时间 / 日期 (DATE / TIME)
33、第 33	数量 / 序数 (CARDINAL / ORDINAL)
江苏	地名 / 行政区划 (LOC / GPE)
冯唯歆、金裕	人名 (PERSON)
全国土地日	事件 / 主题日 (EVENT)
全国土地日主场活动	事件 / 活动 (EVENT)
耕地保护进万村	事件 / 活动名 (EVENT / WORK)
全国耕地保护全媒体创意作品征集	事件 / 活动名 (EVENT / WORK)
在希望的田野上主题直播	事件 / 作品名 (EVENT / WORK)

说明：万村 为泛指（"万个村庄"），不作为专名；全国、今年 为普通名词/时间普通词，不计入命名实体。

(3) 语义角色标注

句子：全国土地日主场将组织策划"耕地保护进万村"等宣传活动。

以谓词 组织策划 为核心：

成分	语义角色	说明
全国土地日主场	ARG0 (施事 Agent)	动作的发起者 / 主办方
宣传活动 (含 耕地保护进万村等)	ARG1 (受事 / 客体 Patient-Theme)	被组织策划的对象
将	ARGM-MOD (情态 / 将来)	助动词，表将来时

第 2 题 计算题 (10 分)

三个训练句分词（与第 (1) 问"以词为单位"保持一致）：

- (a) 他 / 喜欢 / 大 / 模型 / 。
- (b) 大 / 模型 / 让 / 他 / 着迷 / 。
- (c) 他 / 没 / 用 / 过 / 大 / 模型 / 。

(1) 句子 (a) 与 (b) 的词级编辑距离

记 $a = \text{他 喜欢 大 模型 。}$ (长度 5)， $b = \text{大 模型 让 他 着迷 。}$ (长度 6)。设 $d[i][j]$ 为 a 的前 i 个词与 b 的前 j 个词的编辑距离，允许 插入 / 删除 / 替换 (各算 1 步)：

$$d[i][j] = \min \begin{cases} d[i-1][j] + 1 & \text{删除} \\ d[i][j-1] + 1 & \text{插入} \\ d[i-1][j-1] + \text{匹配/替换} & \text{匹配/替换} \end{cases}$$

填充 DP 矩阵 (行 = \$a\$, 列 = \$b\$) :

	ε	大	模型	让	他	着迷	。
ε	0	1	2	3	4	5	6
他	1	1	2	3	3	4	5
喜欢	2	2	2	3	4	4	5
大	3	2	3	3	4	5	5
模型	4	3	2	3	4	5	6
。	5	4	3	3	4	5	5

$$\boxed{\text{编辑距离}} \mathrm{ED}(a,b)=d[5][6]=5, \mathcal{E}$$

一种操作序列 (删 2 + 插 3 = 5 步) : 他 喜欢 大 模型 。 → 删 他 → 删 喜欢 → 大 模型 。 → 插 让 → 插 他 → 插 着迷 → 大 模型 让 他 着迷 。

稳健性说明: 若将术语 大模型 视为一个词, 则 $a=4$ 词、 $b=5$ 词, 用同样 DP 求得编辑距离仍为 5 (核心是要处理 4 个不处于公共子序列中的词) , 结论不受切分影响。

(2) 二元文法 + 加 1 平滑, 求 $P(\text{没喜欢过大模型。})$

引入句界符 <BOS> / <EOS> 。训练语料的词序列:

- (a) <BOS> 他 喜欢 大模型 。 <EOS>
- (b) <BOS> 大模型 让 他 着迷 。 <EOS>
- (c) <BOS> 他 没 用 过 大模型 。 <EOS>

(此处将术语 大模型 作为整体词; 目标句分词为 没 喜欢 过 大模型 。 。)

词表 $V=\{\text{他, 喜欢, 大模型, 。, 让, 着迷, 没, 用, 过}\}$, 故 $|V|=9$ (含句号, 不含句界符) 。

二元同现计数 $c(w_{i-1}w_i)$ 与各前驱词计数 $c(w_{i-1})$:

前驱 w_{i-1}	后继 (计数)	$c(w_{i-1})$
<BOS>	他(2), 大模型(1)	3
他	喜欢(1), 着迷(1), 没(1)	3
喜欢	大模型(1)	1
大模型	。(2), 让(1)	3
让	他(1)	1
着迷	。(1)	1
没	用(1)	1

用	过(1)	1
过	大模型(1)	1
。	<EOS>(3)	3

加 1 平滑公式：

$$p(w_i \mid w_{i-1}) = \frac{1 + c(w_{i-1}w_i)}{|V| + c(w_{i-1})}$$

目标句 没 喜欢 过 大模型 的 二元序列及概率：

二元 (w_{i-1}, w_i)	c	计算	概率
<BOS> → 没	0	$\frac{1}{(9+3)}$	$\frac{1}{12}$
没 → 喜欢	0	$\frac{1}{(9+1)}$	$\frac{1}{10}$
喜欢 → 过	0	$\frac{1}{(9+1)}$	$\frac{1}{10}$
过 → 大模型	1	$\frac{1+1}{(9+1)}$	$\frac{2}{10} = \frac{1}{5}$
大模型 → 。	2	$\frac{2+1}{(9+3)}$	$\frac{3}{12} = \frac{1}{4}$
。 → <EOS>	3	$\frac{3+1}{(9+3)}$	$\frac{4}{12} = \frac{1}{3}$


$$P = \frac{1}{12} \cdot \frac{1}{10} \cdot \frac{1}{10} \cdot \frac{1}{5} \cdot \frac{1}{4} \cdot \frac{1}{3} = \frac{1}{72,000} \approx 1.39 \times 10^{-5}$$

$$\boxed{P(\text{没喜欢过大模型。}) = \frac{1}{72000} \approx 1.39 \times 10^{-5}}$$

说明： <BOS>没、 没喜欢、 喜欢过 三个二元在训练语料中均未出现，靠加 1 平滑获得非零小概率；这正是平滑“劫富济贫”、消除零概率的作用。若把句界符也计入 $|V|$ ，数值会略有差异，但方法与量级一致。

第 3 题 分析标注题（10 分）

短语结构树对应的句子为 “他在阳台读书。”：




(1) 依存关系图

以核心动词 读 为根（ROOT），依存弧（支配词 → 从属词，括号内为关系类型）：

- 读 → 他 主谓关系 (SBV / nsubj)
- 读 → 在 状中关系 (ADV / advmod) —— 介宾短语"在阳台"作处所状语修饰"读"
- 在 → 阳台 介宾关系 (POB / obj) —— "阳台"依存于介词"在"
- 读 → 书 动宾关系 (VOB / obj)

依存树（投射式）：



满足 Robinson 四公理：单一父节点、连通、无环、可投射，是一棵有根树。

(2) 语义角色标注

以谓词 读 为核心：

成分	语义角色	说明
他	ARG0 (施事 Agent)	读书的人
书	ARG1 (受事 / 客体 Patient)	被读的对象
阳台 (在阳台)	ARGM-LOC (地点)	动作发生处所

第 4 题 设计题：抽取汉语语义相近词对（近义词对）（10 分）

基本思路：依据**分布式假设**——上下文分布相似的词语义相近。用连续词向量（word embedding）表示每个词，以**余弦相似度**度量近义程度，结合词性过滤与聚类，自动挖掘近义词对。

实现步骤：

1. 语料准备与预处理

- 收集大规模汉语语料（百科、新闻、网页）。
- 分词 → 词性标注 → 去停用词与噪声 → 低频词过滤（避免长尾噪声，对应齐夫定律）。

2. 训练词向量：用 Word2Vec（Skip-gram 对低频词更优 / CBOW 更快）或 GloVe、BERT 字面+上下文向量，得到词向量矩阵 $V \in \mathbb{R}^{|V| \times d}$ 。

3. 计算两两相似度，对每个词 w_i 取 top- k 近邻： $\mathrm{sim}(w_i, w_j) = \cos(\mathbf{v}_i, \mathbf{v}_j) = \frac{\mathbf{v}_i \cdot \mathbf{v}_j}{\|\mathbf{v}_i\| \|\mathbf{v}_j\|}$

4. 过滤与精排：

- 词性一致：**仅保留同词性候选（名词比名词、动词比动词），排除"同形异类"。
- 阈值筛选：** $\mathrm{sim} \geq \theta$ 者作为候选近义词对。
- 去除同形词、包含关系词（如"汽车/车"属上下位而非近义）。

5. (可选) 聚类形成同义词簇: 对相似度矩阵做层次聚类 / 谱聚类, 每个簇内词互为近义 (对应同义词词林的"同义词群")。
6. (可选) 知识库校验与召回: 结合同义词词林、知网 HowNet (强调概念间关系) 进行校验和补充, 提升召回。
7. 评估: 人工抽样计算准确率 (必要时人工标注少量近义词对计算 P / R / F1)。

第 5 题 设计题: 恢复被打乱的句子顺序 (10 分)

基本思路: 把"恢复原文语序"建模为在所有句子排列中寻找使整篇文档 (语言模型) 概率最大的排列。相邻句子衔接越自然, 整体概率越高。

实现步骤:

1. **句子切分:** 按句末标点 (。 ! ? 等) 切分, 得到句子集合 $S = \{s_1, \dots, s_n\}$ 。
2. **构建语言模型:** 在大规模正常文本上训练 n -gram 或神经语言模型 (也可直接用预训练句向量模型)。
3. **定义相邻衔接得分** (两种主流度量, 可加权融合):
 - **基于语言模型的句间转移概率** (用上一句末词 $\rightarrow$ 下一句首词的二元近似):
$$\mathrm{coh}(s_i \rightarrow s_j) \approx \log p(\text{首词}(s_j) | \text{末词}(s_i))$$
 - **基于句向量的连贯性** (Skip-Thought / BERT 句向量):
$$\mathrm{coh}(s_i \rightarrow s_j) = \cos(\mathrm{vec}(s_i), \mathrm{vec}(s_j))$$
4. **求最优排列:** 排列得分定义为相邻衔接之和
$$\mathrm{Score}(\sigma) = \sum_{i=2}^n \mathrm{coh}(s_{\sigma(i-1)} \rightarrow s_{\sigma(i)})$$
$$\sigma^* = \arg\max_{\sigma} \mathrm{Score}(\sigma)$$
全排列为 $n!$ 不可枚举, 将其转化为最大权哈密顿路径问题 (旅行商问题 TSP 变体), 用下列方法近似求解:
 - 贪心 + 回溯 / 束搜索 (beam search);
 - 模拟退火、遗传算法等启发式搜索;
 - 句向量法下可直接用贪心最近邻衔接。
5. **后处理与输出:** 按 σ^* 重排句子, 必要时按段首缩进、标点等规则还原段落, 输出恢复后的文章。

关键点: 句子本身内部概率 (由语言模型保证通顺) + 句间衔接得分 (保证连贯) 共同决定排列优劣; 公式 (3)(4) 是得分核心。

第 6 题 设计题: 自动计算机器译文的充分性 (sufficiency) (10 分)

概念界定: 充分性 (sufficiency / adequacy) 衡量源文语义是否被译文完整、准确地传达 (不漏译、不增译、不误译), 区别于

- **流畅性 fluency:** 译文本身是否通顺自然;
- **正确性 correctness:** 译文是否合乎目标语言语法。

基本思路：以"源文语义内容在译文中的覆盖/对齐程度"度量充分性。下面给出由经典到主流的四种方法，实际系统可综合使用。

方法 A：基于参考译文的 n-gram 召回 (METEOR 思路)

有人工参考译文 \$R\$ 时，统计机器译文 \$T\$ 对 \$R\$ 的语义覆盖，**侧重召回率**（信息是否齐全，区别于 BLEU 侧重精确率）：

$$\mathrm{Adequacy} \approx \mathrm{Recall}_n = \frac{\#\{T \text{ 与 } R \text{ 匹配的 } n\text{-gram}\}}{\#\{R \text{ 的 } n\text{-gram 数}\}}$$

更推荐 **METEOR**：综合精确率与召回率，并允许**同义词、词干**匹配（ F_{mean} + 惩罚项 P_{pen} ），更贴近充分性语义：

$$\mathrm{METEOR} = F_{\text{mean}} \cdot (1 - P_{\text{pen}}), \quad F_{\text{mean}} = \frac{10PR}{R + 9P}$$

方法 B：基于源文—译文词对齐

对源文 \$S\$ 与译文 \$T\$ 做词对齐 (alignment)，统计**源文实词（名词、动词、形容词等）被正确翻译的比例**：

$$\mathrm{Adequacy} = \frac{\#\{\text{被译文覆盖的源文实词}\}}{\#\{\text{源文实词总数}\}}$$

漏译（分母项无对应译文）会直接拉低分数，正好刻画"充分性"。

方法 C：基于跨语言语义嵌入相似度 (无参考译文)

将 \$S\$、\$T\$ 分别编码为句向量 (LASER / LaBSE / 多语 BERT)，计算跨语言余弦相似度，相似度越高说明语义保持越充分：

$$\mathrm{Adequacy} = \cos(\angle(\mathrm{vec}(S), \mathrm{vec}(T))) \in [-1, 1]$$

方法 D：学习型指标 (QE / COMET 类)

用大量**人工充分性评分**训练回归模型，输入 \$(S, T)\$ 或 \$(S, T, R)\$ 的特征（对齐、嵌入、置信度等），输出充分性分数；代表系统如 **COMET**、**BLEURT**、**wmt-QE**，是当前与人工相关性最高的自动指标。

实现步骤（通用）：

1. 数据准备：源文 \$S\$、机器译文 \$T\$（必要时参考译文 \$R\$）；预处理（分词、对齐）。
2. 选定上述方法之一（或组合）；有参考 → A/B；无参考 → C/D。
3. 按公式计算充分性得分。
4. 归一化到统一区间（如 \$[0, 1]\$）；用人工标注做相关性校准（Pearson / Spearman）。

设计题评分要点：明确"充分性 = 语义覆盖/保持"的内涵、给出可计算公式、步骤完整。本答给出 4 种互补方法并附公式，可任选重点展开。