

2022—2023 学年春季学期《自然语言处理》B 卷 —— 参考解答

任课教师：宗成庆 | 考核方式：课堂开卷

说明：本解答给出一种完整、可落地的作答思路。分词、命名实体类型、语义角色标签等在学术界存在多套等价方案（如 ARGM-LOC / AM-LOC、UPenn 标注集 / 北大标注集），只要思路正确、自洽即可得分。设计题给出的步骤越具体、给出计算公式者得分越高。

第 1 题 标注题（10 分）

原文：

6 月 25 日是第 33 个全国土地日，今年的主题是“节约集约用地，严守耕地红线”。江苏在全国首创“责任+激励、行政+市场”耕地保护新机制，筑牢粮食“耕”基……守住用好每一寸土地的号角声愈发嘹亮，此次全国土地日主场活动前后，将组织策划“耕地保护进万村”“全国耕地保护全媒体创意作品征集”“在希望的田野上主题直播”等宣传活动，持续提升全社会保护耕地、节约集约和依法依规用地的意识。（文/冯唯歆 图/金裕）

(1) 词语切分（用 / 标注词边界）

6月25日 / 是 / 第 / 33 / 个 / 全国土地日 / ， / 今年 / 的 / 主题 / 是 / “ / 节约 / 集约 / 用地 / 、 / 严守 / 耕地 / 红线 / ” / 。 /
江苏 / 在 / 全国 / 首创 / “ / 责任 / + / 激励 / 、 / 行政 / + / 市场 / ” / 耕地 / 保护 / 新 / 机制 / ， / 筑牢 / 粮食 / “ / 耕 / ” / 基 / /
守住 / 用好 / 每 / 一 / 寸 / 土地 / 的 / 号角声 / 愈发 / 嘹亮 / ， /
此次 / 全国土地日 / 主场 / 活动 / 前后 / ， / 将 / 组织 / 策划 / “ / 耕地 / 保护 / 进 / 万村 / ” /
“ / 全国 / 耕地 / 保护 / 全媒体 / 创意 / 作品 / 征集 / ” /
“ / 在 / 希望 / 的 / 田野 / 上 / 主题 / 直播 / ” / 等 / 宣传 / 活动 / ， /
持续 / 提升 / 全社会 / 保护 / 耕地 / 、 / 节约 / 集约 / 和 / 依法依规 / 用地 / 的 / 意识 / 。 /
（ / 文 / / / 冯唯歆 / / 图 / / / 金裕 / ）

切分原则：

- **专有名词 / 主题词整体保留：**全国土地日、全媒体、号角声、全社会、依法依规 等作为一个词，避免切碎丢失专有语义（与 NER 一致）。
- **时间、数字：**6月25日、33 作为整体（时间/数量实体）。
- **标点、引号、分隔符（，。、"".....+/）** 独立成词。
- 存在歧义处（如 号角声 → 号角/声、主场活动 → 主场/活动）已采用更细粒度切分，等价切分同样正确。

(2) 命名实体（NER）及其类型

实体	类型
6月25日	时间 / 日期 (DATE / TIME)
33、第 33	数量 / 序数 (CARDINAL / ORDINAL)
江苏	地名 / 行政区划 (LOC / GPE)
冯唯歆、金裕	人名 (PERSON)
全国土地日	事件 / 主题日 (EVENT)
全国土地日主场活动	事件 / 活动 (EVENT)
耕地保护进万村	事件 / 活动名 (EVENT / WORK)
全国耕地保护全媒体创意作品征集	事件 / 活动名 (EVENT / WORK)
在希望的田野上主题直播	事件 / 作品名 (EVENT / WORK)

说明：万村 为泛指 ("万个村庄")，不作为专名；全国、今年 为普通名词/时间普通词，不计入命名实体。

(3) 语义角色标注

句子：全国土地日主场将组织策划"耕地保护进万村"等宣传活动。

以谓词 组织策划 为核心：

成分	语义角色	说明
全国土地日主场	ARG0 (施事 Agent)	动作的发起者 / 主办方
宣传活动 (含 耕地保护进万村 等)	ARG1 (受事 / 客体 Patient-Theme)	被组织策划的对象
将	ARGM-MOD (情态 / 将来)	助动词，表将来时

第 2 题 计算题 (10 分)

三个训练句分词 (与第 (1) 问"以词为单位"保持一致)：

- (a) 他 / 喜欢 / 大 / 模型 / 。
- (b) 大 / 模型 / 让 / 他 / 着迷 / 。
- (c) 他 / 没 / 用 / 过 / 大 / 模型 / 。

(1) 句子 (a) 与 (b) 的词级编辑距离

记 $a = \text{他 喜欢 大 模型}。$ (长度 5)， $b = \text{大 模型 让 他 着迷}。$ (长度 6)。设 $d[i][j]$ 为 a 的前 i 个词与 b 的前 j 个词的编辑距离，允许 插入 / 删除 / 替换 (各算 1 步)：

$$d[i][j] = \min \begin{cases} d[i-1][j] + 1 & \text{(删除)} \\ d[i][j-1] + 1 & \text{(插入)} \\ d[i-1][j-1] + 1[a_i \neq b_j] & \text{(匹配/替换)} \end{cases}$$

填充 DP 矩阵（行 = a ，列 = b ）：

	ε	大	模型	让	他	着迷	。
ε	0	1	2	3	4	5	6
他	1	1	2	3	3	4	5
喜欢	2	2	2	3	4	4	5
大	3	2	3	3	4	5	5
模型	4	3	2	3	4	5	6
。	5	4	3	3	4	5	5

编辑距离 $ED(a,b) = d[5][6] = 5$

一种操作序列（删 2 + 插 3 = 5 步）：他 喜欢 大 模型 。 → 删他 → 删喜欢 → 大 模型 。 → 插让 → 插他 → 插着迷 → 大 模型 让 他 着迷 。

稳健性说明：若将术语 大模型 视为一个词，则 $a=4$ 词、 $b=5$ 词，用同样 DP 求得编辑距离仍为 **5**（核心是要处理 4 个不处于公共子序列中的词），结论不受切分影响。

(2) 二元文法 + 加 1 平滑，求 $P(\text{没喜欢过大模型。})$

引入句界符 $\langle BOS \rangle / \langle EOS \rangle$ 。训练语料的词序列：

- (a) $\langle BOS \rangle$ 他 喜欢 大模型 。 $\langle EOS \rangle$
- (b) $\langle BOS \rangle$ 大模型 让 他 着迷 。 $\langle EOS \rangle$
- (c) $\langle BOS \rangle$ 他 没 用 过 大模型 。 $\langle EOS \rangle$

（此处将术语 大模型 作为整体词；目标句分词为 没 喜欢 过 大模型 。。）

词表 $V = \{\text{他, 喜欢, 大模型, 。, , 让, 着迷, 没, 用, 过}\}$ ，故 $|V| = 9$ （含句号，不含句界符）。

二元同现计数 $c(w_{i-1}w_i)$ 与各前驱词计数 $c(w_{i-1})$ ：

前驱 w_{i-1}	后继（计数）	$c(w_{i-1})$
$\langle BOS \rangle$	他(2), 大模型(1)	3
他	喜欢(1), 着迷(1), 没(1)	3
喜欢	大模型(1)	1
大模型	。(2), 让(1)	3
让	他(1)	1
着迷	。(1)	1
没	用(1)	1
用	过(1)	1

前驱 w_{i-1}	后继 (计数)	$c(w_{i-1})$
过	大模型(1)	1
。	<EOS>(3)	3

加 1 平滑公式：

$$p(w_i \mid w_{i-1}) = \frac{1 + c(w_{i-1}w_i)}{|V| + c(w_{i-1})}$$

目标句 没 喜欢 过 大模型 的 二元序列及概率：

二元 (w_{i-1}, w_i)	c	计算	概率
<BOS> → 没	0	$(1)/(9 + 3)$	$1/12$
没 → 喜欢	0	$(1)/(9 + 1)$	$1/10$
喜欢 → 过	0	$(1)/(9 + 1)$	$1/10$
过 → 大模型	1	$(1 + 1)/(9 + 1)$	$2/10 = 1/5$
大模型 → 。	2	$(2 + 1)/(9 + 3)$	$3/12 = 1/4$
。 → <EOS>	3	$(3 + 1)/(9 + 3)$	$4/12 = 1/3$


$$P = \frac{1}{12} \cdot \frac{1}{10} \cdot \frac{1}{10} \cdot \frac{1}{5} \cdot \frac{1}{4} \cdot \frac{1}{3} = \frac{1}{72\,000} \approx 1.39 \times 10^{-5}$$

$$P(\text{没喜欢过大模型。}) = \frac{1}{72000} \approx 1.39 \times 10^{-5}$$

说明：<BOS>没、没喜欢、喜欢过 三个二元在训练语料中均未出现，靠加 1 平滑获得非零小概率；这正是平滑“劫富济贫”、消除零概率的作用。若把句界符也计入 $|V|$ ，数值会略有差异，但方法与量级一致。

第 3 题 分析标注题（10 分）

短语结构树对应的句子为 "他在阳台读书。":




(1) 依存关系图

以核心动词 读 为根（ROOT），依存弧（支配词 → 从属词，括号内为关系类型）：

- 读 → 他 主谓关系（SBV / nsubj）
- 读 → 在 状中关系（ADV / advmod）—— 介宾短语"在阳台"作处所状语修饰"读"
- 在 → 阳台 介宾关系（POB / obj）—— "阳台"依存于介词"在"
- 读 → 书 动宾关系（VOB / obj）

依存树（投射式）：



满足 Robinson 四公理：单一父节点、连通、无环、可投射，是一棵有根树。

(2) 语义角色标注

以谓词 读 为核心：

成分	语义角色	说明
他	ARG0 （施事 Agent）	读书的人
书	ARG1 （受事 / 客体 Patient）	被读的对象
阳台（在阳台）	ARGM-LOC （地点）	动作发生处所

第 4 题 设计题：抽取汉语语义相近词对（近义词对）（10 分）

基本思路：依据**分布式假设**——上下文分布相似的词语义相近。用连续词向量（word embedding）表示每个词，以**余弦相似度**度量近义程度，结合词性过滤与聚类，自动挖掘近义词对。

实现步骤：

1. 语料准备与预处理

- 收集大规模汉语语料（百科、新闻、网页）。
- 分词 → 词性标注 → 去停用词与噪声 → 低频词过滤（避免长尾噪声，对应齐夫定律）。

2. 训练词向量：用 Word2Vec（Skip-gram 对低频词更优 / CBOW 更快）或 GloVe、BERT 字面+上下文向量，得到词向量矩阵 $V \in \mathbb{R}^{|V| \times d}$ 。

3. 计算两两相似度，对每个词 w_i 取 top- k 近邻：

$$\text{sim}(w_i, w_j) = \cos(\mathbf{v}_i, \mathbf{v}_j) = \frac{\mathbf{v}_i \cdot \mathbf{v}_j}{\|\mathbf{v}_i\| \|\mathbf{v}_j\|}$$

4. 过滤与精排：

- **词性一致**：仅保留同词性候选（名词比名词、动词比动词），排除“同形异类”。
 - **阈值筛选**： $\text{sim} \geq \theta$ 者作为候选近义词对。
 - 去除同形词、包含关系词（如“汽车/车”属上下位而非近义）。
5. **（可选）聚类形成同义词簇**：对相似度矩阵做层次聚类 / 谱聚类，每个簇内词互为近义（对应同义词词林的“同义词群”）。
6. **（可选）知识库校验与召回**：结合同义词词林、知网 **HowNet**（强调概念间关系）进行校验和补充，提升召回。
7. **评估**：人工抽样计算准确率（必要时人工标注少量近义词对计算 P / R / F1）。

第 5 题 设计题：恢复被打乱的句子顺序（10 分）

基本思路：把“恢复原文语序”建模为**在所有句子排列中寻找使整篇文档（语言模型）概率最大的排列**。相邻句子衔接越自然，整体概率越高。

实现步骤：

1. **句子切分**：按句末标点（。！？等）切分，得到句子集合 $S = \{s_1, \dots, s_n\}$ 。
2. **构建语言模型**：在大规模正常文本上训练 n -gram 或神经语言模型（也可直接用预训练句向量模型）。
3. **定义相邻衔接得分**（两种主流度量，可加权融合）：

- **基于语言模型的句间转移概率**（用上一句末词 $\rightarrow$ 下一句首词的二元近似）：

$$\text{coh}(s_i \rightarrow s_j) \approx \log p(\text{首词}(s_j) \mid \text{末词}(s_i))$$

- **基于句向量的连贯性**（Skip-Thought / BERT 句向量）：

$$\text{coh}(s_i \rightarrow s_j) = \cos(\text{vec}(s_i), \text{vec}(s_j))$$

4. **求最优排列**：排列得分定义为相邻衔接之和

$$\text{Score}(\sigma) = \sum_{i=2}^n \text{coh}(s_{\sigma(i-1)} \rightarrow s_{\sigma(i)})$$
$$\sigma^* = \arg \max_{\sigma} \text{Score}(\sigma)$$

全排列为 $n!$ 不可枚举，将其转化为**最大权哈密顿路径**问题（旅行商问题 TSP 变体），用下列方法近似求解：

- **贪心 + 回溯 / 束搜索（beam search）**；
- **模拟退火、遗传算法**等启发式搜索；
- 句向量法下可直接用贪心最近邻衔接。

5. **后处理与输出**：按 σ^* 重排句子，必要时按段首缩进、标点等规则还原段落，输出恢复后的文章。

关键点：句子本身内部概率（由语言模型保证通顺）+ 句间衔接得分（保证连贯）共同决定排列优劣；公式 (3)(4) 是得分核心。

第 6 题 设计题：自动计算机器译文的充分性（sufficiency）（10 分）

概念界定：充分性（sufficiency / adequacy）衡量源文语义是否被译文完整、准确地传达（不漏译、不增译、不误译），区别于

- **流畅性 fluency**：译文本身是否通顺自然；
- **正确性 correctness**：译文是否合乎目标语言语法。

基本思路：以“源文语义内容在译文中的覆盖/对齐程度”度量充分性。下面给出由经典到主流的四种方法，实际系统可综合使用。

方法 A：基于参考译文的 n-gram 召回（METEOR 思路）

有人工参考译文 R 时，统计机器译文 T 对 R 的语义覆盖，**侧重召回率**（信息是否齐全，区别于 BLEU 侧重精确率）：

$$\text{Adequacy} \approx \text{Recall}_n = \frac{\#(T \text{ 与 } R \text{ 匹配的 } n\text{-gram})}{\#(R \text{ 的 } n\text{-gram 数})}$$

更推荐 **METEOR**：综合精确率与召回率，并允许同义词、词干匹配（ $F_{\text{mean}} + \text{惩罚项 } P_{\text{pen}}$ ），更贴近充分性语义：

$$\text{METEOR} = F_{\text{mean}} \cdot (1 - P_{\text{pen}}), \quad F_{\text{mean}} = \frac{10PR}{R + 9P}$$

方法 B：基于源文—译文词对齐

对源文 S 与译文 T 做词对齐（alignment），统计**源文实词（名词、动词、形容词等）被正确翻译的比例**：

$$\text{Adequacy} = \frac{\# \text{ 被译文覆盖的源文实词}}{\# \text{ 源文实词总数}}$$

漏译（分母项无对应译文）会直接拉低分数，正好刻画“充分性”。

方法 C：基于跨语言语义嵌入相似度（无参考译文）

将 S 、 T 分别编码为句向量（LASER / LaBSE / 多语 BERT），计算跨语言余弦相似度，相似度越高说明语义保持越充分：

$$\text{Adequacy} = \cos(\text{vec}(S), \text{vec}(T)) \in [-1, 1]$$

方法 D：学习型指标（QE / COMET 类）

用大量**人工充分性评分**训练回归模型，输入 (S, T) 或 (S, T, R) 的特征（对齐、嵌入、置信度等），输出充分性分数；代表系统如 **COMET**、**BLEURT**、**wmt-QE**，是当前与人工相关性最高的自动指标。

实现步骤（通用）：

1. 数据准备：源文 S 、机器译文 T （必要时参考译文 R ）；预处理（分词、对齐）。
2. 选定上述方法之一（或组合）；有参考 $\rightarrow$ A/B；无参考 $\rightarrow$ C/D。
3. 按公式计算充分性得分。
4. 归一化到统一区间（如 $0 \sim 1$ ）；用人工标注做相关性校准（Pearson / Spearman）。

设计题评分要点：明确"充分性 = 语义覆盖/保持"的内涵、给出可计算公式、步骤完整。本答给出 4 种互补方法并附公式，可任选重点展开。