

国科大-宗成庆《自然语言处理》期末试卷·解答与考点整理

试卷结构：一、完成下列各题（20 分，5 小题）；二、阐述题（10 分）；三、综合题（15 分，2 题）；四、句法分析（15 分）。共 60 分。说明：原卷 PDF 内嵌字体无 Unicode 映射，`pdftotext` 丢中文，下述题干经图像辨识得到；图1/图2 依存树、第(3)题有限状态自动机 M 的细节为图像辨识结果，凡涉及具体数值处已标注，请对照原图核对。

一、完成下列各题（20 分）

(1) 给出一个汉语句子，说明连词引起歧义结构

例句：「我和他的老师」

连词「和」的作用范围（管辖域）不同导致两种句法结构：

- 切分一：[我] 和 [他的老师]
 - 「和」连接「我」与「他的老师」两个并列名词短语；
 - 语义：一个人（我）与另一个人（他的老师）。
- 切分二：[我和他] 的 老师
 - 「和」连接「我」与「他」，整体作定语修饰「老师」；
 - 语义：我和他共同的老师。

类似例：「中国和俄罗斯的关系」→ (中国) 和 (俄罗斯的关系) vs (中国和俄罗斯) 的关系。考点：歧义（结构歧义）是 NLP 的核心困难之一；连词「和/与/或/同」的辖域歧义是典型。

(2) 字符串 `aomnad` 与单词 `command` 的编辑距离

编辑距离（Levenshtein Distance）= 把串 X 变成 Y 所需插入、删除、替换的最少操作数。动态规划：

	ε	c	o	m	m	a	n	d
ε	0	1	2	3	4	5	6	7
a	1	1	2	3	4	4	5	6
o	2	2	1	2	3	4	5	6
m	3	3	2	1	2	3	4	5
n	4	4	3	2	2	3	3	4
a	5	5	4	3	3	2	3	4
d	6	6	5	4	4	3	3	3

编辑距离 = $D[6][7] = 3$

一种最优对齐（3 步）：

a o m n a d	操作
c o m m a n d	_____
	a → c (替换)
a→c	
o=o (匹配)	
m=m (匹配)	
n→m (替换)	n 替换为 command 的第 2 个 m
a=a (匹配)	
+n (插入)	插入 n
d=d (匹配)	

结论: $\text{ed}(\text{aomnad}, \text{command}) = 3$ 。 **考点:** 噪声信道模型在拼写检查中的应用；编辑距离的定义与 DP 求解；阈值 t 的作用（限定截取范围与编辑距离上界）。

(3) 由有限状态自动机 M 构造正则文法 G ，使 $L(G) = T(M)$

⚠ 原图自动机的状态/转移辨识不清，下面给出通用构造方法，套用到具体 M 即可。

构造方法 (FA → 右线性正则文法)

设 $M = (\Sigma, Q, \delta, q_0, F)$ ，令文法 $G = (N, \Sigma, P, S)$ ，其中 $N = Q$ (状态作非终结符)， $S = q_0$ ：

1. 对每个转移 $\delta(A, a) = B$ ，加产生式 $A \rightarrow aB$ ；
2. 若 $\delta(A, a) = B$ 且 $B \in F$ (B 为终态)，再加 $A \rightarrow a$ (直接生成终极符)；
3. 若 $q_0 \in F$ ，加 $S \rightarrow \epsilon$ 。

示例: M 接受所有以 1 结尾的 0/1 串。 $Q = \{q_0, q_1\}$ ， $\Sigma = \{0,1\}$ ， q_0 起始， $F = \{q_1\}$ ， $\delta(q_0,0)=q_0$ ， $\delta(q_0,1)=q_1$ ， $\delta(q_1,0)=q_1$ ， $\delta(q_1,1)=q_1$ 。

构造得：

$$\begin{aligned} q_0 &\rightarrow 0 q_0 \mid 1 q_1 \mid 1 \\ q_1 &\rightarrow 0 q_1 \mid 1 q_1 \mid 0 \mid 1 \end{aligned}$$

考点: 正则文法 (3 型) 与有限状态自动机的等价性 $T(M) = L(G)$ ；右线性规则形式 $A \rightarrow xB$ 或 $A \rightarrow x$ 。

(4) 复杂特征集 $A \cup B = ?$

$A = [$	POS = NN	$B = [$	Lex = boy
	Lex = boy		Num = Single
	Sem = Agent]		Case = Subject]

合一 (Unification) 运算: 对同名属性要求值一致 (冲突则失败)，不同名属性合并。

- 共有属性 **Lex**: A 、 B 均为 **boy**，一致 ✓；

- 其余属性互补，直接合并。

```
A ∪ B = [ POS   = NN
           Lex    = boy
           Sem    = Agent
           Num    = Single
           Case   = Subject ]
```

考点：复杂特征集（feature structure）与合一运算，用于基于合一的句法分析；合一满足交换律、结合律，冲突则不可合一。

(5) 写出句子 "I study English every day." 的所有 3 元文法（Tri-grams）

为统计句首/句尾概率，引入边界符 $\langle s \rangle$ 、 $\langle /s \rangle$ （trigram 通常再加一个起始符）。

句子词序列（加边界）： $\langle s \rangle \langle s \rangle$ I study English every day $\langle /s \rangle$

所有 3 元文法（共 6 个）：

#	Trigram
1	$\langle s \rangle \langle s \rangle$ I
2	$\langle s \rangle$ I study
3	I study English
4	study English every
5	English every day
6	every day $\langle /s \rangle$

若不设边界符，则仅有 3 个词内 trigram：I study English、study English every、English every day。**考点：**n 元文法模型；trigram 条件概率 $P(w_i \mid w_{i-2} w_{i-1})$ ；边界符的作用。

二、阐述题（10 分）：设计一种新的、可计算的机器翻译译文质量自动评价方法

方法：语义加权 BLEU（Semantic-weighted BLEU, SW-BLEU）

动机：传统 BLEU 只做表面 n-gram 精确匹配，对同义替换（如 *important/crucial*）、语态转换、词序调整等合法译法过度惩罚；而人工评价又不可大规模复用。需要一个**仍可自动计算**但能感知**语义**的方法。

步骤与公式

1. 对参考译文 R、机器译文 H 分别分词，得词序列。
2. 取 H 中每个 n-gram，在 R 中查找匹配，按匹配类型加权：
 - **精确匹配**（n-gram 完全相同）：权重 $w = 1$ ；
 - **语义近似匹配**（逐词词向量余弦相似度均值 $\geq$ 阈值 τ ）：权重 $w = \lambda$ ($0 < \lambda < 1$ ，如 0.6)；

- 无匹配： $w = 0$ 。
3. 加权 n-gram 精度：

$$P_n^{sem} = \frac{\sum_{g \in H_n} w(g)}{\text{H 中 n-gram 总数}}$$

4. 几何平均 + 长度惩罚（沿用 BLEU）：

$$\text{SW-BLEU} = BP \cdot \exp\left(\sum_{n=1}^N \alpha_n \log P_n^{sem}\right), \quad BP = \min(1, e^{1-|R|/|H|})$$

（可选）再与目标语言模型困惑度（流畅度项）线性组合，兼顾通顺度。

合理性论证

- **可计算**：n-gram 计数、词向量（预训练）、余弦相似度、BP 均为确定可程序化的运算，无需人工介入；
- **语义感知**：词向量把“同义不同形”的译法纳入奖励，缓解 BLEU 的表面惩罚，更贴近人工“忠实度”判断；
- **可调**：阈值 τ 、权重 λ 、阶数 N 、组合系数 α_n 均可据语料调参，便于优化；
- **兼容性**：当 $\lambda = 0$ （关闭语义匹配）时退化为标准 BLEU，便于对照。

考点：译文评估的三大要素（流畅度、充分性、语义保持）；客观评测方法（WER、BLEU、METEOR、基于深度学习的方法）；新方法须“可计算”的设计要求。

三、综合题（15 分）

1. 分词与词性标注系统的准确率、召回率、F1

原句：2013年轻工业产品质量大幅度提升。

标准答案（Gold，7 词） vs 系统输出（Sys，9 词），按字符跨度对齐：

Gold 词	跨度	Sys 词	跨度	匹配
2013年	[0,4]	2013	[0,3]	X
轻工业	[5,7]	年轻	[4,5]	X
产品	[8,9]	工业	[6,7]	X
质量	[10,11]	产品	[8,9]	✓
大幅度	[12,14]	质量	[10,11]	✓
提升	[15,16]	大	[12]	X
。	[17]	幅度	[13,14]	X
		提升	[15,16]	✓
		。	[17]	✓

正确匹配词数 **C = 4**（产品、质量、提升、。）。Gold 词数 $G = 7$ ，Sys 词数 $S = 9$ 。

$$P = \frac{C}{S} = \frac{4}{9} \approx 44.4\%, \quad R = \frac{C}{G} = \frac{4}{7} \approx 57.1\%$$
$$F_1 = \frac{2PR}{P+R} = \frac{2C}{G+S} = \frac{8}{16} = 0.5 \text{ (50\%)}$$

结论：准确率 ≈ 44.4%，召回率 ≈ 57.1%，F1 = 0.5。 考点：分词评测以词的字符跨度完全一致计为正确；P/R/F1 公式与 F1 = 2C/(G+S) 捷径。

2. 依存关系分析性能指标 UA / LA / DA

句子 (9 词)：这(1) 将(2) 成为(3) 解决(4) 伊朗(5) 核(6) 问题(7) 的(8) 动力(9)

图1 标准答案 (Gold) 依存树 (成为 为根，共 8 条非根弧)：

词	支配词(头)	关系标记
这	成为	SUB
将	成为	VMOD
成为	ROOT	—
解决	成为	VOBJ
伊朗	问题	NMOD
核	问题	NMOD
问题	解决	VOBJ
的	问题	DEC
动力	解决	VOBJ

图2 系统输出 (图像辨识，请对照原图)：

词	系统: 头	系统: 标记	判定
这	将	SUB	头X (应为 成为)
将	成为	VMOD	✓
成为	ROOT	—	✓
解决	成为	VOBJ	✓
伊朗	问题	NMOD	✓
核	问题	NMOD	✓
问题	解决	VOBJ	✓
的	问题	DEC	✓
动力	成为	VOBJ	头X (应为 解决)

指标定义与计算（分母为需判定依存的词数 = 9 - 1(根) = 8）

- **UA 无标记依存正确率**（只看支配词是否正确）： 正确 6（将、解决、伊朗、核、问题、的），错误 2（这、动力） → **UA = 6/8 = 75%**
- **LA 带标记依存正确率**（支配词 + 标记都对）： 上述 6 个头正确的词标记也均正确 → **LA = 6/8 = 75%**
- **DA 依存正确率**（依存弧，含标记）： 正确弧 6 / 总弧 8 → **DA = 6/8 = 75%**

⚠ 上表“图2 系统输出”依图像辨识而得，若原图中某条弧的支配词或标记不同，**按同样三公式重算即可**：分别统计“头正确数 / 头+标记正确数 / 弧正确数”，除以 8。 **考点**：UAS/LAS/DA 三指标的定义与逐弧统计；依存树根节点不计入分母。

四、句法分析（15 分）

文法 **G(S)**: ① $S \rightarrow P VP$ ② $VP \rightarrow PP V$ ③ $VP \rightarrow Prop VP$ ④ $PP \rightarrow Prop$ ⑤ $VP \rightarrow VP V$ ⑥ $VP \rightarrow V Aux$ ⑦ $VP \rightarrow VP N$ (⑧ $PP \rightarrow Prop$)

词典（兼类用逗号）： 从:Prop 从小:Prop 他:P 会:V,N 学:V 学会:V,N 了:Aux 解:V,N 了解:V 解题:V 小:A 小学:N 题:N

给定句子：他从小学会了解题（不计句号）

(1) 正向最大匹配 vs 逆向最大匹配

词典最长词长 = 2（学会/了解/解题/小学/从小），取最大词长 = 2。

正向最大匹配 (FMM)：从左向右每步取最长匹配

位置	候选	结果
1	他从?否 → 他	他
2	从小 ✓	从小
4	学会 ✓	学会
6	了解 ✓	了解
8	题	题

FMM = 他 / 从小 / 学会 / 了解 / 题

逆向最大匹配 (BMM)：从右向左每步取最长匹配

位置	候选	结果
8	解题 ✓	解题
6	会了?否 → 了	了
4	学会 ✓	学会
2	从小 ✓	从小
1	他	他

BMM = 他 / 从小 / 学会 / 了 / 解题

两者在「了解题」处分歧：FMM → 了解/题，BMM → 了/解题。这是经典的分词歧义。考点：机械分词（最大匹配法）的正向/逆向实现、歧义与局限。

(2) 用 BMM 分词结果 + 线图句法分析 (Chart Parser)

输入词串 (BMM)：他(P) 从小(Prop) 学会(V) 了(Aux) 解题(V)，位置 0-5。


线图分析过程 (Chart=已完成成分 (i,j,X); Agenda=待处理; ActiveArc=活动边, 圆点表期待项)

步骤	处理	Chart 新增	ActiveArc 新增/推进	Agenda 新增
1	词 (0,1,P)	(0,1,P)	R1: S→P·VP, [0,1] 期待VP	—
2	词 (1,2,Prop)	(1,2,Prop)	R3: VP→Prop·VP [1,2] 期待VP	(1,2,PP) [R4]
3	(1,2,PP)	(1,2,PP)	R2: VP→PP·V [1,2] 期待V	—
4	词 (2,3,V)	(2,3,V)	R6: VP→V·Aux [2,3] 期待Aux	—
5	词 (3,4,Aux)	(3,4,Aux)	R6 完成于 [2,3]+Aux	(2,4,VP)
6	(2,4,VP)	(2,4,VP)	R5: VP→VP·V [2,4] 期待V; R3 完成 [1,2]+VP	(1,4,VP)
7	(1,4,VP)	(1,4,VP)	R1 完成于 [0,1]+VP	(0,4,S) 未覆盖词5
8	词 (4,5,V)	(4,5,V)	R5 完成于 [2,4]+V	(2,5,VP)
9	(2,5,VP)	(2,5,VP)	R3 完成 [1,2]+VP	(1,5,VP)
10	(1,5,VP)	(1,5,VP)	R1 完成于 [0,1]+VP	(0,5,S) ✓

(0,5,S) 入线图 → 分析成功。

句法分析树 A (主推导路径：从小先与学会了组VP，再并入解题)





两棵树对应不同依附结构 → 文法歧义（这正是该题要求直接给出的“其他可能句法树”）。**考点：**线图（Chart）句法分析算法三要素 Chart/Agenda/ActiveArc 的协同；自底向上成分归约；句法歧义。

五、考点整理（按章节）

题号	考点	对应章节
一(1)	连词辖域结构歧义	Ch1 绪论（歧义） / Ch9 句法
一(2)	编辑距离 DP、拼写纠错（噪声信道）	Ch3 形式语言与自动机
一(3)	FA ↔ 正则文法等价、右线性文法构造	Ch3 形式语言与自动机
一(4)	复杂特征集、合一（Unification）运算	Ch9 句法分析（合一语法）
一(5)	n 元文法、trigram、边界符	Ch4 N 元文法模型
二	MT 译文自动评测（BLEU/METEOR 及改进）、可计算性	Ch13 机器翻译（译文评估）
三(1)	分词评测：P / R / F1（按词字符跨度）	Ch8 词语切分 / Ch14 分类评估
三(2)	依存句法评测：UA / LA / DA	Ch9 句法分析（依存语法）
四(1)	机械分词：正向/逆向最大匹配	Ch8 词语切分
四(2)	线图（Chart）句法分析、句法歧义	Ch9 句法分析

高频主线：歧义（结构/分词）→ 形式语言与自动机（编辑距离、正则文法）→ n 元文法 → 分词与评测 → 句法分析（合一、依存、线图）→ 机器翻译评测。宗成庆试卷偏重**经典统计 NLP 的计算与算法**（DP、最大匹配、线图、依存评测），弱化深度学习。

参考：指标公式（P/R/F1、n-gram、BLEU）对照 [国科大《自然语言处理》复习（宗成庆老师）](#) — CSDN 核对。