

自然语言处理 期末复习总结

课程:自然语言处理(宗成庆,中国科学院大学 B0912014Y) 依据:第01-10章讲义 + 2022-2023 春季学期 B 卷(真实开卷期末卷,6 题×10 分) 用法:开卷考试速查——按题型组织,标注/计算题给方法与示范,设计题给模板,公式集中速查。

一、考试题型与考点分布(据 B 卷)

考核方式:课堂开卷(可带纸质资料)。B 卷结构:

题号	题型	分值	考查内容	对应章节
1	标注题	10	词语切分 + 命名实体识别 + 语义角色标注	04(分词/NER)、语义角色
2	计算题	10	编辑距离 + 二元文法"加1"平滑算句子概率	03(n-gram/平滑)
3	分析标注题	10	短语结构树→依存关系图 + 语义角色标注	04(句法)
4	设计题	10	抽取近义词对	05/06(词向量)
5	设计题	10	打乱句子重新排序	06(句子表示/相似度)
6	设计题	10	自动计算机器译文充分性	10(MT 评测)

权重结论:第04章(分词/NER/句法/SRL)≈ 20 分、第03章 ≈ 10 分、第05/06章 ≈ 20 分、第10章 ≈ 10 分 → 第03、04、06、10章是重中之重;02/07 是理论支撑。

一、B 卷真题考点详解(核心!)

★ 第1题:标注题(分词 + NER + SRL)

(1) 词语切分:用 / 或空格标词界。

- 原则:词是能独立使用的最小单位;专名合并(如"全国土地日""江苏");数量、时间整体。
- 切分歧义:交集型(中国/人/为...), 组合型(门把手)。
- 示例: 6月25日/ 是/ 第/ 33/ 个/ 全国土地日/ , / 今年/ 的/ 主题/ 是/ "..."/ 。

(2) 命名实体(NE)识别——列出所有 NE 并标类型:

- NE 类型:人名(PN)、地名(LN)、组织机构名(ON)、时间、日期、数字、货币、数量。
- 例文中:"6月25日"(日期/时间)、"第33个"(数字)、"江苏"(地名)、"全国土地日"(事件/专有名词)、"冯唯馨"(人名)、"金裕"(人名)。

(3) 语义角色标注(SRL)——以谓词为核心,标论元角色:

- ARG0 施事者、ARG1 受事者/宾语,ARG2-5(范围/起点/终点),ARGM-*(修饰):ARGM-TMP 时间、ARGM-LOC 地点、ARGM-ADV 状语、ARGM-MNR 方式、ARGM-PRP 目的。
- 句"全国土地日主场将组织策划"...等活动":谓词=组织策划;ARG0(施事)=全国土地日主场;ARG1(受事)=活动;ARGM-TMP=将。

★ 第2题:计算题(编辑距离 + 二元文法加1平滑)

(1) 编辑距离(以词为单位)

- 定义:把串 A 变成串 B 所需最少"插入/删除/替换"操作数。

- **DP 递推:** $d[i][j] = \min \begin{cases} d[i-1][j] + 1 & \text{删除} \\ d[i][j-1] + 1 & \text{插入} \\ d[i-1][j-1] + \text{替换/匹配} \end{cases}$, $d[0][j] = j, d[i][0] = i$ 。
- **B 卷示范:** $a = \text{"他/喜欢/大模型"}, b = \text{"大模型/让/他/着迷"} \rightarrow$ 填 4×5 矩阵, **编辑距离 = 4**。

对齐参考: a 删"喜欢"(1) $\rightarrow$ 他/大模型; 再 "他 $\rightarrow$ 大模型" 替换 + 插"让/着迷"等, 合计 4 步。

(2) 二元文法 + "加1"平滑算概率 ★ (必会)

- **链式:** $p(s) = \prod_i p(w_i | w_{i-1})$
- **加1平滑:** $p(w_i | w_{i-1}) = \frac{1 + c(w_{i-1} w_i)}{|V| + \sum_w c(w_{i-1} w)} = \frac{1 + c(w_{i-1} w_i)}{|V| + c(w_{i-1})}$
- **训练语料(先分词, 加 BOS/EOS):**
 - (a) $\langle \text{BOS} \rangle$ 他 喜欢 大模型 。 $\langle \text{EOS} \rangle$
 - (b) $\langle \text{BOS} \rangle$ 大模型 让 他 着迷 。 $\langle \text{EOS} \rangle$
 - (c) $\langle \text{BOS} \rangle$ 他 没 用 过 大模型 。 $\langle \text{EOS} \rangle$
- **目标句:** $\langle \text{BOS} \rangle$ 没 喜欢 过 大模型 。 $\langle \text{EOS} \rangle$
- **需要的条件概率**(词表 $|V|$ = 训练中出现的词数: 他/喜欢/大模型/。/让/着迷/没/用/过 = 9):

$w_i w_{i-1}$	$c(w_{i-1} w_i)$	$c(w_{i-1})$	加1概率
没 $\langle \text{BOS} \rangle$	0	3	$\frac{1+0}{9+3} = 1/12$
喜欢 没	0	1	$\frac{1+0}{9+1} = 1/10$
过 喜欢	0	1	$\frac{1+0}{9+1} = 1/10$
大模型 过	1	1	$\frac{1+1}{9+1} = 2/10 = 1/5$
。 大模型	2	3	$\frac{1+2}{9+3} = 3/12 = 1/4$
$\langle \text{EOS} \rangle$ 。	3	3	$\frac{1+3}{9+3} = 4/12 = 1/3$

- **结**
果: $p = \frac{1}{12} \cdot \frac{1}{10} \cdot \frac{1}{10} \cdot \frac{1}{5} \cdot \frac{1}{4} \cdot \frac{1}{3} = \frac{1}{72000} \approx 1.39 \times 10^{-5}$
- **注:** $|V|$ 与是否含 BOS/EOS 的约定会影响分母, 按题意说明即可。

★ 第3题: 分析标注题(短语树 $\rightarrow$ 依存图 + SRL)

(1) 短语结构树 $\rightarrow$ 依存关系图:

- 规则: **每短语找中心词**(动词短语 $\rightarrow$ 动词、介词短语 $\rightarrow$ 介词、名词短语 $\rightarrow$ 名词); 非中心词依存于中心词; 整个句子中心是**主动词(谓语)**, 作根(root)。
- 句"他在阳台读书": 短语树 $S(NP \text{他})(VP(PP(P \text{在})(NP \text{阳台}))(VP(V \text{读})(NN \text{书})))$ 。
 - 中心: $VP \rightarrow$ 读(根); $PP \rightarrow$ 在; $NP(\text{阳台}) \rightarrow$ 阳台; $NN \text{书} \rightarrow$ 书。
 - **依存弧:** 阳台 依存于 在(介词宾语); 在 依存于 读(状语); 书 依存于 读(宾语); 他 依存于 读(主语)。
 - root = 读。

(2) **语义角色:** 谓词=读; ARG0(施事)=他; ARG1(受事)=书; ARG-M-LOC(地点)=在阳台。

★ 第4题: 设计题——抽取近义词对 ★

思路(词向量 + 余弦相似度):

1. 大规模语料预处理(分词、清洗);

2. 训练**分布式词向量**(CBOW / Skip-gram, word2vec);
 3. 对词表每对词算**余弦相似度** $\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$;
 4. 设阈值 τ , 相似度 $> \tau$ 的词对为近义候选;
 5. 过滤(去停用词、同词性、人工校验); 可结合同义词典(HowNet/WordNet)或点式互信息 PMI 辅助。
- **公式:** $\text{sim}(w_i, w_j) = \cos(e(w_i), e(w_j))$ 。

★ 第5题:设计题——打乱句子重新排序

思路(句子表示 + 相似度/语言模型):

1. 对每个句子求**分布式表示**(词向量平均 / Skip-Thought / BERT [CLS]);
 2. 计算**相邻句子的相似度**(余弦), 用语言模型算"句子 B 接在 A 后"的概率 $p(B|A)$ (困惑度越小越可能相邻);
 3. 构造**完全图**(节点=句, 边权=相邻度), 求**最大生成树** / **最短哈密顿路径**得到顺序;
 4. 以首句(含时间/指代 Intro)为起点, 贪心或动态规划选下一句;
- **公式:** 相邻度 $s(A, B) = \cos(e(A), e(B))$ 或 $s(A, B) = \log p(B|A)$; 目标 $\arg \max_{\pi} \sum_t s(S_{\pi_t}, S_{\pi_{t+1}})$ 。

★ 第6题:设计题——自动计算机器译文充分性(sufficiency)

思路(对照参考译文, 算语义/词汇覆盖):

1. 收集多个**人工参考译文**;
2. 计算 n-gram 覆盖(**BLEU** 衡量充分性/准确度)、METEOR(综合 P/R/F + 同义词/词干);
3. 进一步用**语义嵌入相似度**: BERT 编码候选与参考, 算余弦(BERTScore), 衡量语义充分性;
4. 困惑度/COMET(预训练多语言模型打分);

• **公式:**

- BLEU $F = \text{BP} \cdot \exp(\sum_{n=1}^N w_n \ln p_n)$, $\text{BP} = \begin{cases} 1, & c > r^{e^{1-r/c}}, \\ e^r, & \text{else} \end{cases}$
- BERTScore $F = \frac{2 \cdot P \cdot R}{P + R}$ (基于 token 最大余弦匹配)。

充分性(sufficiency) = 译文是否传达了原文全部信息 → 用召回导向指标(BLEU 中的 n-gram 命中率、BERTScore 的 R)。

二、十单元核心考点速查

第01章 绪论

- 术语: NLU / CL / NLP / HLT / CIP; 发展节点 1947→1954→1956→1966→1980s→2013→2022。
- **三大范式**: 理性主义(规则/符号)、经验主义(统计 n-gram/HMM/SVM)、连接主义(神经网络, 大数据+大模型+大算力)。
- MT 三方法: 规则(分析-转换-生成)、统计(噪声信道)、神经(Transformer 端到端)。

第02章 统计学习基础 ★ (计算重区)

- **熵** $H(X) = -\sum p \log_2 p$; 联合熵; 条件熵; **链式规则** $H(X, Y) = H(X) + H(Y|X)$; **交叉熵** $H(X, q) = -\sum p \log q$; **困惑度** $PP = 2^{H(L, q)}$; **互信息** $I(X; Y) = H(X) - H(X|Y)$ 。
- **齐夫定律** $f \cdot r = C$; 长尾。
- 生成式(n-gram/HMM) vs 判别式(NB/ME/CRF/SVM)。
- **最大熵模型**: $p^*(y|x) = \frac{1}{Z(x)} \exp(\sum \lambda_j f_j)$, GIS 训练。
- **CRF**: $p(Y|X) = \frac{1}{Z(X)} \exp(\sum \lambda_j F_j)$; 负对数似然+L2 训练; **Viterbi 解码 $O(N^2T)$ 。

第03章 N元文法模型 ★★ (B 卷第2题)

- 链式法则 + 马尔可夫假设; uni/bi/tri-gram。
- **MLE**: $p(w_i | w_{-i-n+1}^{i-1}) = c(w_{-i-n+1}^i) / c(w_{-i-n+1}^{i-1})$; 零概率 → 平滑。
- **平滑**(必会手算): **加1** $p = \frac{1+c}{|V|+\sum c}$; **Good-Turing** $r^* = (r+1)n_{r+1}/n_r$; Katz 后退、绝对/线性减值、删除插值 $p = \sum \lambda p'$ 。
- 应用: 分词 $\hat{W} = \arg \max p(W)p(S|W)$; 困惑度 50~1000。

第04章 传统NLP关键技术 ★★★ (B 卷第1、3题)

- **分词**: 交集型/组合型歧义(链长); MM 最大匹配(95%); n-gram; **字标注 BMES**; P/R/F1/\$R_{\{OOV\}}\$/\$R_{\{IV\}}\$。
- **NER**: 人名/地名/机构名(占未登录词 95%)。
- **子词 BPE**; **词性标注**(兼类; UPenn 33 类/北大 106 码)。
- **句法**: 短语结构 **CYK** ($t_{0,n} = S$ 判定)、**PCFG**(三假设: 位置不变/上下文无关/祖先无关; 树概率 = 规则积; 消歧义); **依存语法**(Tesnière、价、**Robinson 四公理**: 单一父结点/连通/无环/可投射; 移进-归约 4 操作; **UAS/LAS/DA**)。
- **语义角色标注 SRL**(ARG0-5 / ARGM-*, PropBank; 四类方法)。

第05章 神经网络与神经语言模型 ★

- 激活函数: σ / $\tanh$ / **ReLU**。
- **FNN**: $a^{(l)} = f(W^{(l)}a^{(l-1)} + b^{(l)})$; 交叉熵 + L2(Frobenius) + SGD + BP。
- **RNN**: $h_t = f(Uh_{t-1} + Wx_t + b)$; 梯度消失/爆炸。
- **LSTM** ★: 遗忘门 f_t /输入门 i_t /输出门 o_t ; $\tilde{c}_t = \tanh(\cdot)$; $c_t = f_t \odot \tilde{c}_t + i_t \odot \tilde{c}_t$; $h_t = o_t \odot \tanh c_t$; Peephole。

第06章 文本表示 ★ (B 卷第4、5题)

- **VSM/词袋**; **TF-IDF** $= \text{tf} \times \log(N/\text{df})$; 长度规范化。
- 词表示: **C&W**、**CBOW**(上下文 → 中心, 平均, 无隐层)、**Skip-gram**(中心 → 上下文)。
- 句子/文档: 词袋平均、PV-DM、Skip-Thought、BiLSTM、层次自编码器。
- 相似度: **余弦相似度**。

第07章 Transformer与LLM ★★

- **注意力**: 位置编码($\sin/\cos$) → Q/K/V → **缩放点积** $\text{Softmax}(q^T k / \sqrt{d_k})$ → 加权聚值 → 多头拼接。q、k 定权重, v 定内容。
- **Transformer**: 编码器 2 子层(自注意力+前馈)、解码器 3 子层(掩码+编码-解码+前馈); 残差+层归一化; 并行、远程依赖强。
- **PLM**: ELMo / **BERT**(编码器, 双向, MLM+NSP) / **GPT**(解码器, 单向自回归)。
- **ChatGPT**: 预训练 + **SFT 指令微调** + **RLHF(RM+PPO)**; **LoRA** $h = W_0 x + AB^T x$ 。
- **ICL** 上下文学习 / **CoT** 思维链。

第08章 知识增强LLM

- LLM 缺陷: 幻觉、过时、推理弱。
- **RAG**: 分块 → Embedding → 向量库 → 检索 k 个 → Query + 检索文本 → LLM; 可溯源、动态更新。
- RAG vs 微调; 知识图谱增强(KC-E 指标)。

第09章 文本分类与情感分析

- 特征选择: **DF / MI / IG / CHI** ($\chi^2 = \frac{N(AD-CB)^2}{(A+C)(B+D)(A+B)(C+D)}$)。
- 分类器: NB(生成)/SVM·ME-CRF(判别); **Softmax** $p = \exp(x_c) / \sum \exp$; 交叉熵损失。
- **BERT 分类**(预训练+微调)。
- 情感/情绪分析: ABSA 要素级; ARG 持有者/目标; 词典(HowNet/SentiWordNet)/语料($SO = \text{PMI}\{pos\} - \text{PMI}\{neg\}$)。

第10章 机器翻译 ★ (B 卷第6题)

- 噪声信道: $\hat{T} = \arg \max_T p(T) \cdot p(S|T)$ (LM+TM+解码器); 对位模型; IBM 1-5。
- NMT: Seq2Seq 编码器-解码器, $J = \sum \log p(e_i|C)$; 训练用标准答案(teacher forcing); 注意力解决固定向量瓶颈。
- 评测: 主观(流畅/充分/语义保持); BLEU $= \frac{\text{BP}}{\text{BP}} \cdot \exp(\sum w_n \ln p_n)$ (几何平均+短译惩罚); METEOR/COMET/BERTScore。
- 语音翻译: ASR→MT→TTS; 同传(低延迟)。

三、高频公式速查表

信息论(第02章)

$$\begin{aligned} H(X) &= -\sum p \log_2 p \quad H(X,Y) = H(X) + H(Y|X) \quad H(X,q) = -\sum p \log q \\ PP &= 2^{H(L,q)} \quad I(X;Y) = \sum p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \quad D(p|q) = \sum p \log \frac{p}{q} \end{aligned}$$

语言模型(第03章)

$$\begin{aligned} \text{MLE: } p(w_i | w_{-i}) &= \frac{c(w_{-i} w_i)}{c(w_{-i})} \quad \text{加1: } \frac{1}{1+c|V|+c(w_{-i})} \quad \text{Good-Turing: } r^* = \frac{(r+1)n_{r+1}}{n_r} \end{aligned}$$

模型(第02/05/07章)

$$\begin{aligned} \text{最大熵/CRF: } p(y|x) &= \frac{\exp(\sum \lambda_j f_j)}{\sum \exp(\sum \lambda_j f_j)} \quad \text{Viterbi: } \Delta_t(j) = \max_i [\Delta_{t-1}(i) + \Delta_{ij}] \quad O(N^2T) \\ \text{FNN: } a^{(l)} &= f(W^{(l)} a^{(l-1)} + b^{(l)}) \quad \text{RNN: } h_t = f(U h_{t-1} + W x_t + b) \\ \text{LSTM: } c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad h_t = o_t \odot \tanh c_t \\ \text{注意力: } \text{Att}(Q,K,V) &= \text{Softmax}(\text{Big}(\frac{QK^T}{\sqrt{d_k}}))V \quad \text{Softmax: } p(c|x) = \frac{\exp(x_c)}{\sum \exp} \end{aligned}$$

表示与分类(第06/09章)

$$\begin{aligned} \text{TF-IDF} &= \text{tf} \times \log \frac{N}{\text{df}} \quad \text{余弦} = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \quad \text{交叉熵} = -\sum L_k \log p_k \\ \chi^2 &= \frac{N(AD-CB)^2}{(A+C)(B+D)(A+B)(C+D)} \quad \text{IG} = H(C) - H(C|T_i) \end{aligned}$$

机器翻译(第10章)

$$\begin{aligned} \hat{T} &= \arg \max_T p(T) \cdot p(S|T) \quad \text{BLEU} = \frac{\text{BP}}{\text{BP}} \cdot \exp(\sum_{n=1}^4 w_n \ln p_n \text{Big}) \\ \text{BP} &= e^{1-r/c} (c \leq r) \quad \text{编辑距离 } d[i][j] = \min(d[i-1][j]+1, d[i][j-1]+1, d[i-1][j-1]+\mathbb{1}_{a_i \neq b_j}) \end{aligned}$$

四、设计题通用答题模板(4-6 题适用)

1. 问题理解: 明确输入/输出/目标。
2. 基本思路(2-3 句): 用什么模型/表示/度量。
3. 实现步骤(编号): ① 数据收集与预处理(分词/清洗/标注); ② 特征或表示学习(词向量/句向量); ③ 核心计算(相似度/概率/检索); ④ 决策/排序/筛选(阈值、最优路径); ⑤ 评价(准确率/召回率/F1/BLEU)。
4. 关键公式: 给出 1-2 个核心式。
5. (可选)可行性/优缺点/改进。

五、临考要点提醒

- **开卷:**带这份总结 + 各章详细总结;重点练**手算**(编辑距离、bi-gram 加1、BLEU、熵、PCFG 树概率、IG/CHI)和**标注**(分词、NER、依存图、SRL)。
- **易错:**加1平滑分母 $|V| + c(w_{i-1})$ 不是 $|V|$;BLEU 用**几何平均**+BP;LSTM 三门别混;依存树**单一根**(主动词);编辑距离替换 vs 插删。
- **设计题:**务必写清"思路+步骤+公式",即使算不出也给步骤分。