

自然语言处理 期末复习总结

课程:自然语言处理(宗成庆,中国科学院大学 B0912014Y) 依据:第01–10章讲义 + **2022–2023 春季学期 B 卷**(真实开卷期末卷,6 题×10 分) 用法:**开卷考试速查**——按题型组织,标注/计算题给方法与示范,设计题给模板,公式集中速查。

○、考试题型与考点分布(据 B 卷)

考核方式:课堂开卷(可带纸质资料)。B 卷结构:

题号	题型	分值	考查内容	对应章节
1	标注题	10	词语切分 + 命名实体识别 + 语义角色标注	04(分词/NER)、语义角色
2	计算题	10	编辑距离 + 二元文法"加1"平滑算句子概率	03(n-gram/平滑)
3	分析标注题	10	短语结构树→依存关系图 + 语义角色标注	04(句法)
4	设计题	10	抽取近义词对	05/06(词向量)
5	设计题	10	打乱句子重新排序	06(句子表示/相似度)
6	设计题	10	自动计算机器译文充分性	10(MT 评测)

权重结论:第04章(分词/NER/句法/SRL)≈ 20 分、第03章 ≈ 10 分、第05/06章 ≈ 20 分、第10章 ≈ 10 分 → **第 03、04、06、10章是重中之重**;02/07 是理论支撑。

一、B 卷真题考点详解(核心!)

✦ 第1题:标注题(分词 + NER + SRL)

(1) 词语切分:用 / 或空格标词界。

- 原则:词是能独立使用的最小单位;专名合并(如"全国土地日""江苏");数量、时间整体。
- 切分歧义:交集型(中国/人/为...)、组合型(门把手)。
- 示例:6月25日/ 是/ 第/ 33/ 个/ 全国土地日/ , / 今年/ 的/ 主题/ 是/ "..."/ 。

(2) 命名实体(NE)识别——列出所有 NE 并标类型:

- **NE 类型:**人名(PN)、地名(LN)、组织机构名(ON)、时间、日期、数字、货币、数量。
- 例文中:"6月25日"(日期/时间)、"第33个"(数字)、"江苏"(地名)、"全国土地日"(事件/专有名词)、"冯唯馨"(人名)、"金裕"(人名)。

(3) 语义角色标注(SRL)——以谓词为核心,标论元角色:

- **ARG0 施事者、ARG1 受事者/宾语**,ARG2–5(范围/起点/终点),**ARGM-*(修饰)**:ARGM-TMP 时间、ARGM-LOC 地点、ARGM-ADV 状语、ARGM-MNR 方式、ARGM-PRP 目的。
- 句"全国土地日主场将组织策划'...'等活动":谓词=组织策划;ARG0(施事)=全国土地日主场;ARG1(受事)=活动;ARGM-TMP=将。

✦ 第2题:计算题(编辑距离 + 二元语法加1平滑)

(1) 编辑距离(以词为单位)

- **定义:**把串 A 变成串 B 所需最少"插入/删除/替换"操作数。
- **DP 递推:** $d[i][j] = \min \begin{cases} d[i-1][j] + 1 & (\text{删}) \\ d[i][j-1] + 1 & (\text{插}) \\ d[i-1][j-1] + 1[a_i \neq b_j] & (\text{替换/匹配}) \end{cases}$, $d[0][j] = j, d[i][0] = i$ 。
- **B 卷示范:** a="他/喜欢/大模型", b="大模型/让/他/着迷" → 填 4×5 矩阵, **编辑距离 = 4**。

对齐参考: a 删"喜欢"(1)→ 他/大模型;再 "他↔大模型"替换 + 插"让/着迷"等,合计 4 步。

(2) 二元语法 + "加1"平滑算概率 ★ (必会)

- **链式:** $p(s) = \prod_i p(w_i | w_{i-1})$
- **加1平滑:** $p(w_i | w_{i-1}) = \frac{1 + c(w_{i-1}w_i)}{|V| + \sum_w c(w_{i-1}w)} = \frac{1 + c(w_{i-1}w_i)}{|V| + c(w_{i-1})}$
- **训练语料(先分词,加 BOS/EOS):**
 - (a) <BOS> 他 喜欢 大模型 。 <EOS>
 - (b) <BOS> 大模型 让 他 着迷 。 <EOS>
 - (c) <BOS> 他 没 用 过 大模型 。 <EOS>
- **目标句:** <BOS> 没 喜欢 过 大模型 。 <EOS>
- **需要的条件概率**(词表 $|V|$ = 训练中出现的不重复词数: 他/喜欢/大模型/。/让/着迷/没/用/过 = 9):

$w_i w_{i-1}$	$c(w_{i-1}w_i)$	$c(w_{i-1})$	加1概率
没 <BOS>	0	3	$(1+0)/(9+3) = 1/12$
喜欢 没	0	1	$(1+0)/(9+1) = 1/10$
过 喜欢	0	1	$(1+0)/(9+1) = 1/10$
大模型 过	1	1	$(1+1)/(9+1) = 2/10 = 1/5$
。 大模型	2	3	$(1+2)/(9+3) = 3/12 = 1/4$
<EOS> 。	3	3	$(1+3)/(9+3) = 4/12 = 1/3$

- **结果:** $p = \frac{1}{12} \cdot \frac{1}{10} \cdot \frac{1}{10} \cdot \frac{1}{5} \cdot \frac{1}{4} \cdot \frac{1}{3} = \frac{1}{72000} \approx 1.39 \times 10^{-5}$

注: $|V|$ 与是否含 BOS/EOS 的约定会影响分母,按题意说明即可。

✦ 第3题:分析标注题(短语树→依存图 + SRL)

(1) 短语结构树 → 依存关系图:

- **规则:**每短语找**中心词**(动词短语→动词、介词短语→介词、名词短语→名词);非中心词依存于中心词;整个句子中心是**主动词(谓语)**,作根(root)。
- 句"他在阳台读书":短语树 $S(NP他)(VP(PP(P在)(NP阳台))(VP(V读)(NN书)))$ 。
 - 中心: VP→读(根); PP→在; NP(阳台)→阳台; NN书→书。
 - **依存弧:** 阳台 依存于 在(介词宾语); 在 依存于 读(状语); 书 依存于 读(宾语); 他 依存于 读(主语)。

- root = 读。

(2) **语义角色**:谓词=读;ARG0(施事)=他;ARG1(受事)=书;ARGM-LOC(地点)=在阳台。

✦ 第4题:设计题——抽取近义词对 ✨

思路(词向量 + 余弦相似度):

1. 大规模语料预处理(分词、清洗);
2. 训练**分布式词向量**(CBOW / Skip-gram, word2vec);
3. 对词表每对词算**余弦相似度** $\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$;
4. 设阈值 τ , 相似度 $> \tau$ 的词对为近义候选;
5. 过滤(去停用词、同词性、人工校验);可结合同义词典(HowNet/WordNet)或点式互信息 PMI 辅助。

- **公式**: $\text{sim}(w_i, w_j) = \cos(e(w_i), e(w_j))$ 。

✦ 第5题:设计题——打乱句子重新排序

思路(句子表示 + 相似度/语言模型):

1. 对每个句子求**分布式表示**(词向量平均 / Skip-Thought / BERT [CLS]);
2. 计算**相邻句子的相似度**(余弦),用语言模型算"句子 B 接在 A 后"的概率 $p(B|A)$ (困惑度越小越可能相邻);
3. 构造**完全图**(节点=句,边权=相邻度),求**最大生成树 / 最短哈密顿路径**得到顺序;
4. 以首句(含时间/指代 Intro)为起点,贪心或动态规划选下一句;

- **公式**:相邻度 $s(A, B) = \cos(e(A), e(B))$ 或 $s(A, B) = \log p(B|A)$;目标 $\arg \max_{\pi} \sum_t s(S_{\pi_t}, S_{\pi_{t+1}})$ 。

✦ 第6题:设计题——自动计算机器译文充分性(sufficiency)

思路(对照参考译文,算语义/词汇覆盖):

1. 收集多个**人工参考译文**;
2. 计算 n-gram 覆盖(**BLEU** 衡量充分性/准确度)、METEOR(综合 P/R/F + 同义词/词干);
3. 进一步用**语义嵌入相似度**:BERT 编码候选与参考,算余弦(BERTScore),衡量语义充分性;
4. 困惑度/COMET(预训练多语言模型打分);

- **公式**:

$$\begin{aligned} \circ \text{BLEU} &= \text{BP} \cdot \exp(\sum_{n=1}^N w_n \ln p_n), \text{BP} = \begin{cases} 1, & c > r \\ e^{1-r/c}, & c \leq r \end{cases} \\ \circ \text{BERTScore } F &= \frac{2 \cdot P \cdot R}{P + R} \text{ (基于 token 最大余弦匹配)。} \end{aligned}$$

充分性(sufficiency)= 译文是否传达了原文全部信息 → 用召回导向指标(BLEU 中的 n-gram 命中率、BERTScore 的 R)。

二、十单元核心考点速查

第01章 绪论

- 术语:NLU / CL / NLP / HLT / CIP;发展节点 1947→1954→1956→1966→1980s→2013→2022。
- **三大范式**:理性主义(规则/符号)、经验主义(统计 n-gram/HMM/SVM)、连接主义(神经网络,大数据+大模型+大算力)。
- MT 三方法:规则(分析-转换-生成)、统计(噪声信道)、神经(Transformer 端到端)。

第02章 统计学习基础 ★ (计算重区)

- 熵 $H(X) = -\sum p \log_2 p$;联合熵;条件熵;**链式规则** $H(X, Y) = H(X) + H(Y|X)$;交叉熵 $H(X, q) = -\sum p \log q$;困惑度 $PP = 2^{H(L, q)}$;互信息 $I(X; Y) = H(X) - H(X|Y)$ 。
- **齐夫定律** $f \cdot r = C$;长尾。
- 生成式(n-gram/HMM)vs 判别式(NB/ME/CRF/SVM)。
- **最大熵模型**: $p^*(y|x) = \frac{1}{Z(x)} \exp(\sum \lambda_j f_j)$,GIS 训练。
- **CRF**: $p(Y|X) = \frac{1}{Z(X)} \exp(\sum \lambda_j F_j)$;负对数似然+L2 训练;**Viterbi 解码** $O(N^2T)$ 。

第03章 N元文法模型 ★★ (B 卷第2题)

- 链式法则 + 马尔可夫假设;uni/bi/tri-gram。
- **MLE**: $p(w_i|w_{i-n+1}^{i-1}) = c(w_{i-n+1}^i)/c(w_{i-n+1}^{i-1})$;零概率→平滑。
- **平滑**(必会手算):**加1** $p = \frac{1+c}{|V|+\sum c}$; **Good-Turing** $r^* = (r+1)n_{r+1}/n_r$;Katz 后退、绝对/线性减值、删除插值 $p = \sum \lambda p'$ 。
- 应用:分词 $\hat{W} = \arg \max p(W)p(S|W)$;困惑度 50~1000。

第04章 传统NLP关键技术 ★★★ (B 卷第1、3题)

- **分词**:交集型/组合型歧义(链长);MM 最大匹配(95%);n-gram;**字标注 BMES**;P/R/F1/ R_{OOV}/R_{IV} 。
- **NER**:人名/地名/机构名(占未登录词 95%)。
- **子词 BPE**;词性标注(兼类;UPenn 33 类/北大 106 码)。
- **句法**:短语结构 **CYK**($t_{0,n} = S$ 判定)、**PCFG**(三假设:位置不变/上下文无关/祖先无关;树概率=规则积;消歧义);**依存语法**(Tesnière、价、**Robinson 四公理**:单一父结点/连通/无环/可投射;移进-归约 4 操作;**UAS/LAS/DA**)。
- **语义角色标注 SRL**(ARG0-5 / ARGM-*;PropBank;四类方法)。

第05章 神经网络与神经语言模型 ★

- 激活函数: σ / $\tanh$ / **ReLU**。
- **FNN**: $a^{(l)} = f(W^{(l)}a^{(l-1)} + b^{(l)})$;交叉熵+L2(Frobenius)+SGD+BP。
- **RNN**: $h_t = f(Uh_{t-1} + Wx_t + b)$;梯度消失/爆炸。
- **LSTM** ★:遗忘门 f_t /输入门 i_t /输出门 o_t ; $\tilde{c}_t = \tanh(\cdot)$; $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$; $h_t = o_t \odot \tanh c_t$;Peephole。

第06章 文本表示 ★ (B 卷第4、5题)

- **VSM/词袋**;TF-IDF = $\text{tf} \times \log(N/\text{df})$;长度规范化。
- 词表示:**C&W**、**CBOW**(上下文→中心,平均,无隐层)、**Skip-gram**(中心→上下文)。
- 句子/文档:词袋平均、PV-DM、Skip-Thought、BiLSTM、层次自编码器。
- 相似度:余弦相似度。

第07章 Transformer与LLM ★★

- **注意力**:位置编码(sin/cos)→ Q/K/V → **缩放点积** $\text{Softmax}(q^T k / \sqrt{d_k})$ → 加权聚值 → 多头拼接。q、k 定权重, v 定内容。
- **Transformer**:编码器 2 子层(自注意力+前馈)、解码器 3 子层(掩码+编码-解码+前馈);残差+层归一化;并行、远程依赖强。
- **PLM**:ELMo / **BERT**(编码器,双向,MLM+NSP)/ **GPT**(解码器,单向自回归)。
- **ChatGPT**:预训练 + **SFT 指令微调** + **RLHF(RM+PPO)**; **LoRA** $h = W_0 x + AB^T x$ 。
- **ICL** 上下文学习 / **CoT** 思维链。

第08章 知识增强LLM

- LLM 缺陷:幻觉、过时、推理弱。
- **RAG**:分块→Embedding→向量库→检索 k 个→Query+检索文本→LLM;可溯源、动态更新。
- RAG vs 微调;知识图谱增强(KC-E 指标)。

第09章 文本分类与情感分析

- 特征选择:**DF / MI / IG / CHI**($\chi^2 = \frac{N(AD-CB)^2}{(A+C)(B+D)(A+B)(C+D)}$)。
- 分类器:NB(生成)/SVM·ME·CRF(判别);**Softmax** $p = \exp(x_c) / \sum \exp$;交叉熵损失。
- **BERT 分类**(预训练+微调)。
- 情感/情绪分析:ABSA 要素级;ARG 持有者/目标;词典(HowNet/SentiWordNet)/语料($SO = \text{PMI}_{pos} - \text{PMI}_{neg}$)。

第10章 机器翻译 ★(B 卷第6题)

- **噪声信道**: $\hat{T} = \arg \max p(T) \cdot p(S|T)$ (LM+TM+解码器);对位模型;IBM 1-5。
- **NMT**:Seq2Seq 编码器-解码器, $J = \sum \log p(e_i|C)$;训练用标准答案(teacher forcing);**注意力**解决固定向量瓶颈。
- **评测**:主观(流畅/充分/语义保持);**BLEU** = BP · exp($\sum w_n \ln p_n$)(几何平均+短译惩罚);METEOR/COMET/BERTScore。
- 语音翻译:ASR→MT→TTS;同传(低延迟)。

三、高频公式速查表

信息论(第02章)

$$H(X) = - \sum p \log_2 p \quad H(X, Y) = H(X) + H(Y|X) \quad H(X, q) = - \sum p \log q$$

$$PP = 2^{H(L, q)} \quad I(X; Y) = \sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)} \quad D(p||q) = \sum p \log \frac{p}{q}$$

语言模型(第03章)

$$\text{MLE: } p(w_i|w_{i-1}) = \frac{c(w_{i-1}w_i)}{c(w_{i-1})} \quad \text{加1: } \frac{1+c}{|V|+c(w_{i-1})} \quad \text{Good-Turing: } r^* = \frac{(r+1)n_{r+1}}{n_r}$$

模型(第02/05/07章)

$$\text{最大熵/CRF: } p(y|x) = \frac{1}{Z(x)} \exp \left(\sum \lambda_j f_j \right) \quad \text{Viterbi: } \delta_t(j) = \max_i [\delta_{t-1}(i) + \delta_{ij}], O(N^2T)$$

$$\text{FNN: } a^{(l)} = f(W^{(l)}a^{(l-1)} + b^{(l)}) \quad \text{RNN: } h_t = f(Uh_{t-1} + Wx_t + b)$$

$$\text{LSTM: } c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, h_t = o_t \odot \tanh c_t$$

$$\text{注意力: } \text{Att}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad \text{Softmax: } p(c|x) = \frac{\exp(x_c)}{\sum \exp}$$

表示与分类(第06/09章)

$$\text{TF-IDF} = \text{tf} \times \log \frac{N}{\text{df}} \quad \text{余弦} = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \quad \text{交叉熵} = - \sum L_k \log p_k$$

$$\chi^2 = \frac{N(AD - CB)^2}{(A + C)(B + D)(A + B)(C + D)} \quad \text{IG} = H(C) - H(C|T_i)$$

机器翻译(第10章)

$$\hat{T} = \arg \max_T p(T) \cdot p(S|T) \quad \text{BLEU} = \text{BP} \cdot \exp\left(\sum_{n=1}^4 w_n \ln p_n\right), \text{BP} = e^{1-r/c} (c \leq r)$$

$$\text{编辑距离 } d[i][j] = \min(d[i-1][j] + 1, d[i][j-1] + 1, d[i-1][j-1] + 1[a_i \neq b_j])$$

四、设计题通用答题模板(4-6 题适用)

1. **问题理解**:明确输入/输出/目标。
2. **基本思路**(2-3 句):用什么模型/表示/度量。
3. **实现步骤**(编号): ① 数据收集与预处理(分词/清洗/标注); ② 特征或表示学习(词向量/句向量); ③ 核心计算(相似度/概率/检索); ④ 决策/排序/筛选(阈值、最优路径); ⑤ 评价(准确率/召回率/F1/BLEU)。
4. **关键公式**:给出 1-2 个核心式。
5. (可选)可行性/优缺点/改进。

五、临考要点提醒

- **开卷**:带这份总结 + 各章详细总结;重点练**手算**(编辑距离、bi-gram 加1、BLEU、熵、PCFG 树概率、IG/CHI)和**标注**(分词、NER、依存图、SRL)。
- **易错**:加1平滑分母 $|V| + c(w_{i-1})$ 不是 $|V|$;BLEU 用**几何平均**+BP;LSTM 三门别混;依存树**单一根**(主动词);编辑距离替换 vs 插删。
- **设计题**:务必写清"思路+步骤+公式",即使算不出也给步骤分。