

第01章 绪论 —— 总结

课程：自然语言处理（NLP-B） / 授课：宗成庆 / 单位：中国科学院自动化研究所 本章定位：建立全局认知 —— NLP 是什么、从哪来、难在哪、怎么做、本课学什么。

一、基本概念

1. 问题提出

- 什么是语言？
 - 《现代汉语词典》：语言是人类特有的、用来表达意思、交流思想的工具，是一种特殊的社会现象，由**语音、词汇、语法**构成一定的系统。
 - 吴蔚天（1994）：语言可以被看成一个**抽象的数学系统**。
- 什么是自然语言？（区别于人工语言 / 形式语言 / 编程语言）
- 核心追问：**自然语言是可计算的吗？如何判断计算机是否“理解”了语言？**

2. 学科的产生与发展（关键时间线）

时间	事件	意义
1946	第一台计算机 ENIAC 诞生	技术基础
1947.3.4	Warren Weaver 提出"用计算机翻译是否不可想象"	MT 思想萌芽
1949.7	维纳 N. Wiener （控制论创始人，1894–1964）"Translation" 备忘录	—
1954	Georgetown-IBM 用 IBM-701 实现首个 MT 系统（俄译英，250 词 + 6 条规则）	MT 第一次公开演示，引发热潮
1956	达特茅斯会议 （人工智能夏季研讨会）	自然语言理解 (NLU) 成为 AI 核心问题之一
1962	ACL （国际计算语言学学会）成立	学科组织化
1965	ICCL （国际计算语言学委员会）成立	—
1964 / 1966.11	ALPAC 报告 （"语言与机器"）	"计算语言学"术语首次进入官方学术报告；MT 热潮降温
1970–80s	计算机网络普及，语言工程兴起	"自然语言处理 (NLP)" 术语诞生
70/80s	中文信息处理 (CIP) 出现	以汉语为处理对象

金句：“自然语言处理是人工智能皇冠上的明珠。”

3. 核心术语辨析

术语	全称	提出年代	侧重
----	----	------	----

NLU	Natural Language Understanding	1950s	探索人类语言能力与认知过程本质；AI 早期研究领域
CL	Computational Linguistics	1960s	用形式化计算模型分析/理解/生成语言； 偏基础理论
NLP	Natural Language Processing	1970–80s	用计算机技术处理语言文本（词法/句法/语义/语用）， 偏工程实现
HLT	Human Language Technology	1980s	统称人类语言技术
CIP	Chinese Information Processing	70/80s	中文（汉语）信息处理

NLU、CL、NLP、HLT 三者研究对象交叉，界限随时代演变；**CL 偏理论、NLP 偏技术系统。**

4. 研究内容（多模态生态）

语音技术 + 文本处理 + 图像/视频 + 神经/认知科学			
语音识别	分类/情感	OCR	语言学
语音合成	检索/校对	文档分析	语言认知
说话人识别	机器翻译	多模态交互	计算智能

- **理解与生成**两大主线任务：机器翻译、自动摘要、问答系统、自动写作.....
- 分析处理：文本分类、情感分类、观点挖掘、主题发现、信息检索.....

5. 应用需求

- 人类以语言文字记载的知识占知识总量 **80% 以上**。
- "任意时间、任意地点、任意语言"的无障碍自由通讯是人类梦想。
- HLT 广泛用于：国家与公共安全、国民经济发展、社会生活服务、国际交流合作。
- 例：已与 152 国、32 个国际组织签合作文件，涉及 110+ 种语言（截至 2023.6）。

二、问题与挑战

1. 歧义 (ambiguity) —— 不确定性无处不在

- **词法歧义 (分词)**： 门把手弄坏了 → 门/把/手...、门把手/...、门/把手/...
 - 自动化研究所取得的成就 → 自动化/研究所/...、自动化/研究/所/...
- **句法/结构歧义**： I saw a boy in the park with a telescope.
- **语义歧义**： 喜欢乡下的孩子 、 夏天/冬天能穿多少穿多少
- **语用 / 隐喻 / 缩略语**：把权力装进制度的笼子、老虎苍蝇一起打、像石榴籽一样团结。

2. 大量未知语言现象

- **新词 / 未登录词**：给力、内卷、非典、新冠肺炎；人名地名（不来梅、Tony Blair=布莱尔）。
- **新含义**：苹果、奔腾、老虎、后台（词义漂移/引申）。
- **新用法 / 新句型**：被长工资、很中国、百度一下（非规范表达）。

3. 知识表示与获取的复杂性

- 知识（尤其常识）模糊、隐蔽、密切相关，且通过自然语言描述。

4. 跨语言概念差异

- 历史、文化、宗教、思维方式差异 → 语义概念不对等。

总命题：如何从大量复杂多样的不确定性中寻找确定性结论？

5. 关于"理解"的标准 —— 图灵测试（Turing Test）

- 图灵设计的"模仿游戏"：通过 act（表现）/ react（反应）/ interact（相互作用）评估系统智能，与有意识的人比较。

6. 人脑如何学习、记忆、理解语言？

- 涉及语言学、心理学、认知科学、神经科学、计算机科学、统计学/信息论、背景知识与常识..... 多学科交叉、远未解决。

三、技术方法

1. 三大主义范式（核心！）

范式	代表技术	基本思路	系统构成
理性主义（符号主义）	规则、句法（Chomsky 1957《句法结构》、Tesnière 1953 依存）	由代表性语料归纳语言规律，建立 符号规则系统 ：设计规则（ $N+N \rightarrow NP$ ）、标注词典、推导/归约/消歧	知识库 + 推理系统
经验主义（统计学习）	n-Gram、HMM、SVM、ME、CRFs	用大规模真实数据，统计语言规律（概率）；统计单元为 离散事件 （词、短语、词性）	数据 + 标注 + 统计模型
连接主义（神经网络）	CNN/RNN/LSTM/Attention/Transformer	超大规模数据，用 连续实数向量 表示语言单元，精细刻画大范围上下文，统一模型框架	大数据 + 大模型 + 大算力

2. 以机器翻译为例：三种方法对比

① 基于规则的方法（分析—转换—生成）

- 流程：分词词性标注 → 句法分析 → 结构转换（查双语词典）→ 译文生成。
 - 例：桌子上有一本书。 → There is a book on the desk.
- ✔ 优点：保持原文结构、可追溯可溯源；规范句、已知现象效果好。

- ✗ 弱点：人工编规则、工作量大、主观性强、一致性差、难扩充、非规范语言差；移植性差、开发周期长。

② 统计翻译方法（噪声信道模型 Noise Channel）

- 源句 $S = s_1 \dots s_m$ ，目标句 $T = t_1 \dots t_l$ ： $T^* = \arg\max_T p(T) \cdot p(S|T)$
 - $p(T)$ = 语言模型； $p(S|T)$ = 翻译模型。
- 需要双语平行句对训练（例：维汉平行语料）。
- ✓ 优点：不需深层分析，只要有足够多高质量双语句对即可，开发周期短。
- ✗ 弱点：高质量双语句对难收集；长复杂句译文差；语义一致性无保证；测试集与训练集差异大/出现生词时质量骤降。

③ 神经网络方法（Transformer 端到端，统一框架）

- token 用连续实数向量表示； $\hat{e}_i = \arg\max_{p(e_i | e_{1 \dots e_{i-1}}, C)}$ 。
- 不同语言、不同模态、不同任务几乎无差别处理（统一框架）。
- ✓ 优点：不需分析源句，仅凭大规模单语 + 双语词典/句对 + 提示指令即可；译文流畅，缩略语/术语处理好。
- ✗ 弱点：高质量数据/词典/指令难收集；流畅但语义错误、“幻觉”/“无中生有”问题。

3. 大语言模型时代（2022.11 起）

- **2022.11.29 OpenAI 发布 ChatGPT (GPT-3.5)**：以自然语言提问即可获高质量回答 → 范式转变。
- 后续里程碑：GPT-4（2023.3）、Sora（2024.2）、GPT-4o（2024.5）、o1/o3（2024.9–2025.1）。
- 开源/他山：LLaMA（2023.3 → LLaMA4 2025.4）、Vicuna、StableLM、Grok 4（2025.7）。
- 国产：豆包、千问、文心一言、星火、ChatGLM、DeepSeek.....
- 能力例证（o1）：AIME 83.3 / 96.7(o3)；GPQA Diamond 78%（超人类博士 69.7%）；IOI 超金牌门槛；Codeforces 89%。

4. 方法演进总览

Template-based → Rule-based(40年) → Statistical(20年) → Deep learning → 大模型
(理性主义) (经验主义) (连接主义)
"To be or not to be, this is a question."

- MT 关键节点：IBM-701(1954) → ALPAC(1966) → TAUM-METEO(1976) → EBMT(1984) → SMT(1989) → GIZA/GIZA++/Pharaoh/Moses → Google翻译(2006)/百度翻译(2011) → NMT(2013) → ChatGPT(2022.11)。

四、课程内容

- 三大模块：基本概念与基础理论 → 神经网络与大语言模型 → 应用系统。
- 成绩：**开卷考试 60% + 课程实践 40%**；课程实践 = 方法实现 + 技术报告。
- 学时（共 38 学时）：

章节	学时
第1章 绪论	2

第2章 统计学习基础	4
第3章 N 元文法模型	1
第4章 传统 NLP 关键技术	5
第5章 神经网络与神经语言模型	4
第6章 文本表示	2
第7章 Transformer 架构与大语言模型	6
第8章 知识图谱与知识增强的大语言模型	2
第9章 文本分类与情感分析	3
第10章 机器翻译	5
课程总结	2

五、参考文献

专著：

1. 宗成庆、赵阳、百度飞桨《自然语言处理基础与大模型——案例与实践》，清华，2024.1
2. 赵鑫等《大语言模型》，高教社，2024.12
3. 张奇等《大规模语言模型——从理论到实践》，电子工业，2024.1
4. 邱锡鹏《神经网络与深度学习》，机械工业，2020.4
5. 李航《机器学习方法（第2版）》，清华，2025.7
6. 宗成庆《统计自然语言处理（第2版）》，清华，2013.8

海外课程参考：Columbia (Michael Collins, CS4705)、CMU LTI (ANLP2024)、MIT 6.864、Stanford (CS224U / CS224N / CS224S)。

六、本章小结（背诵要点）

- **基本概念**：NLU、CL、NLP、HLT、CIP 的含义与区别。
- **发展节点**：1947 → 1954 → 1956 → 1966 → 1980s → 1990s → 2013 → 2022
- **研究内容**：语音技术 — 文本 — 多模态 — 认知语言计算。
- **问题挑战**：词法/句法/语义/语用各层次无处不在的**歧义**；未知现象；知识获取；跨语言差异；"理解"标准。
- **基本方法**：**理性主义 / 经验主义 / 连接主义**；大语言模型。
- **课程脉络**：基本概念 — 基础理论与传统方法 — 神经网络与大语言模型 — 应用系统。

七、习题要点

1. 选取中英文句子，分析**词性兼类**与**一词多义**。
2. 对比**汉语与英语**句子结构差异。
3. 对比日常对话 / 网络聊天 / 网络新闻 / 规范书面文本（《人民日报》）的用词与句法差异。
4. 举例说明除大模型外，你日常用到的 NLP 系统/工具。

5. 测试 3 个机器翻译系统，对比不同语言对、不同系统译文差异与问题。
6. 测试 ≥ 5 个大模型，用第 5 题的句子测试翻译，与专业翻译系统对比分析。