

第02章 统计学习基础 —— 总结

NLP 的数学基石。涵盖概率论、齐夫定律、信息论、统计学习概念,以及两大经典模型:**最大熵模型 (ME)** 与 **条件随机场 (CRF)**。公式密集,是计算题重灾区。

一、概率论略览

核心概念:概率、**最大似然估计 (MLE)**、条件概率、全概率公式、**贝叶斯决策理论 / 贝叶斯法则**、二项式分布、期望、方差、**随机过程**。

- **贝叶斯法则**: $p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)} = \frac{p(X|Y)p(Y)}{\sum_Y p(X|Y)p(Y)}$
- **随机过程的平稳性 (stationary)**: 联合概率分布对时间平移不变 $f_X(x_1, \dots, x_n, t_1, \dots, t_n) = f_X(x_1, \dots, x_n, t_1 + \Delta t, \dots, t_n + \Delta t)$
- **遍历性 (ergodic)**: 平稳随机变量的"时间统计特性 = 空间(集合)统计特性", 单一样本长时间演化能覆盖所有样本取值。

语言常被假设为"稳态的可遍历性随机过程"——这是后续交叉熵估计的理论前提。

二、齐夫定律 (Zipf's Law)

- **定义(1949, G. K. Zipf)**: 大规模文本中, 词的频率 f 与其频率排名 r 成反比, $f \cdot r = C$ (常数)。
 - log-log 坐标下近似一条直线。
 - 例: Brown 语料库 the(7%)、of(3.5%)、and(2.9%), 比例约 6:3:2; 前 135 个词约占一半。
- **长尾效应 (long tail)**: 少数高频词占大部分, 大量低频词(长尾词)。
 - 实践中只保留词频高于阈值的词, 低频长尾词当 **UNK (生词)** 处理。

三、信息论基础 ★★ (计算题核心)

1. 熵 (Entropy) — 香农, 1948 《通讯的数学原理》

$$H(X) = - \sum_{x \in X} p(x) \log_2 p(x), \quad \text{约定 } 0 \log 0 = 0$$

- 单位 **bit**; 衡量随机变量的**不确定性 / 平均信息量**。熵越大越不确定。
- 例 2-1(英文 27 字符): 等概率 $H = \log_2 27 = 4.75$ bit/字母; 按真实分布 $H = 4.02$ bit/字母。
- 各语言熵: 法语 3.98、英语 4.03、俄语 4.35、**汉字 9.71**(英语单词熵 ≈ 10 , 汉语词熵 ≈ 11.46)。注意: 西文字母熵与汉字熵无可比性。

2. 联合熵

$$H(X, Y) = - \sum_x \sum_y p(x, y) \log_2 p(x, y)$$

3. 条件熵

$$H(Y|X) = \sum_x p(x) H(Y|X=x) = - \sum_x \sum_y p(x,y) \log_2 p(y|x)$$

4. 链式规则 (连锁规则) ★

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

推导: $\log p(x, y) = \log p(x) + \log p(y|x)$ 拆分即得。注意 $H(Y|X) \neq H(X|Y)$ 。

5. 相对熵 / KL 散度

$$D(p||q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

- 衡量两分布差距;两分布相同则 $D = 0$; 约定 $0 \log(0/q) = 0$, $p \log(p/0) = \infty$ 。非对称。

6. 交叉熵 ★

$$H(X, q) = - \sum_x p(x) \log q(x) = H(X) + D(p||q)$$

- 用于语言 L 与其模型 q : $H(L, q) = - \lim_{n \rightarrow \infty} \frac{1}{n} \log q(x_1^n)$ (稳态遍历时)。
- 建模目标 = 最小化交叉熵(使 q 最接近真实 p)。

7. 困惑度 (Perplexity) ★★

$$PP_q = 2^{H(L, q)} \approx [q(x_1^n)]^{-1/n}$$

- 困惑度越小,语言模型越好。等价于"模型对下一个词的平均分支数"。

8. 互信息 ★

$$I(X; Y) = H(X) - H(X|Y) = \sum_x \sum_y p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)}$$

- 含义:知道 Y 后 X 不确定性的减少量。
- 点式互信息 (PMI): $I(x, y) = \log_2 \frac{p(x, y)}{p(x)p(y)}$, 可为负。
- 平均互信息 $I(X; Y) \geq 0$ (恒非负, 证明见附录, 用 $\ln z \leq z - 1$)。
- 应用:汉语分词估计两字结合强度; PMI > 0 结合紧、 ≈ 0 弱、< 0 互补分布。
 - 局限:"教务"案例说明 PMI 作切分判据效果有限, 用"成词比率"更好。

关系图: $H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$, 互信息 $I(X; Y)$ 是两圆交集; 熵 = 自信息 $H(X) = I(X; X)$ 。

例 2-2(必会计算): 给定联合分布表, 算得 $H(X) = 7/4$, $H(Y) = 2$, $H(X|Y) = 11/8$, $H(Y|X) = 13/8$, $H(X, Y) = 27/8$ bits。

四、统计学习概念

- 特点: 数据驱动、以方法为中心构建模型、对数据预测分析。

- **学习类型:**监督学习、非监督学习、半监督学习、强化学习。
- **监督学习步骤:**① 获取训练集 → ② 确定假设空间 → ③ 确定模型选择准则(策略)→ ④ 学习最优模型 → ⑤ 对新数据预测。
- **形式化:**训练集 $T = \{(x_1, y_1), \dots, (x_N, y_N)\}$, 样本独立同分布。

生成式 vs 判别式模型 ★★(必考对比)

	生成式 (Generative)	判别式 (Discriminative)
建模对象	$P(O Q)$, 先建概率模型再预测	$P(Q O)$, 直接建判别函数
基础	统计学 + Bayes	寻找最优分类面, 反映类间差异
数据要求	需大量标注样本	有限样本即可
代表	n-gram、 HMM	朴素贝叶斯、最大熵、 CRF 、k-NN、决策树、感知机、SVM

相关术语

- 语料 (corpus)、训练集 / 开发集 (development) / 测试集。
- **过拟合:**只在训练集好;**欠拟合:**训练集都未达最优;**鲁棒性:**测试集差异对性能影响小。

五、最大熵模型 (ME) 及应用

1. 引例:词义消歧 (WSD)

- 一词多义普遍, 不同词义对应不同上下文 → **WSD 转化为上下文分类任务**。
- 例:"打"有 24 种动词义项(打鼓/打破/打架/打官司...). 上下文特征:词形、词性、位置(±n 窗口)。

2. 最大熵原理 ★★

在只掌握部分知识(约束)时,使熵最大的概率分布最真实地反映事件分布。无先验时取均匀分布熵最大(一视同仁最公平)。把已知先验知识作为约束,让熵最大。

3. 模型定义

- **特征函数(0/1 二值,Kronecker):** $f(x, y) = \begin{cases} 1, & x, y \text{ 满足某条件} \\ 0, & \text{否则} \end{cases}$
- 经验期望 $\tilde{E}_p(f) = \sum_{x,y} \tilde{p}(x, y) f(x, y)$; 理论期望 $E_p(f) = \sum_{x,y} p(x) p(y|x) f(x, y)$ 。
- **约束:** $E_p(f_j) = \tilde{E}_p(f_j)$, 对 $j = 1, \dots, n_i$ 且 $\sum_y p(y|x) = 1$ 。
- **优化目标:**

$$p^*(y|x) = \arg \max_{p \in \mathbf{P}} H(p) = - \sum_{x,y} \tilde{p}(x) p(y|x) \log p(y|x)$$

4. 解的形式 ★(拉格朗日乘子法推导)

$$p^*(y|x) = \frac{1}{Z(x)} \exp\left(\sum_{j=1}^l \lambda_j f_j(x, y)\right), \quad Z(x) = \sum_y \exp\left(\sum_{j=1}^l \lambda_j f_j(x, y)\right)$$

- $Z(x)$ 为归一化因子,保证 $\sum_y p(y|x) = 1$ 。

5. 特征选择(3 种)

① 选频次超阈值的特征;② 用互信息筛选;③ 增量式特征选择(Della Pietra)。

6. 参数训练:GIS 算法(广义迭代尺度)

- 要求 $\sum_{j=1}^k f_j(x, y) = C$ (常量);不满足则加修正特征 $f_l = C - \sum f_j$ 。
- 初始化 $\lambda = 0 \rightarrow$ 算经验期望 $\rightarrow$ 迭代算模型期望并修正 $\lambda \rightarrow$ 直到对数似然变化 $|L_{i+1} - L_i| < \varepsilon$ 或达迭代上限。
- 实验:2000 年《人民日报》训练,WSD 正确率 **94.34%**。

六、条件随机场 (CRF) 及应用

1. 提出与思想(Lafferty 等,2001)

- 为**序列标注 / 结构划分**设计的概率化结构模型。
- 思想:给定观察序列 X ,输出标记序列 Y ,求 $P(Y|X)$ 最大。

2. 定义

- 设 $G = (V, E)$ 为无向图, $Y = \{Y_v \mid v \in V\}$ 。若给定 X 时每个 Y_v 满足**马尔可夫性**:

$$p(Y_v \mid X, Y_w, w \neq v) = p(Y_v \mid X, Y_w, w \sim v) \quad (w \sim v \text{ 表相邻})$$

则 (X, Y) 为条件随机场。常用**链式结构**。

3. 概率公式 ★

$$p(Y|X) = \frac{1}{Z(X)} \exp\left(\sum_{i,j} \lambda_j t_j(y_{i-1}, y_i, X, i) + \sum_{i,k} \mu_k s_k(y_i, X, i)\right)$$

- t_j **转移函数(二元特征)**:标记 $i-1 \rightarrow i$ 的转移。
- s_k **状态函数(一元特征)**:位置 i 的标记概率。
- 统一特征: $F_j(Y, X) = \sum_{i=1}^n f_j(y_{i-1}, y_i, X, i)$;归一因子 $Z(X) = \sum_Y \exp\left(\sum_j \lambda_j F_j(Y, X)\right)$ 。

4. ME vs CRF 对比 ★★ (必考)

	最大熵 ME	条件随机场 CRF
形式	特征函数计算概率,模型形式相同,可用同样训练法	同左
求解	对输入 X 的 整体/单点 分类(点问题)	对 X 序列标注 ,求 全局最优标注序列 Y
能力	—	ME 能做的 CRF 也能做(更强)

5. 三大问题

① **特征选取**(同 ME);② **参数训练**;③ **解码**(搜最优路径)。

6. 参数训练 ★

- 最大化 $P(Y|X, \lambda)$; 损失 = 负对数似然 + L2 正则:

$$L(\lambda) = -\log p(Y|X, \lambda) + \frac{\mu}{2} \|\lambda\|_2^2, \quad \mu \in [10^{-6}, 10^{-3}]$$

- 梯度下降更新: $\lambda_j^{(k+1)} = \lambda_j^{(k)} - \eta \frac{\partial L}{\partial \lambda_j} \Big|^{(k)}, \eta \approx 0.1$ 。

7. 解码: Viterbi 算法(动态规划) ★ ★

- 暴力枚举复杂度 N^T 不可行; Viterbi 分治, 时间复杂度 $O(N^2T)$ 。
- **Viterbi 变量** $\delta_t(i)$: t 时刻沿某路径到达 y_i 的最大得分。
- 递推: $\delta_{t+1}(j) = \max_{1 \leq k \leq N} [\delta_t(k) + \delta_{\text{path}}]$
- 流程: ① 初始化 $\delta_1(i) \rightarrow$ ② 递推 $\delta_t(j) = \max_i [\delta_{t-1}(i) + \delta_{ij}] \rightarrow$ ③ 终止 $\hat{Y}_T = \arg \max_i \delta_T(i)$ 回溯。
- 剪枝: $\delta_t(j) \geq$ 阈值; $N_{\text{Path}} \leq$ 上限。

8. 应用: 基于字标注的分词(Xue & Converse, 2002)

- 分词 = 字的分类: 4 词位 **B(词首)**、**M(词中)**、**E(词尾)**、**S(单独)**。
- 例: 乒乓球拍卖完了。 $\rightarrow$ 兵/B 乓/M 球/E 拍/B 卖/E 完/S 了/S。/S。
- 特征: 一元(当前字、前/后字)、二元(前字标签 $\rightarrow$ 当前字标签)。
- 开源工具: CRF++、CRFSuite、MALLET、NLTK。

🎯 考点提取

一、概念 / 定义(名解·填空·选择)

- ★ 熵 $H(X)$ 、联合熵、条件熵、链式规则 $H(X, Y) = H(X) + H(Y|X)$ 的含义。
- ★ 交叉熵 $H(X, q) = H(X) + D(p||q)$ 、为什么建模要最小化交叉熵。
- ★ 困惑度定义 $PP = 2^{H(L, q)} \approx q(x_1^n)^{-1/n}$ 及其含义。
- ★ 相对熵(KL 散度): 对称性? 是否非负?(非对称、非负)
- ★ 互信息 $I(X; Y) = H(X) - H(X|Y)$; 点式互信息 vs 平均互信息(PMI 可负, 平均互信息 ≥ 0)。
- ★ 齐夫定律 $f \cdot r = C$ 、长尾效应、UNK。
- ★ 生成式 vs 判别式模型(建模对象 $P(O||Q)$ vs $P(Q||O)$ 、代表算法)。
- ★ 最大熵原理(约束下熵最大的分布最合理; 无先验时均匀分布熵最大)。
- ★ CRF 定义(无向图 + 马尔可夫性)、转移函数(二元)/状态函数(一元)。
- 平稳性 / 遍历性的含义; 为何假设语言是稳态遍历随机过程。
- 过拟合 / 欠拟合 / 鲁棒性; 训练集 / 开发集 / 测试集。
- BMES 四词位标注。

二、公式 / 计算 / 推导题

- ★ ★ 给定概率分布算熵 $H = -\sum p \log_2 p$ (例 2-1: 等概率 $\log_2 27 = 4.75$; 实际 4.02)。
- ★ ★ 给定联合分布表算 $H(X), H(Y), H(X|Y), H(Y|X), H(X, Y)$ (例 2-2: 7/4, 2, 11/8, 13/8, 27/8)。
- ★ 用链式规则推导 $H(X, Y) = H(X) + H(Y|X)$ 。

- ★ 困惑度计算; PP 与交叉熵的换算。
- ★ 互信息计算(两字结合强度 PMI)。
- ★ 最大熵模型解的形式 $p^*(y|x) = \frac{1}{Z(x)} \exp(\sum \lambda_j f_j)$ 。
- ★ CRF 的 $P(Y|X)$ 公式、损失 $L(\lambda) = -\log P(Y|X, \lambda) + \frac{\mu}{2} \|\lambda\|^2$ 、梯度更新。
- ★★ **Viterbi 递推** $\delta_t(j) = \max_i [\delta_{t-1}(i) + \delta_{ij}]$; 复杂度 $O(N^2T)$; 能手算小规模序列(如"乒乓球拍卖完了"分词例)。
- 证明题:交叉熵公式 $H(p, q) = -\sum p \log q$; 平均互信息非负(琴生不等式 $\ln z \leq z - 1$)。

三、对比 / 分析题

- ★★ **生成式 vs 判别式模型**(对象、思想、代表、数据需求)。
- ★★ **ME vs CRF**(形式同、ME 解点问题 / CRF 解序列全局最优)。
- ★ 相对熵 vs 交叉熵(衡量对象、是否对称、用途区别)。
- 点式互信息 vs 平均互信息(取值范围)。
- 特征选择三种方法。

四、简答 / 论述题

- ★ 阐述最大熵建模的完整流程:特征提取筛选 → 特征函数构造 → 参数训练(GIS) → 测试决策。
- ★ 阐述 CRF 的三个基本问题(特征选取 / 参数训练 / 解码)及各自方法。
- ★ 为何用困惑度衡量语言模型?它与交叉熵关系?
- ★ 简述 Viterbi 算法思想(动态规划、剪枝)及其复杂度。
- 齐夫定律对 NLP 的指导意义(长尾、UNK、词表规模)。
- 互信息用于分词的局限(教务案例)。

本章小结(背诵要点)

- **概率论**: 贝叶斯法则、随机过程的平稳性与遍历性(语言=稳态遍历过程)。
- **齐夫定律**: $f \cdot r = C$; 长尾效应; 低频词当 UNK。
- **信息论**: 熵 / 联合熵 / 条件熵 / 相对熵(KL) / 交叉熵 / 困惑度 / 互信息; 链式规则; 平均互信息 ≥ 0 。
- **统计学习**: 监督/半监督; **生成式(n-gram, HMM) vs 判别式(NB, ME, CRF, SVM)**; 过拟合/欠拟合。
- **最大熵模型**: 约束(特征期望相等)下使熵最大 → 指数族解 $p^* = \frac{1}{Z} \exp(\sum \lambda f)$; GIS 训练。
- **条件随机场**: 序列标注全局最优; $P(Y|X) = \frac{1}{Z(X)} \exp(\sum \lambda F_j)$; 负对数似然+L2 训练; **Viterbi 解码** $O(N^2T)$; 应用字标注分词(BMES)。