

第03章 N元文法模型 —— 总结

统计语言模型的起点(Jelinek 提出)。用马尔可夫假设给句子算概率,核心难点是数据稀疏→数据平滑。是计算题另一重点章。

一、模型定义

1. 问题:如何计算句子的概率?

语句 $s=w_1w_2\dots w_m$,由链式法则(条件概率展开):

$$p(s)=p(w_1)p(w_2|w_1)p(w_3|w_1w_2)\cdots p(w_m|w_1\dots w_{m-1})=\prod_{i=1}^mp(w_i|w_1\dots w_{i-1})$$

- w_i 称统计基元(字/词/短语/词类),常以"词 token"代之。
- $w_1,\dots,w_{i-1}$ 称 w_i 的**历史 (history)**。

2. 参数爆炸问题

- 第 i 个基元有 L^{i-1} 种不同历史组合(L =词表大小)。
- 长度 m 的句子有 L^m 个自由参数 $p(w_m|w_1\dots w_{m-1})$ 。
- 例: $L=6763,m=3 \rightarrow$ 自由参数 $\approx 3.09\times 10^{11}$,无法估计。

3. 马尔可夫假设(等价类映射) ★

- 把历史 $w_1\dots w_{i-1}$ 映射到等价类 $S(\cdot)$:当且仅当两历史最近的 $n-1$ 个基元相同时归同类。
 $p(w_i|w_1\dots w_{i-1})=p(w_i|w_{i-n+1},\dots,w_{i-1})$
- 即只考虑前 $n-1$ 个基元对当前词的影响。

n 值	名称	依赖	别名
n=1	一元文法	独立于历史	uni-gram / monogram
n=2	二元文法	前 1 个词	bi-gram,1 阶马尔可夫链
n=3	三元文法	前 2 个词	tri-gram,2 阶马尔可夫链

此模型即语言模型 (Language Model, LM),又称 n -gram 模型。提出者:弗雷德·贾里尼克 (Fred Jelinek)(基于 HMM 的语音识别,IBM→JHU CLSP)。

二、参数估计(MLE)

1. 最大似然估计 ★

用相对频次(计数比)估计:

$$p(w_i|w_{i-n+1}^{i-1})=\frac{c(w_{i-n+1}^i)}{c(w_{i-n+1}^{i-1})}=\frac{\text{历史串+}w_i\text{的同现次数}}{\text{历史串出现次数}}$$

2. 计算示例(必会)

训练语料:

```
<BOS> John read Moby Dick <EOS>
<BOS> Mary read a different book <EOS>
<BOS> She read a book by Cher <EOS>
```

- $p(\text{John}|\text{BOS})=c(\text{BOS}|\text{John})/\sum_w c(\text{BOS}|w)=1/3$
- $p(\text{read}|\text{John})=1/1, \ p(a|\text{read})=2/3, \ p(\text{book}|a)=1/2, \ p(\text{EOS}|\text{book})=1/2$
- $p(\text{John read a book})=\frac{13\times 1\times 23\times 12}{12}\approx 0.06$

3. 数据稀疏(零概率)问题 ★

- $p(\text{Cher}|\text{BOS})=0/3=0 \rightarrow$ 整句概率为 0。

- 原因:训练数据有限,大量合法 n-gram 未出现(sparse data)。→ 需要**数据平滑**。

三、数据平滑 ★★☆☆(本章核心)

1. 基本思想

调整 MLE 概率, **零概率增值**、**非零概率下调**, “劫富济贫”, 消除零概率, 改进整体正确率。

- 目标: 测试样本困惑度越小越好。
- 约束: $\sum_i p(w_i | w_{-i-n+1}^{i-1}) = 1$ 。

2. 困惑度回顾

$$p(T) = \prod_{i=1}^{|T|} p(s_i), \quad H_p(T) = -\frac{1}{|T|} \log_2 p(T), \quad PP_p(T) = 2^{H_p(T)}$$

- n-gram 对英语文本困惑度 **50~1000**, 交叉熵 **6~10 bits/word**。

3. 平滑方法一览

方法	提出者/年代	核心思路
加1法	(Laplace)	每种情况计数 + 1
Good-Turing	Good, 1953	按公式削减非0计数, 节省概率均分给0事件
Katz 后退 (back-off)	Katz, 1987	非零用 GT 减值, 未见事件按低阶 (n-1)gram 分配
绝对减值	Ney & Essen, 1993	每个计数减固定量 b, 余量均分给未见
线性减值	—	每个计数减与计数成正比的量, 余量均分
删除插值法	—	高阶文法由低阶文法插值得到

① 加1法 (Add-one)

$$p(w_i | w_{-i-1}) = \frac{1 + c(w_{-i-1} w_i)}{|V| + \sum_j c(w_{-i-1} w_j)}$$

- 例: 加1平滑后 $p(\text{Cher read a book}) = \frac{1}{16} \cdot \frac{1}{14} \cdot \frac{3}{16} \cdot \frac{2}{15} \cdot \frac{2}{15} \approx 1.49 \times 10^{-5}$ ($|V|=13$)。
- 同句 John read a book 加1后 $\approx 5.95 \times 10^{-5}$ (原 0.06)。缺点: 把过多概率分给未见事件。

② Good-Turing 估计 ★

- 设 N_r 为某历史下 n-gram 总数, n_r = 恰好出现 r 次的 n-gram 个数, 则 $N = \sum_r n_r \cdot r$ 。
- 调整计数 $r^* = (r+1) \cdot \frac{n_{r+1}}{n_r}$; 概率 $p_r = \frac{r^*}{N}$ 。
- 所有出现事件的概率和 $\sum_{r>0} n_r p_r = 1 - \frac{n_1}{N} < 1$, 剩余 $\frac{n_1}{N}$ 分配给所有未见事件 ($r=0$)。
- 未见事件个数 $n_0 = |V|^T - \sum_{r>0} n_r$; 每个未见事件概率 $p_0 = n_0 / N$ 。需归一化 $\hat{p}_r = p_r / \sum_r p_r$ 。

③ Katz 后退法 (back-off)

$$p_{\text{katz}}(w_i | w_{-i-1}) = \begin{cases} d_r \cdot \frac{C(w_{-i-1} w_i)}{C(w_{-i-1})}, & C(w_{-i-1} w_i) = r > 0 \\ p_{\text{ML}}(w_i), & C(w_{-i-1} w_i) = 0 \end{cases}$$

- 非零计数按折扣率 $d_r = r^* / r$ (来自 Good-Turing) 减值; 未见事件按低阶 unigram 概率 + 归一化因子 $\alpha(w_{-i-1})$ 分配, 保证 $\sum = 1$ 。

④ 绝对减值法

$$p_r = \begin{cases} \frac{r-b}{N}, & r > 0 \\ \frac{b}{N - n_0}, & r = 0 \end{cases}$$

- $R =$ 所有可能事件数 ($R = L^n$), $n_0 =$ 未见事件数, $b \leq 1$ 为减去的固定量 (用留存数据估计, $b \leq \frac{1}{n_1 + 2n_2}$)。

⑤ 线性减值法

$$p_r = \begin{cases} \frac{1-\alpha}{N}, & r > 0 \\ \frac{\alpha}{n_0}, & r = 0 \end{cases}$$

- $\alpha = n_1 / N$ 。实验中**绝对减值通常优于线性减值**。

⑥ 删除插值法 ★

$$p(w_3|w_{1:w_2}) = \lambda_3 p(w_3|w_{1:w_2}) + \lambda_2 p(w_3|w_2) + \lambda_1 p(w_3), \text{quad} \\ \lambda_1 + \lambda_2 + \lambda_3 = 1$$

- λ 在留存数据上以困惑度最小为目标估计。

4. 四种减值法对比(简答)

方法	非零事件减值方式	节省概率分配给0事件的方式
Good-Turing	按 GT 公式削减	均分
Katz 后退	按 GT 削减	按低阶 (n-1)gram 分配
绝对减值	减固定量 b	均分
线性减值	按比例减	均分

四、N-gram 应用

1. 两类用途

- ① 计算语句概率,在相关任务中筛选最可能的句子。
- ② 已知前文预测后文(语言生成 / 自动写作 / AIGC): $p(\text{word}|\text{context})$ 。

2. 汉语分词 ★

待切分句 $S = z_1 \dots z_m$, 候选词序列 $W = w_1 \dots w_N$: $\hat{W} = \arg \max_W p(W|S) = \arg \max_W \big(p(W) \cdot p(S|W)\big)$

- $p(W)$ = 语言模型, $p(S|W)$ = 生成模型。
- 改进:把词分词类(LW 词表词、MW 派生词、PN/LN/ON 专名、FT 其他实体),用词类序列 C 的 trigram + 生成模型 $p(S|C) \approx \prod p(w_i|c_i)$ 。
- 实验:词表词 98,668、派生词 59,285;正确率 **96.3%**。(专名占未登录词 95%)

3. 其它应用(噪声信道统一框架)

任务	模型
语音识别	$p(\text{chars} \text{speech})$
拼音输入法	$p(\text{chars} \text{pinyin})$
汉语分词	$p(\text{words} \text{chars})$
命名实体识别	$p(\text{NE} \text{chars})$
机器翻译	$p(\text{zh} \text{en}), T^* = \arg \max_T p(T) \cdot p(S T)$

4. 音字转换(拼音输入法)

- 输入拼音串 $\rightarrow$ 候选汉字句; $\hat{C} = \arg \max_C p(C) \approx \arg \max_C p(\text{Py}|C) \cdot p(C)$ 。
- 一元搜索空间 N ,二元 N^2 (效果明显提升);汉字约 4 元更好。智能狂拼、微软拼音均基于 n-gram。

5. N-gram 的局限(→ 引出神经语言模型)

- 只能考虑前面 3~4 个词,无法建模长上下文;
- 每个离散符号一视同仁,无语义相似度;
- 易产生零概率,平滑技术损害概率准确性。 → 解决:连续向量表示 + 注意力机制 + Transformer。

五、附录要点

模型自适应(三类)

1. 基于缓存 (cache) 的 LM:刚出现的词易再现;缓存概率与 n-gram 插值;距离呈指数衰减 $e^{-(i-j)/\beta}$ 。

2. **基于混合方法的 LM**:训练语料异源,划成 n 个子模型 $M_j, \hat{p} = \sum_j \lambda_j \hat{p}_{M_j}, \lambda$ 用 **EM** 估计。
3. **基于最大熵的 LM**:结合多信息源(如 bigram + skip-gram),约束下取熵最大模型,求权重。

分词与词性标注一体化

- $p(W,T) = p(W|T) \cdot p(T) \approx \prod_i p(w_i|t_i) \cdot p(t_i|t_{i-1}, t_{i-2})$ (基于词性三元)。
- 测试:集外分词正确率 96.79% → 98.06%,词性标注约 96%/93%。

🎯 考点提取

一、概念 / 定义

- ★ n-gram 模型 / 语言模型定义;统计基元;历史。
- ★ 马尔可夫假设(等价类映射);unigram/bigram/trigram 对应几阶马尔可夫链。
- ★ MLE 参数估计公式(计数比)。
- ★ 数据稀疏 / 零概率问题;为什么要平滑("劫富济贫")。
- ★ 困惑度公式 $PP = 2^H$;英语 n-gram 困惑度范围(50~1000)。
- 各平滑方法的思想与提出者(Good-Turing/Good1953、Katz/1987、绝对减值/Ney1993)。
- cache LM、混合 LM、最大熵 LM 的思想。
- n-gram 的三大局限。

二、公式 / 计算 / 推导

- ★★ 链式法则展开句子概率。
- ★★ MLE 计数比估计;手算 bigram 句子概率(如 John read a book ≈ 0.06)。
- ★★ 加1平滑公式及手算(原 0 概率句 $\rightarrow 1.49 \times 10^{-5}$)。
- ★★ Good-Turing: $r^* = (r+1)n_{r+1}/n_r, p_r = r^*/N$, 剩余概率 n_1/N 给未见。
- ★ Katz back-off 公式、绝对减值 $p_r = (r-b)/N$ 、线性减值、删除插值 $p = \sum \lambda p'$ 。
- ★ 分词目标 $\hat{W} = \arg \max p(W) \cdot p(S|W)$;噪声信道 $T^* = \arg \max p(T) \cdot p(S|T)$ 。
- 参数量推导: $L^{(i-1)}$ 历史 / L^m 自由参数。

三、对比 / 分析

- ★★ 四种减值法对比(减值方式 + 分配方式),尤以 Katz 的"按低阶分配"区别于其余"均分"。
- ★ 加1法 vs Good-Turing(加1 过度分给未见)。
- 绝对减值 vs 线性减值(固定量 vs 比例;绝对通常更优)。
- n-gram 应用中语言模型 vs 生成模型的角色。
- 基于词的三元模型 vs 基于词性的三元模型($p(W|T)p(T)$ vs $p(T|W)p(W)$)。

四、简答 / 论述

- ★ 简述 n-gram 参数估计为何出现零概率,平滑的基本思想与约束。
- ★ 简述 Good-Turing 估计法的原理与剩余概率分配。
- ★ 简述 Katz 后退法如何利用低阶模型。
- ★ 简述汉语分词中如何用 n-gram + 生成模型求解 $\hat{W}$ 。
- ★ n-gram 模型的局限及神经语言模型如何改进。
- 简述删除插值法及 λ 的确定方法(留存数据最小化困惑度)。

本章小结(背诵要点)

- **定义**:链式法则 $p(s) = \prod p(w_i|w_{i-n+1}^{i-1})$;马尔可夫假设;uni/bi/tri-gram。
- **估计**:MLE 计数比 $c(\cdot \cdot \cdot)/c(\cdot \cdot \cdot)$;数据稀疏致零概率。
- **平滑**(核心):加1、Good-Turing($r^* = (r+1)n_{r+1}/n_r$)、Katz 后退、绝对减值、线性减值、删除插值;前两类必会手算。
- **应用**:分词 $\arg \max p(W)p(S|W)$ 、音字转换、机器翻译(噪声信道);用于算概率 / 预测生成。
- **局限**:短上下文、离散符号、需平滑 $\rightarrow$ 神经语言模型。