

第03章 数据平滑方法 —— 详解（结合例子）

本文用「同一组例子」串讲六种平滑方法，便于横向对比。公式与术语与《第03章 N元文法模型-总结》一致。

对应章节：第03章 N元文法模型 → 三、数据平滑 ★★★（本章核心）。

0. 为什么需要平滑

MLE 直接用频率当概率： $p(w \mid h) = c(hw)/c(h)$ 。问题是**训练集没见过的 n-gram 概率直接是 0**，连乘一下整句概率归零。

例子：训练里"我"后面跟过「爱(5)、喜欢(3)、吃(1)、看(1)」共 10 次，但"我/书"没出现过 $\rightarrow p(\text{书} \mid \text{我}) = 0 \rightarrow$ "我书。"整句概率为 0。

平滑的任务就是 **"劫富济贫"**：把出现过的词概率往下压一点，匀给没见过的词，保证没有 0、且 $\sum_w p(w \mid h) = 1$ 。

1. 统一例子（贯穿 加1 / 绝对 / 线性减值）

设历史 $h = \text{"我"}$ ，**总共出现 10 次** ($c(h) = N = 10$)，词表大小 $|V| = 6$ ：

后继词 w	计数 $c(hw)$
爱	5
喜欢	3
吃	1
看	1
书、跑（未见）	0, 0

MLE: $p(\text{爱} \mid \text{我}) = 0.5, p(\text{喜欢} \mid \text{我}) = 0.3, p(\text{吃} \mid \text{我}) = 0.1, p(\text{看} \mid \text{我}) = 0.1, p(\text{书} \mid \text{我}) = p(\text{跑} \mid \text{我}) = 0$ 。

① 加1法 Add-one (Laplace) ★ —— B 卷第 2 题考的就是它

公式：

$$p(w \mid h) = \frac{1 + c(hw)}{|V| + c(h)}$$

分子分母各 +1，相当于"假装每个词至少出现 1 次"。

w	计算	概率
爱	$(1 + 5)/(6 + 10)$	$6/16 = \mathbf{0.375}$

w	计算	概率
喜欢	4/16	0.250
吃	2/16	0.125
看	2/16	0.125
书	1/16	0.0625
跑	1/16	0.0625

和 = $16/16 = 1 \checkmark$ 。

缺点一目了然：两个从没出现过的词（书、跑）白白各拿了 0.0625，合计抢走 **12.5%** 的概率。词表越大 ($|V|$ 越大)，这个“劫贫济未见”越严重——这就是“加1法把过多概率分给未见事件”。

④ 绝对减值法 Absolute Discounting

思路：每个非零计数减一个固定小量 b ($b \leq 1$)，省下来的总概率均分给未见事件。

公式：

$$p_r = \begin{cases} \frac{r - b}{N}, & r > 0 \\ \frac{b(R - n_0)}{N \cdot n_0}, & r = 0 \end{cases}$$

其中 $R = |V|$ 为可能事件数、 n_0 为未见事件个数。取 $b = 0.5$, $R = 6$, $n_0 = 2$ ：

w	计算	概率
爱	$(5 - 0.5)/10$	0.45
喜欢	$(3 - 0.5)/10$	0.25
吃	$(1 - 0.5)/10$	0.05
看	$(1 - 0.5)/10$	0.05
书、跑（各）	$0.5 \cdot (6 - 2)/(10 \cdot 2)$	0.10

校验：见过合计 $0.8 +$ 未见合计 $0.2 = 1 \checkmark$ 。

对比加1：未见词各拿 0.10（合计 0.20），但对高频词的打压更轻（爱：加1砍到 0.375，绝对减值只到 0.45）——因为它只减固定一点点、不随 $|V|$ 膨胀，所以更准。

⑤ 线性减值法 Linear Discounting

思路：按比例打折，每个计数乘同一个因子 $(1 - \alpha)$ ，省下的 α 均分给未见； $\alpha = n_1/N$ (n_1 =出现恰好 1 次的事件个数)。

公式：

$$p_r = \begin{cases} \frac{(1-\alpha)r}{N}, & r > 0 \\ \frac{\alpha}{n_0}, & r = 0 \end{cases}$$

本例 $n_1 = 2$ (吃、看), $\alpha = 2/10 = 0.2$:

w	计算	概率
爱	$0.8 \times 5/10$	0.40
喜欢	$0.8 \times 3/10$	0.24
吃	$0.8 \times 1/10$	0.08
看	$0.8 \times 1/10$	0.08
书、跑 (各)	$0.2/2$	0.10

校验: 见过合计 $0.8 +$ 未见 $0.2 = 1 \checkmark$ 。

和绝对减值的差别 (必背):

- **绝对减值**: 每个计数减**相同的绝对量** b (爱 $5 \rightarrow 4.5$ 、吃 $1 \rightarrow 0.5$)。
- **线性减值**: 每个计数乘**相同比例** (爱 $5 \rightarrow 4$ 、吃 $1 \rightarrow 0.8$)，高频词被砍掉的绝对量更多 (爱丢 1.0 、吃只丢 0.2)。
- 实验结论: **绝对减值通常优于线性减值**。

2. Good-Turing 与 Katz (需要"计数之计数" n_r)

这两个不再针对单个 bigram 计数，而是看"出现 r 次的事件一共有多少个"——记作 n_r 。换一个例子。

设某历史下，出现 r 次的词各有 n_r 个:

r (出现次数)	1	2	3	4	5
n_r (这样的词有几个)	30	15	8	4	2

总计数 $N = \sum_r r \cdot n_r = 30 + 30 + 24 + 16 + 10 = 110$ 。

② Good-Turing 估计 ★

核心: 把计数 r 调整为 $r^* = (r + 1) \frac{n_{r+1}}{n_r}$ ，概率 $p_r = r^*/N$ 。

r	r^* 计算	r^*
1	$2 \cdot n_2/n_1 = 2 \cdot 15/30$	1.0
2	$3 \cdot n_3/n_2 = 3 \cdot 8/15$	1.6
3	$4 \cdot n_4/n_3 = 4 \cdot 4/8$	2.0
4	$5 \cdot n_5/n_4 = 5 \cdot 2/4$	2.5

直观：见过 4 次的词，概率从 4/110 降到 2.5/110——被削了，削下来的总量留给没见过的。

关键性质：所有见过的事件概率之和

$$\sum_{r>0} n_r \cdot r^*/N = (30 + 24 + 16 + 10)/110 = 80/110 \approx 0.727$$

剩余 $1 - 0.727 = n_1/N = 30/110 \approx 0.273$ 全部留给未见事件。

这就是 GT 的精髓——用“只出现一次的事件” n_1 去估计未见事件的总概率（因为只出现 1 次的，本质上和 0 次的最接近）。

③ Katz 后退法 back-off

GT 有个毛病：它把省下来的概率均分给所有未见事件（不管这个词本身常不常见，都给一样多）。Katz 改进两点：

- 1. 见过的事件：用 GT 的折扣率 $d_r = r^*/r$ 减值（如 $d_4 = 2.5/4 = 0.625$ ），概率 = $d_r \cdot c(w_{i-1}w_i)/c(w_{i-1})$ 。
- 2. 没见过的事件：不均分！而是按低阶（unigram）概率分配——越常见的词分得越多；再用归一化因子 $\alpha(w_{i-1})$ 把总概率凑回 1。

$$p_{\text{katz}}(w_i \mid w_{i-1}) = \begin{cases} d_r \frac{c(w_{i-1}w_i)}{c(w_{i-1})}, & c(w_{i-1}w_i) = r > 0 \\ \alpha(w_{i-1}) p_{ML}(w_i), & c(w_{i-1}w_i) = 0 \end{cases}$$

一句话区分：**Good-Turing** 给未见事件“均分”，**Katz** 给未见事件“按低阶文法分”——后者更合理，因为一个高频词（如“的”）即便在当前二元没出现，也该比生僻词更可能。

3. 删除插值法（思路完全不同）

不是减值，而是把高阶和低阶文法加权混合：

$$p(w_3 \mid w_1w_2) = \lambda_3 p'(w_3 \mid w_1w_2) + \lambda_2 p'(w_3 \mid w_2) + \lambda_1 p'(w_3), \quad \lambda_1 + \lambda_2 + \lambda_3 = 1$$

例子：算 $p(\text{书} \mid \text{我}, \text{爱})$ 。若三元“我爱书”训练里没见过 $\rightarrow p'(\text{书} \mid \text{我}, \text{爱}) = 0$ ，但二元 $p'(\text{书} \mid \text{爱})$ 和一元 $p'(\text{书})$ 都 > 0 ，三项加权后仍得非零值。

权重 λ 在留存数据上以“困惑度最小”为目标估计——数据多就让高阶权重大，数据少就退回低阶。

4. 总对比表（简答题背诵核心）

方法	见过的事件怎么压	省下的概率怎么分给未见
加1法	计数 +1、分母 \$+\$	V
Good-Turing	按 $r^* = (r+1) n_{r+1}/n_r$ 削减	均分（总量 = n_1/N ）
Katz 后退	按 GT 折扣率 d_r 削减	按低阶 (n-1)gram 概率分 ★
绝对减值	每个计数减固定量 b	均分

方法	见过的事件怎么压	省下的概率怎么分给未见
线性减值	每个计数乘比例 $(1-\alpha)$	均分
删除插值	不减值，直接高低阶加权混合	(靠低阶文法本身非零)

记忆口诀：

- 「减」字辈（绝对/线性）的区别 = **减固定量 vs 减比例**；
- GT vs Katz 的区别 = **未见事件均分 vs 按低阶分**；
- 加1 = 最简单但最不准；删除插值 = 唯一"插值"而非"减值"的思路。

 考点提示

- 手算：重点练 **加1法**（B 卷第 2 题原题）和 **Good-Turing** 的 r^* 。
- 简答：背 **四种减值法对比表**（见过怎么压 / 未见怎么分两列）。
- 易错点：
 - 加1分母是 $|V| + c(w_{i-1})$ ，**不是** $|V|$ ；
 - GT 留给未见的总量是 n_1/N ；
 - 绝对减值减固定量、线性减值减比例，别混。