

第04章 传统NLP关键技术 —— 总结

神经网络深度学习出现之前的 NLP 技术(理性主义 + 经验主义)。传统 NLP 的"三步走":词法分析与词性标注 → 句法分析 → 语义分析。本章是 5 学时大章。

- 4.1 词语切分与命名实体识别
- 4.2 句法分析
- 4.3 语义分析

4.1 词语切分与命名实体识别

一、分词要点

切分意义:词是能独立使用的最小语言单位;分词是句法/语义/篇章分析的前提;所有 NLP 方法(含深度学习)都以词或子词为统计基元。

汉语分词的主要问题:

- 分词规范问题**(GB13715):"什么是词"两个不清界限——单字词与词素;词与短语。
- 歧义切分字段** ★:
 - 交集型歧义:**如"结合成分子"(结合/合成/成分/分子),链长=3;中国人为了...、"研究生物"、"中国产品质量"(链长4)、"部分居民生活水平"(链长6)。
 - 链长 = 交集型歧义拥有的交集串个数。
 - 组合型歧义:**如"门把手弄坏了"(门/把/手 vs 门把手)、"将来/现在/才能/学生会"。
 - 统计(梁南元1987):切分歧义约 **1.2 次/100字**,交集型:组合型 ≈ **12:1**。
- 未登录词(集外词):**命名实体(人名/地名/机构名,占未登录词 **95%**)、新词术语(博客/非典/内卷/新冠)、新冠相关(德尔塔/方舱/密接)。集外词错误占总错误 98.33%。

评价指标 ★:

- 正确率(精确率) $P = n/N$;召回率 $R = n/M$ (M = 标准答案数)。
- F-测度 $F = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$,常取 $\beta = 1$: $F_1 = \frac{2PR}{P + R}$ 。
- $R_{\{OOV\}}$ 集外词召回率; $R_{\{IV\}}$ 集内词召回率。

二、切分方法

方法	类型	思想	评价
最大匹配 MM	有词典/机械	FMM 正向 / BMM 逆向 / 双向;取最长词匹配	简单、歧义差,约 95%
基于 n-gram 语言模型	无词典/生成式	$\hat{W} = \arg\max p(W) \cdot p(S W)$	依赖语料,计算量大
由字构词(字标注)	无词典/判别式	4 词位 B/M/E/S (见第2章CRF)	集外词好、集内词略逊
生成式+判别式结合	—	n-gram(集内强)+ 字构词(集外强)	—

神经网络	序列标注	BiLSTM + CRF,n:m 对应	长距离、 LSTM>CNN
------	------	---------------------	------------------

三、命名实体识别(NER)

- **命名实体 NE**:人名、地名、事件名、组织机构名、数字、日期、货币、数量(医学领域含术语)。
- **与分词关系**:可在分词基础上以词为单位识别;也可直接以字为单元序列标注。
- **方法**:同分词(规则/统计/神经网络,如 LSTM-CRF + 偏旁部首特征)。
- **主要问题**:过度依赖训练样本(多限新闻领域);**领域差异和生词识别是最大挑战**(网络文本、微博、专业领域)。

四、子词压缩(sub-word)

- 动机:词粒度(长尾、词表大、UNK)与字粒度(歧义、序列长)各有缺点 → 子词折中。
- **BPE(Byte Pair Encoding)算法**:① 统计相邻字符(汉字)对出现次数;② 合并频次最高的一对,用新符号替换;③ 重复直到频次 ≤ 1 或达上限。
- 应用:机器翻译 WMT14 英德 450 万句对压缩后词表约 3.2 万子词。

五、词性标注(POS tagging)

- **词性 POS** 是词汇最重要的语法特性,是词连接句法的桥梁(实词:体词名词/代词、谓词动词/形容词;虚词)。
- **核心问题:消除词性兼类歧义**。Brown 语料库 55% 词次兼类;汉语兼类词占 22.5%。
- 兼类类型:形同音不同(好 hǎo/hào)、同形同音异义(会=会议/能够)、典型兼类(教育=名/动)、组合(行 xíng/háng)。
- **标注集**:UPenn Treebank **33 类**(NN/NR/NT/VV/AD/M...);北大 **106 码**(n/v/a/d/p...)。
- **方法**:规则/有限状态机;统计(HMM 分词标注一体化、CRF 序列标注);规则+统计。指标:**准确率**。

4.2 句法分析

一、短语结构分析(phrase structure parsing)

- 又称**成分结构分析 / 完全句法分析(full parsing)**:识别句子结构关系,输出句法树。汉语需先完成分词、词性标注、再结构分析。
- **局部句法分析(partial parsing / 浅层分析 / 语块划分 chunking)**:只分析某类短语(如 Base NP)。
- **困难**:大量**结构歧义**(I saw a boy with a telescope)。
- **目标**:高准确率、高鲁棒性、快速。

分析方法:

1. 基于 CFG 规则:**线图分析 Chart parsing**、CYK、Earley、LR/Tomita。
2. **PCFG**(概率上下文无关文法)。
3. 神经网络(把句法树当序列"翻译"出来)。

CYK 算法 ★

- 先对 Chomsky 文法**范式化(CNF)**:规则只能 $A \rightarrow w$ 或 $A \rightarrow BC$ 。
- **自下而上**,构造 $(n+1) \times (n+1)$ 识别矩阵(n =句子长)。
- 步骤:① 主对角线放单词;② $t_{i,i+1}$ 放能推导出该词的非终结符;③ 按平行对角线方向填 $t_{i,j}$:若 $\exists k$,有 $A \rightarrow BC$ 且 $B \in t_{i,k}, C \in t_{k,j}$,则 A 写入 $t_{i,j}$ 。
- **判定**: $t_{0,n} = S$ 则句子被该文法接受。

- 评价:实现简单、效率高;需范式化、**无法区分歧义**。

PCFG ★★

- 规则 $A \rightarrow \alpha, p$, 约束 $\sum_{\alpha} p(A \rightarrow \alpha) = 1$ 。
- **树概率 = 各规则概率之积**。
- **三大假设**:① **位置不变性**;② **上下文无关性**;③ **祖先无关性**。
- 作用:计算各候选树概率,取概率最大者消歧(例 Astronomers saw stars with ears: $p(t_1) = 0.0009072 > p(t_2) = 0.0006804$, 选 t_1)。
- **优点**:可用概率剪枝加速;可定量比较分析器。**弱点**:概率计算假设苛刻。
- **三个问题**:① 算 $p(S|G)$ (内向算法);② 找最佳树(Viterbi);③ 估参数使 $p(S|G)$ 最大(内外向/EM 算法)。

评价:PARSEVAL

- **精度 P** = 正确短语数/分析得到短语数;**召回率 R** = 正确短语数/标准树短语数;**F1**:**交叉括号数 (crossing brackets)**。
- 现状:英文规范文本约 **95%**;汉语略逊;非规范文本大幅下降。

二、依存关系分析(dependency parsing) ★★

- **创立者**:法国语言学家 **Tesnière(泰尼埃)**,《结构句法基础》(1959 初版,1965 二版)。
- **核心思想**:句法关联建立词与词的**从属关系**(支配词 + 从属词);**动词是句子中心**,支配其他成分,本身不受支配。三大核心:关联、组合、转位。
- **价(valence/valency)**:动词能支配的行动元个数 → 零价(地震)、一价(休息)、二价(爱)、三价(给)。

表示:有向图 / 依存树 / 依存投射树(支配者在弧发出端,从属者在箭头端)。

Robinson 四公理(1970) ★ → 形式约束:

1. 一个句子只有一个独立成分;
 2. 其他成分都从属于某成分;
 3. 任何成分不能依存于两个或多个成分;
 4. A 直接从属于 B, C 位于 A、B 之间,则 C 从属于 A 或 B 或其间成分。
- 等价约束:**单一父结点、连通、无环、可投射** → 保证是一棵有根树。

投射(projective)vs 非投射:依存弧是否与其他词相交。

依存优势:简单、天然词汇化;不强调固定词序,适合自由语序;受语义驱动;形式化浅、灵活。

方法:

类别	说明
生成式	整体建模概率
判别式	判别函数
决策式(确定性)移进-归约	Nivre 2003, 线性 $O(n)$,但局部最优致错误传递、不能处理非投射
约束满足	—
神经网络 + 决策式	主流

移进-归约算法(arc-eager) ★ :格局三元组 (S, I, A) (栈/输入/弧集)。**4 种操作**:

- **Left-Arc**:加左向依存弧,弹栈;
- **Right-Arc**:加右向依存弧,压入输入词;
- **Reduce**:弹栈(已找到支配者);
- **Shift**:把输入词压栈。
- 自左向右扫描,每步用分类器选最优动作(特征:词、词性、左右孩子、依存关系等)。

评价 ★:

- **UAS**(无标记依存正确率)= 找到正确支配词的词占比(含根)。
- **LAS**(带标记依存正确率)= 支配词和关系类型都对(含根)。
- **DA**(依存正确率)= 非根词中正确占比。
- 现状:英文规范文本 UAS **90%+**,汉语略逊。

三、附录要点

- **线图 Chart parsing**:时间复杂度 $O(Kn^3)$;数据结构 Chart/Agenda/ActiveArc。
- **PCFG 三问题**:内向算法(动态规划求句子概率)、外向算法、**Viterbi**(最佳树)、**内外向算法(EM)** 估参数。
- **神经网络句法分析**:Vinyals 2015 *Grammar as a Foreign Language*,seq2seq 把句子翻译成括号序列;WSJ F1 达 92.1%。
- **局部句法分析**(Abney 1991):语块 chunking,识别 Base NP/Base VP。

4.3 语义分析

一、概述

- **目标**:解释词、词组、句子、段落、篇章的含义。
- **困难**:歧义(指代/同义多义/量词辖域/隐喻)、语境相关性、语义表示方法、认知机理不清。
- 经典反例(语义悖论):"中国队大胜/大败美国队"、"好热闹/好不热闹"、"夏天/冬天能穿多少穿多少"——结构相反但语义相近。

二、语义网络(semantic network)

- **提出者**:美国心理学家 **M. R. Quillian(1968)**;Hendrix(1977)提出**分块语义网络**,结合格语法。
- **表示**:有向图,**结点**=实体/概念,**边**=关系。
- **边类型**:IS-A(是一种)、PART-OF(是一部分)、IS(属性)、HAVE(拥有)、BEFORE(在先)。
- **事件表示**:结点关系可为施事(Agentive)/受事(Objective)/时间等;三元组表示 帮助(张三,李四)。
- **知识图谱**:实体+关系的网络(如人物关系图)。
- **知网 HowNet**(董振东):常识性知识库,强调概念间关系,是"网"非"树"。

三、语义角色标注(SRL) ★

- **任务**:以句子中**谓词为核心**,分析其他成分与谓词的关系("谁对谁做了什么")。
- **资源**:**PropBank**(在 Treebank 上加论元标记)、NomBank、FrameNet。
- **两类语义角色 ★**:
 - **核心角色 ARG0-ARG5**:ARG0=施事者(agent)、ARG1=受事者(patient/object)、ARG2=范围/程度、ARG3=起点、ARG4=终点。
 - **修饰角色 ARGM-***:ARGM-TMP(时间)、ARGM-LOC(地点)、ARGM-ADV(状语)、ARGM-CND(条件)、ARGM-DIR(方向)、ARGM-MNR(方式)、ARGM-PRP(目的)、ARGM-BNF(受益者)等。
- **方法**:

1. 基于短语结构树(Xue & Palmer 2004):候选论元剪枝 → 论元识别(二分类)→ 论元标注(多分类)。
2. 基于依存关系:论元=中心词 + 角色,判断词对关系。
3. 基于语块(chunking):**BIO 序列标注**,识别与标注同时进行,用 CRF/LSTM+CRF。
4. 深度学习:BiLSTM + 双仿射打分;BERT 端到端。

- **性能**:英汉规范文本 SRL **F1 > 90%**;主要问题:严重依赖句法分析器、领域适应差。

考点提取

一、概念 / 定义

- ★ 交集型 vs 组合型歧义;**链长**定义(交集串个数)。
- ★ 未登录词;命名实体 NE(占未登录词 95%)。
- P / R / F1 / $\$R_{\{OOV\}}\$$ / $\$R_{\{IV\}}\$$ 定义。
- 最大匹配法(FMM/BMM/双向);由字构词 BMES。
- 子词、BPE 算法。
- 词性兼类:UPenn 33 类 / 北大 106 码。
- 完全句法分析 vs 局部句法分析(语块 chunking, Base NP)。
- CYK 算法、CNF 范式。
- ★ PCFG 三大假设(位置不变/上下文无关/祖先无关)。
- ★ 依存语法(Tesnière)、价(valence)、动词为中心。
- ★ Robinson 四公理 → 单一父结点/连通/无环/可投射。
- 投射 vs 非投射。
- 移进-归约(arc-eager)4 操作。
- UAS / LAS / DA。
- 语义网络(Quillian)、边类型。
- 知网 HowNet(董振东)。
- ★ 语义角色两类(ARG0-5 核心 / ARGM-* 修饰),ARG0/ARG1 含义。
- PropBank。

二、公式 / 计算

- ★ F1 计算 $\$F_1=2PR/(P+R)\$$ 。
- ★ **CYK 识别矩阵**填写; $\$t_{\{0,n\}}=\$S\$$ 判定。
- ★★ **PCFG 树概率计算**(规则概率连乘)与歧义消解(比较两棵树概率)。
- PCFG 内向算法递推 $\$\alpha_{\{ij\}}(A)=\sum p(A\to BC)\alpha_{\{ik\}}(B)\alpha_{\{(k+1)j\}}(C)\$$;Viterbi(取 max)。
- PARSEVAL 的 P/R 计算(括号匹配)。
- UAS/LAS/DA 计算(给定答案树与系统树)。
- n-gram 分词 $\$\hat{W}=\arg\max p(W)p(S|W)\$$ 。

三、对比 / 分析

- ★★ **交集型 vs 组合型歧义**(出现比例 12:1)。
- ★ **生成式(n-gram)vs 判别式(字构词)** 分词方法优劣(集内 vs 集外)。
- ★ **短语结构分析 vs 依存分析**(树结构 vs 有向图;中心词)。
- **CYK vs Chart vs PCFG**(确定性 vs 概率;能否消歧)。
- 决策式依存(移进-归约,线性快但错误传递)vs 全局最优算法。

- 基于短语结构树 vs 基于依存 vs 基于语块的 SRL 方法。

四、简答 / 论述

- ★ 简述汉语分词的主要问题(规范/歧义/未登录词)及两类歧义。
- ★ 简述 CYK 算法步骤及其判定准则。
- ★ 简述 PCFG 如何消解结构歧义(树概率比较)及其三大假设。
- ★ 简述 PCFG 的三个问题及对应算法(内向/Viterbi/内外向EM)。
- ★ 简述依存语法的核心思想(动词为中心、支配/从属)与 Robinson 四公理。
- ★ 简述移进-归约算法的 4 种操作及决策式依存分析的优缺点。
- ★ 简述语义角色标注任务及两类语义角色。
- 简述 SRL 的几类方法及深度学习方法的思路。
- 简述 BPE 子词压缩的思想。
- 评价句法分析器:PARSEVAL(短语)vs UAS/LAS(依存)。

本章小结(背诵要点)

- **4.1 分词**:两类歧义(交集型链长 / 组合型,12:1)、未登录词(NE 占95%)、P/R/F1;方法 = MM(95%) / n-gram / 字构词BMES / 神经网络;NER;BPE 子词;词性标注(兼类、标注集)。
- **4.2 句法**:短语结构(CYK、PCFG 三假设 + 三问题、PARSEVAL);依存(Tesnière、价、Robinson 四公理、移进-归约 4 操作、UAS/LAS)。
- **4.3 语义**:语义网络(Quillian,边类型)、知识图谱/HowNet;**SRL**(谓词核心、PropBank、ARGO-5/ARGM-*、四类方法、F1>90%)。