

第05章 神经网络与神经语言模型 —— 总结

从离散符号到连续向量(分布式表示),用神经网络建语言模型。涵盖 FNN / RNN / LSTM 三类神经语言模型。公式密集。

一、问题提出

- **n-gram 的缺陷**:词以词形本身表示,离散符号,无法度量词间相似度(如"风趣/幽默/有趣"近义但符号不同)。
- **核心思路**:用低维、稠密的连续实数向量(词向量)表示每个词,相似语义的词向量相近。
- 引出:神经网络 → 学习词向量 + 建语言模型。

二、神经网络概述

1. 历史脉络

时间	事件	人物
1943	神经网络数学模型(M-P 神经元)	McCulloch & Pitts
1957	感知机 Perceptron(单层)	Rosenblatt
1982	循环神经网络 / Hopfield 网络(1984电路)	Hopfield
1985	Boltzmann 机(玻尔兹曼机)	Hinton
1986	BP 反向传播算法(两层网络学习)	Rumelhart & Hinton
1991	循环神经网络 RNN	Schmidhuber
1997	LSTM	Hochreiter & Schmidhuber
2003	基于前馈神经网的语言模型 NNLM	Bengio;Hinton

Hopfield 与 Hinton 获 2024 年诺贝尔物理学奖。

2. 神经元数学描述

$$y=f(WX^T+b)$$

- $x_1\ldots x_n$ 输入; $w_1\ldots w_n$ 权值; b 偏置; f 激活函数(非线性)。

3. 感知机(Perceptron,1957)

$$\hat{y}=\text{sgn}(w^T x),\quad \text{sgn}=\begin{cases}1,&w^T x>0\\-1,&w^T x\leq 0\end{cases}$$

- **局限**:无法处理 XOR(异或) 问题 → 需多层网络。

4. 激活函数 ★★

函数	公式	值域	特点
----	----	----	----

Logistic (Sigmoid)	$\sigma(x) = \frac{1}{1+e^{-x}}$	(0,1)	挤压;两端饱和→梯度消失
Tanh	$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} = 2\sigma(2x) - 1$	(-1,1)	放大平移的 Logistic,零中心
ReLU	$\text{ReLU}(x) = \max(0, x)$	$[0, \infty)$	$x > 0$ 导数1,缓解梯度消失,加速收敛; 左饱和 ;非零中心化,易"神经元死亡"

5. 常用网络:FNN、CNN、RNN、LSTM。

三、前馈神经网络(FNN)及语言模型

1. FNN / 多层感知机(MLP)

- 信息单向传播、无反向、有向无环图、全连接。
- 前向传播**(逐层迭代): $z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)}, \text{quad} a^{(l)} = f_l(z^{(l)})$
- 整个网络是复合函数 $\hat{y} = g(x; W, b) = a^{(0)} \rightarrow z^{(1)} \rightarrow \dots \rightarrow a^{(L)}$ 。

2. 参数学习 ★

- 损失(交叉熵): $L(y, \hat{y}) = -y^T \log \hat{y}$
- 结构化风险**(经验风险 + L2 正则): $R(W, b) = \frac{1}{N} \sum_{n=1}^N L(y^{(n)}, \hat{y}^{(n)}) + \frac{\lambda}{2} \|W\|_F^2$
 - $\|W\|_F^2$ Frobenius 范数(只约束权重 W ,防过拟合); λ 越大 W 越趋 0。
- SGD 随机梯度下降更新**: $W^{(l)} \leftarrow W^{(l)} - \eta \frac{\partial R}{\partial W^{(l)}}$, 梯度用 **BP 反向传播** 高效计算; η 学习率。

3. 词向量表示(Look-up Table, LT) ★

- 矩阵 $E \in \mathbb{R}^{D \times V}$, 每列是一个 D 维词向量(D 几十~几百,超参数)。
- one-hot $\times E \rightarrow$ 词向量;通常**随机初始化**,随语言模型目标函数一起优化。
- 词汇表三种确定法:全部词 / 频率超阈值词 / 前 V 高频词。

4. Softmax 回归(多类 Logistic) ★

$$p(y=c|x) = \text{Softmax}(w_c^T x) = \frac{\exp(w_c^T x)}{\sum_{c'=1}^C \exp(w_{c'}^T x)}$$

- 决策: $\hat{y} = \arg \max_c w_c^T x$; 可视为**条件最大熵模型**。

5. 基于 FNN 的语言模型(Bengio 2003) ★

- 输入:窗口内前 $n-1$ 个词的词向量拼接 $x = (LT(w_{t-n+1}), \dots, LT(w_{t-1}))$ 。
- 结构:**查表 LT** $\rightarrow$ **拼接** $\rightarrow$ **隐藏层(线性+tanh)** $\rightarrow$ **Softmax** 输出 $p(w_t | \text{context})$ 。
- 训练:BP 反复调整 W, b 和每个词向量,直至风险损失最小。

6. FNN 的问题($\rightarrow$ RNN)

- 单向、每次输入独立;输入输出维度固定,不适变长序列;
- 只建模有限窗口($n-1$ 个词)历史**,无法建模更长依赖。

四、循环神经网络(RNN)及语言模型

1. RNN(Schmidhuber 1991)

- 用带自反馈的神经元处理任意长度时序数据。隐状态 h_t 既依赖当前输入 x_t ,又依赖上一时刻 h_{t-1} :
$$h_t = f(Uh_{t-1} + Wx_t + b)$$
 - U 状态-状态权重, W 状态-输入权重; f 常用 tanh/Logistic。
- 按时间展开 → 时间维度上权值共享的 FNN。

2. 基于 RNN 的语言模型(Mikolov 2010)

- 输入:历史 h_{t-1} + 当前词向量 x_t ;输出:历史积累 h_t + 该位置词概率 $p(w_t) = \text{Softmax}(L^T h_t)$ 。
- h_t 可看作整个句子的向量表示。

3. RNN 的问题(→ LSTM) ★

- 梯度消失 / 爆炸:参数经多次传递, $W < 1$ 梯度消失, $W > 1$ 梯度爆炸。
- 难以学习长距离依赖(长期记忆失效)。
- 能否选择性保留/遗忘? → LSTM。

五、长短时记忆网络(LSTM) ★ ★ (本章核心)

1. 提出(Hochreiter & Schmidhuber,1997)

- 又称基于门控机制的循环神经网络;通过门控选择性保留/遗忘信息,克服梯度消失,建模长距离依赖。

2. 三个门 + 候选状态 + 内部状态

门控(0/1 开关,用 σ 输出 (0,1)):

门	公式	作用
遗忘门 f_t	$f_t = \sigma(U_{fh}h_{t-1} + W_{fx}x_t + b_f)$	控制上一状态 c_{t-1} 遗忘多少
输入门 i_t	$i_t = \sigma(U_{ih}h_{t-1} + W_{ix}x_t + b_i)$	控制候选状态 $\tilde{c}_t$ 保留多少
输出门 o_t	$o_t = \sigma(U_{oh}h_{t-1} + W_{ox}x_t + b_o)$	控制内部状态 c_t 输出多少给 h_t

候选状态、内部状态、外部状态:
$$\tilde{c}_t = \tanh(U_{ch}h_{t-1} + W_{cx}x_t + b_c) \quad \text{((候选状态))}$$
$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad \text{((内部状态/记忆单元,) \odot \text{元素乘})}$$
$$h_t = o_t \odot \tanh(c_t) \quad \text{((外部状态/隐状态))}$$

- 每个 t 时刻, c_t 记录到当前为止的历史信息。

3. LSTM 计算流程

① 用 h_{t-1}, x_t 算三门 f_t, i_t, o_t 和候选 $\tilde{c}_t$; ② 结合 f_t, i_t 更新记忆 c_t ; ③ 结合 o_t 把信息传给 h_t 。

4. Peephole 改进(Gers & Schmidhuber,2000)

- 门控不但依赖 x_t, h_{t-1} , 还依赖上一记忆单元 c_{t-1} : $f_t = \sigma(W_{fx_t} + U_{fh_{t-1}} + \textcolor{red}{V_{fc_{t-1}}} + b_f)$ (输入门、输出门同理)

5. 基于 LSTM 的语言模型

- 输入 $h_{t-1}, x_t \rightarrow$ LSTM 单元 $\rightarrow h_t \rightarrow$ Softmax 预测下一词概率。

考点提取

一、概念 / 定义

- ★ 分布式表示 / 词向量(连续 vs 离散符号)。
- ★ 神经元、感知机(为何不能解 XOR)。
- ★ 激活函数: Logistic / Tanh / ReLU 的公式、值域、特点(饱和、梯度消失、神经元死亡)。
- ★ FNN(MLP)、前向传播、BP 反向传播、SGD。
- 交叉熵损失、Frobenius 范数正则、过拟合。
- Softmax 回归(=条件最大熵)。
- 词向量 Look-up Table(LT)。
- ★ RNN: 隐状态、按时间展开、权值共享。
- ★ LSTM: 三个门(遗忘/输入/输出)、记忆单元 c_t 、门控思想; Peephole。

二、公式 / 计算 / 推导

- ★ 神经元 $y = f(Wx + b)$; 感知机 sgn 。
- ★ 激活函数公式(σ , $\tanh$, ReLU)。
- ★★ FNN 前向 $a^{(l)} = f_l(W^{(l)}a^{(l-1)} + b^{(l)})$ 。
- ★ 交叉熵 $L = -y^T \log \hat{y}$; 结构化风险 $R = \frac{1}{N} \sum L + \frac{\lambda}{2} \|W\|_F^2$; SGD 更新。
- ★★ **Softmax** $p(y=c|x) = \frac{\exp(w_c^T x)}{\sum \exp(w_{c'}^T x)}$ 。
- ★★ RNN $h_t = f(Uh_{t-1} + Wx_t + b)$ 。
- ★★ ★ **LSTM 五个核心公式**: $f_t, i_t, o_t = \sigma(\cdots)$; $\tilde{c}_t = \tanh(\cdots)$; $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$; $h_t = o_t \odot \tanh(c_t)$ 。
- FNN/RNN/LSTM 语言模型的前向计算(给定参数算下一词概率, 会看懂示例)。

三、对比 / 分析

- ★★ **FNN vs RNN vs LSTM** (能否处理变长序列、长距离依赖、梯度问题)。
- ★ ReLU vs Sigmoid (梯度消失、收敛速度)。
- n-gram (离散) vs 神经语言模型 (连续向量)。
- LSTM 三门的作用区别 (遗忘/输入/输出)。
- LSTM 是否解决了 RNN 的梯度消失? 如何解决? (门控 + 线性记忆传递)。

四、简答 / 论述

- ★ 为什么 n-gram 模型需要被神经语言模型替代? (离散符号、短上下文、稀疏)。
- ★ 简述 FNN 神经语言模型的结构 (Bengio 2003: 查表 $\rightarrow$ 拼接 $\rightarrow$ 隐藏 $\rightarrow$ Softmax) 及训练。
- ★ 为什么 RNN 会出现梯度消失/爆炸? 如何影响长依赖?
- ★★ 简述 LSTM 的结构与门控机制, 如何克服梯度消失、建模长距离依赖。
- 简述词向量 (Look-up Table) 的获得方式。
- 简述 Softmax 回归及其与最大熵的关系。

本章小结(背诵要点)

- **动机**: 离散符号 $\rightarrow$ 连续词向量(分布式表示)。
- **基础**: M-P 神经元、感知机(不能解 XOR)、激活函数($\sigma/\tanh/\text{ReLU}$)、BP + SGD。
- **FNN 语言模型**(Bengio 2003): 查表 $\rightarrow$ 拼接 $\rightarrow$ 隐藏($\tanh$) $\rightarrow$ Softmax; 交叉熵 + L2 正则。
- **RNN 语言模型**: $h_t = f(Uh_{t-1} + Wx_t + b)$, 时间展开、权值共享; 缺陷: 梯度消失/爆炸、难学长依赖。
- **LSTM**(Hochreiter&Schmidhuber 1997): **三门**(遗忘 f_t /输入 i_t /输出 o_t) + 候选 $\tilde{c}_t$ + 记忆 $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$ + $h_t = o_t \odot \tanh c_t$; 门控选择性记忆/遗忘, 解决长依赖。Peephole 改进依赖 c_{t-1} 。
- **Hopfield & Hinton 2024 诺奖**, 关键人物: Bengio(2003 NNLM)、Mikolov(2010 RNN LM)、Schmidhuber(RNN/LSTM)。