

第06章 文本表示 —— 总结

用形式化方法把文本变成可计算的向量。从传统**向量空间模型 VSM(TF-IDF)** 到**分布式表示学习 (word2vec 系列)**。

一、问题提出

- **文本**:由文字和标点组成的字符串,词/短语/句子/段落/篇章是不同粒度。
- **目的**:用形式化方法描述文本,既反映内容、体现差异,又可计算。

二、向量空间模型(VSM)

1. 概念(G. Salton,1960s,信息检索)

- 核心思想:**文本 = 特征项的集合** → 词袋模型(Bag-of-Words, BOW)。
- **特征项**:最小语言单元(字/词/短语/n-gram),可从语料统计获得,集合=词汇表。
- 文本 $d=\{t_1:w_1,t_2:w_2,\dots,t_n:w_n\}$, w_i 为权重。

2. 特征项权重 ★

权重	公式	含义
布尔	$w_{ij}=\begin{cases}1,&t_i\in d\\0,&\text{否}\end{cases}$	是否出现
项频 TF	$\text{tf}_i=\log f_i+1$	频率越高信息越多
逆文档频率 IDF	$\text{idf}_i=\log\frac{N}{\text{df}_i}$	N =文档总数, df_i =含 t_i 的文档数;全局统计
TF-IDF ★	$\text{tf-idf}_i=\text{tf}_i\times\text{idf}_i$	当前文本频率高 + 其他文本频率低 → 区分性强

IDF 思想:一个特征在某个文档出现频率越高,**全局有效信息反而越低**。

3. 文本长度规范化

- 1-范数: $|d|_1=\sum w_i$; $d_i'=w_i/|d|_1$
- 2-范数: $|d|_2=\sqrt{\sum w_i^2}$; $d_i'=w_i/|d|_2$
- 最大词频规范化: $d_i'=w_i/\max_k w_k$

4. VSM 的问题

- 特征项/特征选择如何定?基于**离散符号**统计,表达不精细,**无法反映语义相似性**。→ 分布式表示。

三、表示学习模型

两类方法

1. **文本概念表示模型(主题模型)**:LSA / PLSA / **LDA**(潜在狄利克雷分配),文本表示为**主题分布向量**。
2. **分布式表示学习**:深度学习优化目标函数,学低维实数向量。

(一) 词汇表示学习 ★★

① C&W 模型(Collobert & Weston, 2008)

- 思路: 用上下文词预测当前词, 使**正样本(真实词)得分 > 负样本(随机替换词)得分 1 分**。
- 拼接上下文窗口向量 $x_0, h_1 = \tanh(W_1 x_0 + b_1)$, 得分 $s = w_1 h_1 + b_1$ 。
- 目标(hinge loss): $L = \sum_{w, w' \in S} \max(0, 1 + s(w', c) - s(w, c))$
- 问题: 词序敏感、训练慢、固定窗口。

② CBOW 模型(Mikolov, 2013; Word2Vec) ★

- 用上下文词预测中心目标词。
- 输入: 上下文窗口词向量**平均**(不拼接, **无隐层**, 直接接输出层): $h = \frac{1}{2C} \sum_{i=C}^{i+C-1} e(w_i)$
- 预测中心词: $p(w_i | W_C) = \frac{\exp(h \cdot e(w_i))}{\sum_{k=1}^{|V|} \exp(h \cdot e(w_k))}$
- 优化词向量矩阵: $LT = \arg \max_{LT} \sum_{w_i \in V} \log p(w_i | W_C)$ 。

③ Skip-gram 模型(Mikolov, 2013) ★

- 用**中心词**预测**所有上下文词**(与 CBOW 相反)。 $p(w_j | w_i) = \frac{\exp(e(w_i) \cdot e(w_j))}{\sum_{k=1}^{|V|} \exp(e(w_i) \cdot e(w_k))}$
- 目标: $LT = \arg \max_{LT} \sum_{w_i \in V} \sum_{w_j \in W_C} \log p(w_j | w_i)$ 。

CBOW vs Skip-gram: 输入→输出方向相反; CBOW 上下文平均预测中心、快; Skip-gram 中心预测各上下文、对低频词效果更好。两者目标都是最大化词的对数似然, 优化词向量矩阵 LT。

(二) 短语表示学习

- ① **词袋法:** $e(\text{ph}) = \frac{1}{n} \sum e(w_k)$ (平均) / $\max_k e(w_k)$ / 加权平均 $\sum v_k \cdot e(w_k)$ 。
- ② **递归自编码器 RAE:** 二叉树式组合, 父节点=子节点向量组合, 重构误差最小化; 用余弦距离度量短语相似度。

(三) 句子表示学习

- ① 词袋平均 / TF-IDF 加权平均。
- ② **PV-DM / PV-DBOW** (Le & Mikolov): 给每个句子分配一个**段落向量**(矩阵 PV 一行), PV-DM 基于 CBOW 扩展、PV-DBOW 基于 Skip-gram 扩展, 把句子序号 SenId 与上下文一起输入。
- ③ **Skip-Thought 模型:** 借鉴 Skip-gram, 用**当前句子预测前后句子**; Encoder-Decoder 架构, 编码器用 RNN/GRU(LSTM 简化, 去掉记忆单元)/LSTM, 最后一个词的隐表示作句子编码; 解码器重构前后句子。

(四) 文档表示学习

- ① 词袋平均 / TF-IDF 加权平均。
- ② **基于句子语义组合:** 先 LSTM 得句子向量, 再**双向 LSTM**(BiLSTM)聚合句子, $h_i = [\overrightarrow{h_i}; \overleftarrow{h_i}]$, 加权平均或注意力机制得文档向量。
- ③ **层次化自编码器:** 编码得到 e_D , 能重构出原文档则 e_D 正确。

开源工具

- Google **Word2Vec / word2phrase** (CBOW & Skip-gram)。

一、概念 / 定义

- ★ 向量空间模型 VSM、词袋模型 BOW、特征项。
- ★ TF、IDF、TF-IDF 的含义与思想。
- 文本长度规范化($1/2/\infty$ 范数)。
- 主题模型 LSA/PLSA/LDA(文本=主题分布)。
- ★★ **C&W**、**CBOW**、**Skip-gram** 三种词表示模型。
- PV-DM / PV-DBOW、Skip-Thought(GRU/LSTM)。
- 递归自编码器 RAE;层次化自编码器。

二、公式 / 计算 / 推导

- ★★ **IDF** $\log(N/\text{df}_i)$ 、**TF-IDF** $\text{tf} \times \text{idf}$ 。
- $1/2/\infty$ 范数规范化。
- ★★ **CBOW**: $h = \frac{1}{2C} \sum e(w_k), p(w_i|W_C) = \text{softmax}(h \cdot e(w_i))$ 。
- ★★ **Skip-gram**: $p(w_j|w_i) = \text{softmax}(e(w_i) \cdot e(w_j))$ 。
- ★ C&W 的 hinge loss 目标函数 $\max(0, 1 + s_{\text{负}} - s_{\text{正}})$ 。
- 词袋平均 / 加权平均表示。

三、对比 / 分析

- ★★ **CBOW vs Skip-gram**(输入输出方向、对低频词、速度)。
- CBOW/Skip-gram vs C&W(拼接 vs 平均、是否有隐层)。
- VSM(离散) vs 分布式表示(连续、含语义)。
- TF vs IDF(局部 vs 全局)。
- GRU vs LSTM(GRU 去掉记忆单元,简化)。

四、简答 / 论述

- ★ 简述 TF-IDF 的原理及为何能区分文本。
- ★ 简述 VSM 及其主要问题(离散、无语义相似性)。
- ★★ 简述 CBOW 和 Skip-gram 模型的原理与区别。
- 简述 C&W 模型的训练思想(正样本得分高于负样本 1 分)。
- 简述 Skip-Thought / PV-DM 句子表示思想。
- 简述短语、句子、文档表示的常用方法(词袋平均 / RAE / BiLSTM / 层次自编码器)。

本章小结(背诵要点)

- VSM**(Salton 1960s):文本=特征项集合=**词袋 BOW**;权重 **TF-IDF** = $\text{tf} \times \log(N/\text{df})$;需长度规范化($1/2/\infty$ 范数)。缺陷:离散、无语义相似性。
- 主题模型**:LSA/PLSA/**LDA**,文本=主题分布。
- 词表示**(分布式,word2vec):**C&W**(正>负1分,hinge)、**CBOW**(上下文平均预测中心,无隐层)、**Skip-gram**(中心预测上下文)。
- 短语/句子/文档表示**:词袋平均 / RAE / **PV-DM**(CBOW扩展)/ **Skip-Thought**(预测前后句,GRU/LSTM)/ BiLSTM 聚合 / 层次自编码器。
- 关键:Mikolov 2013 word2vec;Salton VSM;Le&Mikolov PV-DM。