

第06章 文本表示 —— 总结

用形式化方法把文本变成可计算的向量。从传统向量空间模型 VSM(TF-IDF) 到分布式表示学习 (word2vec 系列)。

一、问题提出

- **文本**: 由文字和标点组成的字符串, 词/短语/句子/段落/篇章是不同粒度。
- **目的**: 用形式化方法描述文本, 既反映内容、体现差异, 又可计算。

二、向量空间模型(VSM)

1. 概念(G. Salton, 1960s, 信息检索)

- 核心思想: **文本 = 特征项的集合** → 词袋模型(Bag-of-Words, BOW)。
- **特征项**: 最小语言单元(字/词/短语/n-gram), 可从语料统计获得, 集合=词汇表。
- 文本 $d = \{t_1 : w_1, t_2 : w_2, \dots, t_n : w_n\}$, w_i 为权重。

2. 特征项权重 ★

权重	公式	含义
布尔	$w_{ij} = \begin{cases} 1, & t_i \in d \\ 0, & \text{否} \end{cases}$	是否出现
项频 TF	$\text{tf}_i = \log f_i + 1$	频率越高信息越多
逆文档频率 IDF	$\text{idf}_i = \log \frac{N}{\text{df}_i}$	N =文档总数, df_i =含 t_i 的文档数; 全局统计
TF-IDF ★	$\text{tf-idf}_i = \text{tf}_i \times \text{idf}_i$	当前文本频率高 + 其他文本频率低 → 区分性强

IDF 思想: 一个特征在某个文档出现频率越高, **全局**有效信息反而越低。

3. 文本长度规范化

- **1-范数**: $\|d\|_1 = \sum |w_i|; d'_i = w_i / \|d\|_1$
- **2-范数**: $\|d\|_2 = \sqrt{\sum w_i^2}; d'_i = w_i / \|d\|_2$
- **最大词频规范化**: $d'_i = w_i / \max_k w_k$

4. VSM 的问题

- 特征项/特征选择如何定? 基于**离散符号**统计, 表达不精细, **无法反映语义相似性**。→ 分布式表示。

三、表示学习模型

两类方法

1. **文本概念表示模型(主题模型)**:LSA / PLSA / **LDA**(潜在狄利克雷分配),文本表示为**主题分布向量**。
2. **分布式表示学习**:深度学习优化目标函数,学低维实数向量。

(一)词汇表示学习 ★★

① C&W 模型(Collobert & Weston,2008)

- 思路:用上下文词预测当前词,使**正样本(真实词)得分 > 负样本(随机替换词)得分 1 分**。
- 拼接上下文窗口向量 $x_0, h_1 = \tanh(W_1 x_0 + b_1)$,得分 $s = w_1 h_1 + b_1$ 。
- 目标(hinge loss):

$$L = \sum_{w, w' \in S} \max(0, 1 + s(w', c) - s(w, c))$$

- 问题:词序敏感、训练慢、固定窗口。

② CBOW 模型(Mikolov,2013;Word2Vec) ★

- 用上下文词预测中心目标词。
- 输入:上下文窗口词向量**平均**(不拼接,无隐层,直接接输出层):

$$h = \frac{1}{2C} \sum_{i-C \leq k \leq i+C, k \neq i} e(w_k)$$

- 预测中心词:

$$p(w_i | W_C) = \frac{\exp(h \cdot e(w_i))}{\sum_{k=1}^{|V|} \exp(h \cdot e(w_k))}$$

- 优化词向量矩阵: $LT = \arg \max_{LT} \sum_{w_i \in V} \log p(w_i | W_C)$ 。

③ Skip-gram 模型(Mikolov,2013) ★

- 用中心词预测所有上下文词(与 CBOW 相反)。

$$p(w_j | w_i) = \frac{\exp(e(w_i) \cdot e(w_j))}{\sum_{k=1}^{|V|} \exp(e(w_i) \cdot e(w_k))}$$

- 目标: $LT = \arg \max_{LT} \sum_{w_i \in V} \sum_{w_j \in W_C} \log p(w_j | w_i)$ 。

CBOW vs Skip-gram:输入→输出方向相反;CBOW 上下文平均预测中心、快;Skip-gram 中心预测各上下文、对低频词效果更好。两者目标都是最大化词的对数似然,优化词向量矩阵 LT。

(二)短语表示学习

- ① **词袋法**: $e(\text{ph}) = \frac{1}{n} \sum e(w_k)$ (平均) / max / 加权平均 $\sum v_k \cdot e(w_k)$ 。
- ② **递归自编码器 RAE**:二叉树式组合,父节点=子节点向量组合,重构误差最小化;用余弦距离度量短语相似度。

(三)句子表示学习

- ① 词袋平均 / TF-IDF 加权平均。
- ② **PV-DM / PV-DBOW**(Le & Mikolov):给每个句子分配一个**段落向量**(矩阵 PV 一行),PV-DM 基于 CBOW 扩展、PV-DBOW 基于 Skip-gram 扩展;把句子序号 SenId 与上下文一起输入。
- ③ **Skip-Thought 模型**:借鉴 Skip-gram,用**当前句子预测前后句子**;Encoder-Decoder 架构,编码器用 RNN/**GRU**(LSTM 简化,去掉记忆单元)/LSTM,最后一个词的隐表示作句子编码;解码器重构前后句子。

(四)文档表示学习

- ① 词袋平均 / TF-IDF 加权平均。
- ② **基于句子语义组合**:先 LSTM 得句子向量,再**双向 LSTM**(BiLSTM)聚合句子, $h_i = [\vec{h}_i; \overleftarrow{h}_i]$,加权平均或注意力机制得文档向量。
- ③ **层次化自编码器**:编码得到 e_D ,能重构出原文档则 e_D 正确。

开源工具

- Google **Word2Vec / word2phrase**(CBOW & Skip-gram)。

考点提取

一、概念 / 定义

- ★ 向量空间模型 VSM、词袋模型 BOW、特征项。
- ★ TF、IDF、TF-IDF 的含义与思想。
- 文本长度规范化(1/2/∞ 范数)。
- 主题模型 LSA/PLSA/LDA(文本=主题分布)。
- ★★ **C&W、CBOW、Skip-gram** 三种词表示模型。
- PV-DM / PV-DBOW、Skip-Thought(GRU/LSTM)。
- 递归自编码器 RAE;层次化自编码器。

二、公式 / 计算 / 推导

- ★★ **IDF** $\log(N/df_i)$ 、**TF-IDF** $= tf \times idf$ 。
- 1/2/∞ 范数规范化。
- ★★ CBOW: $h = \frac{1}{2C} \sum e(w_k), p(w_i|W_C) = \text{softmax}(h \cdot e(w_i))$ 。
- ★★ Skip-gram: $p(w_j|w_i) = \text{softmax}(e(w_i) \cdot e(w_j))$ 。
- ★ C&W 的 hinge loss 目标函数 $\max(0, 1 + s_{\text{负}} - s_{\text{正}})$ 。
- 词袋平均 / 加权平均表示。

三、对比 / 分析

- ★★ **CBOW vs Skip-gram**(输入输出方向、对低频词、速度)。
- CBOW/Skip-gram vs C&W(拼接 vs 平均、是否有隐层)。
- VSM(离散) vs 分布式表示(连续、含语义)。
- TF vs IDF(局部 vs 全局)。
- GRU vs LSTM(GRU 去掉记忆单元,简化)。

四、简答 / 论述

- ★ 简述 TF-IDF 的原理及为何能区分文本。
- ★ 简述 VSM 及其主要问题(离散、无语义相似性)。
- ★★ 简述 CBOW 和 Skip-gram 模型的原理与区别。
- 简述 C&W 模型的训练思想(正样本得分高于负样本 1 分)。
- 简述 Skip-Thought / PV-DM 句子表示思想。
- 简述短语、句子、文档表示的常用方法(词袋平均 / RAE / BiLSTM / 层次自编码器)。

本章小结(背诵要点)

- **VSM**(Salton 1960s):文本=特征项集合=**词袋 BOW**;权重 **TF-IDF** = $tf \times \log(N/df)$;需长度规范化(1/2/ ∞ 范数)。缺陷:离散、无语义相似性。
- **主题模型**:LSA/PLSA/**LDA**,文本=主题分布。
- **词表示**(分布式,word2vec):**C&W**(正>负1分,hinge)、**CBOW**(上下文平均预测中心,无隐层)、**Skip-gram**(中心预测上下文)。
- **短语/句子/文档表示**:词袋平均 / RAE / **PV-DM**(CBOW扩展)/ **Skip-Thought**(预测前后句,GRU/LSTM)/ BiLSTM 聚合 / 层次自编码器。
- 关键:Mikolov 2013 word2vec;Salton VSM;Le&Mikolov PV-DM。