

第07章 Transformer与大语言模型 —— 总结

课程核心章(6学时)。从注意力机制到 Transformer,再到预训练模型(BERT/GPT)与大语言模型(ChatGPT/RLHF/LoRA)。

一、多头注意力机制 ★★ ★

动机

- RNN/LSTM 中前 $t-1$ 个词对当前词权重相同,而人阅读时对不同词关注度不同。

执行过程(8 步)

Step 1 加位置编码:词向量 + 位置向量(直接相加)。位置向量两种确定方式:① 当参数学习;② 按规则:
 $y_{2i} = \sin(\frac{\text{pos}}{10000^{2i/d}})$, $y_{2i+1} = \cos(\frac{\text{pos}}{10000^{2i/d}})$

- 优点: $\text{PE}(\text{pos}+k)$ 可表示为 $\text{PE}(\text{pos})$ 的线性函数,便于学习相对位置。

Step 2 算 Q/K/V(用三个权重矩阵投影): $q=W_q x'$, $k=W_k x'$, $v=W_v x'$

- **q(查询):**当前 token 要找什么("我想找什么");**k(键):**被匹配的标识("我有什么特征");**v(值):**实际内容("我提供什么")。 **q、k 决定"看哪里"(权重),v 决定"看到什么"(内容)**。

Step 3 多头分解:把 q/k/v 拆成多个头(子空间),并行计算。

Step 4 缩放点积打分 ★: $b = \frac{q \cdot k}{\sqrt{d_k}}$ (d_k 为 q、k 维度)

Step 5 Softmax 归一化得注意力权重: $a = \text{Softmax}(b)$ 。

Step 6 聚合值: $c = \sum_i a_i v_i$ (加权求和, c 相当于隐层向量 h)。

Step 7 拼接多头:把各头的 c 拼接成完整语义向量。

Step 8 预测: $p(x_t | c_{1-t-1}) = \text{Softmax}(L^T \cdot c_{1-t-1})$ 。

代表论文:Vaswani et al., "Attention Is All You Need", NeurIPS 2017。

二、Transformer 架构 ★★

RNN/LSTM 问题

- 语义关系需逐词传递,远程依赖建模不足;必须按序编码,无法并行。

Transformer(谷歌,2017;端到端自注意力框架)

编码器(Encoder):N 层,每层 2 个子层:

1. 多头自注意力子层;
 2. 前馈网络子层。
- 每个子层间用残差连接 + 层归一化。

解码器(Decoder):N 层(6~8),每层 3 个子层:

1. 掩码多头注意力子层(只与之前词计算,掩盖后续——保证训练/测试一致);
2. 编码-解码注意力子层(q 来自目标端,k/v 来自源端,利用源语言信息);
3. 前馈网络子层。

两个关键技巧

- 残差连接 $h(x)=f(x)+x$:正向把输入与变换相加;反向时 $\frac{\partial E}{\partial x}$ 含常数项 1, 误差直接传到低层,缓解梯度弥散(He, CVPR 2016)。
- 层归一化(LayerNorm):稳定每层输入分布,加速训练: $y_i'=(x_i-\mu)/\sigma$ 。

优势 ★

1. 自注意力直接建模任意两词的语义关系,强远程依赖能力;
2. 训练时可同时编码/解码所有词,支持并行;
3. 广泛用于翻译、问答、分类、摘要、生成、语音、图像等。

三、预训练语言模型(PLM) ★★

模型	提出者/年	架构	特点
ELMo	Peters, 2018	双向 LSTM	特征抽取器;一词多义;双向拼接融合
BERT	Devlin, 2019	Transformer 编码器	双向上下文;一体化融合;全向预测
GPT	Radford, 2018	Transformer 解码器	单向自回归;生成式

GPT(生成式预训练 Transformer)

- 预训练:最大化条件似然 $L_1=\sum\sum\log p(x_j|\text{range } s, x_1,\dots,x_{j-1};\theta)$ 。
- 微调:加线性层 + Softmax 预测标签 $p(y|x)=\text{Softmax}(h(\text{range } e)W_y)$;目标 $L_2=\sum\log p(y|x)$;组合 $L=L_2+\lambda L_1$ 。

BERT ★ (与 GPT 区别)

1. 双向上下文编码;
 2. 两个无监督目标:
 - 掩码语言模型 MLM:随机掩蔽 15% 词,其中 80% 用 [MASK]、10% 随机替换、10% 不变;
 - 下一句预测 NSP:句对 50% 真正相邻(正例)/ 50% 随机(负例),用首词 $s\text{range}$ 的隐表示预测;
 3. 更大数据:BookCorpus(8 亿词)+ 英文维基(25 亿词)。
- 微调:分类任务用首词隐表示;序列标注用每词隐表示,接线性层 + Softmax。

深度学习框架:TensorFlow(Google Brain)、PyTorch(FAIR)——提供 GPU 加速 + 自动求导。

四、ChatGPT 基本原理 ★★

GPT 演进

模型	参数	关键
----	----	----

GPT 1.0 (2018)	1.17 亿	无监督预训练 + 有监督微调
GPT 2.0 (2019)	15 亿	多任务、Zero-shot
GPT 3.0 (2020)	1750 亿	Few-shot 小样本学习
ChatGPT (2022)	1750 亿	RLHF

三项基本技术 ★★

1. **预训练大模型 GPT-3/3.5**:大量文本(45TB)+ 代码(179G),自回归语言模型。
2. **指令微调(Instruction Tuning, SFT)**:收集真实人类指令 + 人工答案微调,使模型遵循指令、具备处理未知任务能力。
3. **基于人类反馈的强化学习 RLHF**:
 - 人工对多答案排序 → 训练**奖励模型 RM**;
 - 用 **PPO(近端策略优化)** 强化学习调参,使生成更符合人类偏好。

训练三步骤:① 指令微调 SFT → ② 训练奖励模型 RM → ③ PPO 强化学习。 **LLM 定义**:参数量超 10 亿的语言模型。核心:**大数据 + 大模型 + 大算力**。

五、数据处理与模型训练

- **数据来源**(GPT-3):CommonCrawl(45TB→570GB,约 5000 亿子词)、WebText2、Books1/2、英文 Wikipedia。两类:**通用数据**(网页/图书/新闻/对话)、**专业数据**(多语言科学文本/代码)。
- **数据处理**:① 质量过滤(统计分类器/启发式规则);② 冗余去除(句子级公共子串阈值如 50、文档级 n-gram 重复比);③ 隐私去除(人名/电话/邮件);④ 子词切分 + 词元表。
- **模型训练**:**分布式训练,并行策略**(数据分区 + 模型算子并行 + 梯度同步)。

六、微调与强化训练

有监督微调 SFT(指令微调)

- 用标注任务数据微调,使模型遵循指令,提升零样本表现。
- 目标 $\mathcal{L}(\theta) = -\sum_i \sum_j \log p_{\theta}(t_{i,j} | s_i, t_{i,<j})$ (指令 + 历史回复 → 当前词)。
- 两种:传统微调(更新参数)、**提示学习(prompt-based,不需更新参数)**。

奖励模型 RM

- 人工排序多答案(如 $a > b > c = d$),训练打分模型。

PPO 强化学习

- 用 RM 作奖励,近端策略优化调整模型参数,对齐人类偏好(**Alignment**,InstructGPT 起)。

LoRA(低秩适配微调) ★

- 问题:大模型过参数化。
- 思路:冻结原参数 W_0 ,用低秩分解 $A \in \mathbb{R}^{H \times R}, B \in \mathbb{R}^{R \times H}$ 近似更新: $h = W_0 x + A B^T x \quad (\Delta W = AB^T)$
- 训练完合并: $W = W_0 + AB^T$ 。只训练 A、B,大幅减少可训练参数(轻量化微调)。

七、上下文学习与思维链

上下文学习 In-Context Learning(ICL)(Brown, NeurIPS 2020)

- 给任务描述 + 若干示例(few-shot)+ 新输入,LLM 直接生成答案,不更新参数: $\text{LLM}(T, f(x_1, y_1), \dots, f(x_k, y_k), f(x_{k+1}, \cdot)) \rightarrow \hat{y}_{k+1}$

思维链 Chain-of-Thought(Wei, Google 2022)

- 在提示中加入**中间推理步骤**,引导模型一步步推理(如数学题先列式再算)。
- 问题:自治性、思维树搜索、错误传播、计算成本大、“是否真思考”。

八、大模型技术改进与评测(简)

- 借鉴人脑功能分区**:多头注意力存在**功能专用**(functional specialization),用 IAP(重要注意力头剪枝)量化、IAT 只微调任务前 k 个重要头。
- 低资源语言改进**:低资源语言安全性差、忽略文化知识;**X-Instruction** 从原始语料挖掘跨语言指令数据(生成英文指令→伪标签过滤→聚类采样)。
- 评测:GLUE 等基准。

考点提取

一、概念 / 定义

- ★ 注意力机制动机;q/k/v 的含义与作用(q、k 定权重,v 定内容)。
- ★★ 缩放点积注意力、多头注意力。
- ★ 位置编码(sin/cos)及其作用(相对位置)。
- ★★ Transformer 编码器(2 子层)/ 解码器(3 子层,掩码/编码-解码/前馈)。
- 残差连接、层归一化的作用。
- ★★ ELMo / BERT / GPT 的区别(双向 vs 单向、架构)。
- ★ BERT 的 MLM(15%/80%/10%/10%)与 NSP。
- ★★ ChatGPT 三项技术(预训练 + SFT + RLHF);RM + PPO。
- 指令微调、提示学习、对齐 Alignment。
- ★ LoRA(低秩适配)。
- ICL 上下文学习、CoT 思维链。
- LLM 定义(>10 亿参数)。

二、公式 / 计算 / 推导

- ★ 位置编码 $y_{2i} = \sin(\text{pos}/10000^{2i/d})$, $y_{2i+1} = \cos(\dots)$ 。
- ★★ **Q/K/V 投影** $q=W_qx', k=W_kx', v=W_vx'$ 。
- ★★★ **缩放点积注意力** $a = \text{Softmax}(q^T k / \sqrt{d_k})$, $c = \sum a_i v_i$ 。
- ★★ 多头注意力:拆分→并行→拼接→预测 $\text{Softmax}(L^T T_c)$ 。
- 残差 $h(x) = f(x) + x$;层归一化。
- GPT 预训练目标 $L_1 = -\sum \log p(x_j | \dots)$;微调 $L = L_2 + \lambda L_1$ 。
- BERT MLM/NSP 任务设置。
- ★ LoRA: $h = W_0 x + AB^T x$ 。
- SFT 指令微调目标 $\mathcal{L} = -\sum \log p(t_{i,j} | s_i, t_{i, < j})$ 。

三、对比 / 分析

- ★★ **RNN/LSTM vs Transformer**(远程依赖、并行)。
- ★★ **BERT vs GPT**(双向 vs 单向;编码器 vs 解码器;MLM vs 自回归)。
- ★ **ELMo vs BERT**(双向拼接 vs 一体化融合;LSTM vs Transformer)。
- 编码器自注意力 vs 解码器掩码注意力 vs 编码-解码注意力。
- 参数微调 vs 提示学习 vs LoRA。
- Few-shot(ICL)vs SFT(微调参数)。
- 传统微调 vs LoRA(全参更新 vs 低秩冻结)。

四、简答 / 论述

- ★★ 简述多头注意力机制的完整计算流程(8 步:位置→QKV→多头→打分→归一化→聚合→拼接→预测)。
- ★ 简述缩放点积注意力为何除以 $\sqrt{d_k}$ (防止点积过大使 softmax 饱和)。
- ★★ 简述 Transformer 编码器与解码器的结构(子层、残差、层归一化、掩码)。
- ★★ 简述 BERT 与 GPT 的区别及各自的预训练任务。
- ★★ 简述 ChatGPT 的三项核心技术与 RLHF 三步训练。
- ★ 简述 LoRA 的原理与优势(冻结 W_0 ,低秩分解减少参数)。
- 简述上下文学习(ICL)与思维链(CoT)。
- Transformer 为何能并行训练、为何适合远程依赖。
- 大模型数据处理流程(质量过滤、冗余去除、隐私、子词)。

本章小结(背诵要点)

- **注意力**:位置编码(sin/cos)→ **Q/K/V** → 多头拆分 → **缩放点积** $q^T k / \sqrt{d_k}$ → Softmax → 加权聚合 → 拼接 → Softmax 预测。q、k 定权重,v 定内容。
- **Transformer**(2017):编码器 2 子层(自注意力+前馈)、解码器 3 子层(掩码注意力+编码-解码注意力+前馈);残差连接 + 层归一化;支持并行、强远程依赖。
- **PLM**:ELMo(双向LSTM)、**BERT**(Transformer 编码器,双向,MLM+NSP)、**GPT**(Transformer 解码器,单向自回归)。
- **ChatGPT**:预训练 GPT-3.5 + **指令微调 SFT** + **RLHF**(RM + PPO);三步训练;>10 亿参数 = LLM。
- **微调**:SFT、提示学习、**LoRA**($h=W_0x+AB^T x$,冻结 W_0)。
- **应用**:ICL 上下文学习(few-shot,不改参数)、CoT 思维链(中间推理步)。
- 关键论文:Vaswani 2017(Transformer)、Devlin 2019(BERT)、Brown 2020(GPT-3/ICL)、Wei 2022(CoT)、Ouyang 2022(InstructGPT/RLHF)、Hu 2022(LoRA)。