

第08章 知识增强的大语言模型 —— 总结

解决 LLM 的幻觉等问题:用**检索增强生成(RAG)** 与**知识图谱**等外挂知识库为大模型"补脑"。

一、问题概述

1. 大模型的缺陷 ★

- 幻觉(Hallucination)
- 信息过时
- 参数化知识效率低
- 缺乏专业领域**深度知识**
- 推理能力弱

2. 实际应用需求

领域精准问答、数据频繁更新、生成内容**可解释可溯源**、成本可控、数据隐私保护。

3. 幻觉的类型 ★

类型	含义
语境冲突性幻觉(忠实性幻觉)	生成内容与之前生成内容/用户输入相冲突
与事实相冲突的幻觉	生成内容有悖客观事实
无中生有	完全捏造

4. 幻觉原因分析

- **缺乏知识或内化错误知识**:把相关性(位置接近/高度共现)误解为事实;偏向肯定测试样本、复制放大幻觉;训练数据含模仿性/重复性/偏见/过时。
- **高估自己能力**:大模型正确/错误答案分布熵相似,生成错误时同样"自信"。
- **对齐过程问题**:预训练缺先决知识时,错误对齐促发幻觉;**谄媚(sycophancy)**——偏向用户观点而非正确答案。
- **生成策略**:局部最优化(标记预测)≠全局最优(序列);top-p/top-k 抽样引入随机性。

5. 幻觉评估

- 事实性陈述的判别标准?如何度量幻觉指标?(需数据集)

二、检索增强生成(RAG) ★ ★

1. 概念

- LLM 回答/生成时,**先从大量文档检索相关信息,再基于检索结果生成**。
- **不必为每个任务重新训练整个大模型**,只需外挂知识库;尤其适合**知识密集型**任务。

2. 大模型优化三方式(外挂知识库 vs 知识参数化)

方式	场景
提示工程 Prompt Engineering	—
检索增强 RAG	用户需要特定信息
指令微调 Instruct/Fine-tuning	模型需要掌握一种能力

3. RAG vs Fine-tuning 对比 ★

因素	RAG	Fine-tuning
外部知识利用	擅长,适合结构化/非结构化库	需构造监督数据内化,不适用频繁更改
知识更新	直接更新检索库,适合动态环境	重新微调,耗资源
训练数据要求	对数据加工要求低	依赖高质量数据集
可解释性/可溯源	高,可追溯特定数据源	低,黑匣子
可扩展性	高,动态衔接多数据源	低,新知识需重新微调
耗时	多次检索有延迟	微调后无需检索,响应快

4. RAG 基本流程(三步) ★ ★

① 构建数据索引:

- 文档切成均匀块(chunk);
- 用编码模型为每块生成 **Embedding**;
- 存入**向量数据库**。

Small-to-Big:句子级嵌入,生成时扩大窗口。

② 检索:用向量相似度检索与问题**最相关**的 **k** 个文档。

③ 生成:原始 Query + 检索文本组合 → 输入 LLM → 回答。

5. 三个问题(检索什么/何时/如何用)

- **检索什么**:词元/词组/句子/段落/实体/知识图谱。
- **何时检索**:单次/每 token/每 n token(phrase)/自适应检索。
- **何时增强**:预训练/指令微调/推理。
- **如何用**:输入数据层/模型中间层/输出预测层。

6. 使用场景

数据长尾、知识更新频繁、回答需验证追溯、领域专业、隐私保护。代表方法:RETRO、REALM、ATLAS、RAG(Lewis 2020)、kNN-MT、FLARE、kNN-Prompt 等(问答/事实验证/对话/翻译/代码/文摘/推理/情感)。

三、其他改进方法:动态知识引导

1. 知识表示方法

逻辑表示(命题/谓词逻辑)、产生式(IF...THEN)、框架、面向对象、**语义网** → **知识图谱**、本体表示。

2. 知识图谱(回顾第4章)

- **构建**: 实体识别(边界/类别)、**实体消歧**(迈克·乔丹=篮球/教授?)、关系定义与抽取(关系分类)、事件抽取(限定域/开放域/事件关系)。
- **开源知识图谱**: 英文 WikiData、YAGO、DBpedia; 中文 OpenKG(openkg.cn)。
- **知识推理**: **归纳推理**、**演绎推理**((姚明, 出生地, 上海)+(上海, 属于, 中国)⇒(姚明, 是中国人))。

3. 动态知识引导的自动写作

- **问题**: LLM 生成文本过于关注提示中的实体, 信息丰富度低(信息丰富度排名: 人工 1.60 > GPT 各版本 > LLAMA-13B 4.00)。
- **改进思路**: 在知识图谱中找**子图约束文本生成**(一跳关系的子图), 增强信息丰富度、避免偏离主题。

4. 评价指标

- 文本质量: **PPL**、**Dist-3**、**ROUGE-L**、**BERTScore**。
- 信息丰富度: **知识约束实体数量(KC-E)**——生成文本中与输入提示实体在知识图谱中存在直接关系(至少一条边)的实体数。相关性最好(斯皮尔曼 0.554)。

考点提取

一、概念 / 定义

- ★ 大模型五大缺陷(幻觉/过时/参数化效率低/缺深度知识/推理弱)。
- ★ 幻觉三类(语境冲突/与事实冲突/无中生有)。
- 谄媚(sycophancy)。
- ★★ RAG 概念; RAG vs Fine-tuning vs 提示工程。
- 向量数据库、Embedding、chunk。
- 知识表示方法; 知识图谱构建步骤。
- 实体消歧、归纳/演绎推理。
- KC-E 指标。

二、公式 / 计算

- (本章概念为主, 无重点公式)
- RAG 三步流程(索引→检索→生成)。

三、对比 / 分析

- ★★ **RAG vs Fine-tuning**(外部知识/更新/数据/可解释/扩展/耗时)。
- 外挂知识库 vs 知识参数化(提示工程/RAG/指令微调)。
- LLM 生成文本信息丰富度低于人工的原因。

四、简答 / 论述

- ★ 大模型存在哪些缺陷?为什么要知识增强?
- ★ 幻觉有哪几种类型?产生原因?
- ★★ 简述 RAG 的基本流程(三步)及适用场景。
- ★ 比较 RAG 与 Fine-tuning 的优劣。
- 简述知识图谱的构建流程。
- 简述动态知识引导改进文本生成的方法与评价指标(KC-E)。

本章小结(背诵要点)

- **缺陷**:幻觉、信息过时、参数化知识效率低、缺专业深度、推理弱。
- **幻觉三类**:语境冲突(忠实性)、与事实冲突、无中生有;原因:缺知识/高估能力/对齐问题(谄媚)/生成策略。
- **RAG**:先检索后生成;三步(分块+Embedding 入向量库 → 向量相似检索 k 个 → Query+检索文本输入 LLM);适合知识密集/动态更新;**可溯源可解释**;外挂知识库无需重训。
- **RAG vs 微调**:RAG 擅长外部知识/动态/可解释/可扩展但有延迟;微调内化能力但耗资源、黑匣子。
- **知识图谱增强**:子图约束生成提升信息丰富度;指标 PPL/Dist-3/ROUGE-L/BERTScore + **KC-E**(知识约束实体数)。