

# 第09章 文本分类与情感分析 —— 总结

把海量文本按需分类。客观性内容分类 + 主观性观点(情感/情绪)分析;方法从规则/统计到 BERT/LLM。

## 一、问题提出

### 文本信息分类两大类

- 1. 客观性事实/内容(facts/contents) → 文本分类(如《中国图书分类法》22 大类)。
- 2. 主观性观点(opinions) → 观点挖掘(opinion mining):
  - 情感(sentiment)倾向性:正面 positive / 负面 negative / 中立 neutral。
  - 情绪(emotion):7 类(喜怒忧思悲恐惊);数据集有 6/8/9/11/13 类不等(愤怒/厌恶/恐惧/喜悦/悲伤/惊讶/信任/期待/爱...).

### 情感 vs 情绪

- 情感(sentiment):对事物是否满足需要的态度体验(喜好倾向)。
- 情绪(emotion):主观认知经验 + 行为反应(具体情绪类别)。

### 研究意义

自动分类提效;情报筛选推荐;企业观点挖掘/在线名誉管理;用户个性化服务;政府舆情监测与社会治理。

## 二、分类方法

### 总框架

知识工程方法(基于规则) + 机器学习方法:

- I. 统计模式分类(特征表示 → 特征选择 → 分类器)
- II. 神经网络分类(Softmax 回归 / 预训练语言模型)

### 1. 特征表示

- 向量空间模型 VSM(离散符号,TF-IDF 权重);分布式表示(词/句/文档向量)。

### 2. 特征选择 ★ (4 种)

设特征  $t_i$  与类别  $c_j$  的  $2 \times 2$  统计: $A_{ij}$ (含特征且属该类)、 $B_{ij}$ (含特征不属该类)、 $C_{ij}$ (不含特征属该类)、 $D_{ij}$ (不含特征不属该类), $N_{\text{all}}$ =总文档数, $C$ =类别数。

| 方法           | 思想/公式                                                                                                      |
|--------------|------------------------------------------------------------------------------------------------------------|
| 文档频率<br>DF   | 特征在某类出现文档数;出现多则保留                                                                                          |
| 互信息<br>MI ★  | $I(X,Y)=H(X)-H(X Y)=\sum p(x,y)\log\frac{p(x,y)}{p(x)p(y)};I(t_i,c_j)=\log\frac{P(t_i,c_j)}{P(t_i)P(c_j)}$ |
| 信息增益<br>IG ★ | $I\{C,T_i\}=H(C)-H(C T_i)=-\sum p(c_j)\log p(c_j)+p(t_i)\sum p(c_j t_i)\log p(c_j t_i)+p(\bar{t_i})\dots$  |

|             |                                                                                                                                                                |
|-------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 卡方 CHI<br>★ | $\chi^2(t_i, c_j) = \frac{(N_{\text{all}}(A_{ij}D_{ij} - C_{ij}B_{ij})^2 / ((A_{ij} + C_{ij})(B_{ij} + D_{ij})(A_{ij} + B_{ij})(C_{ij} + D_{ij})))}{}$ , 越大越相关 |
|-------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|

概率做加 1 平滑(如  $P(c_j|t_i) \approx \frac{A_{ij}+1}{A_{ij}+B_{ij}+C_{ij}+D_{ij}}$ )。例:"计算机"  $IG=0.1308 >$  "北京"  $IG=0.0293$ 。

### 3. 分类器

- **生成式**:朴素贝叶斯 NB(最大似然/最大后验)。
- **判别式**:线性判别、**SVM**(最大间隔)、**最大熵 ME**、**CRF**。
- **组合分类器**:多特征 + 多分类器投票/加和/最大/乘法。

### 4. 神经网络分类

#### ① 基于 Softmax 回归:

- 文档表示  $e_D \rightarrow$  全连接  $x = W e_D + b$  (维度=类别数  $C$ )  $\rightarrow$  Softmax:  

$$p(L(D)=c|x) = \frac{\exp(x_c)}{\sum_{c'} \exp(x_{c'})}$$
- 训练目标**最小化交叉熵**: 
$$\text{Loss} = -\sum_{D \in T} \sum_{k=1}^C L_k(D) \log p_k(D)$$
  
 $(L_k(D)=1 \text{ 若 } D \text{ 属第 } k \text{ 类, 梯度下降训练 } W, b)$

#### ② 基于预训练语言模型(BERT) ★:

- **预训练**(自监督):掩码语言模型 MLM + 句子衔接预测 NSP(见第7章)。
- **微调**:在 [CLS] + 文本 后加任务层(线性 + Softmax),用少量标注数据微调。句子级情感、篇章级内容分类均可。

## 三、情感与情绪分析

### 任务划分

1. **文本情感分析**:① 文档/句子情感识别 ② **要素级情感分析(ABSA)**(针对 aspect)③ 观点要素抽取(持有者/目标抽取、摘要)④ 观点检索。
2. **文本情绪分析**:情绪分类、情绪溯因、情绪-原因对抽取、情绪强度检测。

### 层次(词/特征/句子/文档级)

词级  $\rightarrow$  特征/要素级(aspect,如"价格")  $\rightarrow$  句子级  $\rightarrow$  文档级(考虑篇章结构)。

### 情感识别方法

#### 词汇级:

- ① **基于词典**:用 WordNet/HowNet 的同义反义关系扩展情感词典。
- ② **基于语料**:
$$SO(\text{word}) = \text{PMI}(\text{word}, \text{"excellent"}) - \text{PMI}(\text{word}, \text{"poor"})$$
。

#### 句子级:

- A. 基于词典(词性标注选情感短语  $\rightarrow$  PMI 算极性  $\rightarrow$  平均)。
- B. 基于统计学习(uni/bi-gram、POS、形容词特征;NB/SVM/ME/组合分类器)。
- C. 基于 Softmax / 预训练语言模型(BERT)。

组合学习:多特征(POS/依赖)×多分类器(NB/SVM/MaxEnt)→集成打分,优势互补。

## 四、基于 LLMs 的情绪支持对话(ESC)

- **情绪支持代理(Emotional Support Agent)**:缓解用户情绪困扰,用于社交、客服、心理健康。
- **\*\*流程 + 策略(8 种支持策略)\*\***。
- **LLM 局限**:缺乏共情、回复过长、程式化、数据多样性不足、策略预测不准。
- **改进方法**:用先进 LLM 增强 ES 数据——**Completion / Rewriting / Simulation**;角色扮演对话生成(Seeker/Counselor/Supporter 多视角),如 **SweetieChat**、**ServeForEmo**(45 类问题)。

## 五、资源与评测

### 情感词典

- **英文**:General Inquirer、SentiWordNet(基于 WordNet)、OpinionFinder、IBM Lexicon。
- **中文**:HowNet(6 子集:正/负情感、正/负评价、程度、主张)、**大连理工情感词汇本体库**。

### 评测会议

- **TREC Blog Track**(2006起,英文网页,观点检索+极性)。
- **NTCIR**(多语新闻,主题/观点识别/极性/持有者/目标抽取)。
- **COAE**(中文,词级/文档级 sub-obj、正负、目标抽取、检索)。

### 数据集

- 句子级:IMDb、**SST**(SST-2/SST-5)、Yelp、中文微博。
- 属性级 **ABSA:SemEval-14**(餐馆/笔记本,属性抽取/情感/类别)、Sentihood、ASAP(中文电商,18 属性)。

### 评价指标

分类:准确率(Accuracy)、精确率 P、召回率 R、F1;排序任务等。

## 考点提取

### 一、概念 / 定义

- ★ 文本分类 vs 观点挖掘;情感 vs 情绪。
- 情绪类别(6/8/9/11/13);情感三极性。
- 知识工程 vs 机器学习方法;统计模式 vs 神经网络分类。
- ★ 特征选择 4 法:DF / MI / IG / CHI。
- 生成式(NB)vs 判别式(SVM/ME/CRF)分类器。
- 组合分类器。
- ABSA 要素级情感分析;观点持有者/目标抽取。
- 情感识别三层次方法(词典/语料/统计神经网络)。
- BERT 分类(MLM + NSP 预训练 + 微调)。
- 情绪支持对话 ESC。

### 二、公式 / 计算

- ★★ **互信息**  $I(X,Y)=\sum p(x,y)\log\frac{p(x,y)}{p(x)p(y)}$ 。
- ★★ **信息增益**  $I_G = H(C) - H(C|T_i)$ (展开三部分)。

- ★ 卡方  $\chi^2 = \frac{N_{\text{all}}(AD-CB)^2}{(A+C)(B+D)(A+B)(C+D)}$ 。
- ★ Softmax 分类  $p = \exp(x_c) / \sum \exp$ ; 交叉熵损失  $\text{Loss} = -\sum \sum L_k \log p_k$ 。
- 情感倾向  $SO(\text{word}) = \text{PMI}(\text{word, excellent}) - \text{PMI}(\text{word, poor})$ 。
- $2 \times 2$  列联表(A/B/C/D)的概率估计(含 +1 平滑)。
- 会手算 IG(如"计算机"特征)。

### 三、对比 / 分析

- ★ 生成式(NB)vs 判别式(SVM)分类器。
- 四种特征选择方法的思想差异(DF/MI/IG/CHI)。
- 基于词典 vs 基于语料 vs 统计/神经网络 的情感识别。
- 传统分类 vs Softmax vs BERT 分类。
- 情感 vs 情绪任务的区别。

### 四、简答 / 论述

- ★ 简述文本分类的完整流程(特征表示→特征选择→分类器→评价)。
- ★ 简述 4 种特征选择方法的原理(DF/MI/IG/CHI)。
- ★ 简述基于 BERT 的文本分类方法(预训练 + 微调)。
- ★ 简述情感分析的任务划分与层次(词/句子/文档/要素级 ABSA)。
- 简述句子级情感识别的三类方法。
- 简述组合分类器(集成学习)的思想。
- 简述中文/英文情感词典资源。

## 本章小结(背诵要点)

- **分类**: 客观内容分类 + 主观情感/情绪分析; 情感(倾向)vs 情绪(类别)。
- **分类流程**: 特征表示(VSM/分布式) → **特征选择(DF/MI/IG/CHI)** → 分类器(生成式 NB / 判别式 SVM·ME-CRF) → 组合分类。
- **神经网络分类**: **Softmax 回归**(交叉熵损失) + **预训练模型微调**(BERT: MLM + NSP 预训练, 任务层微调)。
- **情感分析**: 任务 = 情感识别 / **ABSA 要素级** / 观点要素(持有者 + 目标)抽取 / 观点检索; 层次 = 词/句/文档/aspect; 方法 = 词典(WordNet/HowNet)/语料( $SO = \text{PMI}\{pos\} - \text{PMI}\{neg\}$ )/统计(NB·SVM)/神经网络;**组合学习**优势互补。
- **ESC**: LLM 情绪支持对话, 角色扮演数据增强(SweetieChat/ServeForEmo)。
- **资源**: 词典(HowNet、SentiWordNet)、评测(TREC/NTCIR/COAE)、数据集(SST/IMDb/SemEval-14 ABSA)。