

第09章 文本分类与情感分析 —— 总结

把海量文本按需分类。**客观性内容分类** + **主观性观点(情感/情绪)分析**;方法从规则/统计到 BERT/LLM。

一、问题提出

文本信息分类两大类

- 1. **客观性事实/内容(facts/contents)** → **文本分类**(如《中国图书分类法》22 大类)。
- 2. **主观性观点(opinions)** → **观点挖掘(opinion mining)**:
 - **情感(sentiment)倾向性**:正面 positive / 负面 negative / 中立 neutral。
 - **情绪(emotion)**:7 类(喜怒忧思悲恐惊);数据集有 6/8/9/11/13 类不等(愤怒/厌恶/恐惧/喜悦/悲伤/惊讶/信任/期待/爱...)。

情感 vs 情绪

- **情感(sentiment)**:对事物是否满足需要的态度体验(喜好倾向)。
- **情绪(emotion)**:主观认知经验 + 行为反应(具体情绪类别)。

研究意义

自动分类提效;情报筛选推荐;企业观点挖掘/在线名誉管理;用户个性化服务;政府舆情监测与社会治理。

二、分类方法

总框架

知识工程方法(基于规则) + 机器学习方法:

- I. 统计模式分类(特征表示 → 特征选择 → 分类器)
- II. 神经网络分类(Softmax 回归 / 预训练语言模型)

1. 特征表示

- **向量空间模型 VSM**(离散符号,TF-IDF 权重);**分布式表示**(词/句/文档向量)。

2. 特征选择 ★(4 种)

设特征 t_i 与类别 c_j 的 2×2 统计: A_{ij} (含特征且属该类)、 B_{ij} (含特征不属该类)、 C_{ij} (不含特征属该类)、 D_{ij} (不含特征不属该类), N_{all} =总文档数, C =类别数。

方法	思想/公式
文档频率 DF	特征在某类出现文档数;出现多则保留

方法	思想/公式
互信息 MI ★	$I(X, Y) = H(X) - H(X Y) = \sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$; $MI(t_i, c_j) = \log \frac{P(t_i, c_j)}{P(t_i)P(c_j)}$
信息增益 IG ★	$IG(C, T_i) = H(C) - H(C T_i) = -\sum p(c_j) \log p(c_j) + p(t_i) \sum p(c_j t_i) \log p(c_j t_i) + p(\bar{t}_i) \dots$
卡方 CHI ★	$\chi^2(t_i, c_j) = \frac{N_{\text{all}}(A_{ij}D_{ij} - C_{ij}B_{ij})^2}{(A_{ij} + C_{ij})(B_{ij} + D_{ij})(A_{ij} + B_{ij})(C_{ij} + D_{ij})}$, 越大越相关

概率做加 1 平滑(如 $P(c_j|t_i) \approx \frac{A_{ij} + 1}{A_{ij} + B_{ij} + C}$)。例:"计算机" IG=0.1308 > "北京" IG=0.0293。

3. 分类器

- **生成式**:朴素贝叶斯 NB(最大似然/最大后验)。
- **判别式**:线性判别、**SVM**(最大间隔)、**最大熵 ME**、**CRF**。
- **组合分类器**:多特征 + 多分类器投票/加和/最大/乘法。

4. 神经网络分类

① 基于 Softmax 回归:

- 文档表示 $e_D \rightarrow$ 全连接 $x = We_D + b$ (维度=类别数 C) $\rightarrow$ Softmax:

$$p(L(D) = c|x) = \frac{\exp(x_c)}{\sum_{c'} \exp(x_{c'})}$$

- 训练目标**最小化交叉熵**:

$$\text{Loss} = - \sum_{D \in T} \sum_{k=1}^C L_k(D) \log p_k(D)$$

($L_k(D) = 1$ 若 D 属第 k 类,梯度下降训练 W、b)

② 基于预训练语言模型(BERT) ★:

- **预训练**(自监督):掩码语言模型 MLM + 句子衔接预测 NSP(见第7章)。
- **微调**:在 [CLS] + 文本 后加任务层(线性 + Softmax),用少量标注数据微调。句子级情感、篇章级内容分类均可。

三、情感与情绪分析

任务划分

1. **文本情感分析**:① 文档/句子情感识别 ② **要素级情感分析(ABSA)**(针对 aspect)③ 观点要素抽取(持有者/目标抽取、摘要)④ 观点检索。
2. **文本情绪分析**:情绪分类、情绪溯因、情绪-原因对抽取、情绪强度检测。

层次(词/特征/句子/文档级)

词级→特征/要素级(aspect,如"价格")→句子级→文档级(考虑篇章结构)。

情感识别方法

词汇级:

- ① **基于词典**:用 WordNet/HowNet 的同义反义关系扩展情感词典。
- ② **基于语料**: $SO(\text{word}) = \text{PMI}(\text{word}, \text{"excellent"}) - \text{PMI}(\text{word}, \text{"poor"})$ 。

句子级:

- A. 基于词典(词性标注选情感短语 → PMI 算极性 → 平均)。
- B. 基于统计学习(uni/bi-gram、POS、形容词特征;NB/SVM/ME;组合分类器)。
- C. 基于 Softmax / 预训练语言模型(BERT)。

组合学习:多特征(POS/依赖)× 多分类器(NB/SVM/MaxEnt)→ 集成打分,优势互补。

四、基于 LLMs 的情绪支持对话(ESC)

- **情绪支持代理(Emotional Support Agent)**:缓解用户情绪困扰,用于社交、客服、心理健康。
- **流程 + 策略(8 种支持策略)**。
- **LLM 局限**:缺乏共情、回复过长、程式化、数据多样性不足、策略预测不准。
- **改进方法**:用先进 LLM 增强 ES 数据——**Completion / Rewriting / Simulation**;角色扮演对话生成(Seeker/Counselor/Supporter 多视角),如 **SweetieChat**、**ServeForEmo**(45 类问题)。

五、资源与评测

情感词典

- **英文**:General Inquirer、SentiWordNet(基于 WordNet)、OpinionFinder、IBM Lexicon。
- **中文**:**HowNet**(6 子集:正/负情感、正/负评价、程度、主张)、**大连理工情感词汇本体库**。

评测会议

- **TREC Blog Track**(2006起,英文网页,观点检索+极性)。
- **NTCIR**(多语新闻,主题/观点识别/极性/持有者/目标抽取)。
- **COAE**(中文,词级/文档级 sub-obj、正负、目标抽取、检索)。

数据集

- 句子级:IMDb、**SST**(SST-2/SST-5)、Yelp、中文微博。
- 属性级 **ABSA**:**SemEval-14**(餐馆/笔记本,属性抽取/情感/类别)、Sentihood、ASAP(中文电商,18 属性)。

评价指标

分类:**准确率(Accuracy)**、**精确率 P**、**召回率 R**、**F1**;排序任务等。

🎯 考点提取

一、概念 / 定义

- ★ 文本分类 vs 观点挖掘;情感 vs 情绪。
- 情绪类别(6/8/9/11/13);情感三极性。
- 知识工程 vs 机器学习方法;统计模式 vs 神经网络分类。
- ★ 特征选择 4 法:DF / MI / IG / CHI。
- 生成式(NB)vs 判别式(SVM/ME/CRF)分类器。
- 组合分类器。
- ABSA 要素级情感分析;观点持有者/目标抽取。
- 情感识别三层次方法(词典/语料/统计神经网络)。
- BERT 分类(MLM + NSP 预训练 + 微调)。
- 情绪支持对话 ESC。

二、公式 / 计算

- ★★ 互信息 $I(X, Y) = \sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$ 。
- ★★ 信息增益 $IG = H(C) - H(C|T_i)$ (展开三部分)。
- ★ 卡方 $\chi^2 = \frac{N_{\text{all}}(AD - CB)^2}{(A + C)(B + D)(A + B)(C + D)}$ 。
- ★ Softmax 分类 $p = \exp(x_c) / \sum \exp$;交叉熵损失 $\text{Loss} = - \sum \sum L_k \log p_k$ 。
- 情感倾向 $SO(\text{word}) = \text{PMI}(\text{word}, \text{excellent}) - \text{PMI}(\text{word}, \text{poor})$ 。
- 2×2 列联表(A/B/C/D)的概率估计(含 +1 平滑)。
- 会手算 IG(如"计算机"特征)。

三、对比 / 分析

- ★ 生成式(NB)vs 判别式(SVM)分类器。
- 四种特征选择方法的思想差异(DF/MI/IG/CHI)。
- 基于词典 vs 基于语料 vs 统计/神经网络 的情感识别。
- 传统分类 vs Softmax vs BERT 分类。
- 情感 vs 情绪任务的区分。

四、简答 / 论述

- ★ 简述文本分类的完整流程(特征表示→特征选择→分类器→评价)。
- ★ 简述 4 种特征选择方法的原理(DF/MI/IG/CHI)。
- ★ 简述基于 BERT 的文本分类方法(预训练 + 微调)。
- ★ 简述情感分析的任务划分与层次(词/句子/文档/要素级 ABSA)。
- 简述句子级情感识别的三类方法。
- 简述组合分类器(集成学习)的思想。
- 简述中文/英文情感词典资源。

本章小结(背诵要点)

- 分类:**客观内容分类 + 主观情感/情绪分析;情感(倾向)vs 情绪(类别)。
- 分类流程:**特征表示(VSM/分布式)→ **特征选择(DF/MI/IG/CHI)** → 分类器(生成式 NB / 判别式 SVM·ME·CRF)→ 组合分类。

- **神经网络分类:Softmax 回归**(交叉熵损失)+ **预训练模型微调**(BERT:MLM+NSP 预训练,任务层微调)。
- **情感分析**:任务=情感识别 / **ABSA 要素级** / 观点要素(持有者+目标)抽取 / 观点检索;层次=词/句/文档/aspect;方法=词典(WordNet/HowNet)/语料($SO = PMI_{pos} - PMI_{neg}$)/统计(NB·SVM)/神经网络;**组合学习**优势互补。
- **ESC**:LLM 情绪支持对话,角色扮演数据增强(SweetieChat/ServeForEmo)。
- **资源**:词典(HowNet、SentiWordNet)、评测(TREC/NTCIR/COAE)、数据集(SST/IMDb/SemEval-14 ABSA)。