

第10章 机器翻译 —— 总结

课程应用大章(5学时)。从规则 → 统计(SMT)→ 神经(NMT)→ 大模型翻译;含噪声信道、注意力机制、BLEU 评测、语音翻译。

一、技术产生与发展

概念

- **机器翻译(MT)**:用计算机把一种语言(源语言 SL)翻译成另一种语言(目标语言 TL)。

Weaver 两观点(1947/1949)

1. 翻译类似**解码密码**(原文是用另一种符号编码的译文)。
2. 原文译文"说同样的事",可经**通用/中间语言(universal language/interlingua)** 转换。

发展时间线 ★

- 1954 **Georgetown-IBM**(IBM-701,俄译英,250 词 6 规则);1964/66 **ALPAC 报告**(MT 降温);
- 1976 TAUM-METEO;1984 **EBMT**(长尾真);1989 **SMT**;GIZA/GIZA++/Pharaoh/Moses;
- 2006 Google 翻译、2009 Bing、2011 百度;**2013 NMT**;2017 Transformer;2022.11 ChatGPT。

技术挑战

NLP 所有问题(歧义、非规范、新词、知识)都在 MT 遇到;**文化差异致概念不对等**(馒头/麻婆豆腐/蚂蚁上树)。

二、基本翻译方法

方法	类型	说明
模板直接转换	理性主义	表层单词/短语直接置换 + 简单词序调整
基于规则 RBMT	理性主义	V. Yngve 1957;6 步(词法→句法语义分析→结构转换→生成→词汇转换→词法生成)
中间语言 interlingua	理性主义	源语言 → 中间语言 → 目标语言(C-STAR IF、UNL)
基于事例 EBMT	经验主义	长尾真 1984;输入句与事例库相似度匹配 → 译文重组
统计 SMT	经验主义	噪声信道;IBM 模型
神经 NMT	连接主义	编码器-解码器、注意力、Transformer

统计机器翻译 SMT(IBM,Brown 1990/1993) ★★

噪声信道模型:语言 T 经噪声信道变形为 S,翻译 = 由观察到的 S 恢复最可能的 T: $p(T|S)=\frac{p(T)\cdot p(S|T)}{p(S)}$, $\hat{T}=\arg\max_T p(T)\cdot p(S|T)$

- $p(T)$ = **语言模型 LM**; $p(S|T)$ = **翻译模型 TM**;搜索模块 = **解码器**。
- **三个关键问题**:① 估计 $p(T)$;② 估计 $p(S|T)$;③ 快速搜索使 $p(T)\cdot p(S|T)$ 最大。

翻译模型与对位(alignment):

- 资源:双语平行句对。 $p(S|T)=\sum_A p(S,A|T)$ 。

- **对位模型**:源词 s_j 与目标词 t_i 的对应($a_j=i$,无对齐则 $a_j=0$)。
- **IBM 模型 1~5**:基于词的翻译模型(word-based),不同假设得 5 个模型。
- **演进**:基于词 → 基于短语(phrase-based)→ 层次短语(hierarchical)→ 句法树对齐。

三、神经机器翻译(NMT) ★ ★ ★

提出(2013~2014)

- Kalchbrenner & Blunsom 2013;Sutskever 等 2014 **Seq2Seq**(Sequence to Sequence Learning)。

基本原理(端到端 Encoder-Decoder)

- 源句 $C=c_1\cdots c_l \rightarrow$ 目标句 $E=e_1\cdots e_m$ 。
- $\hat{e}_i \approx \arg \max p(e_i | e_{1:i-1}, C)$; **目标函数** $J = -\sum \log p(e_i | C)$ 。
- 编码器把源句编码为向量;解码器逐步生成译文。

训练(编码器-解码器,RNN)

- 参数:① 词向量;② RNN 参数 $h_t = \tanh(Wx_t + Uh_{t-1} + b)$ 。
- **编码**:逐词更新隐状态,最终 $C = h_l^s$ (源句向量)。
- **解码**:从 START 开始, $h_t = \tanh(W_t \cdot \text{text}(\text{prev}) + U_t \cdot \text{text}(\text{ctx}) + b_t)$,Softmax 预测词概率。
 - **训练**:用**标准答案**作下一时刻输入(teacher forcing),最大化 $P(Y|X, \theta)$;
 - **测试**:用**预测概率最高**的词作下一输入,直到 EOS。

问题与改进:注意力机制(Bahdanau 2015) ★

- **问题**:源端全部信息压缩到**固定长度向量 C**,长句性能急剧下降。
- **改进**:编码成**向量序列**,解码时按**注意力**从源端选合适信息。 $p(y) = \prod_{t=1}^T p(y_t | y_{1:t-1}, x)$, $q(y_i | \dots) = g(y_{1:t-1}, s_i, c_i)$
- **注意力计算**:① 打分 $a_{ij} = (h_i^t)^T h_j^s$;② 归一化;③ 上下文向量 $c_i = \sum_j a_{ij} h_j^s$;④ 融合 $\tilde{c}_i = \tanh(Wc_i + Uh_i^t)$;⑤ Softmax 预测。

进一步改进

- **CNN 翻译**(2017/07);**Transformer 翻译**(2017/12,谷歌):首个**完全依赖自注意力**、不用 RNN/CNN 的转换模型(见第7章)。

SMT vs NMT

- NMT 译文流畅、质量高;但需大量数据、长句、罕见词仍有挑战。

开源工具

tensor2tensor(Google)、fairseq(Facebook)、THUMT(清华)、ZNLP(中科院自动化所)。

四、译文质量评估 ★

主观评测

- ****流畅度(fluency)、充分性(adequacy)、语义保持性(meaning maintenance)****。
- 标准:CET-4(15 分)、CATTI(二/三级笔译)、IWSLT(流畅性/充分性 0-4、语义保持 0-4)。

客观(自动)评测

- 句子错误率、**单词错误率 mWER**、位置无关 mPER、**METEOR**(综合准确率/召回率/F)、**BLEU**、NIST、COMET。

BLEU(Papineni 2002) ★ ★ ★ (必考计算)

- **思想**:系统译文与人工参考译文比较,**n-gram 匹配比例越高越好**。
- n-gram 精度 $p_n = \frac{\text{同时出现在系统译文和参考译文中的 n-gram 数}}{\text{系统译文 n-gram 总数}}$
 - 问题①:n 增大得分指数下降 → 取**几何平均**(对数加权, N 最大 4);

- 问题②:译文越短/重复词得分虚高 → **长度惩罚 BP**。

$$\text{BLEU} = \text{BP} \times \exp\left(\frac{1}{N} \sum_{n=1}^N w_n \ln p_n\right)$$

$$\text{BP} = \begin{cases} 1, & c > r \\ e^{1-r/c}, & c \leq r \end{cases}$$

- c = 系统译文长度, r = 最接近的参考译文长度; 权重常 $w_n = 1/N$ 。
- 范围 **0~1, 越高越好**。
- 例: 7 词译
文, $n=1: 6/7=0.86, n=2: 4/6=0.67, n=3: 2/5=0.40, \text{BP}=1, \text{BLEU} = \exp[(\ln 0.86 + \ln 0.67 + \ln 0.40)/3] = 0.61$ 。

评测活动

NIST 评测(2002)、WMT(2006起, 欧盟)、CWMT/CCMT(中文)、IWSLT(口语)。

五、语音翻译原理

概念

- **语音翻译(speech-to-speech)**: 实现不同语言说话人间话语翻译; 又称口语翻译 SLT / 对话翻译。
- 里程碑: 1989 CMU SpeechTrans(英日医生病人对话)。

类型

交互翻译(交传)、同声传译(同传)、语音到文本。

管道式流程

源语音 → 语音识别(ASR) → 源文字 → 理解与翻译 → 目标文字 → 语音合成(TTS) → 目标语音。关键模块: 语音识别、理解与翻译、语音合成、知识库。

挑战

- 口语输入复杂(重复/冗余/修正/词序颠倒/无标点/省略);
- 环境噪音、非语音信号;
- 含识别错误的字词输入;
- 副语言信息(语气/手势/表情)。

口语 vs 书面语翻译

句长短(8 词 vs 22.5)、结构简单、不规范、用词少、有识别噪声、副语言重要。

同声传译

需兼顾译文准确 + **低延迟** + 易理解; 偏好优化(译文偏好 + 延迟偏好)。

六、技术现状

- **演进**: RBMT(~2000) → SMT(2000) → NMT(2013/2017) → LLM 翻译。
“基于规则的机器翻译是傻子, 基于统计的机器翻译是疯子。”
- **LLM 翻译评测**(Flores-200): 高资源(中/德)、中资源(爱沙尼亚/立陶宛)、低资源(僧伽罗/尼泊尔)。指标 COMET/BLEU。
 - 高资源语言 LLM 接近 Google 翻译; **低资源语言 LLM 明显落后**(数据不足)。

🎯 考点提取

一、概念 / 定义

- ★ MT、源/目标语言; Weaver 两观点。
- ★★ 五类翻译方法(模板/规则/中间语言/EBMT/SMT/NMT)及范式归属(理性/经验/连接)。

- ★★ 噪声信道模型;语言模型 / 翻译模型 / 解码器;SMT 三关键问题。
- 对位模型(alignment);IBM 模型 1~5;基于词/短语翻译。
- ★★ NMT:端到端、编码器-解码器、Seq2Seq。
- 注意力机制(Bahdanau 2015)动机(固定向量瓶颈)。
- ★★ BLEU;METEOR;WER。
- 主观评测(流畅度/充分性/语义保持)。
- 语音翻译管道(ASR→MT→TTS);同传延迟。

二、公式 / 计算

- ★★ ★ 噪声信道 $p(T|S) = \frac{p(T)p(S|T)}{p(S)}$, $\hat{T} = \arg\max p(T)p(S|T)$ 。
- NMT 目标 $J = \sum \log p(e_i|C)$ 。
- 注意力 $a_{ij} = (\mathbf{h}_i^t \cdot \mathbf{h}_j^s)$, $c_i = \sum a_{ij} \mathbf{h}_j^s$ 。
- ★★ ★ BLEU $= \text{BP} \cdot \exp(\sum w_n \ln p_n)$; $\text{BP}=1$ 若 $c > r$ 否则 $e^{1-r/c}$;会手算 n-gram 精度与 BLEU。

三、对比 / 分析

- ★★ 规则/统计/神经三种 MT 方法对比(见第1章绪论)+ 本章展开(噪声信道、端到端)。
- ★★ SMT vs NMT(原理、流畅性、数据需求、长句)。
- RNN-NMT vs CNN-NMT vs Transformer-NMT(并行、远程依赖)。
- 各翻译方法优劣(规则:可溯源但移植差;SMT:数据驱动;NMT:流畅但幻觉)。
- 口语翻译 vs 书面语翻译。
- BLEU 的两个缺陷(短译、重复词)及修正(几何平均、BP)。

四、简答 / 论述

- ★ 简述机器翻译方法的演进(RBMT→SMT→NMT→LLM)。
- ★★ 简述噪声信道模型及 SMT 的三个关键问题。
- ★★ 简述神经机器翻译的编码器-解码器原理与训练/测试区别(teacher forcing)。
- ★ 简述注意力机制如何改进 NMT(解决固定向量瓶颈)。
- ★★ 简述 BLEU 的计算方法(n-gram 精度 + BP)及其缺陷。
- 简述语音翻译的管道流程与挑战。
- 简述基于规则翻译方法的 6 个步骤及其优缺点。
- 比较 LLM 与专用翻译系统在不同资源语言上的表现。

本章小结(背诵要点)

- 演进:RBMT(规则)→ SMT(统计,1989/IBM)→ NMT(神经,2013)→ Transformer(2017)→ LLM(2022)。
- SMT 噪声信道: $\hat{T} = \arg\max p(T) \cdot p(S|T)$; LM + TM + 解码器;对位模型 + IBM 模型 1-5(基于词);短语/层次短语改进。
- NMT:Seq2Seq 编码器-解码器, $J = \sum \log p(e_i|C)$;训练用标准答案,测试用预测词;注意力(Bahdanau 2015)解决固定向量瓶颈, $c_i = \sum a_{ij} \mathbf{h}_j^s$;CNN(2017)、Transformer(2017) 自注意力并行。
- 评测:主观(流畅度/充分性/语义保持)+ 客观(BLEU $= \text{BP} \cdot \exp(\sum w_n \ln p_n)$, BP 惩罚短译, METEOR/COMET)。
- 语音翻译:ASR→MT→TTS 管道;交传/同传;口语短、不规范、有噪声、重副语言。
- 现状:"规则是傻子、统计是疯子";LLM 在高资源语言接近 Google,低资源语言落后。