

自然语言处理

宗成庆

中国科学院自动化研究所

cqzong@nlpr.ia.ac.cn

◆什么是语言？

- 语言是人类所特有的用来表达意思、交流思想的工具，是一种特殊的社会现象，由语音、词汇和语法构成一定的系统。

《现代汉语词典》，商务印书

- 语言可以被看成一个抽象的**数学系统**。

—吴蔚天，1994

◆什么是自然语言？


◆自然语言是可计算的吗？如何判断计算机是否“理解”了语言？……

第1章 绪论

- 
1. 基本概念
 2. 问题挑战
 3. 技术方法
 4. 课程内容
 5. 参考文献
 6. 习题

1. 基本概念

◆ 学科产生



世界上第一台计算机ENIAC
诞生。



Warren Weaver

- ✧ 信息论先驱
- ✧ 1920至1932年威斯康星大学数学教授
- ✧ 1932至1955年担任 Rockefeller Institute 自然科学部主任



A. D. Booth

- ✧ 数学物理学家
- ✧ 1947年3月至9月在普林斯顿大学参与 John von Neumann 研究组，后来曾在伦敦大学工作

1. 基本概念



诺伯特·维纳 (N. Wiener)
(1894-1964)

[Reproduced by permission of the Rockefeller Foundation Archives]

March 4, 1947

Dear Norbert:

I was terribly sorry, when in Cambridge recently, that I got unavoidably held up by several unexpected jobs, and did not get a chance to see you.

One thing I wanted to ask you about is this. A most serious problem, for UNESCO and for the constructive and peaceful future of the planet, is the problem of translation, as it unavoidably affects the communication between peoples. Huxley has recently told me that they are appalled by the magnitude and the importance of the translation job.

Recognizing fully, even though necessarily vaguely, the semantic difficulties because of multiple meanings, etc., I have wondered if it were unthinkable to design a computer which would translate. Even if it would translate only scientific material (where the semantic difficulties

I have wondered if it were unthinkable to design a computer which would translate.

article in Russian, I say "This is really written in English, but it has been coded in some strange symbols. I will now proceed to decode."

Have you ever thought about this? As a linguist and expert on computers, do you think it is worth thinking about?

Cordially,

Warren Weaver.

Professor Norbert Wiener
Massachusetts Institute of Technology
Cambridge 39, Massachusetts

WW:AEB

**July 1949:
“Translation” 备忘录**

1. 基本概念

- 自W. Weaver 和 A. D. Booth 提出机器翻译(machine translation, MT)概念后，美国和英国的学术界对机器翻译产生了浓厚的兴趣，并得到了实业界的支持。
- 1954年 Georgetown 大学在 IBM 协助下，用IBM-701计算机实现了世界上第一个 MT 系统，实现俄译英翻译，1954年1月该系统在纽约公开演示。系统只有250条俄语词汇，6 条语法规则，可以翻译简单的俄语句。
- 随后10 多年里，机器翻译研究在国际上出现热潮。
- 与此同时，人机接口、自动文摘、信息检索等以语言技术为核心的相关研究随之兴趣，学科萌芽逐渐产生。

1. 基本概念



达特茅斯学院(Dartmouth College, 1769)



摩尔、麦卡锡、明斯基、赛弗里奇、所罗门诺夫

人工智能夏季研讨会(Summer Research Project on **Artificial Intelligence (AI)**), 1956

自然语言理解(natural language understanding, NLU)成为人工智能研究的核心问题之一。

1. 基本概念

- 1962年国际计算语言学学会(Association for Computational Linguistics, ACL)成立
- 1965年国际计算语言学委员会(International Committee on Computational Linguistics, ICCL)成立
- 1964年, 美国科学院成立语言自动处理咨询委员会(Automatic Language Processing Advisory Committee, ALPAC), 调查机器翻译的研究情况, 并于1966年11月公布了一个题为“语言与机器”的调查报告, 简称 ALPAC 报告。计算语言学术语首次正式出现在官方发布的学术报告里。
- 1970 ~ 80S, 随着计算机网络的快速发展和普及, 以研发实用技术和系统为目标的语言工程应运而生, 自然语言处理(natural language processing, NLP)术语由此诞生。

“自然语言处理是人工智能皇冠上的明珠。”

1. 基本概念


◆ 术语解释

- **自然语言理解**是探索人类自身语言能力和语言思维活动的本质，研究模仿人类语言认知过程的自然语言处理方法和实现技术的一门学科。它是人工智能早期研究的领域之一，是一门在语言学、计算机科学、认知科学、信息论和数学等多学科基础上形成的交叉学科。（宗成庆，黄昌宁）
- **计算语言学**是通过建立形式化的计算模型来分析、理解和生成自然语言的学科，是人工智能和语言学的分支学科。计算语言学是典型的交叉学科，其研究常常涉及计算机科学、语言学、数学等多个学科的知识。与内容接近的学科自然语言处理相比较，计算语言学更加侧重基础理论和方法的研究。（常宝宝）
- **自然语言处理**是研究如何利用计算机技术对语言文本（句子、篇章或话语等）进行处理和加工的一门学科，研究内容包括对词法、句法、语义和语用等信息的识别、分类、提取、转换和生成等各种处理方法和实现技术。（宗成庆，黄昌宁）



《计算机科学技术百科全书》清华大学出版社，2018.5

1. 基本概念

上个世纪70/80年代，随着自然语言处理术语的出现，产生了主要以中文（尤指汉语）为处理对象的中文信息处理(Chinese information processing, CIP)技术。




1. 基本概念



- NLU: natural language understanding (1956s)
- CL: computational linguistics (1960s)
- NLP: natural language processing (1970~80s)
- HLT: human language technology (1980s)

1. 基本概念

◆ 研究内容(传统划分)



1. 基本概念

◆应用需求

- ❖ 全世界正在使用的语言有? 种
- ❖ 人类历史上以语言文字形式记载和流传的知识占知识总量的**80%**以上
- ❖ 任意时间、任意地点、任意语言的无障碍自由通讯是人类社会的梦想

已与**152个**国家、**32个**国际组织签署了合作文件，涉及**110多种**语言。(止2023年6月)

◆ HLT广泛应用

- 国家与公共安全
- 国民经济发展
- 社会生活服务
- 国际交流与合作



第1章 绪论

1. 基本概念

 2. 问题挑战

3. 技术方法

4. 课程内容

5. 参考文献

6. 习题

2. 问题挑战

◆ 语言中大量存在不确定性——歧义(ambiguity)

(1) 门把手弄坏了

门/ 把/ 手/ 弄/ 坏/ 了

门把手/ 弄/ 坏/ 了

门/ 把手/ 弄/ 坏/ 了

(2) 自动化研究所取得的成就

自动化/ 研究所/ 取得/ 的/ 成就

自动化/ 研究/ 所/ 取得/ 的/ 成就

(3) 喜欢乡下的孩子。

(4) I saw a boy in the park with a telescope.

(5) 夏天/冬天 能穿多少穿多少。



语言表达中大量地使用缩略语和隐喻，如：
把权力装进制度的**笼子**；**老虎苍蝇**一起打；
她厉害得像个**母老虎**；我们要像**石榴籽**一
样紧密团结在一起；**人大**立法机构等。

2. 问题挑战

◆大量存在未知的语言现象

- **新词、人名、地名、术语、网络用语等**,如: 奥特、给力、内卷; 非典、新冠肺炎; 夏天、高山、温馨、温泉、时光、平安、田野、边疆、程序、吉林、桂林, 不来梅 Bremen Tony Blair: 布莱尔
- **新含义**
如: 苹果、奔腾、老虎、后台
- **新用法和新句型等**, 尤其在口语中或部分网络语言中, 不断出现一些“非规范的”新的语句结构。如: 被长工资, 很中国, 百度一下 ……

2. 问题挑战

◆ 知识表示和获取的复杂性

知识（尤其常识）往往是模糊、隐蔽、密切相关地通过自然语言描述的。

◆ 不同语言之间存在概念差异

由于历史、文化、宗教和思维方式等差异导致语义概念不对等。

如何从大量复杂多样的不确定性中寻找确定性结论？

2. 问题挑战

◆关于“理解”的标准

- 如何判断计算机系统的智能？

计算机系统的表现(act)如何？


反应(react)如何？

相互作用(interact)如何？

与有意识的个体
(人) 比较如何？

图灵设计的“模仿游戏”



— 图灵实验(Turing test)



2. 问题挑战

◆人脑是如何学习、记忆和理解语言的？

- 语言学、心理学
- 认知科学、神经科学
- 计算机科学
- 统计学、信息论
- 背景知识、常识等
-







第1章 绪论

1. 基本概念
2. 问题挑战
- ➔ 3. 技术方法
4. 课程内容
5. 参考文献
6. 习题

3. 技术方法



3. 技术方法



3. 技术方法

◆ **理性主义**：通过对一些代表性语句或语言现象的研究得到对人的语言能力的认识，归纳语言使用的规律，以此分析、推断测试样本的预期结果。

● **基本思路**：基于规则的分析方法建立符号处理系统

➤ **设计规则**： $N + N \rightarrow NP$

➤ **标注词典**： #工作, N(uc); V;

➤ **推导算法**： 归约、推导、歧义消解方法...

知识库 + 推理系统 → NLP 系统

3. 技术方法

◆ **经验主义**：利用大规模真实语言数据，借助人的帮助(标注数据和筛选特征等)，统计发现语言使用的规律及其可能性(概率)大小，以此为依据计算预测测试样本的可能结果。统计单元是离散事件(词、短语、词性等)。

● **问题求解思路**：基于大规模真实数据建立统计学习模型

➤ **收集标注数据**：真实性、代表性、标注…

➤ **统计建型**：模型的复杂性、有效性、参数训练…

语言数据收集、标注 + 统计模型 → NLP 系统

3. 技术方法

- ◆ **连接主义**：利用超大规模真实语言数据，统计发现语言使用的规律及其可能性(概率)大小，以此为依据计算预测测试样本的可能结果。统计单元采用连续的实数空间表示(向量)，充分利用和精细刻画大范围上下文信息，建立统一的模型框架。
- **问题求解思路**：基于大规模真实数据建立深度学习模型
 - **收集标注数据**：真实性、代表性、少量标注…
 - **神经网络建型**：模型的复杂性、有效性、参数训练…

大数据 + 大模型 + 大算力 → NLP 系统

3. 技术方法


◆以机器翻译为例 ①基于规则的方法

给定源语言句子：桌子上有一本书。

(a)分词与词性标注：桌子/NN 上/PP 有/VV 一/Num 本/M 书/NN 。/Pun

(b)句法结构分析：

(c)结构转换：



双语对照词典：

#有：have/ there be/...

#一：one/ a

#书：book

.....

(d)译文生成：There is a book on the desk.

3. 技术方法

● 方法评价：

- 优点：可以较好地保持原文的结构，产生的译文结构与源文的结构关系密切，在源文语言现象已知、句法结构规范且词汇歧义不复杂的情况下，具有很好的处理能力，可以得到较好的译文，且分析、转换和生成的每一步都是可追踪、可溯源的。
- 弱点：需要人去编写规则，工作量大，主观性强，一致性难以保障，不利于系统扩充，非规范语言现象的处理能力差。对于很对语言来说，难以找到熟悉该语言的规则和词典编写人员。系统开发周期长，领域、语种等可移植性差。

3. 技术方法

② 统计翻译方法



源语言句子: $S = s_1^m \equiv s_1 s_2 \cdots s_m$

目标语言句子: $T = t_1^l \equiv t_1 t_2 \cdots t_l$

$$p(T | S) = \frac{p(T) \times p(S | T)}{p(S)}$$

$$\hat{T} = \arg \max_T p(T) \times p(S | T)$$

语言模型
(Language model)

翻译模型
(Translation model)

3. 技术方法

➤ 双语平行句对

merkezdiki d ölet apparatliri bilen jaylardiki d ölet apparatlrining xizmet hoquqi merkezning bir tutash rehberlikide jaylarning teshebbuskarliqi we aktipliqini toluq jari qildurush prinsipi boyiche ayrilidu.

中央和地方的国家机构职权的划分，遵循在中央的统一领导下，充分发挥地方的主动性、积极性的原则。

madda jungxua xelq jumhuriyitide hemme millet bapbarawer.

中华人民共和国各民族一律平等。

herqandaq milletni kemsitish we ëzishni men'i qilidu, milletler ittipaqliqini buzidighan we milliy b ölg ünichilik qilidighan qilmishlarni men'i qilidu.

禁止对任何民族的歧视和压迫，禁止破坏民族团结和制造民族分裂的行为。

.....

3. 技术方法

● 方法评价：

- 优点：一般不需要对源语言句子进行深层次的分析，甚至可以对源语言没有任何基本的知识，只要有足够多的高质量双语言句对就可以建立一个机器翻译系统。系统开发周期短。
- 弱点：对于很多语言对来说，难以收集到大规模高质量的双语句对。句法结构复杂的源语言长句的译文质量差，译文与原文的语义一致性无法保证。尤其当测试集与训练集(领域、风格等)差异较大，且出现生词时，译文质量大幅度降低。

3. 技术方法

③ 基于神经网络的翻译方法

给定源语言句子: $C = c_1^l \equiv c_1 c_2 \cdots c_l$

将其翻译成目标语言句子: $E = e_1^m \equiv e_1 e_2 \cdots e_m$

语言单位(token)采用连续的实数空间(向量)表示

$$\hat{e}_i = \arg \max_{e_i} p(e_i | e_1 \cdots e_{i-1}, C)$$

目标函数:
$$L = \sum_i \log(p(e_i | C))$$

基于 Transformer 的端到端的翻译框架

✧ 统一框架

✧ 不同语言、不同模
态信息、不同任务
几乎无差别处理

3. 技术方法

● 方法评价：

- 优点：不需要对源语言句子进行分析，甚至可以对源语言没有任何基本的知识，只需要大规模单语言训练样本、**双语对照词典**、**双语对照句对**（后两种资源甚至可以没有）和针对翻译任务的人工提示指令，就可以建立一个机器翻译系统，开发周期短。译文流畅性好，对缩略语和术语等都有很好的译文质量。
- 弱点：对于很多语言对来说，难以收集到大规模高质量语言数据（语料）、词典和翻译提示指令。存在流畅性好但语义错误、缺失或“无中生有”/“幻觉”等问题。

3. 技术方法



2022年11月29日, OpenAI 公司发布 ChatGPT (GPT-3.5), 允许用户以自然语言的形式提问任何问题, 系统都可以给出较好的回答。

- 2023年3月14日, GPT-4.0
- 2024年2月15日, Sora
- 2024年5月1日, GPT-4o (Omni)
- 2024年9月12日, o1-preview, o1-mini
- 2024年12月20日, o3, o3-mini; 2025年1月31日 o3-mini 正式上线
- 2025年3月25日, OpenAI 宣布GPT-4o 增加图像生成功能

- LLaMA, March 2023, Meta
LLaMA 4, April 2025
Vicuna
 - StableLM (April 2023, Stability AI)
 - Grok 4, July 10, 2025, xAI
 - OpenClaw, Jan. 2026
.....
- 豆包, 千问, 文心一言, 星火, ChatGLM, DeepSeek.....

3. 技术方法

● 数学问题求解能力

- o1系统在2024年的美国(针对高中生的)数学邀请赛(American Invitational Mathematics Examination, AIME)考试题上得分为83.3(满分100分);
- 在博士级别的科学问题上(GPQA Diamond), o1的正确率达到了78%, 超越人类博士69.7%;
- 在国际信息学奥林匹克竞赛(IOI)中在每题 50 次提交的条件下取得了前49%的成绩, 在每题10,000次提交的情况下, 超过了金牌门槛;
- 编码方面, o1在竞争性编程问题(Codeforces)上的得分是89%;
- 在2024年AIME数学竞赛题目测试中, o3的准确度得分为96.7, 超过o1等。


信息来源: <https://news.qq.com/rain/a/20240924A023CH00>
<https://baijiahao.baidu.com/s?id=1819027426169963008&wfr=spider&for=pc>

3. 技术方法


- 我国的大模型研究如火如荼



➤ 为什么 Deepseek 如此受关注？



3. 技术方法



To be or not to be,
this is a question.


第1章 绪论

1. 基本概念
2. 问题挑战
3. 技术方法
- ➡ 4. 课程内容
5. 参考文献
6. 习题

4. 课程内容

◆ 课堂讲授

- 基本概念
- 方法、模型和算法
- 应用系统



打牢理论基础，掌握分析问题、解决问题的基本思路 and 技巧。

◆ 课程实践

- 项目作业：方法实现 + 技术报告

◆ 课程成绩

- 开卷考试 (60%)
- 课程实践 (40%)

4. 课程内容

第1章 绪论 (2学时)

第2章 统计学习基础 (4学时)

第3章 N 元文法模型 (1学时)

第4章 传统NLP关键技术 (5学时)

第5章 神经网络与语言模型 (4学时)

第6章 文本表示 (2学时)

第7章 Transformer 架构与大语言模型 (6学时)

第8章 知识图谱与知识增强的大语言模型 (2学时)

第9章 文本分类与情感分析 (3学时)

第9章 机器翻译 (5学时)

课程总结 (2学时)

NLP基本概念
与传统方法

深度学习
与大语言模型

应用系统

期末考试(2学时)

共计
38
学时

Sir, why you are here ?



- 我今天为什么要坐在这里？
- 为什么我要选听这门课？

你想来吃蛋糕还是学做蛋糕？





第1章 绪论

1. 基本概念
2. 问题挑战
3. 技术方法
4. 课程内容
- ➡ 5. 参考文献
6. 习题



5. 参考文献

- [1] 宗成庆, 赵阳, 百度飞桨, 自然语言处理基础与大模型——案例与实践, 清华大学出版社, 2024.1
- [2] 赵鑫等, 大语言模型, 高等教育出版社, 2024.12
- [3] 张奇等, 大规模语言模型——从理论到实践, 电子工业出版社, 2024.1



5. 参考文献

- [4] 邱锡鹏, **神经网络与深度学习**, 机械工业出版社, 2020.4
- [5] 李航 著, **机器学习方法**(第2版), 清华大学出版社, 2025.7
- [6] 宗成庆, **统计自然语言处理**(第2版), 清华大学出版社, 2013.8



5. 参考文献

◆ 美国几所大学开设的NLP课程 (2024.8)

- Columbia University, Michael Collins
<http://www.cs.columbia.edu/~cs4705/>
- Carnegie Mellon University's Language Technology Institute
<https://phontron.com/class/anlp2024/>
- Massachusetts Institute of Technology
<https://www.mit.edu/~jda/teaching/6.864/>



5. 参考文献

● Stanford School of Engineering

➤ Natural Language Understanding

(CS224U: <https://online.stanford.edu/courses/cs224u-natural-language-understanding>)

What you will learn

- Lexical semantics
- Distributed representations of meaning
- Relation extraction
- Semantic parsing
- Sentiment analysis
- Dialogue agents

(为春季为高年级
本科生和低年级
研究生开设的)

➤ Natural Language Understanding

(XCS224U: <https://online.stanford.edu/courses/xcs224u-natural-language-understanding>)

What you will learn

- Distributed word representations
- Relation extraction with distant supervision
- Natural language inference
- Evaluation methods and metrics
- Contextual word representations (including updated coverage of BERT, RoBERTa, ELECTRA, and XLNet)
- Supervised sentiment analysis
- Grounded language understanding
- Semantic parsing

(为成人进修开设的)

Time Commitment

Expect to commit 8-12 hours/week for the duration of the 10-week program.



5. 参考文献

➤ Natural Language Processing with Deep Learning

(CS224N: <https://online.stanford.edu/courses/cs224n-natural-language-processing-deep-learning>)

(冬季)

What you will learn

- Computational properties of natural languages
- Co-reference, Q&A, and machine translation
- Processing linguistic information
- Syntactic and semantic processing
- Modern quantitative techniques in NLP
- Neural network models for language understanding tasks

➤ Natural Language Processing with Deep Learning

(XCS224N: <https://online.stanford.edu/courses/xcs224n-natural-language-processing-deep-learning>)

What you will learn

- Computational properties of natural languages
- Neural network models for language understanding tasks
- Word vectors, syntactic, and semantic processing
- Co-reference, question answering, and machine translation
- Transformers and pre-training

Time Commitment

- Expect to commit 10-14 hours/week for the duration of the 10-week program.

➤ Spoken Language Processing:

(CS224S: <https://web.stanford.edu/class/cs224s/>)

本章小结

- ◆ 基本概念： NLU, CL, NLP, HLT, CIP
- ◆ 学科的产生与发展： 1947, 1966, 1980s, 1990s, 2013, 2022
- ◆ 研究内容： 语音技术 - 文本 - 多模态 - 认知语言计算
- ◆ 问题与挑战： 从词法、句法、语义到语用无处不在的歧义
- ◆ 基本方法： 理性主义、经验主义和连接主义方法； 大语言模型
- ◆ 课程内容： 基本概念 - 基础理论和传统方法 - 神经网络与大语言模型 - 应用系统
- ◆ 参考文献： 专著； 美国部分大学的NLP课程网站



第1章 绪论

1. 基本概念
2. 问题挑战
3. 技术方法
4. 课程内容
5. 参考文献

 6. 习题

6. 习题

1. 请任意选取一批英文或中文句子，分析其词性兼类和一词多义情况。
2. 试对比分析汉语和英语句子结构之间的差异。
3. 试对比分析日常对话、网络聊天、网络新闻和规范书面文本（如《人民日报》等主流媒体）用词和句子结构之间的差异。
4. 请举例说明你在日常生活、学习和工作中使用的除了大(语言)模型以外与NLP技术相关的系统或工具。
5. 请测试三个不同的机器翻译系统，对比分析不同语言对之间、不同翻译系统译文的差异和存在的问题。
6. 测试不少于5个大(语言)模型，分析系统回复的差异和存在的问题。将题第5中使用的翻译测试句子用于大(语言)模型测试，将大模型的翻译结果与专门翻译系统得到的译文进行对比分析。

谢谢!
Thanks!

