

第2章 统计学习基础

宗成庆

中国科学院自动化研究所

cqzong@nlpr.ia.ac.cn



本章内容

- ➡ 1. 概率论略览
- 2. 齐夫定律
- 3. 信息论基础
- 4. 统计学习概念
- 5. 最大熵模型及应用
- 6. 条件随机场及应用
- 7. 习题
- 8. 附录



1. 概率论略览

- 概率 (probability)
- 最大似然估计 (maximum likelihood estimation)
- 条件概率 (conditional probability)
- 全概率公式 (full probability)
- 贝叶斯决策理论 (Bayesian decision theory)
- 贝叶斯法则 (Bayes' theorem)
- 二项式分布 (binomial distribution)
- 期望 (expectation)
- 方差 (variance)
- 随机过程 (stochastic process)

“语言是稳态的可遍历性随机过程”

1. 概率论略览

- 随机过程 (stochastic process)

假设 $\{\xi_t, t \in T\}$ 是一族随机变量, T 是一个实数集合, 如果对于任意实数 $t \in T$, ξ_t 是一个随机变量, 则称 $\{\xi_t, t \in T\}$ 为随机过程。

任意一个样本点 t , ξ_t 都对应一个实数, 而 ξ_t 是随着试验结果不同而变化的一个变量, 则称 ξ_t 为随机变量。

(有时将 ξ_t 写为: $\xi(t)$, 或者用大写 X 等表示。)

1. 概率论略览

随机过程的平稳性(stationary): 在数学中平稳过程又称严格平稳过程 或者 强平稳过程, 是一种特殊的随机过程, 在任一时间段($\Delta t = t_2 - t_1$)或空间里的联合概率分布, 与将这段时间任意平移后的新时间段里的联合概率分布相等, 即:

$$f_X(x_1, \dots, x_n, t_1 + \Delta t, \dots, t_n + \Delta t) = f_X(x_1, \dots, x_n, t_1, \dots, t_n)$$




1. 概率论略览

随机过程的遍历性(ergodic): 对于一个平稳的随机变量 X , 如果它的所有样本函数在某一固定时刻的统计特性和单一样本函数在长时间内的统计特性一致, 我们则称 X 为各态遍历, 即随机变量单一样本函数随时间变化的过程可以包括该变量所有样本函数的取值经历。



隐藏含义是: 如果一个随机变量是遍历性的, 那么该随机变量的时间统计特性等于其空间统计信息。





本章内容

1. 概率论略览
- ➔ 2. 齐夫定律
3. 信息论基础
4. 统计学习概念
5. 最大熵模型及应用
6. 条件随机场及应用
7. 习题
8. 附录

2. 齐夫定律

齐夫定律 (Zipf's law) 是1949年哈佛大学语言学家乔治·金斯利·齐夫 (George Kingsley Zipf) 发表的**实验定律**。

在自然语言的大规模文本数据上统计，一个单词出现的频率与它在频率表中的名次（序号）成反比。

例如，在100万单词的Brown语料库中，the出现的频率最高，出现了69971次，占比大约7%，名列第一。单词of 出现了36411次，占比约为3.5%，名列第二。and 出现了28852次，约占2.9%，名列第三。粗略的规律是：按词频顺序，第 r (r 为自然数)个词汇出现的频率为第1个词出现频率的 $1/r$ 倍。如英语中的 the, of, and 这三个词的词频和名次约为：6: 3: 2。

在Brown语料库中，前135个词在整个语料库中约占一半。

2. 齐夫定律

有人在2000万字（14829个词汇）的汉语语料库上进行了统计，频次最高的前10个字（单字词）为：

名次	字 (词)	频率	占比(%)	累计占比(%)
1	的	744863	7.7946	7.7946
2	了	130191	1.3624	9.1570
3	在	118823	1.2434	10.4004
4	是	118527	1.2403	11.6407
5	和	83958	0.8786	12.5193
6	一	81119	0.8489	13.3682
7	这	65146	0.6817	14.0499
8	有	53556	0.5604	14.6103
9	他	52912	0.5537	15.1640
10	我	52728	0.5518	15.7158


摘自网站：<https://zhuanlan.zhihu.com/p/44646312>

说明：具体结果取决于选取的统计语料类型和规模。

2. 齐夫定律

一般而言，假设词汇 w 出现的频率为 f ，在排序列表中处于 r 号位置上，那么， f 和 r 的乘积趋于一个常数，即 $f \times r = C$ ， C 为常数。


如果横轴表示 r 的对数值 $\log(r)$ ，纵轴表示 f 的对数值 $\log(f)$ ， $\log(r)$ 与 $\log(f)$ 的取值关系近似为一条直线，如下图中的蓝线。



2. 齐夫定律

从统计结果看，少数高频词占了整个语料规模的大部分比例，而大部分词汇属于低频词。这种现象通常被称为长尾效应(long tail effect)，相应的词汇称为长尾词(long tail word)。

在自然语言处理中，考虑到计算量、存储量和运算效率等因素，通常只考虑出现词频高于某个阈值的词，而将低于该阈值的长尾词当作生词(unknown word)处理。





本章内容

1. 概率论略览
2. 齐夫定律
- ➡ 3. 信息论基础
4. 统计学习概念
5. 最大熵模型及应用
6. 条件随机场及应用
7. 习题
8. 附录

3. 信息论基础

◆ 基本概念

- 熵 (entropy)
- 联合熵 (joint entropy)
- 条件熵 (conditional entropy)
- 相对熵 (relative entropy, or Kullback-Leibler divergence)
- 交叉熵 (cross entropy)
- 困惑度 (perplexity)
- 互信息 (mutual information)

3. 信息论基础

◆熵(entropy; entropie)

熵最初是由德国物理学家鲁道夫·克劳修斯(Rudolf Julius Emanuel Clausius)在1865年发表的《论热的力学理论中的主方程之几种适于应用的不同形式中提出来的，是一个热力学函数，用于描述热量与温度之间关系的函数。

1923年5月25日，鲁道夫·普朗克(Rudolf Aloys Valerian Plank, 1886-1973)来华讲学，胡刚复教授为其翻译时根据这一概念的物理意义 ($ds=dQ/T$ ，认为为热量与温度之商) 造了“熵”这个汉字。

- <https://baike.baidu.com/item/熵/19190273>
- <https://baike.baidu.com/item/胡刚复/4653699>

胡刚复(1892.3.24 ~ 1966.2.19),
江苏无锡人，物理学家、教育家，
中国近代物理学事业奠基人之一。



(1822.1.2 ~ 1888.8.24)




3. 信息论基础

◆ 信息熵

克劳德·艾尔伍德·香农 (Claude Elwood Shannon) 于1940年获得MIT数学博士学位和电子工程硕士学位后，1941年加入贝尔实验室数学部，工作到1972年。1956年他成为MIT客座教授，并于1958年成为终生教授，1978年成为名誉教授。

1948年6月和10月由贝尔实验室出版的《贝尔系统技术》杂志连载了香农博士的文章《通讯的数学原理》，该文奠定了香农信息论的基础。

熵是信息论中重要的基本概念。



克劳德·艾尔伍德·香农
(1916.4.30~2001.2.24)

3. 信息论基础

如果 X 是一个离散型随机变量，其概率分布为：

$p(x) = P(X = x)$, $x \in X$ 。 X 的熵 $H(X)$ 为：

$$H(X) = - \sum_{x \in X} p(x) \log_2 p(x) \quad \dots(1)$$

其中，约定 $0 \log 0 = 0$ 。

$H(X)$ 也可以写为 $H(p)$ 。通常熵的单位为二进制位比特 (bit)。

熵表示随机变量 X 每个具体取值(如信源每发射一个信号)所提供的平均信息量。熵也可以被视为描述一个随机变量的不确定性的数量。一个随机变量的熵越大，它的不确定性越大。那么，正确估计其值的可能性就越小。越不确定的随机变量越需要大的信息量用以确定其值。

3. 信息论基础

例2-1: 计算下列两种情况下英文(26个字母和1个空格, 共27个字符)信息源的熵:
(1)假设27个字符等概率出现; (2)假设英文字母的概率分布如下:

字母	空格	E	T	O	A	N	I	R	S
概率	0.1956	0.105	0.072	0.0654	0.063	0.059	0.055	0.054	0.052

字母	H	D	L	C	F	U	M	P	Y
概率	0.047	0.035	0.029	0.023	0.0225	0.0225	0.021	0.0175	0.012

字母	W	G	B	V	K	X	J	Q	Z
概率	0.012	0.011	0.0105	0.008	0.003	0.002	0.001	0.001	0.001

3. 信息论基础

解：(1) 等概率出现情况：

$$\begin{aligned} H(X) &= - \sum_{x \in X} p(x) \log_2 p(x) \\ &= 27 \times \left\{ -\frac{1}{27} \log_2 \frac{1}{27} \right\} = \log_2 27 = 4.75 \quad (\text{bits/letter}) \end{aligned}$$

(2) 按表中概率计算：

$$H(X) = - \sum_{i=1}^{27} p(x_i) \log_2 p(x_i) = 4.02 \quad (\text{bits/letter})$$

说明：考虑了英文字母和空格实际出现的概率后，英文信源的平均不确定性，比把字母和空格看作等概率出现时英文信源的平均不确定性要小。

3. 信息论基础

法语、意大利语、西班牙语、英语、俄语字母及汉字的熵：

语言	熵 (bits)
法语	3.98
意大利语	4.00
西班牙语	4.01
英语	4.03 (英语单词的熵约为10。)
俄语	4.35
汉字	9.71 (汉语词的熵约为11.46。)

[冯志伟, 1989]

说明：西文字母的熵与汉语字的熵之间没有对比意义。

3. 信息论基础

北京、香港、台北三地汉语词的熵[Tsou,2003]

北京5年		台北5年		香港5年		京、港、台5年	
A1	A2	B1	B2	C1	C2	D1	D2
11.45	11.11	11.69	11.36	11.96	11.64	11.96	11.60

其中，A1, B1, C1 分别是从小港城市大学建立的语料库(LIVAC)中北京、台北、香港三地5年各约1000万字文本中所提取的数据；A2, B2, C2 为三地文本剔除专用名词之后的数据。D1, D2分别为三地文本合并之后剔除专用名词前后的数据。

专用名词又称命名实体(named entity)，主要指：人名、地名、组织机构名、时间、数字及货币等。



3. 信息论基础

◆联合熵(joint entropy)

如果 X, Y 是一对离散型随机变量 $X, Y \sim p(x, y)$, X, Y 的联合熵 $H(X, Y)$ 为:

$$H(X, Y) = - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 p(x, y) \quad \dots(2)$$

联合熵实际上就是描述一对随机变量平均所需要的信息量。

3. 信息论基础

◆ 条件熵(conditional entropy)

给定随机变量 X 的情况下，随机变量 Y 的条件熵定义为：

$$\begin{aligned} H(Y | X) &= \sum_{x \in X} p(x) H(Y | X = x) \\ &= \sum_{x \in X} p(x) \left[- \sum_{y \in Y} p(y | x) \log_2 p(y | x) \right] \\ &= - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 p(y | x) \end{aligned} \quad \dots(3)$$

$$p(x) \cdot p(y | x) = p(x, y)$$

3. 信息论基础

将 (2) 式: $H(X, Y) = - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 p(x, y)$ 中的 $\log_2 p(x, y)$ 根据概率公式展开:

$$H(X, Y) = - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log[p(x) p(y | x)]$$

$$= - \sum_{x \in X} \sum_{y \in Y} p(x, y) [\log p(x) + \log p(y | x)]$$

$$= - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log p(x) - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log p(y | x)$$

$$= - \sum_{x \in X} p(x) \log p(x) - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log p(y | x)$$

$$= H(X) + H(Y | X) \quad \dots(4) \text{ (连锁规则)}$$

3. 信息论基础

例2-2: 假设 (X, Y) 服从如下联合概率分布:

$Y \backslash X$	1	2	3	4
1	1/8	1/16	1/32	1/32
2	1/16	1/8	1/32	1/32
3	1/16	1/16	1/16	1/16
4	1/4	0	0	0

请计算 $H(X)$ 、 $H(Y)$ 、 $H(X|Y)$ 、 $H(Y|X)$ 和 $H(X, Y)$ 各是多少?

3. 信息论基础

例2-2: 假设 (X, Y) 服从如下联合概率分布:

$Y \backslash X$	1	2	3	4
1	1/8	1/16	1/32	1/32
2	1/16	1/8	1/32	1/32
3	1/16	1/16	1/16	1/16
4	1/4	0	0	0
$p(X, \bullet)$	1/2	1/4	1/8	1/8

$$\begin{aligned}
 H(X) &= - \sum_{x \in X} p(x) \log_2 p(x) \\
 &= - \left(\frac{1}{2} \times \log_2 \left(\frac{1}{2} \right) + \frac{1}{4} \times \log_2 \left(\frac{1}{4} \right) + \frac{1}{8} \times \log_2 \left(\frac{1}{8} \right) + \frac{1}{8} \times \log_2 \left(\frac{1}{8} \right) \right) \\
 &= \frac{7}{4}
 \end{aligned}$$

3. 信息论基础

类似地，可以计算 $H(Y)$ 。

$Y \backslash X$	1	2	3	4	$p(\bullet, Y)$
1	1/8	1/16	1/32	1/32	1/4
2	1/16	1/8	1/32	1/32	1/4
3	1/16	1/16	1/16	1/16	1/4
4	1/4	0	0	0	1/4

$$H(Y) = -\sum_{y \in Y} p(y) \log_2 p(y) = 2 \text{ (bits)}$$

3. 信息论基础

$Y \backslash X$	1	2	3	4	$p(\bullet, Y)$
1	1/8	1/16	1/32	1/32	1/4
2	1/16	1/8	1/32	1/32	1/4
3	1/16	1/16	1/16	1/16	1/4
4	1/4	0	0	0	1/4
$p(X, \bullet)$	1/2	1/4	1/8	1/8	

$$p(x_1 | y_1) = \frac{p(x_1, y_1)}{p(y_1)} = \frac{1}{8} \times \frac{4}{1} = \frac{1}{2}$$

$$p(x_2 | y_1) = \frac{p(x_2, y_1)}{p(y_1)} = \frac{1}{16} \times \frac{4}{1} = \frac{1}{4}$$

$$p(x_3 | y_1) = \frac{p(x_3, y_1)}{p(y_1)} = \frac{1}{32} \times \frac{4}{1} = \frac{1}{8}$$

$$p(x_4 | y_1) = \frac{p(x_4, y_1)}{p(y_1)} = \frac{1}{32} \times \frac{4}{1} = \frac{1}{8}$$

.....

3. 信息论基础

$$\begin{aligned}
 H(X | Y) &= \sum_{i=1}^4 p(y=i) H(X | Y=i) \\
 &= \frac{1}{4} H\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\right) + \frac{1}{4} H\left(\frac{1}{4}, \frac{1}{2}, \frac{1}{8}, \frac{1}{8}\right) \\
 &\quad + \frac{1}{4} H\left(\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4}\right) + \frac{1}{4} H(1, 0, 0, 0) \\
 &= \frac{1}{4} \times \frac{7}{4} + \frac{1}{4} \times \frac{7}{4} + \frac{1}{4} \times 2 + \frac{1}{4} \times 0 = \frac{11}{8} \quad (\text{bits})
 \end{aligned}$$

$$- \sum_{i=1}^4 p(x_i | y_1) \log p(x_i | y_1)$$

$$- \sum_{i=1}^4 p(x_i | y_2) \log p(x_i | y_2)$$

类似地, $H(Y|X)=13/8$ (bits), $H(X, Y)=\underbrace{H(X)}_{7/4}+H(Y|X)=27/8$ (bits) 。

$H(Y|X) \neq H(X|Y)$? **No!**

3. 信息论基础

- ◆ 相对熵(relative entropy, 或称 Kullback-Leibler divergence, K-L 距离, 或K-L散度)
两个概率分布 $p(x)$ 和 $q(x)$ 的相对熵定义为:

$$D(p \parallel q) = \sum_{x \in X} p(x) \log \frac{p(x)}{q(x)} \quad \dots(5)$$

该定义中约定 $0 \log (0/q) = 0$, $p \log (p/0) = \infty$ 。

3. 信息论基础

相对熵常被用以衡量两个随机分布的差距。当两个随机分布相同时，其相对熵为0。两个随机分布的差别增加时，其相对熵也增加。

$$D(p \parallel q) = \sum_{x \in X} p(x) \log \frac{p(x)}{q(x)}$$





图2-1. 相对熵示意图

3. 信息论基础

◆交叉熵(cross entropy)

如果一个随机变量 $X \sim p(x)$, 理论模型 $q(x)$ 为用于近似 $p(x)$ 的概率分布, 那么, 统计分布 p 和模型 q 之间的交叉熵定义为:

$$\begin{aligned} H(X, q) &= H(X) + D(p \parallel q) \\ &= -\sum_{x \in X} p(x) \log p(x) + \sum_{x \in X} p(x) \log \frac{p(x)}{q(x)} \\ &= -\sum_{x \in X} p(x) \log q(x) \quad \dots(6) \end{aligned}$$

交叉熵衡量的也是两个模型分布之间的差异。

3. 信息论基础

对于语言 $L = (X) \sim p(x)$ 与其理论模型 q 的交叉熵定义为:

$$H(L, q) = -\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{x_1^n} p(x_1^n) \log q(x_1^n) \quad \dots(7)$$

其中, $x_1^n = x_1 \dots x_n$ 为语言 L 的词序列 (已知样本) ;

$p(x_1^n)$ 为 x_1^n 的概率 (在已知样本上的统计分布) ;

$q(x_1^n)$ 为模型 q 对 x_1^n 的概率估计值 (理论模型) 。

3. 信息论基础

定理：假定语言 L 是稳态(stationary)的可遍历性(ergodic)随机过程, x_1^n 为 L 的样本, 那么, 有:

$$H(L, q) = -\lim_{n \rightarrow \infty} \frac{1}{n} \log q(x_1^n) \quad \dots(8)$$

证明见本章讲义**附录1**。

由此, 我们可以根据模型 q 和一个含有大量数据的 L 的样本来计算交叉熵。在设计模型 q 时, 我们的目的是使交叉熵最小, 从而使模型最接近真实的概率分布 $p(x)$ 。



3. 信息论基础

问题： 相对熵和交叉熵的作用有什么区别呢？

3. 信息论基础

◆ 困惑度(perplexity)

在设计语言模型时，我们通常用困惑度来代替交叉熵衡量语言模型的好坏。给定语言 L 的样本 $x_1^n = x_1 \dots x_n$ ， L 的困惑度 PP_q 定义为：

$$PP_q = 2^{H(L,q)} \approx 2^{-\frac{1}{n} \log q(x_1^n)} = [q(x_1^n)]^{-\frac{1}{n}} \quad \dots(9)$$

语言模型设计的任务就是寻找困惑度最小的模型，使其最接近真实的语言分布。

3. 信息论基础

◆ 互信息(mutual information)

如果 $(X, Y) \sim p(x, y)$, X, Y 之间的互信息 $I(X; Y)$ 定义为:

$$I(X; Y) = H(X) - H(X | Y) \quad \dots(10)$$

根据 $H(X)$ 和 $H(X|Y)$ 的定义:

$$H(X) = - \sum_{x \in X} p(x) \log_2 p(x)$$

$$H(X | Y) = - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 p(x | y)$$

3. 信息论基础

$$\begin{aligned} I(X; Y) &= H(X) - H(X | Y) \\ &= -\sum_{x \in X} p(x) \log_2 p(x) + \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 p(x | y) \\ &= \sum_{x \in X} \sum_{y \in Y} p(x, y) (\log_2 p(x | y) - \log_2 p(x)) \\ &= \sum_{x \in X} \sum_{y \in Y} p(x, y) \left(\log_2 \frac{p(x | y)}{p(x)} \right) \\ I(X; Y) &= \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 \frac{p(x, y)}{p(x) p(y)} \quad \dots(11) \end{aligned}$$

互信息 $I(X; Y)$ 是在知道了 Y 的值以后 X 的不确定性的减少量，即 Y 的值透露了多少关于 X 的信息量。

3. 信息论基础




图 2-2. 互信息、条件熵与联合熵

3. 信息论基础

由于 $H(X|X) = 0$, 所以,

$$H(X) = H(X) - H(X|X) = I(X; X) \quad \dots(12)$$

这就是为什么熵又称为自信息(self-information)。这也意味着两个完全相互依赖的变量之间的互信息并不是一个常量，而是取决于它们的熵。

3. 信息论基础

例如：汉语分词问题

为 人 民 服 务。

利用互信息值估计两个汉字结合的程度：

$$I(x; y) = \log_2 \frac{p(x, y)}{p(x)p(y)} = \log_2 \frac{p(y|x)}{p(y)}$$

理论上，互信息值越大，表示两个汉字之间的结合越紧密，越可能成词。反之，断开的可能性越大。当两个汉字 x 和 y 关联度较强时，其互信息值 $I(x, y) > 0$ ； x 与 y 关系弱时， $I(x, y) \approx 0$ ；而当 $I(x, y) < 0$ 时， x 与 y 称为“互补分布”。



3. 信息论基础

说明: 两个单个离散事件 (x_i, y_j) 之间的互信息 $I(x_i, y_j)$ 通常称为点式互信息(point-wise mutual information), 点式互信息可能为负值。两个随机变量 (X, Y) 之间的互信息 $I(X, Y)$ 称为平均互信息, **平均互信息不可能为负值**。

关于两个随机变量之间平均互信息为非负值的证明见本课件**附录2**。

3. 信息论基础

在汉语分词研究的实践证明中，用互信息作为衡量两个汉字之间是否作为切分边界点的判别依据，效果并不好。

例如：**教务**以连续字符串形式在统计样本中共出现了16次，而**教**字出现了14945次，**务**字出现了6015次。**教**和**务**之间的互信息只有**-0.5119**。如果用互信息来判断的话，这两个字应该被切开。但实际上，**教**和**务**这两个字在文本集中出现的16次全部都是**教务**、**教务长**、**教务处**等词汇。也就是说，这两个字一旦连续同现，一定成词。因此，用两个邻近字在训练样本中构成词的比率作为切分依据比互信息效果更好。



本章内容

1. 概率论略览
2. 齐夫定律
3. 信息论基础
- ➡ 4. 统计学习概念
5. 最大熵模型及应用
6. 条件随机场及应用
7. 习题
8. 附录

4. 统计学习概念

◆ 统计学习方法 (1980s~)

- ✧ 语音识别, 如 SPHINX 语音识别系统(CMU)
- ✧ 训练控制系统用于驾驶车辆, 如 ALVINN 系统
- ✧ 在各种大规模数据库中发现隐藏的一般规律, 如美国国家航空和航天局(NASA)使用决策树进行天体分类
- ✧ 世界级水平的西洋双陆棋博弈
- **学习过程:** 通过经验提高模型的性能
- **理论基础:** 统计学、信息论、计算复杂性理论、人工智能、神经生物学

4. 统计学习概念

◆ 统计学习方法

- ✧ 数据驱动
- ✧ 对数据进行预测与分析
- ✧ 以方法为中心，构建模型

◆ 统计学习类型

- 监督学习(supervised learning)
- 非监督学习(unsupervised learning)
- 半监督学习(semi-supervised learning)
- 强化学习(reinforcement learning)

4. 统计学习概念

● 监督学习(supervised learning)

- 给定有限的、人工标注好的大量数据，假设这些数据是独立同分布产生的(训练集, training data)
- 假设要学习的模型属于某个函数的集合，即假设空间(hypothesis space)
- 应用某（些）个评价准则(evaluation criterion)，从假设空间中选取最优的模型，使其对已知的训练数据和未知的测试数据(test data)在给定的评价准则下有最优的预测


4. 统计学习概念

一般步骤:

- ① 获得一个有限的训练数据集
- ② 确定包含所有可能的模型的假设空间，即学习模型的集合
- ③ 确定模型选择的准则，即学习的策略
- ④ 通过学习方法选择最优模型
- ⑤ 利用学习到的最优模型对新数据进行预测或分析

4. 统计学习概念

问题的形式化:



给定一个训练数据集: $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中, $(x_i, y_i), i=1, 2, \dots, N$, 称为样本。 x_i 是输入的观测值, 也称输入或实例; y_i 是输出的观测值, 也称输出。



4. 统计学习概念

◆ 模型的类别

- 生成式方法(generative model)
- 区分式方法/判别式方法(discriminative model)

4. 统计学习概念

● 生成式方法 (generative model)

假设 O 是观察值， Q 是模型。生成式模型首先在训练数据集上建立概率模型 Q ，然后，利用模型 Q 对输入实例进行预测，即通过概率 $P(O'|Q)$ 进行预测。它建立在统计学和Bayes理论的基础之上，要求标注的训练样本无穷多或者足够多。

代表性模型：

- n 元文法模型(n -gram)
- 隐马尔可夫模型(Hidden Markov Model, HMM)



4. 统计学习概念

● 区分式/判别式方法 (Discriminative Model)


假设 O 是观察值, Q 是模型, 区分式方法对 $P(Q|O)$ 进行建模。其基本思路是: 在有限样本条件下建立判别函数, 不考虑样本的产生模型, 直接研究预测模型, 寻找不同类别之间的最优分类面, 反映的是不同类别数据之间的差异性。

代表性模型:

➤ 各种分类器



4. 统计学习概念





4. 统计学习概念

◆ 相关概念

- 语料(corpus)/ 语料库(corpus base): 语言资源 (数据集)
- 训练集(training data/set): 用于模型参数训练
- 开发集(development data/set): 用于模拟测试, 优化参数
- 测试集(test data/set): 测试模型或模型实际处理的数据
- 过拟合(overfitting): 模型只在训练集上性能优良
- 欠拟合(under-fitting): 模型在训练集上性能远未达到最优
- 鲁棒性(robustness): 测试集的差异对模型性能影响不大

4. 统计学习概念

◆常用的统计模型

- 生成式模型

- 语言模型 (language model)
- 隐马尔可夫模型(hidden Markov model, HMM)

- 区分式模型

- 朴素贝叶斯法(naïve Bayes): 多类分类问题
- 最大熵(maximum entropy): 多类分类问题
- 条件随机场(conditional random field, CRF): 序列标注
- k -近邻法(k -nearest neighbor, k -NN): 多类分类问题
- 决策树(decision tree): 多类分类问题
- 感知机(perceptron): 二类分类
- 支持向量机(support vector machine, SVM): 二类分类



本章内容

1. 概率论略览
2. 齐夫定律
3. 信息论基础
4. 统计学习概念
- ➔ 5. 最大熵模型及应用
6. 条件随机场及应用
7. 习题
8. 附录



5. 最大熵模型及应用

例2-3: 词汇歧义消解

●问题提出

任何一种语言中，一词多义（歧义）现象是普遍存在的。如何区分不同上下文中的词汇语义，就是词汇歧义消解问题，或称词义消歧(word sense disambiguation, WSD)。

词义消歧是自然语言处理中的基本问题之一。

5. 最大熵模型及应用

以“打”字为例：

- | | |
|-------------------|-----------------|
| (1) 他会打鼓。 | (13) 给他打个电话吧。 |
| (2) 他把碗打破了。 | (14) 他把款打过去了。 |
| (3) 他在学校打架了。 | (15) 你别打权。 |
| (4) 他想打官司。 | (16) 你打两瓶水去。 |
| (5) 他用土打了一堵墙。 | (17) 他想打车票回家。 |
| (6) 他会用木头打家具。 | (18) 他以打鱼为生。 |
| (7) 她用面打浆糊贴对联。 | (19) 他放学后去打猪草了。 |
| (8) 他打铺盖卷儿走人了。 | (20) 你打个草稿再写。 |
| (9) 她会用毛线打毛衣。 | (21) 八路军会打游击。 |
| (10) 他用尺子在纸上打了格子。 | (22) 我们一起打扑克吧。 |
| (11) 他打开了井盖子。 | (23) 他给她打了个手势。 |
| (12) 这种人打着灯笼也难找。 | (24) 你别打官腔/马虎眼。 |

5. 最大熵模型及应用

● 解决思路

每个词表达不同的含意时其上下文（语境）往往不同，也就是说，不同的词义对应不同的上下文，因此，如果能够将多义词的上下文区别开，其词义自然就明确了。**词义消歧变成一个上下文分类任务。**

他/P 打/V 鼓/N 很/D 在行/A 。/PU
-1 ↑ +1 +2
 0

基本的上下文信息：词、词性、位置。

5. 最大熵模型及应用


●最大熵分类器

➤基本原理:

在只掌握关于未知分布的部分知识的情况下，符合已知知识的概率分布可能有多多个，使熵值最大的概率分布能够最真实地反映事件的分布情况，由于熵定义了随机变量的不确定性，当熵最大时，随机变量最不确定。也就是说，在已知部分知识的前提下，关于未知分布最合理的推断应该是符合已知知识最不确定或最大随机的推断。

5. 最大熵模型及应用

假设变量 x 有两种可能的取值: a 和 b , 那么, $p(a)+p(b)=1$, 将 $p(a)$ 简记为 p , p 的取值与其熵 $H(p)$ 的关系如下图所示:



在没有先验知识的情况下, 均匀分布时熵最大, 反映的理念是对所有可能发生的情况一视同仁, 赋予同等的概率, 这是最公平、最合理的处理策略。

5. 最大熵模型及应用

如果已知样本向我们提供了关于该随机变量一些取值的概率分布，例如： $p(a') + p(b') = \alpha$ ，那么，我们在拥有这个先验知识的前提下，应该如何处理 $p(a)$ 和 $p(b)$ 的概率分布呢？

$$\begin{cases} p(a') + p(b') = \alpha \\ p(a') + p(b') + p(a) + p(b) = 1 \end{cases}$$

让熵最大是对未知分布推断最合理的准则。换句话说，推断未知分布合理的做法是将已知的先验知识作为约束，让未知分布的熵最大。

5. 最大熵模型及应用

➤ 模型定义

已知训练数据集 $T=\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, x_i 表示输入条件, y_i 表示预测值。
训练集中每一种情况的概率 $\tilde{p}(x, y)$ 可以通过简单的统计计算出来:

$$\tilde{p}(x, y) \equiv \frac{\text{样本中含有}(x, y)\text{的数量}}{N}$$

对于训练集 T 中的所有样本可通过特征函数(feature function)描述 $x \in X$ 和 $y \in Y$ 之间基于某种条件的关系:

$$f(x, y) = \begin{cases} 1, & \text{当} x \text{和} y \text{之间满足某种条件时} \\ 0, & \text{否则} \end{cases}$$

$f(\cdot)$ 实际上是克罗内克(Kronecker)函数。

5. 最大熵模型及应用

那么, $f(x, y)$ 在训练集上关于经验分布 $\tilde{p}(x, y)$ 的期望值可通过下面的式子计算出来:

$$E_{\tilde{p}}(f) = \sum_{x, y} \tilde{p}(x, y) f(x, y) \quad \dots(13)$$

而理论值为:

$$E_p(f) = \sum_{x, y} \underline{p(x, y)} f(x, y) \quad \dots(14)$$

由于 $p(x, y) = p(x)p(y|x)$, 而且所建立的理论模型应该符合训练集中的概率分布 (近似相等), 即 $p(x) = \tilde{p}(x)$, 因此, 理论期望值计算公式(14)式可以写为:

$$E_p(f) = \sum_{x, y} \tilde{p}(x) p(y|x) f(x, y) \quad \dots(15)$$

5. 最大熵模型及应用

约束: $E_p(f) = E_{\tilde{p}}(f)$, 或者

$$\sum_{x,y} \tilde{p}(x) \cdot p(y|x) \cdot f(x,y) = \sum_{x,y} \tilde{p}(x,y) f(x,y) \quad \dots(16)$$

假设训练集中有 $n \in N$ 个特征函数 $f_j(x,y)$, 它们在建模过程中都对输出结果有影响, 即有 n 个约束条件, 而理论上能够满足这些约束的模型有很多, 它们构成一个集合:

$$P = \{p \mid E_p(f_j) = E_{\tilde{p}}(f_j), j \in \{1, 2, \dots, n\}\}$$

5. 最大熵模型及应用

在所有满足约束的模型中，使条件熵最大的模型就是最大熵模型，也就是我们要寻找的是最合理的模型。最大熵模型的学习等价于求解条件约束的优化问题：

$$\begin{aligned} p^*(y|x) &= \arg \max_{p \in P} H(p) \\ &= \arg \max_{p \in P} \left\{ - \sum_{x,y} \tilde{p}(x) p(y|x) \log p(y|x) \right\} \quad \dots(17) \\ \text{s. t. } E_p(f_j) &= E_{\tilde{p}}(f_j), \quad j = 1, 2, \dots, n \\ \sum_y p(y|x) &= 1 \end{aligned}$$

5. 最大熵模型及应用

经推导(见本章[附录3](#)), 有:

$$p^*(y | x) = \frac{1}{Z(x)} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right) \quad \dots(18)$$

$$\text{其中, } Z(x) = \sum_y \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right) \quad \dots(19)$$

$Z(x)$ 为归一化常量, 确保对于所有的 x 使 $\sum_y p(y | x) = 1$ 。

$\exp(\bullet) = e^\bullet$, $e = 2.71828$

5. 最大熵模型及应用

➤ 确定特征函数

对于词义消歧问题,设 X 为上下文条件, Y 为某个多义词所有义项的集合。可定义 $\{0, 1\}$ 域上的二值函数 $f(x,y)$ 表示上下文条件与义项之间的关系:

$$f(x,y) = \begin{cases} 1 & \text{若}(x,y) \in (X,Y), \text{ 且满足某种条件} \\ 0 & \text{否则} \end{cases}$$

例如: “打” 字的动词义项集合: $Y = \{s_1, s_2, s_3, \dots, s_{24}\}$, $X = \{\text{“打”字出现的上下文}\}$ 。



5. 最大熵模型及应用

上下文条件(X)表示有:

(1) 词形信息:

他很会与人打交道。

(2) 词性信息:

他/PN 很/D 会/V 与/C 人/N 打 交道/N。/Pu

 ↑

(3) 词形 + 词性信息:

他/PN 很/D 会/V 与/C 人/N 打 交道/N。 /Pu

5. 最大熵模型及应用

上下文有两种表示方法：

①位置无关：目标词周围的词形、词性或其组合构成的集合，如取 ± 2 窗口范围内的词形：

{与，人，交道，。}
= {交道，与，。，人}

词袋模型
(通常用向量表示)



他/PN 很/D 会/V 与/C 人/N 打 交道/N 。/Pu

②位置有关：词形(± 2): $\langle \text{与}_{-2}, \text{人}_{-1}, \text{交道}_{+1}, \text{。}_{+2} \rangle$

模板表示

$\neq \langle \text{与}_{-2}, \text{。}_{+2}, \text{交道}_{+1}, \text{人}_{-1} \rangle$

5. 最大熵模型及应用

他/P 很/D 会/V 与/C 人/N 打/V s_3 交道/N 。/Pu
↑

假设以词形和词性等表示条件，可以构造特征函数：

$$f_1(x, y) = \begin{cases} 1 & \text{If } x = \{\text{与, 人, 交道, 。}\} \text{ and } y = s_3 \\ 0 & \text{Otherwise} \end{cases}$$

$$f_2(x, y) = \begin{cases} 1 & \text{If } x = \{C, N, N, Pu\} \text{ and } y = s_3 \\ 0 & \text{Otherwise} \end{cases}$$

...



5. 最大熵模型及应用

他/P 很/D 会/V 与/C 人/N 打/ V_{s_3} 交道/N 。/Pu

跟/C 美国/N 政府/N 打/ V_{s_3} 交道/N 他/P 最/D 有/V 经验/N 。/Pu

杯子/N 今天/N 被/J 他/P 打/ V_{s_2} 破/A 了/Aux 。/Pu

她/P 打/ V_{s_1} 起/X 腰鼓/N 来/Aux 真/D 好看/A 。/Pu

打/ V_{s_1} 锣/N 敲/V 鼓/N 是/V 他/P 的/Aux 强项/N 。/Pu

..... (假设已有大规模标注样本)

不考虑上下文时,
 $p(s_3|\text{打}) = ?$

(打, s_3) 一共出现了多少次? 2

“打”字总共出现了多少次? 5

$$p(s_3|\text{打}) = \frac{2}{5} = 0.4$$



5. 最大熵模型及应用

他/P 很/D 会/V 与/C 人/N 打/ V_{s_3} 交道/N 。/Pu

跟/C 美国/N 政府/N 打/ V_{s_3} 交道/N 他/P 最/D 有/V 经验/N 。/Pu

杯子/N 今天/N 被/J 他/P 打/ V_{s_2} 破/A 了/Aux 。/Pu

她/P 打/ V_{s_1} 起/X 腰鼓/N 来/Aux 真/D 好看/A 。/Pu

打/ V_{s_1} 锣/N 敲/V 鼓/N 是/V 他/P 的/Aux 强项/N 。/Pu

..... (假设已有大规模标注样本)

取 ± 2 个词为语境窗口，词形、词性为特征，“与”关系，那么，

$f(\text{打}, s_3)=1$ (左1词“人”，右1词“交道”);

$f(\text{打}, s_3)=1$ (左1词性“N”，右1词性“N”);

$f(\text{打}, s_3)=1$ (左2词“美国/ 政府”，右2词“交道/ 他”);

$f(\text{打}, s_3)=1$ (左2词性“C/ N”，右2词性“N/ Pu”);

$f(\text{打}, s_3)=1$ (左1词“人”，右1词性“N”);

$f(\text{打}, s_3)=1$ (左1词“人”，右2词性“N/ Pu”);

..... (取值等于0的函数忽略)

$$p(s_3|\text{打}) = ?$$

5. 最大熵模型及应用

$$p^*(y | x) = \frac{1}{Z(x)} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right) \quad (18)$$

$$\text{其中, } Z(x) = \sum_{y \in Y} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right) \quad (19)$$

$$p^*(s_3 | \text{打}) = \frac{1}{Z(\text{打})} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, s_3)\right)$$

$$Z(\text{打}) = \sum_{y \in Y} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, y)\right)$$



5. 最大熵模型及应用

如果上下文条件由如下三类信息表示：

- (1)特征的类型：词形、词性、词形 + 词性，3种情况；
- (2)上下文窗口大小：当前词的左右2个词，1种情况；
- (3)是否考虑位置：是或否，2种情况。

上述3种情况组合，可得到如下 n 种特征模板：

$$n = 3 \times 1 \times 2 = 6$$

考虑到词形、词性、位置等又可以组合出很多种可能，可以构造出若干特征函数，因此需要对特征进行筛选。

5. 最大熵模型及应用

特征选择一般有三种方法：

- ① 从候选特征集中选择那些在训练数据中出现频次超过一定阈值的特征；
- ② 利用互信息作为评价尺度从候选特征集中选择满足一定互信息要求的特征；
- ③ 利用增量式特征选择方法(Della Pietra *et al.*)从候选特征集中选择特征。[\(比较复杂\)](#)

选定特征之后确定特征函数 f ，假设共有 k ($k > 0$) 个特征函数。

5. 最大熵模型及应用

➤ 获取 λ 参数

- 利用GIS(generalized iterative scaling) 算法

GIS 迭代过程要求对于训练集中每个实例的任意 $(x, y) \in X \times Y$, k 个特征函数之和为一常量 C , 即:

$$\sum_{j=1}^k f_j(x, y) = C$$

若该条件不满足, 则根据训练集取: $C = \max_{x \in X, y \in Y} \sum_{j=1}^k f_j(x, y)$

并增加一个修正特征 f_l : $f_l(x, y) = C - \sum_{j=1}^k f_j(x, y)$

$l = k+1$ 。 $f_l(x, y)$ 与其它特征函数不一样, 其取值范围为: $0 \sim C$ 。

5. 最大熵模型及应用

➤ GIS算法描述

(a) 初始化: $\lambda[1..l]=0$;

(b) 计算每个特征函数 f_j 的训练样本期望值 $E_{\tilde{p}}(f_j)$;

(c) 迭代计算特征函数的模型期望值 $E_p(f_j)$:

①利用公式(23)、(22)计算概率 p^* ;

$$Z(x) = \sum_y \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right)$$
$$p^*(y|x) = \frac{1}{Z(x)} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right)$$

λ 修正方法:

$$\lambda^{(n+1)} = \lambda^{(n)} + \frac{1}{C} \ln \left(\frac{E_{\tilde{p}}(f_j)}{E_{p^{(n)}}(f_j)} \right)$$

②若满足终止条件, 则结束迭代; 否则, **修正 λ** , 继续下轮迭代。

(d) 算法结束, 确定 λ , 算出每个 p^* 。

5. 最大熵模型及应用

迭代终止条件:

(a) 限定迭代次数;

(b) 对数似然($L(p)$)的变化小到可以忽略: $|L_{i+1} - L_i| < \varepsilon$


$$L(p) = \sum_{x,y} \tilde{p}(x,y) \log p(y|x)$$

关于GIS算法及改进, 请参阅如下文献:

- [1] J. N. Darroch, D. Ratcliff. Generalized Iterative Scaling for Log-linear Models. *Annals of Math. Statistics*, 1972, 43: 1470-1480
- [2] A. L. Berger. The improved iterative scaling algorithm: A gentle introduction, *Technical report*, Carnegie Mellon University, 1997
- [3] D. Pietra et al. Inducing Features of Random Fields, *IEEE Trans. on PAMI*, 1997, 19(4): 380-393

5. 最大熵模型及应用

➤ 整个过程：



5. 最大熵模型及应用

➤ 实验验证:

- ✧ 训练数据: 用2000年1月1 ~ 28日28天的《人民日报》标注文本作为训练数据 (全部进行了词义标注) ;
- ✧ 测试数据: 2000年1月29 ~ 31日三天的文本作为测试数据, 利用所建立的最大熵模型算法对其进行义项标注实验, 多义词有4931个;
- ✧ 特征模板: 特征类型=词形, 窗口大小=全句, 不考虑位置特征;
- ✧ 标注结果: 正确率为 94.34%。

张仰森: 面向语言资源建设的汉语词义消歧与标注方法研究, 北京大学博士后出站报告, 2006年12月



5. 最大熵模型及应用

➤ 关于最大熵方法在NLP中的应用，请参阅：

- [1] Adam L. Berger, Stephen A. Della Pietra, Vincent J. Della Pietra. A Maximum Entry Approach to Natural Language Processing. *Computational Linguistics*, Vol. 22, No. 1, 1996. Pages 39-71 **[ToT Paper Award, ACL-IJCNLP'2021]**
- [2] A. Ratnaparkhi. A Simple Introduction to Maximum Entropy Models for Natural Language Processing. *Technical Report IRCS-97-08*, Dept. of Computer Science, UPenn., 1997
- [3] A. Ratnaparkhi. Maximum Entropy Models for Natural Language Ambiguity Resolution, PhD Dissertation, UPenn., 1998

➤ 最大熵开源工具：

- ✧ OpenNLP: <https://opennlp.apache.org/docs/2.0.0/manual/opennlp.html#opennlp.ml.maxent>
- ✧ Malouf: <http://tadm.sourceforge.net/>

◆ME模型

$$p^*(y | x) = \frac{1}{Z(x)} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right)$$


其中, $Z(x) = \sum_{y \in Y} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right)$

测试时:

$$p^*(s_i | \text{打}) = \frac{\exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, s_i)\right)}{\sum_{y \in Y} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, y)\right)}$$

$s_1 \sim s_n$

$w_1 w_2 \dots w_i \dots w_n$



Context

Context₁ → s₁
Context₂ → s₂
.....
Context_n → s_n

训练时:

$$p^*(s_i | \text{打}) = \frac{\exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, s_i)\right)}{\sum_{y \in Y} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, y)\right)}$$



本章内容

1. 概率论略览
2. 齐夫定律
3. 信息论基础
4. 统计学习概念
5. 最大熵模型及应用
-  6. 条件随机场及应用
7. 习题
8. 附录

6. 条件随机场及应用

◆ 模型提出

在NLP和图像处理等任务中有一类问题是进行序列标注和结构划分，为了解决这类问题 J. Lafferty 等人于2001年提出了条件随机场(**conditional random fields, CRFs**) 这一概率化的结构模型。

● 基本思想

给定观察序列 X ，输出标识序列 Y ，通过计算 $P(Y|X)$ 求解最优标注序列。

6. 条件随机场及应用

◆模型定义

设 $G=(V, E)$ 为一个无向图, V 为结点集合, E 为无向边的集合, $Y = \{ Y_v | v \in V \}$, 即 V 中每个结点对应于一个随机变量 Y_v , 其取值范围为可能的标记集合 $\{y\}$ 。如果以观察序列 X 为条件, 每个随机变量 Y_v 都满足以下马尔可夫特性:


$$p(Y_v | X, Y_w, w \neq v) = p(Y_v | X, Y_w, w \sim v) \quad \dots (20)$$

其中, $w \sim v$ 表示两个结点在图中是邻近结点。那么, (X, Y) 为一个条件随机场。


6. 条件随机场及应用

图示：

$$p(Y_v | X, Y_w, w \neq v) = p(Y_v | X, Y_w, w \sim v)$$



或者：



序列标注问题可以建模为简单的链式结构图，结点对应标记序列 Y 中的元素。理论上，只要在标记序列中描述一定的条件独立性， G 的图结构可以任意的。

6. 条件随机场及应用

在CRFs中, 给定观察序列 X 时, 某个特定标记序列 Y 的概率可以定义为:

$$p(Y|X) = \frac{1}{Z(X)} \exp \left(\sum_j \lambda_j t_j(y_{i-1}, y_i, X, i) + \sum_k \mu_k s_k(y_i, X, i) \right) \quad \dots (21)$$

其中, $t_j(y_{i-1}, y_i, X, i)$ 是转移函数, 表示对于观察序列 X 的标注序列**从 $i-1$ 到 i 位置上标记的转移概率**。通常把转移函数称作二元特征。 $s_k(y_i, X, i)$ 是状态函数, 表示观察序列 X **在 i 位置的标记概率**。通常把状态函数称作一元特征。 λ_j 和 μ_k 分别是 t_j 和 s_k 的权重, 需要从训练样本中估计出。

$Z(X)$ 为归一化因子:

$$Z(X) = \sum_Y \exp \left(\sum_{i,j} \lambda_j t_j(y_{i-1}, y_i, X, i) + \sum_{i,k} \mu_k s_k(y_i, X, i) \right)$$

6. 条件随机场及应用

定义一组关于观察序列的 $\{0, 1\}$ 二值特征 $b(X, i)$, 表示训练样本中某些特征的分布, 如

$$b(X, i) = \begin{cases} 1 & \text{如果 } X \text{ 的 } i \text{ 位置为某个特定的词} \\ 0 & \text{否则} \end{cases}$$

转移函数可以定义为如下形式:

$$t_j(y_{i-1}, y_i, X, i) = \begin{cases} b(X, i) & \text{如果 } y_{i-1} \text{ 和 } y_i \text{ 满足某种搭配条件} \\ 0 & \text{否则} \end{cases}$$

也可以把状态函数写成如下形式:

$$s(y_i, X, i) = s(y_{i-1}, y_i, X, i)$$

6. 条件随机场及应用

由此，特征函数可以统一表示为：

$$F_j(Y, X) = \sum_{i=1}^n f_j(y_{i-1}, y_i, X, i) \quad \dots (22)$$

其中，每个局部特征函数 $f_j(y_{i-1}, y_i, X, i)$ 表示状态特征 $s(y_{i-1}, y_i, X, i)$ 或转移数 $t(y_{i-1}, y_i, X, i)$ 。

条件随机场定义的条件概率可以由下式给出：

$$p(Y | X, \lambda) = \frac{1}{Z(X)} \exp\left(\sum_j \lambda_j \cdot F_j(Y, X)\right) \quad \dots (23)$$

其中， $Z(X)$ 为归一化因： $Z(X) = \sum_Y \exp\left(\sum_j \lambda_j \cdot F_j(Y, X)\right)$

6. 条件随机场及应用

◆回顾最大熵模型：

对于求解的问题，就是估计在条件 $b \in B$ 下(已知知识)，发生某个事件 $a \in A$ (未知分布)的概率 $p(a|b)$ ，该概率使熵 $H(p(A|B))$ 最大。

$$p^*(a|b) = \frac{1}{Z(b)} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(a, b)\right)$$

特征函数

特征权重

其中，

$$Z(b) = \sum_a \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(a, b)\right)$$


$Z(b)$ 为保证对所有 b ，使得 $\sum_a p(a|b) = 1$ 的归一常量。

6. 条件随机场及应用

◆ ME 模型 与 CRFs 对比:

● 相同点:


- 都是通过特征函数计算概率，模型形式也一样;
- 可以采用同样的参数训练方法。



(a) ME

● 不同点:

- 基于 ME 的分类器对给定输入 X 的整体（作为一个单位）或某个点进行分分类，是解决“点”的问题;
- CRFs 模型是对给定输入 X 进行序列标注，最终求解的是全局最优标注序列 Y 。



(b) CRFs

ME能完成的任务CRFs也能够完成。

6. 条件随机场及应用

◆ 模型实现

- 需要解决的三个问题：

- ① 特征选取 $\longrightarrow$ 参阅最大熵模型。

- ② 参数训练 $\longrightarrow$ 每个特征的权重 λ 如何确定？

- ③ 解码 $\longrightarrow$ 如何快速地搜索最优路径。



6. 条件随机场及应用

②参数训练

通过训练语料估计特征权重 λ_j , 使其在给定一个观察序列 X 的条件下, 找到一个最有可能的标记序列 Y , 即条件概率 $P(Y|X)$ 最大。

条件概率已由上文的(4)式给出:

$$p(Y | X, \lambda) = \frac{1}{Z(X)} \exp(\sum_j \lambda_j \cdot F_j(Y, X))$$

$$Z(X) = \sum_Y \exp(\sum_j \lambda_j \cdot F_j(Y, X))$$

6. 条件随机场及应用

$$p(Y | X, \lambda) = \frac{1}{Z(X)} \exp\left(\sum_j \lambda_j \cdot F_j(Y, X)\right)$$

$$Z(X) = \sum_Y \exp\left(\sum_j \lambda_j \cdot F_j(Y, X)\right)$$

为了训练特征权重 λ_j ，需要计算模型的损失和梯度。由梯度更新 λ_j ，直到 λ_j 收敛。
损失函数可定义为负对数似然函数：

$$L(\lambda) = -\log p(Y | X, \lambda) + \frac{\varepsilon}{2} \|\lambda\|_2^2 \quad (\varepsilon \text{取值范围: } 10^{-6} \sim 10^{-3})$$

$$\lambda = \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_M \end{bmatrix}$$

$$\|\lambda\|_2 = \sqrt{\sum_i \lambda_i^2}$$

6. 条件随机场及应用

$$p(Y | X, \lambda) = \frac{1}{Z(X)} \exp\left(\sum_j \lambda_j \cdot F_j(Y, X)\right)$$

$$Z(X) = \sum_Y \exp\left(\sum_j \lambda_j \cdot F_j(Y, X)\right)$$

$$L(\lambda) = -\log p(Y | X, \lambda) + \frac{\varepsilon}{2} \|\lambda\|_2^2$$

损失函数的梯度为：

$$\frac{\partial L(\lambda)}{\partial \lambda_j} = \frac{\partial \log Z(X)}{\partial \lambda_j} - F_j(Y, X) + \varepsilon \lambda_j$$

$$\lambda_j^{(k+1)} = \lambda_j^{(k)} - \ell \frac{\partial L(\lambda)}{\partial \lambda_j^{(k)}} \quad \dots(24)$$

(k 为迭代的轮次, ℓ 为学习率, 经验值, 可设为0.1等。)



6. 条件随机场及应用

● 算法描述

输入： 训练集 $\mathcal{D} = \{(X^{(i)}, Y^{(i)})\}_{i=1}^N$ ，学习率 ℓ ，正则化系数 ε ，损失变化上界 δ 。

1 令 $k = 0$ ，随机初始化特征权重 λ_k ， $\Delta L(\lambda^{(k)}) = +\infty$ ； // k 是迭代的轮次
将训练集划分成若干批。

2 while TRUE do:

3 采样一个批次的训练样本 $\{(X^{(i)}, Y^{(i)})\}_{i=1}^m$ ($m \leq N$)，
计算得到该批次样本集的概率 $p(Y^{(i)} | X^{(i)}, \lambda^{(k)})$ ；

4 采用负对数似然概函数作为目标函数：

$$L(\lambda^{(k)}) = \sum_{i=1}^m \left(-\log p(Y^{(i)} | X^{(i)}, \lambda^{(k)}) \right) + \frac{\varepsilon}{2} \|\lambda^{(k)}\|_2^2$$

5 if $k > 1$:

6 计算损失变化： $\Delta L(\lambda^{(k)}) = \|L(\lambda^{(k)}) - L(\lambda^{(k-1)})\|$

7 如果 $\Delta L(\lambda^{(k)}) \leq \delta$ 结束循环；

8 计算特征权重的梯度值 $\lambda' = \frac{\partial L(\lambda^{(k)})}{\partial \lambda_j^{(k)}}$ ， $j = 1 \dots M$ ；

9 更新特征权重和迭代轮次计数： $\lambda^{(k+1)} = \lambda^{(k)} - \ell \lambda'$ ； $k = k + 1$ ；

10 End

$$p(Y | X, \lambda) = \frac{1}{Z(X)} \exp\left(\sum_j \lambda_j \cdot F_j(Y, X)\right)$$
$$Z(X) = \sum_Y \exp\left(\sum_j \lambda_j \cdot F_j(Y, X)\right)$$

对整个训练集 $\mathcal{D}$ 上的所有
批次样本反复迭代，使模
型达到整体最优。

6. 条件随机场及应用

③ 解码

- **问题描述：** 给定的 $X = x_1x_2...x_T$ ，从1到 T 的每一时刻 x_i 都有 N 个可能的标记 $y_1, y_2, \dots, y_N$ ，搜索对于 X 的最优标记序列。

- **解决思路：**

- 将所有可能的路径全部列出来，依次对比，选择概率最大的那条路径。


复杂度高： N^T ✗

- 对于每一时刻，选择概率最大的标记。

有时标记之间不同现 ✗

- 动态规划，分而治之。

—— Viterbi 搜索



6. 条件随机场及应用

● **Viterbi 搜索算法：** 采用动态规划策略,搜索全局最优状态序列

➤ **定义：** Viterbi变量 $\delta_t(i)$ 是在 t 时刻模型沿着某一条路径到达 y_i 的概率（得分）。
那么，下一时刻的路径得分为：

$$\delta_{t+1}(j) = \max_{1 \leq k \leq N} \{ \delta_t(k) + \alpha_{\text{path}} \} \quad \dots (25)$$


$$\alpha_{\text{path}} = \log(p(Y | X, \lambda)) = \log \left(\frac{\exp(\sum_j \lambda_j \cdot F_j(Y, X))}{\sum_Y \exp(\sum_j \lambda_j \cdot F_j(Y, X))} \right) \quad \dots (26)$$

$Z(X)$

$$\propto \sum_j \lambda_j \cdot F_j(Y, X)$$

6. 条件随机场及应用

图解
Viterbi
搜索
过程




6. 条件随机场及应用

图解
Viterbi
搜索
过程

剪枝策略:

- ① $\delta_t(j) \geq \Delta$
- ② $NPath \leq \sigma$
- (3)




6. 条件随机场及应用

图解
Viterbi
搜索
过程

剪枝策略:

- ① $\delta_t(j) \geq \Delta$
- ② $NPath \leq \sigma$
- (3)



6. 条件随机场及应用


图解
Viterbi
搜索
过程

剪枝策略:

① $\delta_t(j) \geq \Delta$

② $NPath \leq \sigma$

(3)



6. 条件随机场及应用

● Viterbi 算法描述

(1)初始化: $\delta_1(i)$, $1 \leq i \leq N$

(2)递推计算:

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) + \alpha_{ij}], \quad 2 \leq t \leq T, \quad 1 \leq j \leq N$$

(3)结束:

$$\hat{Y}_T = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$$

**算法的时间
复杂度: $O(N^2T)$**

6. 条件随机场及应用

◆ CRFs应用举例

基于字标注的分词方法(Character-based tagging)

● 基本思想

将分词过程看作是字的分类问题：每个字在构造一个特定的词语时都占据着一个确定的构词位置(即词位)。一般而言，每个字只有4个词位：词首(B)、词中(M)、词尾(E)和单独成词(S)。

该方法由N. Xue (薛念文) 和 S. Converse 提出，首篇论文发表在2002年第一届国际计算语言学学会(ACL)汉语特别兴趣小组 SIGHAN(<http://sighan.cs.uchicago.edu/>)组织的汉语分词评测研讨会上[Xue and Converse, 2002]。

6. 条件随机场及应用

例如：乒乓球拍卖完了。

(1) 乒乓球/ 拍/ 卖/ 完/ 了/ 。

(2) 乒乓/ 球拍/ 卖/ 完/ 了/ 。

(3) 乒乓球/ 拍卖/ 完/ 了/ 。

第(3)种切分结果的字位标记形式：

乒/B 兵/M 球/E 拍/B 卖/E 完/S 了/S 。/S

在字标注过程中，对所有的字根据预定义的特征进行词位特征学习，获得一个概率模型，然后在待切分字串上，根据字与字之间的结合紧密程度，得到一个词位的分类结果，最后根据词位定义直接获得最终的分词结果。

6. 条件随机场及应用

乒/B 乒/M 球/E 拍/S 卖完了。

↑ B, E, M, S ?

- 当前字 x_t 的前后 n 个字 $x_{t\pm n}$ (下面假设 $n=1$)
- 当前字左边第一个字的标记 y_{t-1}
- 当前字的标记 y_t

.....

乒	乒	球	拍	卖	完	了	。
B	B	B	B	B	B	B	B
M	M	M	M	M	M	M	M
E	E	E	E	E	E	E	E
S	S	S	S	S	S	S	S

分词结果: 乒/B 乒/M 球/E 拍/B 卖/E 完/S 了/S/。/S



6. 条件随机场及应用

① 特征选取

➤ 一元特征（状态函数）：当前字、当前字的前一个字、当前字的后一个字

$$s_1(y_i, X, i) = \begin{cases} 1 & \text{如果当前字是“拍”，当前字的标记} y_i \text{是S} \\ 0 & \text{否则} \end{cases}$$

$$s_2(y_i, X, i) = \begin{cases} 1 & \text{如果当前字是“拍”，当前字的标记} y_i \text{是E} \\ 0 & \text{否则} \end{cases}$$

.....

乒/B 兵/M 球/E 拍/S 卖/? 完了。

6. 条件随机场及应用

➤ 二元特征（转移函数）：

$$t_1(y_{i-1}, y_i, X, i) = \begin{cases} 1 & \text{如果前一个字的标记 } y_{i-1} \text{ 是B, 当前字的标记 } y_i \text{ 是M} \\ 0 & \text{否则} \end{cases}$$

$$t_2(y_{i-1}, y_i, X, i) = \begin{cases} 1 & \text{如果前一个字的标记 } y_{i-1} \text{ 是M, 当前字的标记 } y_i \text{ 是M} \\ 0 & \text{否则} \end{cases}$$

.....

乒/B 乒/M 球/E 拍/S 卖/? 完了。

假设共选出4个特征：

(a) $F_1(x_{t-1}, x_t, y_t)$

(b) $F_2(x_t, y_t)$

(c) $F_3(x_t, x_{t+1}, y_t)$

(d) $F_4(y_{t-1}, y_t)$

② 参数训练：获得每个特征的权重 λ_i ($1 \leq i \leq 4$)。

6. 条件随机场及应用

③解码:

1	2	3	4	5	6	7
乒	乓	球	拍	卖	完	了

第1步: 计算第1个字“乒”的标记分数(以标记‘B’为例):

$$\delta_1^B = \delta_0 + \alpha_{\text{path}}$$

$$\delta_0 = 1$$

$$\alpha_{\text{path}} = \lambda_1 F_1(x_0 = \text{'null'}, x_1 = \text{'乒'}, y_1 = \text{'B'})$$

$$+ \lambda_2 F_2(x_1 = \text{'乒'}, y_1 = \text{'B'})$$

$$+ \lambda_3 F_3(x_1 = \text{'乒'}, x_2 = \text{'乓'}, y_1 = \text{'B'})$$

$$+ \lambda_4 F_4(y_0 = \text{'null'}, y_1 = \text{'B'})$$

前一个字为空，当前字“乒”被标记为B的得分。

当前字“乒”被标记为B。

当前字“乒”，且后一个字为“乓”，当前字被标记为B。

前一个字的标签为空，当前字被标记为B。

同样可计算出第1个字“乒”被标记为‘S’的得分。

6. 条件随机场及应用

第2步：计算第2个字“兵”的标记分数（以标记M为例）。

首先计算在第1个字“兵”的标记为“B”时，第2个字“兵”的标记为“M”的分数：

$$\delta_2^{BM} = \delta_1('B') + \alpha_{\text{path}}$$

$$\begin{aligned} \alpha_{\text{path}} = & \lambda_1 F_1(x_1 = \text{'兵'}, x_2 = \text{'兵'}, y_2 = \text{'M'}) \\ & + \lambda_2 F_2(x_2 = \text{'兵'}, y_2 = \text{'M'}) \\ & + \lambda_3 F_3(x_2 = \text{'兵'}, x_3 = \text{'球'}, y_2 = \text{'M'}) \\ & + \lambda_4 F_4(y_1 = \text{'B'}, y_2 = \text{'M'}) \end{aligned}$$

然后计算在第1个字“兵”的标记为‘S’时，第2个字“兵”的标记为‘M’的分数：

$$\delta_2^{SB} = \delta_1('S') + \alpha_{\text{path}}$$

$$\begin{aligned} \alpha_{\text{path}} = & \lambda_1 F_1(x_1 = \text{'兵'}, x_2 = \text{'兵'}, y_2 = \text{'M'}) \\ & + \lambda_2 F_2(x_2 = \text{'兵'}, y_2 = \text{'M'}) \\ & + \lambda_3 F_3(x_2 = \text{'兵'}, x_3 = \text{'球'}, y_2 = \text{'M'}) \\ & + \lambda_4 F_4(y_1 = \text{'S'}, y_2 = \text{'M'}) \end{aligned}$$

等等其它情况……

6. 条件随机场及应用

第2步：确定第2个字“兵”被标记为‘M’的得分：

$$\delta_2(M) = \max \{ \delta_2^{BM}, \delta_2^{SM}, \delta_2^{MM}, \delta_2^{EM} \}$$

以此类推，计算第2个字“兵”的标记分别为‘S’、‘B’和‘E’的分数 $\delta_2(S)$ 、 $\delta_2(B)$ 和 $\delta_2(E)$ 。

第3步：循环

根据第2个字“兵”的标记分数，计算第3个字“球”的标记分数..... 根据第6个字“完”的标记分数计算第7个字“了”的标记分数。

结束：最终选择分数最高的路径，然后以该路径的标记点为起始点回溯，得到整个句子的路径标记序列。解码完毕。

6. 条件随机场及应用

◆CRFs 的开源代码:

- CRF++ (C++版):

<http://crfpp.googlecode.com/svn/trunk/doc/index.html>

- CRFSuite (C语言版):

<http://www.chokkan.org/software/crfsuite/>

- MALLET (Java版, 通用的自然语言处理工具包, 包括分类、序列标注等机器学习算法):

<http://mallet.cs.umass.edu/>

- NLTK (Python版, 通用的自然语言处理工具包, 很多工具是从MALLET中包装转成的Python接口): <http://nltk.org/>



6. 条件随机场及应用

◆CRFs 代表论文:

- [1] J. Lafferty et al. Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data. *Proc.ICML'2001*, pages 282-289
- [2] H. M. Wallach. Conditional Random Fields: An Introduction. *CIS Technical Report MS-CIS-04-21*, Univ. of Penn., 2004

◆CRFs模型

$$p^*(y | x) = \frac{1}{Z(x)} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right)$$


其中, $Z(x) = \sum_{y \in Y} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right)$

测试时:

$$p^*(s_i | \text{打}) = \frac{\exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, s_i)\right)}{\sum_{y \in Y} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, y)\right)}$$

$s_1 \sim s_n$

Viterbi 搜索



训练时:

$$p^*(s_i | \text{打}) = \frac{\exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, s_i)\right)}{\sum_{y \in Y} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(\text{打}, y)\right)}$$

◆ 概率论基础

➤ 基本概念和方法（回顾）； 随机过程

◆ 齐夫定律

◆ 信息论基础

➤ 熵，联合熵，条件熵，交叉熵，相对熵，困惑度，互信息

◆ 统计学习的基本概念

➤ 有监督学习，半监督学习，生成式模型，区分式模型，开发集/测试集，过拟合…

◆ 最大熵分类器及应用

◆ 条件随机场模型及应用

① 研究方法

② 特征提取

③ 参数训练

④ 最优求解(Viterbi 搜索)



本章内容

1. 概率论略览
2. 齐夫定律
3. 信息论基础
4. 统计学习概念
5. 最大熵模型及应用
6. 条件随机场及应用
-  7. 习题
8. 附录

7. 习题

1. 利用网络爬虫工具从互联网上收集尽量多的英语和汉语文本，完成下面的工作：
 - ① 对收集的样本进行处理，如清洗乱码等。
 - ② 设计并编程实现算法，计算在收集样本上**英语字母和单词或汉字**的概率和熵（如果有汉语自动分词工具，可以统计计算汉语词汇的概率和熵）。
 - ③ 利用收集的英文文本验证齐夫定律(Zipf's law)。
 - ④ 不断增加样本规模，重新计算上面②③的结果，进行对比分析。
 - ⑤ 完成一份技术报告，在报告中写明利用什么爬虫工具从哪些网站上收集的样本，如何进行的样本清洗，清洗后样本的规模，在不同样本规模下计算的结果等。**实验分析有较大的伸缩空间。**

课程作业1：本章1 ~ 3题任选一个

7. 习题

2. 利用网络爬虫工具从互联网上收集尽量多的汉语文本，完成下面的工作：

- ① 对收集的样本进行处理，如清洗乱码等。
- ② 设计并编程实现算法，计算任意两个**汉字邻近同现**的概率(如果有汉语自动分词工具，可以统计计算汉语词汇的邻近同现概率)。
- ③ 计算任意两个汉字之间的(点式)互信息。
- ④ 计算任意两篇文章之间的(平均)互信息。
- ⑤ 更改样本来源或类型，如来自不同网站的语料或者不同类型的语料等，重新计算上面②③④的结果，进行对比分析。
- ⑥ 完成一份技术报告，在报告中写明利用什么爬虫工具从哪些网站上收集的样本，如何进行的样本清洗，清洗后样本的规模，计算结果分析等。**实验分析有较大的伸缩空间。**

课程作业1：本章1 ~ 3题任选一个

7. 习题

3. 利用北京大学标注的《人民日报》1998年1月份的分词和词性标注语料（见SEP平台本课程附录03）完成如下工作：
- ① 设计并实现算法，计算任意两个汉字之间的点式互信息和它们**邻近同现的概率**，分析两个邻近汉字构成词汇的概率与它们之间点式互信息情况。
 - ② 根据词性分类标记，计算任意两类词汇之间的互信息。
 - ③ 利用网络爬虫从《人民日报》官网(https://paper.people.com.cn/rmrb/pc/layout/202510/15/node_01.html)上爬取尽量多的语料（包括今年1月份的内容），对其进行处理，如清洗乱码等。
 - ④ 利用③中获取的今年1月份的语料与1998年1月的《人民日报》语料进行对比分析，分析词频差异，并抽取出所有的新词。
 - ⑤ 完成一份技术报告，在报告中写明上述各任务的计算结果分析情况，利用什么网络爬虫工具，如何进行的样本清洗等。**结果分析有较大的伸缩空间。**

课程作业1：本章1 ~ 3题任选一个



7. 习题

4. 设 $X \sim p(x)$, $q(x)$ 为用于近似 $p(x)$ 的一个概率分布, 则 $p(x)$ 与 $q(x)$ 的交叉熵定义为:
 $H(p, q) = H(p) + D(p \parallel q)$ 。请证明:

$$H(p, q) = -\sum_x p(x) \log q(x)$$

5. 根据本章内容设计并实现一种算法, 计算任意两个句子之间的相似性。
6. 举例说明自然语言中两个事件 (如“字”“词”或“短语”等) 之间的相关性、因果关系、组合成更大单位的可能性与它们之间点式互信息值大小的关系。



本章内容

1. 概率论略览
2. 齐夫定律
3. 信息论基础
4. 统计学习概念
5. 最大熵模型及应用
6. 条件随机场及应用
7. 习题

 **8. 附录**

8. 附录

1. 证明前面P31公式(8): $H(L, q) = -\lim_{n \rightarrow \infty} \frac{1}{n} \log q(x_1^n)$
(又见《统计自然语言处理》P28, 公式(2-39))

2. 证明: 两个随机变量之间的平均互信息为非负值。

3. 前面P57上概率 $p^*(a|b)$ 的推导说明

1. 证明: $H(L, q) = -\lim_{n \rightarrow \infty} \frac{1}{n} \log q(x_1^n)$

布莱曼渐近均分性(Breiman's AEP)定理: 如果 X 是稳态的遍历性随机过程, 那么

$$H_{\text{rate}}(X) = -\lim_{n \rightarrow \infty} \frac{1}{n} \log p(x_1, x_2, \dots, x_n) = -\lim_{n \rightarrow \infty} \frac{1}{n} \log p(x_1^n)$$

该定理的证明:

假设 $(x_1, x_2, \dots, x_n)$ 符合独立同分布。根据熵率的定义, 左边:

$$\begin{aligned} H_{\text{rate}}(X) &= \lim_{n \rightarrow \infty} \frac{1}{n} H(x_1^n) \\ &= \lim_{n \rightarrow \infty} \frac{1}{n} H(x_1, x_2, \dots, x_n) \\ &= \lim_{n \rightarrow \infty} \left\{ -\frac{1}{n} \sum_{x_1 x_2 \dots x_n} p(x_1, x_2, \dots, x_n) \log p(x_1, x_2, \dots, x_n) \right\} \end{aligned}$$

8. 附录

$$\begin{aligned} &= \lim_{n \rightarrow \infty} \left\{ -\frac{1}{n} \sum_{x_1 x_2 \dots x_n} p(x_1, x_2, \dots, x_n) \left(\sum_{x_i} \log p(x_i) \right) \right\} \\ &= \lim_{n \rightarrow \infty} \left\{ -\frac{1}{n} \left[\sum_{x_1 x_2 \dots x_n} p(x_1, x_2, \dots, x_n) \log p(x_1) + \sum_{x_1 x_2 \dots x_n} p(x_1, x_2, \dots, x_n) \log p(x_2) + \dots \right. \right. \\ &\quad \left. \left. + \sum_{x_1 x_2 \dots x_n} p(x_1, x_2, \dots, x_n) \log p(x_n) \right] \right\} \\ &= \lim_{n \rightarrow \infty} \left\{ -\frac{1}{n} \left[\sum_{x_1 x_2 \dots x_n} p(x_1) p(x_2) \dots p(x_n) \log p(x_1) + \sum_{x_1 x_2 \dots x_n} p(x_1) p(x_2) \dots p(x_n) \log p(x_2) \right. \right. \\ &\quad \left. \left. + \dots + \sum_{x_1 x_2 \dots x_n} p(x_1) p(x_2) \dots p(x_n) \log p(x_n) \right] \right\} \end{aligned}$$

8. 附录

$$\begin{aligned}
 &= \lim_{n \rightarrow \infty} \left\{ -\frac{1}{n} \left[\sum_{x_1} p(x_1) \log p(x_1) \left(\sum_{x_2 x_3 \dots x_n} p(x_2) p(x_3) \dots p(x_n) \right) \right. \right. \\
 &\quad \left. \left. + \sum_{x_2} p(x_2) \log p(x_2) \left(\sum_{x_1, x_3 x_4 \dots x_n} p(x_1) p(x_3) p(x_4) \dots p(x_n) \right) \right. \right. \\
 &\quad \left. \left. + \dots + \sum_{x_n} p(x_n) \log p(x_n) \left(\sum_{x_1 x_2 \dots x_{n-1}} p(x_1) p(x_2) \dots p(x_{n-1}) \right) \right] \right\} \\
 &= \lim_{n \rightarrow \infty} \left\{ -\frac{1}{n} \left[\sum_{x_1} p(x_1) \log p(x_1) + \sum_{x_2} p(x_2) \log p(x_2) + \dots + \sum_{x_n} p(x_n) \log p(x_n) \right] \right\} \\
 &= \lim_{n \rightarrow \infty} \left\{ -\frac{1}{n} \left[\sum_{x_1} p(x_1) \log p(x_1) + \sum_{x_2} p(x_2) \log p(x_2) + \dots + \sum_{x_n} p(x_n) \log p(x_n) \right] \right\} \\
 &= \lim_{n \rightarrow \infty} \left\{ \frac{1}{n} [H(x_1) + H(x_2) + \dots + H(x_n)] \right\} \\
 &= \lim_{n \rightarrow \infty} \left\{ \frac{1}{n} \times n \times H(x_i) \right\} \\
 &= H(x_i)
 \end{aligned}$$

由于 $(x_1, x_2, \dots, x_n)$ 符合概率同分布，所以红线部分可以被看作是联合概率分布对所有的可能取值的求和，其值为1。

而定理右边:

$$\begin{aligned} -\lim_{n \rightarrow \infty} \frac{1}{n} \log p(x_1^n) &= -\lim_{n \rightarrow \infty} \frac{1}{n} \log p(x_1, x_2, \dots, x_n) \\ &= -\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{x_i} \log p(x_i) \end{aligned}$$

(基于概率同分布)

该式中, $\frac{1}{n} \sum_{x_i} \log p(x_i)$ 可以看作是 $\log p(x_i)$ 的均值, 而 $E(\log p(x_i))$ 为其期望值(相当于下面式子中的 μ)。根据**辛钦大数定律**(Wiener-Khinchin Law of Large Numbers): **样本均值依概率收敛于期望值 μ** , 即

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \varepsilon) = 1$$

因此,
$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{x_i} \log p(x_i) - E(\log p(x_i)) \right| < \varepsilon \right) = 1$$

即
$$-\frac{1}{n} \sum_{x_i} \log p(x_i) \rightarrow -E(\log p(x_i)) = H(x_i)$$

(依概率)

所以, 左边等于等式右边。

参阅如下文献(英文第2版P58, 中文第2版P33):

Thomas M.Cover and Joy A.Thomas. Elements of Information Theory, 2nd edition, John Wiley & Sons. 2006

8. 附录

类似地，可以证明在 $(x_1, x_2, \dots, x_n)$ 不满足独立同分布的条件下，该定理同样成立。请参阅下面的文献。

根据布莱曼渐近均分性定理(Breiman's AEP)，可以推广到：

$$\lim_{n \rightarrow \infty} \frac{1}{n} E(\log p(x_1^n)) = \lim_{n \rightarrow \infty} \frac{1}{n} \log p(x_1^n)$$

Paul H.Algoet and Thomas M.Cover. A Sanwich Proof of The Shannon-McMillan-Breiman Theorem. In The Annals of Probability 1998, Vol. 16, No.2 899-909

8. 附录

对于本章讲义公式(8), 《统计自然语言处理》 P28, 公式(2-39):

$$H(L, q) = -\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{x_1^n} p(x_1^n) \log q(x_1^n)$$

$$= \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{x_1^n} p(x_1^n) \log q(x_1^n)^{-1}$$

$$= \lim_{n \rightarrow \infty} \frac{1}{n} E(\log q(x_1^n)^{-1})$$

(利用布莱曼渐进均分性定理的推广)

$$= \lim_{n \rightarrow \infty} \frac{1}{n} \log q(x_1^n)^{-1}$$

$$= -\lim_{n \rightarrow \infty} \frac{1}{n} \log q(x_1^n)$$

证毕。

8. 附录

1. 证明前面P31公式(8): $H(L, q) = -\lim_{n \rightarrow \infty} \frac{1}{n} \log q(x_1^n)$

(又见《统计自然语言处理》P28, 公式(2-39))

2. 证明: 两个随机变量之间的平均互信息为非负值。

3. 前面P57上概率 $p^*(a|b)$ 的推导说明

2. 证明：两个随机变量之间的平均互信息为非负值。

方法一：

证明：根据琴生不等式(Jensen inequality)的积分形式：

$$\frac{\int_a^b f(g(x))p(x)dx}{\int_a^b p(x)dx} \geq f\left(\frac{\int_a^b g(x)p(x)dx}{\int_a^b p(x)dx}\right)$$

其中， $f(x)$ 是凸函数， $g(x)$ 为任意函数。那么，

$$\begin{aligned} I(X,Y) &= \sum_{x \in X} \sum_{y \in Y} p(x,y) \log \left(\frac{p(x,y)}{p(x)p(y)} \right) = \int \int p(x,y) \log \left(\frac{p(x,y)}{p(x)p(y)} \right) dx dy \\ &\geq \int \int p(x,y) \left[-\log \left(\frac{p(x)p(y)}{p(x,y)} \right) \right] dx dy \\ &= -\log \left[\int \int p(x,y) \frac{p(x)p(y)}{p(x,y)} dx dy \right] = 0 \end{aligned}$$

证毕。

8. 附录

方法二：

证明：根据互信息的定义：
$$I(X;Y) = \sum_{x_i \in X} \sum_{y_j \in Y} p(x_i, y_j) \log_2 \frac{p(x_i, y_j)}{p(x_i)p(y_j)}$$

那么，

$$-I(X;Y) = \sum_{x_i \in X} \sum_{y_j \in Y} p(x_i, y_j) \log_2 \frac{p(x_i)p(y_j)}{p(x_i y_j)}$$

利用不等式： $\ln z \leq z-1$ ，且 $\log_2 z = \ln z \cdot \log_2 e$

所以， $\log_2 z \leq (z-1) \cdot \log_2 e$ ， $\log_2 \frac{p(x_i)p(y_j)}{p(x_i y_j)} \leq \left[\frac{p(x_i)p(y_j)}{p(x_i y_j)} - 1 \right] \cdot \log_2 e$

8. 附录

$$\begin{aligned} -I(X; Y) &= \sum_{x_i \in X} \sum_{y_j \in Y} p(x_i, y_j) \log_2 \frac{p(x_i)p(y_j)}{p(x_i, y_j)} \\ &\leq \sum_{x_i \in X} \sum_{y_j \in Y} p(x_i, y_j) \left[\frac{p(x_i)p(y_j)}{p(x_i, y_j)} - 1 \right] \log_2 e \\ &= \left[\sum_{x_i \in X} \sum_{y_j \in Y} p(x_i)p(y_j) - \sum_{x_i \in X} \sum_{y_j \in Y} p(x_i, y_j) \right] \log_2 e \\ &= \left[\sum_{x_i \in X} p(x_i) \sum_{y_j \in Y} p(y_j) - \sum_{x_i \in X} \sum_{y_j \in Y} p(x_i, y_j) \right] \log_2 e = 0 \end{aligned}$$

$$I(X; Y) \geq 0$$

证毕。

根据自然对数的性质： $\ln z \leq z-1, z > 0$, 当且仅当 $z=1$ 时取等号, 因此, 当且仅当 $\frac{p(x_i)p(y_j)}{p(x_i, y_j)} = 1$ 时, 即 $p(x_i, y_j) = p(x_i)p(y_j)$ 时, $I(X; Y) = 0$ 。

8. 附录

1. 证明前面P31公式(8): $H(L, q) = -\lim_{n \rightarrow \infty} \frac{1}{n} \log q(x_1^n)$

(又见《统计自然语言处理》P28, 公式(2-39))

2. 证明: 两个随机变量之间的平均互信息为非负值。

3. 关于最大熵模型的推导说明

3. 概率 $p^*(y|x)$ 的推导说明

根据最大熵方法的基本思路，估计概率 $p(y|x)$ 时应满足如下两个基本约束：

$$p^* = \arg \max_{p \in P} H(p)$$

假设存在 k 个特征 $f_j(j = 1, 2, \dots, k)$ ，它们都在建模过程中对输出有影响，我们所建立的模型应满足所有这些特征，即所建立的模型 p 应该属于这 k 个特征约束下所产生的所有模型的集合 P ：

$$P = \{p \mid E_p(f_j) = E_{\tilde{p}}(f_j), j \in \{1, 2, \dots, k\}\}$$

根据条件熵的定义(理论值):

$$\begin{aligned} H(p) &= H(Y | X) = \sum_{x \in X} p(x) H(Y | X = x) \\ &= - \sum_{x,y} p(x) p(y | x) \log p(y | x) \end{aligned}$$

由于所建模型的概率分布 $p(x)$ 应符合已知样本中的概率分布 $\tilde{p}(x)$, 即: $p(x) = \tilde{p}(x)$, 因此,

$$H(p) = - \sum_{x,y} \tilde{p}(x) p(y | x) \log p(y | x) \quad \dots(27)$$

即求解使 $H(p)$ 值最大的条件概率 $p^*(y|x)$:

$$p^*(y | x) = \arg \max_{p \in P} H(p) = \arg \max_{p \in P} \left(- \sum_{x,y} \tilde{p}(x) p(y | x) \log p(y | x) \right)$$

目标函数

8. 附录

如果有特征函数 $f_j(x, y)$, 它在已知样本中的经验概率分布 $\tilde{p}(x, y)$ 可由下式计算得出:

$$\tilde{p}(x, y) \approx \frac{Count(x, y)}{\sum_{X, Y} Count(x, y)}$$

其中, $Count(x, y)$ 为 (x, y) 在训练语料中出现的次数。

f_j 在训练样本中关于经验概率分布的数学期望为:

$$E_{\tilde{p}}(f_j) = \sum_{x, y} \tilde{p}(x, y) f_j(x, y) \quad \dots(28)$$

8. 附录

假设所建模型的理论分布为 $p(x, y)$, 则特征 f_j 关于 $p(x, y)$ 的数学期望(理论值)为:

$$E_p(f_j) = \sum_{x,y} p(x, y) f_j(x, y) \quad \dots(29)$$

由于 $p(x, y) = p(x)p(y|x)$, 且 $p(x) = \tilde{p}(x)$ 由此, (33)式变为:

$$E_p(f_j) = \sum_{x,y} \tilde{p}(x) p(y|x) f_j(x, y) \quad \dots(30)$$

如果特征 f_j 对所建的模型是有用的, 那么, 所建模型中特征 f_j 的数学期望与它在已知样本中的数学期望应该相同, 即:

$$E_p(f_j) = E_{\tilde{p}}(f_j) \quad \dots(31)$$

该式称为该问题建模的约束方程, 简称约束。

归纳上述各点:

$$p^* = \arg \max_{p \in P} H(p)$$

$$H(p) = - \sum_{x,y} \tilde{p}(x) p(y | x) \log p(y | x)$$

$$E_{\tilde{p}}(f_j) = \sum_{x,y} \tilde{p}(x, y) f_j(x, y)$$

$$E_p(f_j) = \sum_{x,y} \tilde{p}(x) p(y | x) f_j(x, y)$$

$$P = \{ p \mid E_p(f_j) = E_{\tilde{p}}(f_j), j \in \{1, 2, \dots, k\} \}$$

$$\sum_y p(y | x) = 1$$

8. 附录

这样，问题就变成了在满足一组约束的条件下求最优解的问题，可用拉格朗日乘子法解决此问题，从而证明，满足(31)式约束条件的解具有如下形式：

$$p^*(y|x) = \frac{1}{Z(x)} \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right)$$

$$\text{其中, } Z(x) = \sum_y \exp\left(\sum_{j=1}^l \lambda_j \cdot f_j(x, y)\right)$$

$Z(x)$ 为保证对所有 x ，使得 $\sum_y p(y|x) = 1$ 的归一化常量。

更详细的推导可参阅：李航著，《统计学习方法》第2版，清华大学出版社，2019

谢谢!
Thanks!

