

第4章 传统NLP技术简介

(3/3)

宗成庆

中国科学院自动化研究所

cqzong@nlpr.ia.ac.cn

4.3 语义分析

- ➡ 1. 问题概述
- 2. 语义网络
- 3. 语义角色标注
- 4. 习题

1. 问题概述

◆ 目标与任务

解释自然语言的句子或篇章各部分(词、词组、句子、段落、篇章)的含义。

◆ 面临的困难:

- 句子中存在大量的歧义，涉及指代、同义/多义、量词的辖域、隐喻等；
- 语境相关性：同一个句子在不同的语境下可能有不同的含义；
- 语义的表示方法
- 人脑对语义理解的认知过程尚不清楚，语义计算的理论、方法和模型尚未建立。

1. 问题概述

◆ 例子

- | | |
|--------------|-------------|
| ① 有你的好果子吃! | 没你的好果子吃! |
| ② 那点工作量就不算了吧 | 那点工作量就算了吧。 |
| ③ 中国队大胜美国队。 | 中国队大败美国队。 |
| ④ 沙子进眼睛了。 | 眼睛进沙子了。 |
| ⑤ 东西掉地上了。 | 东西掉地下了。 |
| ⑥ 注意危险! | 注意安全! |
| ⑦ 你做梦吧! | 你别做梦了! |
| ⑧ 好热闹啊! | 好不热闹啊! |
| ⑨ 一会儿他就来了。 | 不一会儿他就来了。 |
| ⑩ 别乱丢烟头。 | 别乱丢烟屁股。 |
| ⑪ 以前只想一个人。 | 现在只想一个人。 |
| ⑫ 中国足球谁也打不过。 | 中国乒乓球谁也打不过。 |
| ⑬ 夏天能穿多少穿多少。 | 冬天能穿多少穿多少。 |

1. 问题概述

(1) I bought a car with four wheels.

I bought a car with four dollars.

(2) These boys will be dedicated persons.

These boys will be denied license.

(3) 这件事情很让人头疼。

(4) 那个人就是个饭桶!

(5) 她脸上的两个小酒窝如同月夜里闪烁的星星，一笑便如流星划破夜空，映照出无与伦比的甜美，给人一种温暖可爱的感觉。

1. 问题概述

◆挑战

(撇开歧义、隐喻等复杂问题)

- 基本的语义单元是什么？
- 语义表示的标准是什么？
- 语言产生和演化的神经基础是什么？
- 人脑的语言认知机理是什么？
- 词义如何组合产生新的概念？
- 分布式语义表示的合理性解释是什么？
-



4.3 语义分析

1. 问题概述

➡ 2. 语义网络

3. 语义角色标注

4. 习题

2. 语义网络

◆ 背景

语义网络(semantic network)是由美国心理学家 M. R. Quilian 于1968年在研究人类联想记忆时提出的。1977年美国学者 G. Hendrix 提出了分块语义网络的思想，把语义的逻辑表示与“格语法”结合起来，把复杂问题分解为几个较为简单的子问题，每个子问题用一个语义网络表示，把自然语言理解的研究向前推进了一步。

2. 语义网络

◆ 语义网络表示

语义网络通过由实体、概念或动作、状态及语义关系组成的有向图来表达知识、描述语义。


- **有向图**：图的结点表示实体或概念，图的边表示实体或概念之间的关系。

- **边的类型**：

- (1) **是一种抽象(IS-A)**：A到B的边表示“A是B的一种特例”；
- (2) **是一部分(PART-OF)**：A到B的边表示“A是B的一部分”；
- (3) **是属性(IS)**：A到B的边表示“A是B的一种属性”；
- (4) **拥有/占用(HAVE)**：A到B的边表示“A拥有B”；
- (5) **次序在先/前(BEFORE)**：A到B的边表示“A在B之前”；

... ..

2. 语义网络



(1)



(2)



(3)



(4)



(5)



(6)


通常实体、概念或属性等采用不同形状的节点表示。

2. 语义网络

◆ 事件的语义网络表示

当语义网络表示事件时，结点之间的关系可以是施事、受事、时间等。这里所说的“事件”指某个具体的动作或状态，并非我们日常生活中所说的事件。

例如：张三帮助李四。



三元组表示：

① 帮助(张三, 李四)



或者：

② (张三, 帮助, 李四)

2. 语义网络



◆事件的语义表示

- (1) **分类关系**：事物之间的类属关系。
- (2) **聚焦关系**：多个下位概念构成一个上位概念。
- (3) **推论关系**：由一个概念推出另一个概念。
- (4) **时间、位置关系**：事实发生或存在的时间、位置。



2. 语义网络

◆ 知识图谱





2. 语义网络

◆ 知识图谱构造

给定一批大规模语料，如何构建知识图谱？

2. 语义网络

◆ 知网(HowNet) (<http://www.keenage.com>)

由董振东教授创立。

董振东教授曾在黑龙江大学担任英语老师，军事科学院研究员、机器翻译研究组组长，中国软件公司语言工程实验室主任，新加坡国立大学系统科学研究院 研究员。自上世纪七十年代开始从事机器翻译研究，1987年成功开发了我国第一个商品化机器翻译系统原型“科译1号”。1980年代研究创立知网。



董振东
(1937.4 – 2019.2.28)

2. 语义网络


● 知网的4个基本观点：

- (1) NLP系统最终需要更强大的知识库支持。
- (2) 知识是一个系统，是一个包含着各种概念与概念之间的关系，以及概念的属性与属性之间的关系的系统。一个人比另外一个人有更多的知识说到底是他不仅掌握了更多的概念，尤其重要的是他掌握了更多的概念之间的关系以及概念的属性与属性之间的关系。
- (3) 知识库建设应首先建立一种可以被称为知识系统的常识性知识库。它以通用的概念为描述对象，建立并描述这些概念之间的关系。
- (4) 首先应由知识工程师来设计知识库的框架，并建立常识性知识库的原型。在此基础上再向专业性知识库延伸和发展。专业性知识库或称百科性知识库主要靠专业人员来完成。这里很类似于通用的词典由语言工作者编纂，百科全书则是由各专业的专家编写。

● 知网的特色

知网作为一个知识系统，名副其实是一个网而不是树。它所着力要反映的是概念的共性和个性，同时强调概念之间及概念的属性之间的各种关系。

2. 语义网络



2. 语义网络

◆问题

词义 { 内涵：词本身的意义，是对词代表的概念描述。
外延：词所指代的物体。

- 如何在语义网络（知识图谱）中表示和区分词的内涵和外延？
- 如何确定知识图谱的完备性？
- 如何确定概念、实体、关系划分的粒度？
- 知识图谱与预训练语言模型的关系是什么？
- 知识图谱如何用于端到端的模型？

.....



4.3 语义分析

1. 问题概述
2. 语义网络
- ➡ 3. 语义角色标注
4. 习题

3. 语义角色标注

◆ 语义角色标注任务

自动语义角色标注(semantic role labeling, SRL)是NLP领域研究的热点之一，其基本任务是以句子为分析单位，以句子中的谓词为核心，分析句子中的其他成分与谓词之间的关系。

请分析下面句子的成分：

他们 昨天 在北京 讨论了 方案

句子成分表达的是语义角色吗？



3. 语义角色标注

◆用于SRL的主要资源

- LDC命题库(PropBank)
- LDC名词命题库(NomBank)
- 框架网(FrameNet)

3. 语义角色标注

● 动词命题库(Proposition Bank, PropBank)


起初是在 UPenn 英语树库(English Treebank)的基础上增加语义信息后构建的“命题库”，其基本观点认为：树库仅提供句子的句法结构信息，对于计算机理解人类语言是不够的。因此，PropBank 的目标是对原树库中的句法节点标注上特定的论元标记 (argument label)，使其保持语义角色的相似性。

例如，*John broke the window.*

- 事件是 “打碎 (breaking event)”
- *John* 为事件的 制造者 (instigator)
- *window* 为 受事者 (patient)
- 窗户被打碎 (broken window) 为事件的结果

3. 语义角色标注


例： It operates stores mostly in Iowa and Nebraska.



谓词是operates，它有3个论元：It (ARG0)、stores (ARG1)、mostly in Iowa and Nebraska (ARGM-LOC)，这三个语义角色都处在句法树的某个节点上。

3. 语义角色标注

请看 PropBank 中标注
的中文句子：



3. 语义角色标注

((IP(NP-SBJ (NN 外商) ----- 00
----- (NN 投资) ----- 01
----- (NN 企业)) ----- 02
(VP (PP-TMP (P 在) ----- 03
----- (LCP (IP (NP-SBJ (-NONE- *PRO*)) ----- 04
----- (VP (VV 改善) ----- 05
----- (NP-OBJ (NP-PN (NR 中国)) ----- 06
----- (NP (NN 出口) ----- 07
----- (NN 商品) ----- 08
----- (NN 结构)))) ----- 09
----- (LC 中))) ----- 10
----- (VP (VV 发挥) ----- 11
----- (AS 了) ----- 12
----- (NP-OBJ (ADJP (JJ 显著)) ----- 13
----- (NP (NN 作用)))) ----- 14
(PU 。-)) ----- 15

树结构

3. 语义角色标注

((IP(NP-SBJ (NN 外商)	00
(NN 投资)	01
(NN 企业))	02
(VP (PP-TMP (P 在)	03
(LCP (IP (NP-SBJ (-NONE- *PRO*))	04
(VP (VV 改善)	05
(NP-OBJ (NP-PN (NR 中国))	06
(NP (NN 出口)	07
(NN 商品)	08
(NN 结构))))	09
(LC 中)))	10
(VP (VV 发挥	11
(AS 了)	12
(NP-OBJ (ADJP (JJ 显著))	13
(NP (NN 作用)))	14
文件名 句子号 词序号 标准 动词及框架类型 chtb_0002.fid 4 11 gold 发挥.01 ----- 0:1-ARG0 3:1-ARGM-LOC 13:2-ARG1 11:0-rel	15
chtb_0002.fid 4 5 gold 改善.01 ----- 4:1-ARG0 6:2-ARG1 5:0-rel	

3. 语义角色标注

Frameset: f1

ARG0: *agent*

ARG1: *influence, utility, specialty, etc.*

例句: 今年中国银行仍将继续发挥其在支持外商投资企业方面的主渠道作用。

ARG0: 中国银行

ARG1: 其在 *PRO* 支持外商投资企业方面的主渠道作用

ARGM-TMP: 今年

ARGM-ADV: 仍

ARGM-ADV: 将

REL: 发挥



3. 语义角色标注

Frameset: f2

ARG0: *exerter*

ARG1: *potential, influence, utility, etc.*

例句: 马尔默队的马·尼尔松和斯·尼尔松都发挥出了较高的水平,

ARG0: 马尔默队的马·尼尔松和斯·尼尔松

ARG1: *OP* *T*-1 较高的水平

ARGM-ADV: 都

REL: 发挥

3. 语义角色标注

((IP(NP-SBJ (NN 外商)	-----	00	
-----	(NN 投资)	-----	01
-----	(NN 企业)	-----	02
(VP (PP-TMP (P 在)	-----	03	
-----	(LCP (IP (NP-SBJ (-NONE- *PRO*))	-----	04
-----	(VP (VV 改善)	-----	05
-----	(NP-OBJ (NP-PN (NR 中国))	-----	06
-----	(NP (NN 出口)	-----	07
-----	(NN 商品)	-----	08
-----	(NN 结构))))	-----	09
-----	(LC 中)))	-----	10
(VP (VV 发挥)	-----	11	
-----	(AS 了)	-----	12
-----	(NP-OBJ (ADJP (JJ 显著))	-----	13
-----	(NP (NN 作用))))	-----	14
-----	-----	-----	15

树结构

起始位置、
上溯深度、
语义角色，
ARG0: 施事者

起始位置、上溯深度、
语义角色，ARGM: 修饰
成分，LOC: 地点。

chtb_0002.fid 4 11 gold 发挥.01 -----0:1-ARG03:1-ARGM-LOC

树结构

起始位置、
上溯深度、
语义角色，
ARG0: 施事者

起始位置、上溯深度、
语义角色，**ARGM: 修饰**
成分，**LOC: 地点。**

chtb_0002.fid 4 11 gold 发挥.01 ----- 0:1-ARG0 3:1-ARGM-LOC
13:2-ARG1 11:0-rel
chtb_0002.fid 4 5 gold 改善.01 ----- 4:1-ARG0 6:2-ARG1 5:0-rel

3. 语义角色标注

((IP(NP-SBJ (NN 外商)	00
(NN 投资)	01
(NN 企业))	02
(VP (PP-TMP (P 在)	03
(LCP (IP (NP-SBJ (-NONE- *PRO*))	04
(VP (VV 改善)	05
(NP-OBJ (NP-PN (NR 中国))	06
(NP (NN 出口)	07
(NN 商品)	08
(NN 结构))))))	09
(LC 中)))	10
(VP (VV 发挥)	11
(AS 了)	12
(NP-OBJ (ADJP (JJ 显著))	13
(NP (NN 作用))))	14
chtb_0002.fid 4 11 gold 发挥.01 ----- 0:1-ARG0 3:1-ARGM-LOC	15
13:2-ARG1 11:0-rel	
chtb_0002.fid 4 5 gold 改善.01 ----- 4:1-ARG0 6:2-ARG1 5:0-rel	

树结构

起始位置、上溯
深度、语义角色,
ARG1: 受事者。

起始位置、上溯
深度, 谓词。

3. 语义角色标注

◆ SRL的两类语义角色

- 与具体谓词直接相关的，这些角色用ARG0, ARG1, ..., ARG5表示，如ARG0通常表示动作的施事者，ARG1表示动作的影响(受事者/宾语(object))等，ARG2-ARG5 对于不同的谓语动词会有不同的语义含义；
- 起修饰作用的辅助性角色，其角色标签都以ARGM开头，常见的有表示时间的角色ARGM-TMP，表示地理位置的角色ARGM-LOC，表示一般性修饰成分的角色 ARGM-ADV等。

3. 语义角色标注


中文语义角色标注的语料库主要有 Chinese PropBank (CPB)和Chinese NomBank。它们都是在中文树库(CTB)的句法成分中加入了人工标注的语义角色信息，也把语义角色分为两类：①核心语义角色 ARG0, ARG1, ..., ARG4, 如ARG0表示动作的施事者, ARG1表示受事者；②起修饰作用的辅助性角色，其角色标签都以ARGM开头，如ARGM-TMP表示时间, ARGM-LOC表示地点等。

➤ **CPB 3.0:** <https://catalog.ldc.upenn.edu/LDC2013T13>

语义角色	角色描述
ARG0	施事者
ARG1	受事者
ARG2	范围或程度
ARG3	动作起点
ARG4	动作结束点
ARGM-ADV	状语
ARGM-BNF	受益者
ARGM-CND	条件
ARGM-DIR	方向
ARGM-LOC	地点
ARGM-MNR	方式
ARM-PRP	目的
ARGM-TMP	时间
ARGM-TPC	主题
ARGM-PRD	次谓词

3. 语义角色标注

◆ 标注方法



(1) 基于短语结构树

(2) 基于依存关系

(3) 基于语块

3. 语义角色标注


(1) 基于短语结构树的SRL统计分析方法(Xue and Palmer, 2004)

- 候选论元剪枝

第1步：将谓词作为当前节点，依次考察它的兄弟节点：如果一个兄弟节点和当前节点在句法结构上不是并列的(coordinated)关系，则将它作为候选项。如果该兄弟节点的句法标签是PP(介词短语)，则将它所有的子节点也都作为候选项。

第2步：将当前节点的父节点设为当前节点，重复第1步的操作，直至当前节点是句法树的根节点。

3. 语义角色标注




3. 语义角色标注

● 论元识别和标注

论元识别和标注看作一个分类问题，在这一阶段最重要的工作是为分类器选择有效的特征。常用的一些有效特征有：

- 谓词本身
- 路径(path): 句法树上从论元到谓词的路径，如上面图中的A0 论元到谓词的路径就是：
NP↑IP↓VP↓VP ↓VP↓VV





3. 语义角色标注

- 短语类型(phrase type): 论元所对应的句法树节点的句法标签
 - 位置(position): 论元出现在谓词之前还是之后
 - 语态(Voice): 谓词是主动语态还是被动语态
 - 中心词(Head Word): 论元的中心词及其词性
 - 从属类别(Sub-categorization): 展开谓词父节点的上下文无关规则, 如前面图中谓词的从属类别就是
VP → ADVP ADVP VP
 - 论元的第一个和最后一个词
 - 组合特征(Combination features): 谓词 + 中心词, 谓词+ 短语类型等。
- 分类器: 贝叶斯、最大熵、SVM、感知机等。


3. 语义角色标注

(2) 基于依存关系的SRL统计分析方法

- 与基于短语结构句法分析的SRL方法的区别在于：

基于短语结构句法分析的语义角色标注方法中，一个论元被表示为连续的几个词（短语）和一个语义角色标签。而在基于依存句法分析的语义角色标注中，一个论元被表示为一个中心词和一个语义角色标签。因此，在这种方法中，谓词论元关系可以表示为谓词与论元的中心词之间的关系。

3. 语义角色标注



3. 语义角色标注


- 实现方法

- 确定候选论元

第1步: 将谓词作为当前节点，将它所有的孩子都作为候选项；

第2步: 将当前节点设为它的父节点，重复第1步的操作，直到当前节点是依存句法树的根节点。

3. 语义角色标注



将谓词“调查”的所有孩子节点“正在，详细，原因，警察”都加入到候选项中。该例中恰巧这些孩子节点是谓词的所有论元。

3. 语义角色标注

➤ 论元的识别和标注

从上述过程可以看出，基于依存句法的语义角色标注最终都是在判断谓词和候选的词之间的关系。于是，无论是论元的识别还是论元的标注，其核心都是判断一对词之间的关系。论元识别和论元标注都被作为分类问题。几种最常用的特征包括：

- 谓词(predicate): 谓词本身及其词根
- 谓词的词义: 谓词在语料中的词义类别
- 谓词词性(predicate POS): 谓词的词性
- 谓词父节点的词及词性
- 谓词与其父节点之间的依存关系类别
- 依存关系路径(relation path): 依存句法树上从候选词到谓词的路径；例如上图中从“事故”到谓词的路径就是NMOD↑OBJ ↑

3. 语义角色标注

- 位置(position): 论元出现在谓词之前还是之后
- 语态(voice): 谓词是主动语态还是被动语态
- 从属类别(dependency sub-categorization): 谓词的所有孩子对它的依存关系, 如上图
中谓词“调查”的依存从属类别是SBJ_VMOD_VMOD_OBJ
- 候选词本身
- 候选词最左边和最右边的孩子的词与词性
- 候选词左边和右边最近的兄弟的词与词性
- 分类器: 贝叶斯、最大熵、SVM、感知机等。

3. 语义角色标注

(3) 基于语块分析的SRL方法

用语块分析(Chunking)的结果来进行语义角色标注。谓词 - 论元关系的表示方法与基于短语句法分析中的表示方法相同，每一个论元都表示为连续的几个词，将语义角色标注作为一个序列标注任务。

- **基本思路**：将语义角色标注作为一个序列标注问题来解决。一般采用BIO(分别表示：开始、属于、不属于)的方式来定义序列标注的标签集，将不同的语块赋予不同的标签。

不需要剪除候选论元，论元识别和标注同时进行。

3. 语义角色标注

● 举例：

句子	警察	已	到现场	，	正在	详细	调查	事故	原因
语块	[NP]	[ADVP]	[VP]		[ADVP]	[ADVP]	[VP]	[NP]	[NP]
序列	B-A0	0	0		B-AM-TMP	B-AM-MNR	B-V	B-A1	I-A1
角色	[A0]				[AM-TMP]	[AM-MNR]	[V]	[A1]	


◆ 标注方法：

● CRFs

● LSTM+CRFs

3. 语义角色标注


(4)基于Deep Learning 的SRL方法 — A



Z. Li et al., Dependency or Span, End-to-End Uniform Semantic Role Labeling. *Proc. of AAAI 2019*

3. 语义角色标注

(4)基于Deep Learning 的SRL方法 — B



BERT based end-to-end framework.

E. Spaulding et al., Joint End-to-End Semantic Proto-role Labeling. *Proc. ACL 2023, Vol. 2* (short paper), pages 723–736

3. 语义角色标注

◆ 已有方法的主要问题

- 对句法分析器性能的严重依赖性
- 领域适应能力差

◆ 基本性能

- 在规范文本上，英语和汉语SRL标注的F1值超过90%，汉语的性能略逊于英语。

3. 语义角色标注

◆大模型的分析结果

输入：警察已到现场，正在详细调查事故原因。



这句话的语义角色标注结果如下：

 复制代码

```
1  [并列关系]
2  └─ [动词]到
3  │   └─ [施事] 警察
4  │   └─ [受事] 现场
5  └─ [动词]正在调查
6      └─ [施事] 警察
7      └─ [修饰] 详细
8      └─ [受事] 原因
9          └─ [修饰] 的 事故
```

其中，[施事]表示动作、行为的发出者；[受事]表示动作行为直接的承受者；[并列关系]表示存在并列关系，是对一般的非核心语义关系的重要补充。

3. 语义角色标注



对句子“警察已到现场，正在详细调查事故原因。”进行语义角色标注，我们可以分解出以下成分：

- 谓词 (Predication) : 调查
- 施事者 (Agent) / 主语 (Subject) : 警察
- 受事者 (Patient) / 宾语 (Object) : 事故原因
- 方位/地点 (Location) : 现场
- 方式/程度 (Manner) : 详细

具体标注如下：

- 警察 [ARG0 / 施事者]
- 已到 [ARGM-TMP / 时间副词] (表示动作已经完成)
- 现场 [ARGM-LOC / 地点] (表示动作发生的地点)
- 正在详细 [ARGM-MNR / 方式] (表示动作的方式)
- 调查 [PRED / 谓词]
- 事故原因 [ARG1 / 受事者]

整个句子可以分解为两部分，第一部分描述了警察到达现场的情况，第二部分描述了警察正在进行的动作。为了简化，我们只关注“调查”这一谓词及其相关的语义角色。



◆ 概述

语义分析的基本任务及其面临的困难。

◆ 语义网络

概念、关系、语义网络表示、事件的语义关系。

◆ 语义角色标注方法

● 基本任务

● PropBank

● 基本方法：基于句法结构，基于依存关系，基于语块。统计分类；序列标注。



4.3 语义分析

1. 问题概述

2. 语义网络

3. 语义角色标注

➡ 4. 习题

5. 习题

1. 请测试分析大语言模型在词义消歧任务上的性能，对比分析不同语言模型的差异。
2. 请测试分析大语言模型在语义角色标注任务上的性能，对比分析不同语言模型的差异。
3. 请查阅深度学习方法用于语义角色标注的论文，了解最新进展。
4. 请设计实现一种基于神经网络端到端的语义角色标注方法。
5. 请阅读有关 HowNet 理论的文献，学习其思想方法。

谢谢!
Thanks!

