

第4章 传统NLP技术简介

(2/3)

宗成庆

中国科学院自动化研究所

cqzong@nlpr.ia.ac.cn

4.2 句法分析



1. 短语结构分析



2. 依存关系分析

3. 习题

4. 附录

◆ 任务

◆ 目标和困难

◆ 分析方法

◆ 方法评价

1. 短语结构分析

◆ 短语结构分析任务

短语结构分析(phrase structure parsing)又称成份结构分析(constituent structure parsing), 或简称句法分析(syntactic parsing), 其任务是识别句子的结构关系。例如, 给定如下句子:

他还提出一系列具体措施的政策要点。


1. 短语结构分析

句子结构:

```
( IP (NP-SBJ (PN 他 ))  
    (VP (ADVP ( AD 还 ))  
        (VP (VV 提出 ))  
            (NP-OBJ (QP (CD 一)  
                      (CLP ( M 系列 )))  
                          (NP (NP (ADJP ( JJ 具体)  
                                         (NP (NN 措施)))  
                        ( CC 和)  
                        ( NP ( NN 政策 )  
                          ( NN 要点 ))))))  
    ( PU 。 ))
```

1. 短语结构分析

树状图:



被分析的句子构成一棵完整的句法分析树。因此，这种分析过程被称为完全句法分析(full parsing)。

1. 短语结构分析

对于汉语而言，需要完成如下三个任务：

(1) 词语切分：

他/ 还/ 提出/ 一/ 系列/ 具体/ 措施/ 和/ 政策/ 要点/ 。

(2) 词性标注：

他/PN 还/AD 提出/VV 一/CD 系列/M 具体/JJ 措施/NN 和/CC 政策/NN
要点/NN 。/PU

(3) 结构分析：设计分析算法。可以与词性标注过程一起考虑。

1. 短语结构分析

有时候，并不需要分析整个句子的完整结构，而只需要分析句子中的某些短语，如“基本名词短语(base NP)”：

你们是咱们学院最优秀的学生。



[你们] 是 [咱们学院最优秀的学生]。

如果只分析句子中某种类型的短语结构，这种分析过程称为局部句法分析 (partial parsing)。

请见附录

1. 短语结构分析

◆设计句法分析器的目标

实现高准确率、高鲁棒性(robustness)、快速的句子结构自动分析过程。

◆困难

自然语言中存在大量的复杂的结构歧义(structural ambiguity)。

例如：(1) I saw a boy with a telescope **in the park**

[I saw a boy] with a telescope

I saw a **[boy with a telescope]**

(2) 关于鲁迅的文章。

(3) 把重要的书籍和手稿带走了。

1. 短语结构分析

◆ 基本方法

● 基于CFG规则的分析方法

- ✧ 线图分析法(chart parsing)
- ✧ CYK 分析算法
- ✧ Earley (厄尔利)算法
- ✧ LR 算法 / Tomita 算法... ..

请见附录

● PCFG 分析方法基本思路

● 基于神经网络的分析方法

请见附录

1. 短语结构分析

◆Coke-Younger-Kasami (CYK) 分析算法


- 对 Chomsky 上下文无关文法进行范式化:

$$A \rightarrow w \text{ 或 } A \rightarrow BC$$


$$A, B, C \in V_N, w \in V_T, G=(V_N, V_T, P, S)$$

- 自下而上的分析方法。
- 构造 $(n+1) \times (n+1)$ 识别矩阵, n 为输入句子长度。假设输入句子 $x=w_1w_2\cdots w_n$, 其中, w_i 为构成句子的单词, $n=|x|$ 。方阵对角线以下全部为0
- 主对角线上的元素为输入句子的终结符(单词), 主对角线以上是文法 G 的非终结符。

1. 短语结构分析




1. 短语结构分析






1. 短语结构分析





1. 短语结构分析



1. 短语结构分析

◆ 算法描述

- (1) 首先构造主对角线，令 $t_{0,0}=0$ ，然后，从 $t_{1,1}$ 到 $t_{n,n}$ 在主对角线的位置上依次放入输入句子 x 的单词 w_i 。
- (2) 构造主对角线以上紧靠主对角线的元素 $t_{i,i+1}$ ，其中， $i = 0, 1, 2, \dots, n-1$ 。对于输入句子 $x = w_1 w_2 \dots w_n$ ，从 w_1 开始分析。

如果在文法 G 的产生式集中有一条规则为如下形式：

$$A \rightarrow w_1$$

则 $t_{0,1}=A$ 。依此类推，如果有 $A \rightarrow w_{i+1}$ ，则 $t_{i,i+1}=A$ 。即对于主对角线上的每一个终结符 w_i ，所有可能推导出它的非终结符写在它的右边主对角线上方的位置上。

1. 短语结构分析

(3) 按平行于主对角线的方向，一层一层地向上填写矩阵的各个元素 $t_{i,j}$ ，其中，
 $i = 0, 1, \dots, n-d$, $j = d+i$, $d=2, 3, \dots, n$ 。如果存在一个正整数 k , $i+1 \leq k \leq j-1$ ，在文法 G 的规则集中有产生式 $A \rightarrow BC$ ，并且， $B \in t_{i,k}$, $C \in t_{k,j}$ ，那么，将 A 写到矩阵 $t_{i,j}$ 位置上。

判断句子 x 由文法 G 所产生的充要条件是： $t_{0,n}=S$ 。

1. 短语结构分析

◆ 例子

给定文法 $G(S)$:

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

(4) $P \rightarrow \text{他}$

(5) $V \rightarrow \text{喜欢}$

(6) $V \rightarrow \text{读}$

(7) $N \rightarrow \text{书}$

请用 CYK 算法分析句子: 他喜欢读书

1. 短语结构分析

(1) 进行汉语分词和词性标注，结果如下：

他/P 喜欢/V 读/V 书/N

(2) 构造识别矩阵， $n=4$ ：

G(S):

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

.....

	0	1	2	3	4
0		P	?		
1		他	V		
2			喜欢	V	
3				读	N
4					书

1. 短语结构分析

(1) 进行汉语分词和词性标注，结果如下：

他/P 喜欢/V 读/V 书/N

(2) 构造识别矩阵， $n=4$ ：

G(S):

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

.....

	0	1	2	3	4
0		P			
1		他	V	?	
2			喜欢	V	
3				读	N
4					书

1. 短语结构分析

(1) 进行汉语分词和词性标注，结果如下：

他/P 喜欢/V 读/V 书/N

(2) 构造识别矩阵， $n=4$ ：

G(S):

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

.....

	0	1	2	3	4
0		P	P		
1		他	V	VP	
2			喜欢	V	N
3				读	N
4					书

1. 短语结构分析

(1) 进行汉语分词和词性标注，结果如下：

他/P 喜欢/V 读/V 书/N

(2) 构造识别矩阵， $n=4$ ：

G(S):

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$

(3) $VP \rightarrow VP \ N$

.....

	0	1	2	3	4
0		P	P	S?	
1		他	V	VP	
2			喜欢	V	N
3				读	N
4					书

1. 短语结构分析

(1) 进行汉语分词和词性标注，结果如下：

他/P 喜欢/V 读/V 书/N

(2) 构造识别矩阵， $n=4$ ：

G(S):

(1) $S \rightarrow P \ VP$

(2) $VP \rightarrow V \ V$


(3) $VP \rightarrow VP \ N$

.....

	0	1	2	3	4
0		P	P	P	S
1		他	V	VP	VP
2			喜欢	V	N
3				读	N
4					书

1. 短语结构分析

分析结果:



◆CYK 算法的评价

● 优点

- 实现简单，执行效率高

● 弱点

- 文法需要范式化处理
- 无法区分歧义

1. 短语结构分析

◆ 概率上下文无关文法

(probabilistic/stochastic context-free grammar, PCFG/SCFG)

规则形式: $A \rightarrow \alpha, p$

约束: $\sum_{\alpha} p(A \rightarrow \alpha) = 1$


例如: $NP \rightarrow NN \ NN, 0.50$	}	$\Sigma p=1$
$NP \rightarrow Nf \ Ng, 0.30$		
$NP \rightarrow A \ NN, 0.20$		
$CD \rightarrow Num \ Num, 0.85$	}	$\Sigma p=1$
$CD \rightarrow Num \ DM, 0.15$		

1. 短语结构分析


- 例子: $S \rightarrow NP \ VP, 1.00$
 - $NP \rightarrow NP \ PP, 0.40$
 - $NP \rightarrow \text{astronomers}, 0.10$
 - $NP \rightarrow \text{ears}, 0.18$
 - $NP \rightarrow \text{stars}, 0.18$
 - $PP \rightarrow P \ NP, 1.00$
 - $VP \rightarrow V \ NP, 0.70$
 - $V \rightarrow \text{saw}, 1.00$
 - $NP \rightarrow \text{saw}, 0.04$
 - $NP \rightarrow \text{telescopes}, 0.1$
 - $P \rightarrow \text{with}, 1.00$
 - $VP \rightarrow VP \ PP, 0.30$

给定句子: *Astronomers saw stars with ears.*

1. 短语结构分析



1. 短语结构分析




1. 短语结构分析


◆ 计算分析树概率的基本假设

- **位置不变性**: 子树的概率与其管辖的词在整个句子中所处的位置无关, 即对于任意的 k , $p(A_{k(k+C)} \rightarrow w)$ 一样。
- **上下文无关性**: 子树的概率与子树管辖范围以外的词无关, 即: $p(A_{kl} \rightarrow w | \text{任何超出 } k \sim l \text{ 范围的上下文}) = p(A_{kl} \rightarrow w)$ 。
- **祖先无关性**: 子树的概率与推导出该子树的祖先结点无关, 即:
 $p(A_{kl} \rightarrow w | \text{任何除 } A \text{ 以外的祖先结点}) = p(A_{kl} \rightarrow w)$ 。

1. 短语结构分析



1. 短语结构分析




$$\begin{aligned}
 p(t_1) &= p(S \rightarrow NP \ VP) \times \\
 &= p(NP \rightarrow \text{Astr.}) \times p(\text{Tree}_{VP}) \\
 &= 1 \times 0.1 \times p(VP \rightarrow V \ NP) \times p(\text{Tree}_{NP}) \\
 &= 0.1 \times 0.7 \times 1 \times 0.4 \times 0.18 \times p(\text{Tree}_{PP}) \\
 &= 0.0009072
 \end{aligned}$$

1. 短语结构分析

$$\begin{aligned}
 p(t_2) &= 1.00 \times 0.10 \times 0.30 \times \\
 &\quad 0.70 \times 1.00 \times 0.18 \times \\
 &\quad 1.00 \times 1.00 \times 0.18 \\
 &= 0.0006804
 \end{aligned}$$

对于给定的句子S，两棵句法分析树的概率不等， $p(t_1) > p(t_2)$ ，因此，可以得出结论：分析结果 t_1 正确的可能性大于 t_2 。



1. 短语结构分析

◆ PCFG的三个问题

- 给定句子 $S=w_1w_2\dots w_n$ 和 PCFG G , 如何快速地计算 $p(S|G)$?
- 给定句子 $S=w_1w_2\dots w_n$ 和 PCFG G , 如何快速地选择最佳句法结构树?
- 给定句子 $S=w_1w_2\dots w_n$ 和 PCFG G , 如何调节 G 的参数, 使得 $p(S|G)$ 最大?

请见附录

1. 短语结构分析

◆PCFG Parser 执行过程示例

给定如下 PCFG $G(S)$: $V_N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$; $V_T = \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$;

规则集 P:

(1) $S \rightarrow NP VP$	1.0	(7) $PP \rightarrow IN NP$	1.0	(13) $NN \rightarrow \text{dog}$	0.5
(2) $VP \rightarrow Vi$	0.3	(8) $Vi \rightarrow \text{sleeps}$	1.0	(14) $DT \rightarrow \text{the}$	0.5
(3) $VP \rightarrow Vt NP$	0.4	(9) $Vt \rightarrow \text{saw}$	1.0	(15) $DT \rightarrow \text{a}$	0.5
(4) $VP \rightarrow VP PP$	0.3	(10) $NN \rightarrow \text{man}$	0.1	(16) $IN \rightarrow \text{with}$	0.6
(5) $NP \rightarrow DT NN$	0.8	(11) $NN \rightarrow \text{woman}$	0.1	(17) $IN \rightarrow \text{in}$	0.4
(6) $NP \rightarrow NP PP$	0.2	(12) $NN \rightarrow \text{telescope}$	0.3		

输入句子: the man saw the dog with a telescope

DT 0.5							
[0,1]	[0,2]	[0,3]	[0,4]	[0,5]	[0,6]	[0,7]	[0,8]
the	[1,2]	[1,3]	[1,4]	[1,5]	[1,6]	[1,7]	[1,8]
	man	[2,3]	[2,4]	[2,5]	[2,6]	[2,7]	[2,8]
		saw	[3,4]	[3,5]	[3,6]	[3,7]	[3,8]
			the	[4,5]	[4,6]	[4,7]	[4,8]
				dog	[5,6]	[5,7]	[5,8]
					with	[6,7]	[6,8]
						a	[7,8]
							telescope

第1步:

DT → the 0.5

DT 0.5							
[0,1]	[0,2]	[0,3]	[0,4]	[0,5]	[0,6]	[0,7]	[0,8]
the	NN 0.1						
	[1,2]	[1,3]	[1,4]	[1,5]	[1,6]	[1,7]	[1,8]
	man						
		[2,3]	[2,4]	[2,5]	[2,6]	[2,7]	[2,8]
		saw					
			[3,4]	[3,5]	[3,6]	[3,7]	[3,8]
			the				
				[4,5]	[4,6]	[4,7]	[4,8]
				dog			
					[5,6]	[5,7]	[5,8]
					with		
						[6,7]	[6,8]
						a	
							[7,8]
							telescope

第2步:

NN → man 0.1

DT 0.5	NP 0.04						
[0,1]	[0,2]	[0,3]	[0,4]	[0,5]	[0,6]	[0,7]	[0,8]
the	NN 0.1						
	[1,2]	[1,3]	[1,4]	[1,5]	[1,6]	[1,7]	[1,8]
	man						
		[2,3]	[2,4]	[2,5]	[2,6]	[2,7]	[2,8]
		saw					
			[3,4]	[3,5]	[3,6]	[3,7]	[3,8]
			the				
				[4,5]	[4,6]	[4,7]	[4,8]
				dog			
					[5,6]	[5,7]	[5,8]
					with		
						[6,7]	[6,8]
						a	
							[7,8]
							telescope

第3步:

NP → DT NN 0.8

DT 0.5	NP 0.04						
[0,1]	[0,2]	[0,3]	[0,4]	[0,5]	[0,6]	[0,7]	[0,8]
the	NN 0.1						
	[1,2]	[1,3]	[1,4]	[1,5]	[1,6]	[1,7]	[1,8]
	man	Vt 1.0					
		[2,3]	[2,4]	[2,5]	[2,6]	[2,7]	[2,8]
		saw	DT 0.5				
			[3,4]	[3,5]	[3,6]	[3,7]	[3,8]
			the	NN 0.5			
				[4,5]	[4,6]	[4,7]	[4,8]
				dog			
					[5,6]	[5,7]	[5,8]
					with		
						[6,7]	[6,8]
						a	
							[7,8]
							telescope

第4~6步:

Vt → saw 1.0


DT → the 0.5


NN → dog 0.5


DT 0.5	NP 0.04						
[0,1]	[0,2]	[0,3]	[0,4]	[0,5]	[0,6]	[0,7]	[0,8]
the	NN 0.1						
	[1,2]	[1,3]	[1,4]	[1,5]	[1,6]	[1,7]	[1,8]
	man	Vt 1.0					
		[2,3]	[2,4]	[2,5]	[2,6]	[2,7]	[2,8]
		saw	DT 0.5	NP 0.2			
			[3,4]	[3,5]	[3,6]	[3,7]	[3,8]
			the	NN 0.5			
				[4,5]	[4,6]	[4,7]	[4,8]
				dog			
					[5,6]	[5,7]	[5,8]
					with		
						[6,7]	[6,8]
						a	
							[7,8]
							telescope


第7步:


NP → DT NN 0.8





















1. 短语结构分析




句法树 t_1







1. 短语结构分析



句法树 t_2

1. 短语结构分析

◆ 基于PCFG 的分析方法评价

● 优点:

- 可利用概率进行子树剪枝，减少分析过程的搜索空间，加快分析效率；
- 可以定量地比较两个句法分析器的性能。

● 弱点:

- 分析树的概率计算条件比较苛刻，甚至不够合理。

1. 短语结构分析

◆ 短语结构分析结果评价

目前广泛使用的句法分析器性能评价指标是PARSEVAL评测提出的，主要包括如下几个：

- 精度(precision)：句法分析结果中正确的短语个数所占的比例，即分析结果中与标准分析树（答案）中的短语相匹配的个数占分析结果中所有短语个数的比例，即：

$$P = \frac{\text{分析得到的正确的短语个数}}{\text{分析得到的所有的短语个数}} \times 100\%$$

1. 短语结构分析

- 召回率(recall): 句法分析结果中正确的短语个数占标准分析树中全部短语个数的比例, 即:

$$R = \frac{\text{分析得到的正确的短语个数}}{\text{标准树库中(答案)的短语个数}} \times 100\%$$

- F-measure:

$$F = \frac{(\beta^2 + 1) \times P \times R}{\beta^2 \times P + R}$$

一般地, $\beta = 1$, 称作 $F1$ 测度。

1. 短语结构分析

- 交叉括号数(crossing brackets): 一棵分析树中与其他分析树中边界相交叉的成分个数的平均值。

分析树中除了词性标注符号以外的其他非终结符节点采用如下标记格式: **XP-(起始位置: 终止位置)**。其中, **XP**为短语名称; **(起始位置: 终止位置)**为该节点的跨越范围, **起始位置**指该节点所包含的子节点的起始位置, **终止位置**为该节点所包含的子节点的终止位置。在计算PARSEVAL指标时, 通常需要计算分析结果与标准分析树之间括号匹配的数目或括号交叉的数目。


例如, 下面的图(a)为句子:

Sales executives were examining the figures with great care yesterday.

正确的分析树(答案标准)。

1. 短语结构分析


(a) 句法分析实例 (标准答案)



在标准答案树中，除了词性标注符号以外(即除了叶子节点和其直接父节点以外)的其他非终结符节点(短语)有：S-(0:11), NP-(0:2), VP-(2:9), VP-(3:9), NP-(4:6), PP-(6:9), NP-(7:9), *NP-(9:10)。

1. 短语结构分析

(b)系统分析结果



在系统输出的分析树中，除了词性标注符号以外的其他非终结符节点(短语)有：

S-(0:11), NP-(0:2),
VP-(2:10), VP-(3:10),
NP-(4:10), NP-(4:6),
PP-(6:10), NP-(7:10)。

1. 短语结构分析

标准答案: S-(0:11), NP-(0:2), VP-(2:9), VP-(3:9), NP-(4:6), PP-(6:9), NP-(7:9), *NP-(9:10)

系统结果: S-(0:11), NP-(0:2), VP-(2:10), VP-(3:10), NP-(4:10), NP-(4:6), PP-(6:10),
NP-(7:10)

只有这3个短语与标准答案完全一样，因此，

$$\text{Precision} = \frac{3}{8} \times 100\% = 37.5\%$$

$$\text{Recall} = \frac{3}{8} \times 100\% = 37.5\%$$

注：图(a)中加*号的一元的节点 (*NP) 在实际情况下计算时应该被排除在外，但在这里也被包括进来了。



1. 短语结构分析

◆ 部分短语结构分析器

✧ Berkeley Parser: <http://nlp.cs.berkeley.edu/Main.html#Parsing>

✧ Stanford Parser: <http://nlp.stanford.edu/downloads/lex-parser.shtml>

✧ Collins Parser: <http://people.csail.mit.edu/mcollins/code.html>

✧ Charniak Parser: <http://www.cs.brown.edu/people/ec/#software>

✧ Bikel Parser: <http://www.cis.upenn.edu/~dbikel/software.html#stat-parser>

☀ Oboe Parser (可执行程序):

<http://www.openpr.org.cn/index.php/NLP-Toolkit-for-Natural-Language-Processing/>

1. 短语结构分析

◆性能现状

- ✧ 英文规范文本的句法分析准确率大约在95%左右（取决于句子结构的复杂性和规范程度）；
- ✧ 汉语句法分析准确率略逊于英语的分析性能；
- ✧ 对非规范文本而言，准确率大幅度降低。

◆主要问题和挑战

- ✧ 模型对训练样本的依赖性强，缺乏泛化能力，鲁棒性差；
- ✧ 缺乏足够规模的标注样本；
- ✧ 在实际应用任务中面对的语料复杂（领域、生词、非规范性等）。

4.2 句法分析

1. 短语结构分析



2. 依存关系分析



- ◆ 依存关系分析任务
- ◆ 依存关系分析方法
- ◆ 分析结果评价

3. 习题

4. 附录

2. 依存关系分析

◆ 依存语法理论

现代依存语法(dependency grammar)理论的创立者是法国语言学家吕西安 泰尼埃 (Lucien Tesnière, 其姓氏也被译作: 特思尼耶尔或特尼耶尔)(1893.5-1954.12)。他的主要成就是提出“结构句法”理论, 后称“依存语法”或“从属语法”。为了提出一种普适的语法理论, 他作了大量的语言对比研究, 从1939年起他开始撰写巨著《结构句法基础》(Élément de Syntaxe Structurale), 边写边改, 历时十余载, 直到1950年才完成。1954年泰尼埃去世之后, 他的朋友们整理了他的遗稿, 于1959年出了《结构句法基础》的初版, 1965年出了第二版。

冯志伟: “泰尼埃与依存语法”,
见《现代语文》2014年第11期

2. 依存关系分析

L. Tesnière 的理论认为:

一切结构句法现象可以概括为关联(connexion)、组合(jonction)和转位(tanslation)这三大核心。句法关联建立起词与词之间的从属关系，这种从属关系是由支配词和从属词联结而成；动词是句子的中心，并支配其他成分，它本身不受其他任何成分的支配。

欧洲传统的语言学突出一个句子中主语的地位，句中其它成分称为“谓语”。依存语法打破了这种主谓关系，认为“谓语”中的动词是一个句子的中心，其他成分与动词直接或间接地产生联系。


2. 依存关系分析

Tesnière 在《结构句法基础》中将化学中“价”的概念引入到依存语法中。“价”亦称“配价”或“向”(valence/ valency), 一个动词所能支配的行动元(名词词组)的个数即为该动词的价数。也就是说, 它能支配几个行动元, 它就是几价动词。例如, 汉语中的零价动词: “地震、刮风”; 一价动词: “病、醉、休息、咳嗽、游泳”等; 二价动词: “爱、采、参观、讨论”等; 三价动词: “给、送、告诉、赔偿”等。


在依存语法理论中, “依存”就是指词与词之间支配与被支配的关系, 这种关系**不是对等的, 而是有方向的**。处于支配地位的成分称为支配者(governor, regent, head), 而处于被支配地位的成分称为从属者(modifier, subordinate, dependency)。

2. 依存关系分析

◆ 依存关系表示




(a) 有向图



(b) 有向图


两个有向图用带有方向的弧(或称边, edge)来表示两个成分之间的依存关系, **支配者在有向弧的发出端, 被支配者在箭头端**, 我们通常说被支配者依存于支配者。

2. 依存关系分析



(c) 依存树

图(c)是用树表示的依存结构，树中子节点依存于该节点的父节点。



(d) 依存投射树

图(d)是带有投射线的树结构，实线表示依存联结关系，位置低的成份依存于位置高的成份，虚线为投射线。

2. 依存关系分析

◆ 依存语法的四条公理

1970年计算语言学家 J. Robinson在论文《依存结构和转换规则》中提出了依存语法的4条公理：

- (1) 一个句子只有一个独立的成分；
- (2) 句子的其他成分都从属于某一成分；
- (3) 任何一成分都不能依存于两个或多个成分；
- (4) 如果成分A直接从属于成分B，而成分C在句子中位于A和B之间，那么，成分C或者从属于A，或者从属于B，或者从属于A和B之间的某一成分。

2. 依存关系分析


这4条公理相当于对依存图和依存树的形式约束为：

- 单一父结点(single headed)
- 连通(connective)
- 无环(acyclic)
- 可投射(projective)

由此保证了句子的依存分析结果是一棵有“根(root)”的树结构。

2. 依存关系分析

◆ 投射(projective)与非投射(no-projective)




2. 依存关系分析

◆ 依存关于确定的基本原则

- 谓语动词为句子的中心词
- 名词短语的中心词一般在右边；如果左边为人名、右边为称谓名词时，人名为中心词；数量词短语中数字为中心词；
- 动词短语的中心词为动词；
- 介词短语的中心词为介词；
- 连词短语的中心词为连词；
- “的”字结构的中心词为“的”。

2. 依存关系分析

◆标注示例



?

我们 要 向 雷锋 同志 学习



2. 依存关系分析

从 今 天 起 他 正 式 成 为 我 们 班 的 同 学 。

2. 依存关系分析

◆ 依存语法的优势

- 简单，直接分析词语之间的依存关系，是天然词汇化的；
- 不过多强调句子中的固定词序，对自由语序的语言分析更有优势；
- 受深层语义结构的驱动，词汇的依存本质是语义的；
- 与短语结构语法相比，其形式化程度较浅，对句法结构的表述更为灵活。

2. 依存关系分析

◆ 依存关系分析方法概览

输入：句子 x ；

输出：依存结构 y ，通常采用有向图描述。

目前依存句法结构描述一般采用有向图方法或依存树方法，所采用的句法分析算法可大致归为以下几类：

- 生成式分析方法(generative parsing)
- 判别式分析方法(discriminative parsing)
- 决策式(确定性)分析方法(deterministic parsing)
- 基于约束满足的分析方法(constraint satisfaction parsing)
- 神经网络方法与决策方法相结合 请见附录

2. 依存关系分析

◆ 决策式(确定性)方法(deterministic parsing)

✧ 基本思想：模仿人的认知过程，按照特定方向每次读入一个词，每次都要根据当前状态做出决策，如判断当前读入的词是否与前一个词发生依存关系。一旦做出决策，之后不再改变。所谓的决策就是“采取什么样的分析动作(action)”。分析过程可以看作是一步一步地作用于输入句子之上的一系列分析动作(action)。

2. 依存关系分析

✧ 移进-归约算法(shift-reduce algorithm)

J. Nivre 等人2003年提出了一种自左向右、自底向上的分析算法，基本思路如下：
当前分析状态的格局(configuration)是一个三元组：(S, I, A)，S 表示栈顶词(Stack)、I表示未处理序列中的当前词(Input)，A表示依存弧集合(Arcs)。4种操作(actions)：Left-Arc（依存弧向左指）、Right-Arc（依存弧向右指）、Reduce（归约）和 Shift（移进）。用一个stack栈和一个queue输入序列来分别储存已经被处理的词和未被分析的句子中的词。

J. Nivre, and J. Nilsson. Three Algorithms for Deterministic Dependency Parsing. *Proc. of the 15th NODALIDA*, 2003, pp. 47-56

Joakim Nivre and Mario Scholz. Deterministic Dependency Parsing of English Text. *Proc. of COLING'2004*.

2. 依存关系分析

✧ Arc-eager 分析算法:

初始: $(\text{nil}, I, \emptyset)$ 终止: (S, nil, A)


Left-Arc _l	$\frac{[\dots, w_i]_S \quad [w_j, \dots]_{\text{Input}} \quad \neg \exists w_k \rightarrow w_i \in A \quad \text{条件}}{[\dots]_S \quad [w_j, \dots]_{\text{Input}} \quad A \cup \{w_i \xleftarrow{l} w_j\}, \text{pop}(w_i)}$
Right-Arc _r	$\frac{[\dots, w_i]_S \quad [w_j, \dots]_{\text{Input}} \quad \neg \exists w_k \rightarrow w_j \in A}{[\dots w_i, w_j]_S \quad [\dots]_{\text{Input}} \quad A \cup \{w_i \xrightarrow{r} w_j\}, \text{push}(w_j)}$
Reduce	$\frac{[\dots w_i]_S \quad [\dots]_{\text{Input}} \quad \exists w_k \rightarrow w_i \in A}{[\dots]_S \quad [\dots]_{\text{Input}} \quad \text{pop}(w_i)}$
Shift	$\frac{[\dots]_S \quad [w_i, \dots]_{\text{Input}}}{[\dots w_i]_S \quad [\dots]_{\text{Input}} \quad \text{push}(w_i)}$

对当前词 w_i 的操作。横上是动作执行之前的句子状态，线下执行动作及之后的句子状态。


2. 依存关系分析

✧ 举例


给定如下句子：脚步声打断了我的沉思




2. 依存关系分析



2. 依存关系分析




2. 依存关系分析




可以看出，一旦子节点在父节点的左边，执行left_arc后可以马上归约，但如果子节点在父节点的右边，则不能马上把右边的孩子归约掉，因为也许这个孩子还有孩子在更右边的位置，还没有遍历到。(主要是由从左到右的遍历顺序导致的)。

2. 依存关系分析



2. 依存关系分析

是一种阶段性的方法，
认为每一步都是对的！



2. 依存关系分析

✧方法评价

➤优点:

- 算法可以使用之前产生的所有句法结构作为特征;
- 可以达到线性复杂度: $O(n)$ 。

➤弱点:

- 以局部最优的加和代替全局最优, 导致错误传递;
- 不可处理非投射现象, 准确率稍逊于全局最优算法。



2. 依存关系分析

✧ Arc-eager 算法的实现

- 基本思路: 在每一个状态(configuration)下根据当前状态提取特征, 然后通过分类器决定下一步应该采取的“动作”(action): 移进(shift)、左弧(left-arc)、右弧(right-arc)、归约(reduce), 选择最优动作执行, 转换到下一个状态。
- 具体实现: ①标注大量的依存关系句法树, 建立训练集。每个句子都可以一对一地转换为动作序列; ②确定特征集合, 构造动作分类器。

2. 依存关系分析

假设有足够多的训练集：




2. 依存关系分析

假设选取如下特征构造分类器：word/w: 词； pos/p: 词性； lc: left_most_child; rc: right_most_child; rel: 依存关系。

	word	pos	lc_w	lc_p	lc_rel	rc_w	rc_p	rc_rel
T1	√							
T0	√	√		√	√	√		√
N0	√	√		√	√		√	√
N1	√	√						

其中，N0、N1分别表示Input序列中(即“I”)的前两个token(N0)和token(N1)，依次向后排；T0、T1分别表示Stack栈中(即“S”)最顶的token(T0)、次顶的token(T1)，依次向下排。表中的“√”是指在当前状态下，分类器的特征从哪里取、取什么。如T0和pos对应的框里画√，表示取栈顶词的词性作为特征之一。依此类推。



2. 依存关系分析

根据前面的图(b)得到如下训练实例:

动作 特征序列

Shift T0w:这 T0p:PN N0w:将 N0p:AD N1w:成为 N1p:VV
L_A T1p:PN T0w:将 T0p:AD N0w:成为 N0p:VV N1w:解决 N1p:VV
L_A T0w:这 T0p:PN N0w:成为 N0p:VV N1w:解决 N1p:VV
N0lc_p:AD N0lc_rel:VMOD N0rc_w:将 N0rc_rel:VMOD
Shift T0w:成为 T0p:VV T0lc_p:PN T0lc_rel:SUB N0w:解决 N0p:VV
N1w:伊朗 N1p:NR
Shift T1w:成为 T1p:VV T1lc_p:PN T0lc_rel:SUB T0w:解决
T0p:VV N0w:伊朗 N0p:NR N1w:核 N1p:NN
.....

2. 依存关系分析

根据前面的图(b)得到如下训练实例:

动作 特征序列

Shift T0w:这 T0p:PN N0w:将 N0p:AD N1w:成为 N1p:VV

L_A T1p:PN T0w:将 T0p:AD N0w:成为 N0p:VV N1w:解决 N1p:VV

L_A T0w:这 T0p:PN N0w:成为 N0lc_p:AD N0lc_rel:VMC “将”为栈顶,“成为”为输入序列第一个token时,执行动作“left-arc”(“将”是“成为”的孩子)。

Shift T0w:成为 T0p:VV T0lc_p:PN T0lc_rel:SUB N0w:解决 N0p:VV
N1w:伊朗 N1p:NR

Shift T1w:成为 T1p:VV T1lc_p:PN T0lc_rel:SUB T0w:解决
T0p:VV N0w:伊朗 N0p:NR N1w:核 N1p:NN

.....

“这”为栈顶T0,“将”为输入序列第一个token N0 时,动作类别标签是Shift。

“将”为栈顶,“成为”为输入序列第一个token时,执行动作“left-arc”(“将”是“成为”的孩子)。

2. 依存关系分析


◆ 依存关系分析结果评价

- 无标记依存正确率(unlabeled attachment score, UA 或 UAS): 所有词中找到其正确支配词的词所占的百分比, 没有找到支配词的词(即根结点)也算在内。
- 带标记依存正确率(labeled attachment score, LA 或 LAS): 所有词中找到其正确支配词并且依存关系类型也标注正确的词所占的百分比, 根结点也算在内。
- 依存正确率(dependency accuracy, DA):
所有非根结点词中找到其正确支配词的词所占的百分比。


2. 依存关系分析

◆ 举例说明

✧ 答案依存树为：



✧ 系统输出的依存分析树为：



2. 依存关系分析


✧答案依存树为：

每个词对应的支配词及依存关系为：

外资(2,nmod), 企业(3,sbj), 成为(0,root),

外贸(6, nmod), 重要(6,nmod),

增长点(3,obj), 。(3,p)




✧系统输出的依存分析树为：

每个词对应的支配词及依存关系为：

外资(3,nmod), 企业(3,sbj), 成为

(0,root), 外贸(6,nmod), 重要(6, sbj),

增长点(3,obj), 。(3,p)



2. 依存关系分析


✧答案依存树为：

每个词对应的支配词及依存关系为：

外资(2,nmod), 企业(3,sbj), 成为(0,root),

外贸(6, nmod), 重要(6,nmod),

增长点(3,obj), 。 (3,p)




✧系统输出的依存分析树为：

每个词对应的支配词及依存关系为：

外资(3,nmod), 企业(3,sbj), 成为

(0,root), 外贸(6,nmod), 重要(6, sbj),

增长点(3,obj), 。 (3,p)



$$UA = \frac{6}{7} \times 100\% = 85.71\%$$

$$LA = \frac{5}{7} \times 100\% = 71.43\%$$

$$DA = \frac{5}{6} \times 100\% = 83.33\%$$

2. 依存关系分析

◆性能水平(神经网络方法与决策方法相结合) (EMNLP 2014, 15)

- ✧ 利用《华尔街日报》(Wall Street Journal, WSJ)语料做训练;
- ✧ 部分WSJ语料用于开发集;
- ✧ 在WSJ语料上训练出来的CRFs 模型进行词性标注。

✧ 结果

Model	UAS	LAS	OOV	OOE
①	89.17	87.21	84.13	91.35
②	89.33	87.21	83.82	90.83
③	90.61	88.68	88.00	93.77

OOV: out-of-vocabulary;

OOE: out-of-embedding vocabulary

Domain	#Sent	#Word	TA(%)
WSJ-train	30060	731678	97.03
WSJ-dev	1336	32092	96.88
WSJ-test	1640	35590	97.51

TA 是词性标注的准确率

对于规范的英文文本，目前分析的总体水平(UAS)可达90%以上，汉语分析的性能略逊于英语。

◆短语结构分析：任务与问题

- CYK分析方法
- 基于PCFG的分析方法
- 分析结果评价

◆依存关系分析：理论、任务与问题

- 移进-归约分析方法
- 分析结果评价

4.2 句法分析

1. 短语结构分析

2. 依存关系分析

 3. 习题

4. 附录



3. 本部分习题

1. 试测试对比不同大语言模型执行句法分析任务的性能，包括短语结构分析和依存关系分析，分别在汉语和英文数据集上测试。
2. 参阅各种开源句法分析器网站，试用相关分析器，包括短语结构分析器和依存句法分析器，分别在汉语和英文数据集上对比分析其性能，并与上面大语言模型的分析结果进行对比。
3. 设计实现程序，对于任意给定的一棵短语结构树将其转换成依存关系图。

4.2 句法分析

1. 短语结构分析

2. 依存关系分析

 3. 附录 

3.1 线图分析算法

3.2 PCFG算法三个问题解决方法

3.3 基于神经网络的分析方法

3.4 局部句法分析

3.5 神经网络与决策式结合的依存关系分析

3.6 短语结构树到依存关系图的转换

3.7 汉英句法结构特点对比

◆三种策略

- 自底向上(Bottom-up)
- 从上到下(Top-down)
- 从上到下和从下到上结合

◆自底向上的 Chart 分析算法


- 给定一组 CFG 规则: $XP \rightarrow \alpha_1 \dots \alpha_n$ ($n \geq 1$)
- 给定一个句子的词性序列: $S = w_1 w_2 \dots w_n$
- 构造一个线图: 一组结点和边的集合;



- 建立一个二维表: 记录每一条边的起始位置和终止位置。

附录3.1：线图分析算法

- 执行操作：查看任意相邻几条边上的词性串是否与某条重写规则的右部相同，如果相同，则增加一条新的边跨越原来相应的边，新增加边上的标记为这条重写规则的头(左部)。重复这个过程，直到没有新的边产生。



附录3.1：线图分析算法

- **点规则**：用于表示规则右部被归约(reduce)的程度。


设有规则：NP $\rightarrow$ Det A N

NP $\rightarrow$ Det N

NP $\rightarrow$ A N

有短语：The good book

词性序列：Det A N

图表示：

点规则：NP $\rightarrow$ Det $\circ$ A N

NP $\rightarrow$ Det A $\circ$ N

NP $\rightarrow$ Det A N $\circ$

附录3.1：线图分析算法

- 点规则：用于表示规则右部被归约(reduce)的程度。

设有规则：NP $\rightarrow$ Det A N

NP $\rightarrow$ Det N

NP $\rightarrow$ A N

有短语：The good book

词性序列：Det A N

图表示：●—●—●—●

点规则：NP $\rightarrow$ Det $\circ$ A N

NP $\rightarrow$ Det A $\circ$ N

NP $\rightarrow$ Det A N $\circ$

活性边(活动弧)：规则右部未被完全匹配

非活性边(非活动弧, 或完成弧)：规则右部已被完全匹配。



附录3.1：线图分析算法

例： $G(S):S \rightarrow NP VP$, $NP \rightarrow Det N$

$VP \rightarrow V NP$, $VP \rightarrow VP PP$

$PP \rightarrow Prep NP$

输入句子： the boy hits the dog with a rod

①形态分析： the boy hit the dog with a rod

②词性标注： Det N V Det N Prep Det N

附录3.1：线图分析算法

③
分析过程

Agenda

ActiveArc

Chart

Acts

① Det (1, 2) ② NP $\rightarrow$ Det $\circ$ N (1,2) ③ Det (1, 2) 返回



(1) S $\rightarrow$ NP VP (2) NP $\rightarrow$ Det N (3) VP $\rightarrow$ VP PP
(4) VP $\rightarrow$ V NP (5) PP $\rightarrow$ Prep NP

附录3.1：线图分析算法

③
分析过程

Agenda

ActiveArc

Chart

Acts

① Det (1, 2)

② NP → Det ◦ N (1,2)

③ Det (1, 2)

返回

④ N (2, 3)

无新的活动边加入

⑤ N (2, 3)

扩展



(1) S → NP VP (2) NP → Det N (3) VP → VP PP
(4) VP → V NP (5) PP → Prep NP

附录3.1：线图分析算法

③
分析过程


Agenda

ActiveArc

Chart

Acts

① Det (1, 2)	② NP $\rightarrow$ Det $\circ$ N (1,2)	③ Det (1, 2)	返回
④ N (2, 3)	⑥ NP $\rightarrow$ Det N $\circ$ (1,3)	⑤ N (2, 3)	返回
⑦ NP (1, 3)	⑧ S $\rightarrow$ NP $\circ$ VP (1, 3)	⑨ NP (1, 3)	返回
⑩ V (3, 4)	⑪ VP $\rightarrow$ V $\circ$ NP (3, 4)	⑫ V (3, 4)	返回




(1) S $\rightarrow$ NP VP (2) NP $\rightarrow$ Det N (3) VP $\rightarrow$ VP PP
(4) VP $\rightarrow$ V NP (5) PP $\rightarrow$ Prep NP

附录3.1：线图分析算法

③
分析过程

Agenda	ActiveArc	Chart	Acts
⑬ Det (4,5)	⑭ $NP \rightarrow Det \circ N (4,5)$	⑮ Det (4,5)	返回
⑯ N (5,6)	无新的活动边加入	⑰ N (5,6)	扩展




(1) $S \rightarrow NP VP$ (2) $NP \rightarrow Det N$ (3) $VP \rightarrow VP PP$
 (4) $VP \rightarrow V NP$ (5) $PP \rightarrow Prep NP$

附录3.1：线图分析算法

③
分析过程

Agenda	ActiveArc	Chart	Acts
⑬ Det (4,5)	⑭ $NP \rightarrow Det \circ N$ (4,5)	⑮ Det (4,5)	返回
⑯ N (5,6)	无新的活动边加入	⑰ N (5,6)	扩展
⑲ NP(4,6)	⑳ $S \rightarrow NP \circ VP$ (4, 6)	㉑ NP(4,6)	扩展

将第11步的点规则 $VP \rightarrow V \circ NP$ (3, 4) 扩展



(1) $S \rightarrow NP VP$ (2) $NP \rightarrow Det N$ (3) $VP \rightarrow VP PP$
 (4) $VP \rightarrow V NP$ (5) $PP \rightarrow Prep NP$

附录3.1：线图分析算法

③
分析过程

Agenda

ActiveArc

Chart

Acts

22 VP $\rightarrow$ V NP $\circ$ (3, 6)


23 VP (3,6)

24 VP $\rightarrow$ VP $\circ$ PP (3,6)

25 VP (3,6) 扩展

...


...




(1) $S \rightarrow NP VP$ (2) $NP \rightarrow Det N$ (3) $VP \rightarrow VP PP$
 (4) $VP \rightarrow V NP$ (5) $PP \rightarrow Prep NP$

附录3.1：线图分析算法

分析结果：



附录3.1：线图分析算法



将上图中的边改为结点，将结点改为边，得到分析结果的直观图。

附录3.1：线图分析算法

◆ 算法描述

● 数据结构


- **线图(Chart)**: 保存分析过程中已经建立的成分(包括终结符和非终结符)、位置(包括起点和终点)。通常以 $n \times n$ 的数组表示(n 为句子包含的词数)。
- **代理表(待处理表)(Agenda)**: 记录刚刚得到的一些重写规则所代表的成分, 这些重写规则的右端符号串与输入词性串(或短语标志串)中的一段完全匹配, 通常以栈或线性队列表示。
- **活动边集(ActiveArc)**: 记录那些右端符号串与输入串的某一段相匹配, 但还未完全匹配的重写规则, 通常以数组或列表存储。

附录3.1：线图分析算法

● 算法过程：

从输入串的起始位置到最后位置，循环执行如下步骤：

- (1) 如果待处理表(Agenda)为空，则找到下一个位置上的词，将该词对应的(所有)词类 X 附以 (i, j) 作为元素放到待处理表中，即 $X(i, j)$ 。其中， i, j 分别是该词的起始位置和终止位置， $j > i$ ， $j - i$ 为该词的长度。
- (2) 从 Agenda 中取出一个元素 $X(i, j)$ 。
- (3) 对于每条规则 $A \rightarrow X \circ \gamma$ ，将 $A \rightarrow X \circ \gamma(i, j)$ 加入活动边集ActiveArc 中，然后调用扩展弧子程序。



附录3.1：线图分析算法


✧ 扩展弧子程序：

- (a) 将 X 插入图表(Chart)的 (i, j) 位置中。
- (b) 对于活动边集(ActiveArc)中每个位置为 (k, i) ($1 \leq k < i$) 的点规则，如果该规则具有如下形式： $A \rightarrow \alpha \circ X$ ，如果 $A=S$ ，则把 $S(1, n+1)$ 加入到 Chart 中，并给出一个完整的分析结果；否则，则将 $A(k, j)$ 加入到Agenda表中。
- (c) 对于每个位置为 (k, i) 的点规则： $A \rightarrow \alpha \circ X \beta$ ，则将 $A \rightarrow \alpha X \circ \beta(k, j)$ 加入到活动边集中。

附录3.1：线图分析算法

◆算法时间复杂度分析

设 n 为输入句子的长度, C 为上下文无关文法中的非终结符的数目, S 为点规则的状态数目(大于 CFG 规则的数目), 显然 $S > C$ 。因为 Agenda 表中的元素形式为 $X(i, j)$, 因此, Agenda 表中最大的元素个数为: Cn^2 。



附录3.1：线图分析算法

由于ActiveArc 表中的元素形式为： $A \rightarrow \alpha \circ X(i, j)$ ，所以该表中最大的元素数目为： Sn^2 。

{Chart 表中的边的形式为： $A(i, j)$ ，因此，Chart 表中最大的元素数目为： Cn^2 。}

我们来考察算法中每一步执行的最大次数：

附录3.1：线图分析算法

● 算法过程：

从输入串的起始位置到最后位置，循环执行如下步骤：

(1) 如果待处理表(Agenda)为空，则找到下一个位置上的词，将该词对应的(所有)词类 X 附以 (i, j) 作为元素放到待处理表中，即 $X(i, j)$ 。其中， i, j 分别是该词的起始位置和终止位置， $j > i$ ， $j - i$ 为该词的长度。


最多执行的次数为： C

(2) 从 Agenda 中取出一个元素 $X(i, j)$ 。

最多执行的次数为：1

(3) 对于每条规则 $A \rightarrow X \circ \gamma$ ，将 $A \rightarrow X \circ \gamma(i, j)$ 加入活动边集ActiveArc 中，然后调用扩展弧子程序。

最多执行的次数为： S_n^2



附录3.1：线图分析算法

✧ 扩展弧子程序：

(a) 将 X 插入图表(Chart)的 (i, j) 位置中。

最多执行的次数为：1

(b) 对于活动边集(ActiveArc)中每个位置为 (k, i) ($1 \leq k < i$) 的点规则，如果该规则具有如下形式： $A \rightarrow \alpha \circ X$ ，如果 $A=S$ ，则把

$S(1, n+1)$ 加入到 Chart 中，并给出一个完整的分析结果；

否则，则将 $A(k, j)$ 加入到Agenda表中。

最多执行的次数为： Sn^2

(c) 对于每个位置为 (k, i) 的点规则： $A \rightarrow \alpha \circ X \beta$ ，则将

$A \rightarrow \alpha X \circ \beta(k, j)$ 加入到活动边集中。

最多执行的次数为： Sn^2

附录3.1：线图分析算法

每处理一个单词需要最多执行的最多操作次数为：

$$C + 1 + Sn^2 + 1 + Sn^2 + Sn^2 = 2 + C + 3Sn^2$$

由于算法对于长度为 n 的输入句子要执行 n 次循环，因此，Chart 算法最大执行的操作次数为：

$$n \times (2 + C + 3Sn^2)$$

所以，Chart算法的时间复杂度为: $O(Kn^3)$, 其中, K 为一常数。

◆ Chart parsing 算法评价

● 优点:

- 算法简单，容易实现，开发周期短。

● 弱点:

- 算法效率低，时间复杂度为 Kn^3 ；
- 需要高质量的规则，分析结果与规则质量密切相关；
- 难以区分歧义结构。

4.2 句法分析

1. 短语结构分析

2. 依存关系分析

➔ 3. 附录



3.1 线图分析算法

3.2 PCFG算法三个问题解决方法

3.3 基于神经网络的分析方法

3.4 局部句法分析

3.5 神经网络与决策式结合的依存关系分析

3.6 短语结构树到依存关系图的转换

3.7 汉英句法结构特点对比



附录3.2: PCFG 三个问题解决方法

假设文法 $G(S)$ 的规则只有两种形式:

$$A \rightarrow w, \quad w \in V_T$$

$$A \rightarrow BC, \quad B, C \in V_N$$

可以通过范式化处理, 使CFG 规则满足上述形式。这种假设的文法形式称为乔姆斯基范式(Chomsky normal form, CNF)。



附录3.2: PCFG 三个问题解决方法

◆ 求解问题1: 快速地计算句子的句法树概率

● 内向算法

- 基本思想: 利用动态规划算法计算由非终结符 A 推导出的某个字串片段 $w_i w_{i+1} \dots w_j$ 的概率 $\alpha_{ij}(A)$ 。语句 $W = w_1 w_2 \dots w_n$ 的概率即为文法 $G(S)$ 中 S 推导出的字串的概率 $\alpha_{1n}(S)$ 。



附录3.2: PCFG 三个问题解决方法

► 定义: 内向变量 $\alpha_{ij}(A)$ 是由非终结符 A 推导出的句子 S 中子字符串 $w_i w_{i+1} \dots w_j$ 的概率:


$$\alpha_{ij}(A) = p(A \xRightarrow{*} w_i w_{i+1} \dots w_j)$$

计算 $\alpha_{ij}(A)$ 的递推公式:

$$\alpha_{ii}(A) = p(A \rightarrow w_i)$$

$$\alpha_{ij}(A) = \sum_{B, C \in V_N} \sum_{i \leq k \leq j} p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C)$$

附录3.2: PCFG 三个问题解决方法



附录3.2: PCFG 三个问题解决方法

➤ 解释:

当 $i=j$ 时, 字符串 $w_i w_{i+1} \dots w_j$ 只是一个字 w_{ii} , 可简单记作 w_i , 由 A 推导出 w_i 的概率就是产生式 $A \rightarrow w_i$ 的概率 $p(A \rightarrow w_i)$; 当 $i \neq j$ 时, 也就是说, 字符串 $w_i w_{i+1} \dots w_j$ 至少有两个词, 根据约定, A 要推导出该词串, 必须首先运用产生式 $A \rightarrow BC$, 那么, 可用 B 推导出前半部 $w_i \dots w_k$, 用 C 推导出后半部 $w_{k+1} \dots w_j$ 。由这一推导过程产生 $w_i w_{i+1} \dots w_j$ 的概率为: $p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C)$ 。考虑到 B 、 C 和 k 取值的任意性, 应计算各种情况下概率的总和。

附录3.2: PCFG 三个问题解决方法

➤ 内向算法描述:

输入: 文法 $G(S)$, 语句 $S = w_1w_2 \dots w_n$;

输出: $p(S \xRightarrow{*} w_1w_2 \dots w_n)$

(1) 初始化: $\alpha_{ii}(A) = p(A \rightarrow w_i) \quad A \in V_N, 1 \leq i \leq n$


(2) 归纳计算: $j=1..n, i=1..n-j$, 重复下列计算:

$$\alpha_{i(i+j)}(A) = \sum_{B, C \in V_N} \sum_{i \leq k \leq i+j} p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)(i+j)}(C)$$

(3) 终结: $p(S \xRightarrow{*} w_1w_2 \dots w_n) = \alpha_{1n}(S)$

附录3.2: PCFG 三个问题解决方法

➤ 图解:



附录3.2: PCFG 三个问题解决方法

循环执行:
(假设: $n=20$)

$$\alpha_{i(i+j)}(A) = \sum_{B,C \in V_N} \sum_{i \leq k \leq i+j} p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)(i+j)}(C)$$

$j=1..n$, $i=1..n-j$ ($i+j$ 表示列, i 表示行):

$j=1$: $i=1..19$: $\alpha_{12}(A), \alpha_{23}(A), \dots, \alpha_{(19)(20)}(A)$

$j=2$: $i=1..18$: $\alpha_{13}(A), \alpha_{24}(A), \dots, \alpha_{(18)(20)}(A)$

$j=3$: $i=1..17$: $\alpha_{14}(A), \alpha_{25}(A), \dots, \alpha_{(17)(20)}(A)$


.....

$j=19$: $i=1$: $\alpha_{1(20)}(A)$


$j=20$: 不执行

附录3.2: PCFG 三个问题解决方法

➤ 图解:



附录3.2: PCFG 三个问题解决方法





附录3.2: PCFG 三个问题解决方法

● 外向算法

➤ 定义:


外向变量 $\beta_{ij}(A)$ 是由文法初始符号 S 推导出语句 $S=w_1w_2\dots w_n$ 的过程中, 到达扩展符号串 $w_1\dots w_{i-1}Aw_{j+1}\dots w_n$ 的概率:

$$A = w_i \dots w_j$$

$$\beta_{ij}(A) = p(S \xRightarrow{*} w_1 \dots w_{i-1}Aw_{j+1} \dots w_n)$$

$\beta_{ij}(A)$ 表示除了以 A 为根节点的子树以外的概率。

附录3.2: PCFG 三个问题解决方法





附录3.2: PCFG 三个问题解决方法

$\beta_{ij}(A)$ 可由动态规划算法求得, 其递推公式:

$$\beta_{1n}(A) = \delta(A, S) \quad (\text{初始化})$$

$$\beta_{ij}(A) = \sum_{B,C} \sum_{k>j} \beta_{ik}(B) p(B \rightarrow AC) \alpha_{(j+1)k}(C) + \sum_{B,C} \sum_{k<i} \beta_{kj}(B) p(B \rightarrow CA) \alpha_{k(i-1)}(C)$$



附录3.2: PCFG 三个问题解决方法

► 解释:

(1) 当 $i=1, j=n$ 时, 即 $w_i w_{i+1} \dots w_j$ 是整个语句 S 时, 根据乔姆斯基语法范式的约定, 不可能有规则 $S \rightarrow A$, 因此, 由 S 推导出句子的过程中, 如果 $A \neq S$ 的话, A 推导出句子的概率为 0 (只有 S 才能推导出句子), 即 $\beta_{1n}(A)=0$ 。

如果 $A=S$, $\beta_{1n}(A)$ 为由初始符 S 推导出句子的概率, 因此, $\beta_{1n}(A)=1$ 。

(2) 当 $i \neq 1$ 或者 $j \neq n$ 时, 如果在 S 推导出句子的过程中出现了字符串 $w_1 \dots w_k A w_{j+1} \dots w_n$, 则该推导过程必定使用了规则 $B \rightarrow AC$ 或 $B \rightarrow CA$ 。假定运用了规则 $B \rightarrow AC$ 推导出

$w_i \dots w_j$ $w_{j+1} \dots w_k$, 则该推导可以分解为以下三步:

附录3.2: PCFG 三个问题解决方法


- (a) 由 S 推导出 $w_1 \dots w_{i-1} B w_{k+1} \dots w_n$, 其概率为 $\beta_{ik}(B)$;
- (b) 运用产生式 $B \rightarrow AC$ 扩展非终结符 B , 其概率为 $p(B \rightarrow AC)$;
- (c) 由非终结符 C 推导出 $w_{j+1} \dots w_k$, 其概率为 $\alpha_{(j+1)k}(C)$ 。

考虑到 B , C 和 k 的任意性, 在计算 $\beta_{ik}(B)$ 时, 必须考虑所有可能的 B , C 和 k , 因此, 计算概率时必须考虑所有情况下的概率之和。

同样方法, 可以计算出运用产生式 $B \rightarrow CA$ 推导出 $w_i \dots w_j w_{j+1} \dots w_k$ 的概率。

附录3.2: PCFG 三个问题解决方法

➤ 图解:





附录3.2: PCFG 三个问题解决方法

➤ 外向算法描述:

输入: PCFG $G=(S, N, T, P)$, 语句 $S = w_1w_2 \dots w_n$;

输出: $p(S)$, $A \in N$, $1 \leq i \leq j \leq n$ 。

(1) 初始化: $\beta_{1n}(A) = \delta(A, S)$, $A \in N$;

(2) 归纳: $j = n-2 \dots 0$, $i = 1 \dots n-j$, 重复计算:

$$\begin{aligned} \beta_{i(i+j)}(A) = & \sum_{B,C} \sum_{i+j < k \leq n} p(B \rightarrow AC) \alpha_{(i+j+1)k}(C) \beta_{ik}(B) \\ & + \sum_{B,C} \sum_{1 \leq k < i} p(B \rightarrow CA) \alpha_{k(i-1)}(C) \beta_{k(i+j)}(B) \end{aligned}$$

(3) 终结: $p(S \xRightarrow{*} w_1w_2 \dots w_n) = \sum_A \beta_{ii}(A) \times p(A \rightarrow w_i)$

附录3.2: PCFG 三个问题解决方法

➤ 图解：假设 $S=w_1w_2\dots w_{10}$ ，即 $n=10$ 。

$$\begin{aligned} j &= n-2 \dots 0 \\ i &= 1 \dots n-j \\ &\dots \dots \end{aligned}$$

$$j = 8$$

$$i = 1, \beta_{i(i+j)} = \beta_{1,9}$$

$$i = 2, \beta_{i(i+j)} = \beta_{2,10}$$


$$j = 7$$

$$i = 1, \beta_{i(i+j)} = \beta_{1,8}$$

$$i = 2, \beta_{i(i+j)} = \beta_{2,9}$$

$$i = 3, \beta_{i(i+j)} = \beta_{3,10}$$

.....





附录3.2: PCFG 三个问题解决方法

◆ 求解问题2: 最佳搜索- Viterbi 算法

➤ 定义:

Viterbi 变量 $\gamma_{ij}(A)$ 是由非终结符 A 推导出句子 S 中子字符串 $w_i w_{i+1} \dots w_j$ 的**最大概率**。

变量 $\psi_{i,j}$ 用于记忆句子 $w_1 w_2 \dots w_n$ 的 Viterbi 句法分析结果。

注意: γ 与内向算法中的 α 略有不同, 计算的是最大概率。

附录3.2: PCFG 三个问题解决方法

● Viterbi 算法描述:

输入: 文法 $G(S)$, 句子 $S = w_1 w_2 \dots w_n$;

输出: $\gamma_{1n}(S)$

(1) 初始化: $\gamma_{ii}(A) = p(A \rightarrow w_i) \quad A \in V_N, 1 \leq i \leq j \leq n$

(2) 归纳计算: $j=1..n, i=1..n-j$, 重复下列计算:

$$\gamma_{i(i+j)}(A) = \max_{B,C \in V_N; i \leq k \leq i+j} p(A \rightarrow BC) \gamma_{ik}(B) \gamma_{(k+1)(i+j)}(C)$$

$$\psi_{i(i+j)}(A) = \max_{B,C \in V_N; i \leq k \leq i+j} p(A \rightarrow BC) \gamma_{ik}(B) \gamma_{(k+1)(i+j)}(C)$$

(3) 终结: $p(S \xRightarrow{*} w_1 w_2 \dots w_n) = \gamma_{1n}(S)$



附录3.2: PCFG 三个问题解决方法

◆ 求解问题3: 参数估计- 内外向算法

➤ 基本思路:

如果有大量已标注句法结构的训练语料, 则可直接通过计算每个句法规则的使用次数, 用最大似然估计方法计算 PCFG 规则的概率参数, 即:

$$\hat{p}(N^j \rightarrow \zeta) = \frac{C(N^j \rightarrow \zeta)}{\sum_{\gamma} C(N^j \rightarrow \gamma)}$$

附录3.2: PCFG 三个问题解决方法

多数情况下，没有可利用的标注语料，只好借助EM (Expectation Maximization) 迭代算法估计PCFG的概率参数。

初始时随机地给参数赋值，得到语法 G_0 ，依据 G_0 和训练语料，得到语法规则使用次数的期望值，以期望次数运用于最大似然估计，得到语法参数新的估计值，由此得到新的语法 G_1 ，由 G_1 再次得到语法规则的使用次数的期望值，然后又重新估计语法参数。循环这个过程，语法参数将收敛于最大似然估计值。

附录3.2: PCFG 三个问题解决方法


➤ 算法设计

给定 CFG G 和训练数据 $S = w_1 w_2 \dots w_n$, 句法规则 $A \rightarrow BC$ 使用次数的期望值为:

$$\begin{aligned}
 \text{Count}(A \rightarrow BC) &= \sum_{1 \leq i \leq k \leq j \leq n} p(A_{ij}, B_{ik}, C_{(k+1)j} \mid w_1 \dots w_n, G) \\
 &= \frac{1}{p(w_1 \dots w_n \mid G)} \sum_{1 \leq i \leq k \leq j \leq n} p(A_{ij}, B_{ik}, C_{(k+1)j}, w_1 \dots w_n \mid G) \\
 &= \frac{1}{p(w_1 \dots w_n \mid G)} \sum_{1 \leq i \leq k \leq j \leq n} \beta_{ij}(A) p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C) \\
 &\quad \dots \text{(E1)}
 \end{aligned}$$

附录3.2: PCFG 三个问题解决方法

- **解释：** 给定句子 $S=w_1w_2 \dots w_n$, PCFG G 中产生式 $A \rightarrow BC$ 在产生 S 的过程中被使用次数的期望值为：在所有可能的情况下，即在条件： $1 \leq i \leq k \leq j \leq n$ 下， S 的句法分析结构中 $w_i \dots w_k$ 由 B 导出， $w_{k+1} \dots w_j$ 由 C 导出， $w_i \dots w_j$ 由 A 导出的概率总和。



附录3.2: PCFG 三个问题解决方法

类似地，语法规则 $A \rightarrow a$ 的使用次数的期望值为：

$$\begin{aligned} \text{Count}(A \rightarrow a) &= \sum_{1 \leq i \leq n} p(A_{ii} \mid w_1 \cdots w_n, G) \\ &= \frac{1}{p(w_1 \cdots w_n \mid G)} \sum_{1 \leq i \leq n} p(A_{ii}, w_1 \cdots w_n \mid G) \\ &= \frac{1}{p(w_1 \cdots w_n \mid G)} \sum_{1 \leq i \leq n} \beta_{ii}(A) p(A \rightarrow a) \delta(a, w_i) \quad \dots \text{(E2)} \end{aligned}$$



附录3.2: PCFG 三个问题解决方法

规则使用的概率可由下面的公式重新估计：

$$\hat{p}(A \rightarrow \mu) = \frac{\text{Count}(A \rightarrow \mu)}{\sum_{\mu} \text{Count}(A \rightarrow \mu)} \quad \dots \text{(E3)}$$

其中， μ 要么为终结符号，要么为两个非终结符号串，即 $A \rightarrow \mu$ 为乔姆斯基语法范式要求的两种形式。

➤ 内外向算法描述:

(1) 初始化: 随机地给 $p(A \rightarrow \mu)$ 赋值, 使得 $\sum_{\mu} p(A \rightarrow \mu) = 1$,
由此得到语法 G_0 。令 $i=0$;

(2) EM迭代:

E-步: 由 G_i 根据公式(E1)和(E2), 计算
期望值 $Count(A \rightarrow BC)$ 和 $Count(A \rightarrow a)$;

M-步: 用 E-步所得的期望值, 根据
公式(E3)重新估计 $p(A \rightarrow \mu)$, 得到 G_{i+1} 。

(3) 循环: $i=i+1$, 重复EM步骤, 直至 $p(A \rightarrow \mu)$ 值收敛。

4.2 句法分析

1. 短语结构分析

2. 依存关系分析

 **3. 附录** 

3.1 线图分析算法

3.2 PCFG算法三个问题解决方法

3.3 基于神经网络的分析方法

3.4 局部句法分析

3.5 神经网络与决策式结合的依存关系分析


3.6 短语结构树到依存关系图的转换

3.7 汉英句法结构特点对比

附录3.3: 基于神经网络的分析方法


● 基本思路

将句法树表示成一个短语标记序列，借助机器翻译原理将一个句子“翻译”成短语标记序列。



附录3.3: 基于神经网络的分析方法

● 翻译模型



Oriol Vinyals *et al.*, Grammar as a Foreign Language, *Proc. NeurIPS* (2015)



附录3.3: 基于神经网络的分析方法

● 实验

- 训练语料: WSJ 40K个句子;
- High-confidence corpus: ~11M parsed sentences + 90K golden sentences (Berkeley-Parser, Zpar);
- 开发集: Section 22 of the Penn Treebank;
- 测试集: Section 23 of the Penn Treebank。
- 结果:
 - 只用WSJ 训练语料时, F1值可以达到 90.5%;
 - 使用High-confidence corpus 语料时, F1值可以达到 92.1%。

4.2 句法分析

1. 短语结构分析

2. 依存关系分析

 3. 附录



3.1 线图分析算法

3.2 PCFG算法三个问题解决方法

3.3 基于神经网络的分析方法

3.4 局部句法分析

3.5 神经网络与决策式结合的依存关系分析

3.6 短语结构树到依存关系图的转换

3.7 汉英句法结构特点对比

附录3.4: 局部句法分析

◆ 概述

S. Abney (1991) 提出了浅层句法分析(shallow parsing)的概念, 也被称为局部 (部分) 句法分析(partial parsing), 或称语块划分(chunking), 其目的是识别句子中某些结构相对简单的独立成分, 如: 非递归的名词短语、动词短语等。

浅层句法分析通常包括: 语块识别和语块之间的关系分析。

附录3.4: 局部句法分析

◆ 概述

根据S. Abney 对语块的解释, 语块是介于词和句子之间的具有非递归特征的核心成分。S. Abney(1995)对英语语块的定义包含三个层次:

(1)词 (words)

(2)非递归的名词短语 (NP)、动词词组 (VG)、副词短语 (DP)和介词短语 (PP)

(3)子句 (clause)

由于NP、VG 和 DP、PP属于不同的类别, 因此, 又将第(2)类进一步划分成“非递归的名词短语和动词词组”和“非递归的介词短语和副词短语”两类。通常非递归的名词短语和动词短语分别称为基本名词短语(Base NP)和基本动词短语(Base VP)。

◆ Base NP定义

基本名词短语指的是简单的、非嵌套的名词短语，不含有其他的子短语。它的主要特点有两个：短语的中心语为名词；短语中不含有其他的子项短语，并且Base NP之间结构上是独立的。

Base NP 的形式化定义：

$\text{Base NP} \rightarrow \text{Base NP} + \text{Base NP}$

$\text{Base NP} \rightarrow \text{Base NP} + \text{名词} \mid \text{名动词}$

$\text{Base NP} \rightarrow \text{限定性定词} + \text{Base NP} \mid \text{名词}$

$\text{Base NP} \rightarrow \text{限定性定词} + \text{名词} \mid \text{名动词}$

$\text{限定性定词} \rightarrow \text{形容词} \mid \text{区别词} \mid \text{动词} \mid \text{名词} \mid \text{处所词} \mid \text{数量词} \mid \text{外文字串} \mid \text{数词和量词}$

附录3.4: 局部句法分析

例1: [Pierre Vinken], [61 years] old, will join [the board] as [a non-executive director] on [Nov. 29].

例2: When [it] is [time] for [their biannual powwow], [the nation]'s [manufacturing titans] typically jet off to [the sunny confines] of [resort towns] like [Boca Raton and Hot Springs].

例3: 一个于[半个世纪]之后重新聚集在[“西南联大”旗帜下的奉献活动]开始了!

◆ Base NP 识别方法

Base NP 识别可以简单地看作分类问题：判断一个短语的边界，识别该短语是 base NP 或非 base NP 两类。

- **常用方法：** 序列标注方法

- **数据标注**

两种标记方法：

- 括号分隔法 (the open/close bracketing)
- IOB 标注方法 (IOB tagging)

附录3.4: 局部句法分析

例如：在IOB标注方法中，字母 ‘B’ (Begin)表示当前词语位于base NP的开端，字母 ‘I’ (In) 表示当前词语在base NP内（非短语首词语），字母 ‘O’ (Out) 表示词语位于base NP 之外。例如：

外商/B 投资/I 成为/O 中国/B 外贸/I 重要/B 增长/I 。/O

与IOB方法类似的标注方法还有：IOE (In, Out, End) 表示方法，或者采用5个标志符号：O, B, E, I, S 等。

- 分类器

- SVM

- CRFs

➤ 基于SVM 的识别方法

T. Kudo等(2003) 在利用 SVM 识别 base NP的系统(YamCha¹)中, 主要使用了三类特征:

- 词: $w_{i-2} w_{i-1} w_i w_{i+1} w_{i+2}$
- 词性: $t_{i-2} t_{i-1} t_i t_{i+1} t_{i+2}$
- Base NP 标志: $c_{i-2} c_{i-1}$

其中, w_i 为句子中位置 i 处的词, t_i 为词的词性, c_i 为待识别的第 i 个词的base NP 标记。

¹<http://chasen.org/~taku/software/yamcha>



附录3.4: 局部句法分析

YamCha 系统识别 base NP 过程示意图:

	COL:0	COL:1	TAG	
	POS: -4	He	PRP	B-NP
	POS: -3	reckons	VBZ	B-VP
	POS: -2	the	DT	B-NP
	POS: -1	current	JJ	I-NP
→ POS: 0		<u>deficit</u>	NN	? I-NP
	POS: +1	will	MD	.
	POS: +2	narrow	VB	.
	POS: +3	to	TO	.

→ Feature Sets

→ Estimated TAG

其中, POS列表示当前词(POS: 0)的前后词位置; COL: 0 列表示给定句子; COL: 1列为给定句子中各词对应的词类标记; TAG列为给定句子中的各词被标记为base NP的标记。要估计位置POS: 0处词的base NP标记, 该词前后各两个位置上的词和它们的词性标记以及前面两个词的base NP 标记共同作为被选取的特征。

附录3.4: 局部句法分析

◆用于Base NP 识别语料资源

✧ 英文: CoNLL-2000 (Conference on Computational Natural Language Learning)提供的《华尔街日报》语料

- 训练语料: 15 – 18章, 211,727个词

<http://www.cnts.ua.ac.be/conll2000/chunking/train.txt.gz>

- 测试语料: 第20章, 47,377个词

<http://www.cnts.ua.ac.be/conll2000/chunking/test.txt.gz>

✧ 汉语: 宾州 LDC 中文树库。

4.2 句法分析

1. 短语结构分析

2. 依存关系分析

 **3. 附录** 

3.1 线图分析算法

3.2 PCFG算法三个问题解决方法

3.3 基于神经网络的分析方法

3.4 局部句法分析

3.5 神经网络与决策式结合的依存关系分析

3.6 短语结构树到依存关系图的转换

3.7 汉英句法结构特点对比




附录3.5: 神经网络与决策式结合的依存关系分析


◆ 基本思路

之前的决策式依存分析方法采用离散的特征、线性模型，而神经网络方法采用连续的实数向量表示词汇，词向量可以从大量未标注的样本中训练获得。神经网络模型可以获得非线性关系。那么，是否可以将离散特征与连续特征结合起来，实现它们各自优势的互补？

✧ 尝试-1: Word2Vec + CRFs



◇尝试-2: 连续特征离散化后与原离散特征结合




Jiang Guo et al. Revisiting Embedding Features for Simple Semi-supervised Learning. *Proc. EMNLP'2014*

离散特征有很多优点:

- 特征的增加或减少都容易处理, 易于模型快速迭代;
- 稀疏向量内积乘法运算速度快, 计算结果方便存储;
- 离散化后的特征对异常数据有较好的鲁棒性...

◇尝试-3: 连续特征隐层向量与原离散特征结合



离散特征 神经网络所抽取的连续特征

$$Score(a) = \sigma \left((\Phi_d(x) \oplus \Phi_h(x)) \cdot (\vec{\theta}_{d,a} \oplus \vec{\theta}_{c,a}) \right)$$

离散特征的权重 神经网络权重

M. Zhang and Y. Zhang, Combining Discrete and Continuous Features for Deterministic Transition-based Dependency Parsing. *Proc. EMNLP'2015*



- 变量 a 表示依存分析动;
- 运算符 $\oplus$ 表示向量拼接;
- x 表示当前状态;
- d 和 h 分别是离散或隐藏特征的标记;
- $\vec{\theta}_{c,a}$ 是隐藏层和输出层之间的权重。




附录3.5: 神经网络与决策式结合的依存关系分析

◆神经网络方法— Stack-LSTM

Stack-LSTM 在原始从左到右LSTM的基础上增加栈指针(TOP)。



出栈




压栈



附录3.5: 神经网络与决策式结合的依存关系分析

弧转移系统：状态 $c = (S, B, A)$ 包括已处理的堆栈(S)、尚未处理的词缓存器(B)和分析算法已执行的动作历史(A)。



4.2 句法分析

1. 短语结构分析

2. 依存关系分析

➔ 3. 附录 ➔

3.1 线图分析算法

3.2 PCFG算法三个问题解决方法

3.3 基于神经网络的分析方法

3.4 局部句法分析

3.5 神经网络与决策式结合的依存关系分析

3.6 短语结构树到依存关系图的转换

3.7 汉英句法结构特点对比



附录3.6: 短语结构树到依存关系图的转换

◆实现方法


- (1) 定义中心词抽取规则，产生中心词表；
- (2) 根据中心词表，为句子短语结构树中的每个节点选择中心子节点；
- (3) 将非中心子节点的中心词依存到中心子节点的中心词上，得到相应的依存结构。

附录3.6: 短语结构树到依存关系图的转换

◆ 举例


例1: 给定如下短语结构树:

Vinken will join the board as a nonexecutive director Nov 29




附录3.6: 短语结构树到依存关系图的转换

(1)根据中心词表为每个节点选择中心子节点 (中心词通过自底向上传递得到)




附录3.6: 短语结构树到依存关系图的转换

(2)将非中心子节点的中心词依存到中心子节点的中心词上




附录3.6: 短语结构树到依存关系图的转换

(3)对所有的节点执行上述操作，最终得到整个句子的依存关系结构



附录3.6: 短语结构树到依存关系图的转换

例2: 句子“我喜欢这本书。”的短语结构树如下:



4.2 句法分析

1. 短语结构分析

2. 依存关系分析

 **3. 附录** 

3.1 线图分析算法

3.2 PCFG算法三个问题解决方法

3.3 基于神经网络的分析方法

3.4 局部句法分析

3.5 神经网络与决策式结合的依存关系分析

3.6 短语结构树到依存关系图的转换

3.7 汉英句法结构特点对比



◆说明

- ① 此处撇开汉语的分词和词性兼类可能对句法分析带来的影响讨论汉英句法结构特点的比较问题，即保证句法分析器的输入为完全正确的词性序列，仅仅考虑句子结构本身的问题。
- ② 以定性对比为主，没有充足的统计数据支撑相应的观点。

附录3.7: 汉英句法结构特点对比

◆特点归纳

- (1) 汉语比英语更少地使用功能词(function words), 且没有形态变化: 汉语中不使用限定词(“这、这个、那个”等)的名词普遍存在, 复数标记(“们”等)有限并且很少出现。
- (2) 英语短语绝大多数以左部为中心, 而汉语短语比较复杂, 大多数短语类以右部为短语中心, 除了动词和介词的补语在它们的中心词之后。如:



附录3.7: 汉英句法结构特点对比

(3)在汉语句子中没有做主语的先行代词的情况普遍存在，但在英语中这种情况很少出现。这样就使得汉语句法分析器很难判断一个输入到底是没有主语的子句(IP)结构还是仅仅是一个动词短语VP，如：

He thinks it is true. / 他认为□是对的。

我喜欢这里。 / I like it here.

(4)本质上，英语是一种“结构型”语言，一个完整的句法结构即表示一个完整的句子。当多个单句连接起来构成复句的时候，单句与单句之间需要有显式的连接词或者短语。汉语则不同，汉语“表意型”的语言特点，使得汉语句子通常受语义的牵引，一个句子是表达一个完整意义的语言单元，这种特点在长句中表现得特别明显。

附录3.7: 汉英句法结构特点对比

因此，在汉语中存在一种独特的长句构成方式，就是一连串独立的简单句通过逗号或分号，连接成一个复杂的“句群”式的长句。

这些长句内部的各个简单句是为了表意的需要而连接在一起的，它们彼此的句法结构完全是独立的，表示彼此之间逻辑关系的连接词不是必需的。所以在很多情况下，它们之间的分隔标记仅仅是一个逗号或者分号。这类长句在汉语中称之为“**流水复句**”，例如：

“我现已步入中年，每天挤车，工作压力也大，累得我精疲力尽，这种状况直接影响了我的生活，家里的孩子也没人照顾，身体一天天跨下来。”


中文资源联盟(Chinese LDC)中流水复句占41.3%[李幸, 2005]。

◆ 汉语长句的层次化句法分析策略


- (1)对包含“分割”标点的长句进行分割;
- (2)对分割后的各个子句分别进行句法分析(即第一级分析), 分析得到的各个最大概率的子树根节点的词类或者短语类别标记作为第二级句法分析的输入;
- (3)通过第二遍分析找到各子句或短语之间的结构关系, 从而获得最终整句的最大概率分析树。

附录3.7: 汉英句法结构特点对比

例句：我喜欢在春天去观赏桃花，在夏天去欣赏荷花，在秋天去看红叶，但更喜欢在冬天去欣赏雪景。



附录3.7: 汉英句法结构特点对比



参见论文:

李幸, 宗成庆, 2006, 引入标点处理的层次化汉语长句句法分析方法, 中文信息学报, 20(4): 8-15

李幸, 汉语句法分析方法研究[硕士学位论文], 中科院自动化所, 2005 年6月

谢谢!
Thanks!

