

第6章 文本表示

宗成庆

中国科学院自动化研究所

cqzong@nlpr.ia.ac.cn

本章内容

- ➡ 1. 问题提出
- 2. 向量空间模型
- 3. 表示学习模型
- 4. 习题

1. 问题提出

◆ 文本

文本是由文字和标点组成的字符串，词汇、短语、句子、段落和篇章都是不同粒度的文本。

◆ 文本表示的目的

用形式化的方法描述文本，既能反映文本的内容，也能体现不同文本之间的差异，且可计算。



本章内容

1. 问题提出

 2. 向量空间模型

3. 表示学习模型

4. 习题


2. 向量空间模型

◆ 概念解释

- 向量空间模型(vector space model, VSM) 由G. Salton等人于1960s末期在信息检索领域中提出，核心思想是将文本视为特征项的集合。
- **特征项**：VSM中最小的语言单元，可以是字、词、短语等。文本表示为特征项集合 $(t_1, t_2, \dots, t_n)$
- **特征项权重**：每个特征项在文本中的重要性不尽相同，用 w 表示特征项 t 的权重，相应地，文本可以表示为 $(t_1:w_1, t_2:w_2, \dots, t_n:w_n)$ ，或 $(w_1, w_2, \dots, w_n)$

2. 向量空间模型

文本1: $d_1 = (w_1, w_2, \dots, w_n)$ 文本2: $d_2 = (w'_1, w'_2, \dots, w'_n)$



2. 向量空间模型

➤ 特征项

- 单词、词组/短语或 n -gram: 若单词作为特征项, 那么特征项的集合可视为一个词汇表。
- 特征项可以从语料中统计获得。所有的特征项可看作一个“词”袋 (集合), 所以向量空间模型被称为词袋模型 (bag-of-words, BOW)。



2. 向量空间模型

➤ 特征项的权重

- 表示每个特征的重要性。

✓ 布尔变量（是否出现）： $w_i = \begin{cases} 1, & \text{如果 } w_i \text{ 在文本 } d \text{ 中} \\ 0, & \text{否则} \end{cases}$

✓ 项频（term frequency, TF）： $w_i = \log(tf_i + 1)$

文档 \ 特征项	d_1	d_2
t_1	tf_{11}	tf_{12}
t_2	tf_{21}	tf_{22}
t_3	tf_{31}	tf_{32}

$(tf_{ij} \geq 0)$

该权重认为，项频越高，包含的信息量越多。

2. 向量空间模型

✓ 逆（倒）文档频率（inverse document frequency, IDF）：

$$w_i = idf_i = \log \frac{N}{df_i}$$

- N 是整个语料集中文档的数量；
- df_i 是指包含特征项 t_i 的文档数目；
- idf 反映的是特征项在整个语料中重要性的全局性统计特征。

一个特征项在某个文档中出现的频率越高，其包含的有效信息越低。

✓ 特征频率-逆文档频率（TF-IDF）： $tf_idf_i = tf_i \times idf_i$

TF-IDF反映的思想是：区别文本最有意义的特征项应该是那些在当前文本中出现频率足够高，而在文本集合的其他文本中出现频率足够小的特征项。

2. 向量空间模型

◆ 举例

有如下文本：

人工 智能 是 计算机 科
学 的一个 分支， 它 企
图 生产 出 一种 能 以 人
类 智能 相似 的 方式 作
出 反应 的 智能 机器。

词频：

0	教育
3	智能
1	人类
0	体育
0	足球
0	运动会
0	AI
⋮	
1	科学
0	文本
1	人工
1	计算机

2. 向量空间模型

问题：文本越长项频越高。

有如下文本：

人工 智能 是 计算机 科学
的 一个 分支， 它 企图
生产 出 一种 能 以 人类
智能 相似 的 方式 作出
反应 的 智能 机器。人工
智能 是 计算机 科学 的
一个 分支， 它 企图 生
产 出 一种 能 以 人类 智
能 相似 的 方式 作出 反
应 的 智能 机器。

词频：

0	教育
6	智能
2	人类
0	体育
0	足球
0	运动会
0	AI
:	
2	科学
0	文本
2	人工
2	计算机

2. 向量空间模型

◆ 文本长度规范化

对于文本: $\mathbf{d} = (w_1, w_2, \dots, w_n)$, w_i 为特征项的权重。

● 1-范数规范化: $d_1 = \frac{d}{\|\mathbf{d}\|_1} = \frac{d}{\sum_i w_i}$

● 2-范数规范化: $d_2 = \frac{d}{\|\mathbf{d}\|_2} = \frac{d}{\sqrt{\sum_i w_i^2}}$

● 最大词频规范化: $d_{\max} = \frac{d}{\|\mathbf{d}\|_\infty} = \frac{d}{\max_i \{w_i\}}$

2. 向量空间模型

◆ 向量空间模型的问题

- 采用什么特征项表示？
- 采用什么特征选择方法？
- 基于离散符号统计，表达不精细，无法反应类似特征之间的语义相似性。

本章内容

1. 问题提出
2. 向量空间模型
- ➡ 3. 表示学习模型
4. 习题

3. 表示学习模型


◆ 两类代表性学习方法

- **文本概念表示模型：**以（概率）潜在语义分析和潜在狄利克雷分布（latent Dirichlet allocation, LDA）为代表的主题模型（topic model），旨在挖掘文本中隐含的主题或概念，文本被表示为主题的分佈向量。
- **基于分布式表示的学习模型：**通过深度学习模型以最优化特定目标函数的方式在分布式向量空间中学习文本的低维实数向量表示。

3. 表示学习模型

◆不同粒度单位的表示学习

- 词汇的表示学习
- 短语的表示学习
- 句子的表示学习
- 文档的表示学习



- 
- ❖ C&W Model
 - ❖ CBOW and Skip-gram Model
 - ❖ 负采样与噪声对比估计
 - ❖ 字-词混合的表示学习

word embedding
Word2Vector

3. 表示学习模型

(1) 词汇的表示学习

① C&W 模型 — 开创性工作

✧ 基本思路

由上下文词预测当前词，使其概率最大(效果最优)。

✧ 举例说明

$(w_i, Context) = w_{i-n}, \dots, w_{i-1}, w_i, w_{i+1}, \dots, w_{i+n}$

we have learned a lot from this lesson



随机替换


$(w'_i, Context) = w_{i-n}, \dots, w_{i-1}, w'_i, w_{i+1}, \dots, w_{i+n}$

we have learned a book from this lesson

$score(w_i, Context) > score(w'_i, Context)$

Collobert R and Weston J. 2008. A Unified Architecture for Natural Language Processing: Deep Neural Networks with Multitask Learning. In *Proceedings of ICML2008*, pages 160-177

3. 表示学习模型



直接采用向量拼接的方法

$$\mathbf{h}_0 = [\mathbf{e}(w_{i-n}), \dots, \mathbf{e}(w_{i-1}), \mathbf{e}(w_i), \mathbf{e}(w_{i+1}), \dots, \mathbf{e}(w_{i+n})]$$

$$\mathbf{h}_1 = f(\mathbf{W}_0 \mathbf{h}_0 + \mathbf{b}_0)$$

向量表示

得到 n 元词组的得分: $score(w_i, Context) = \mathbf{W}_1 \mathbf{h}_1 + \mathbf{b}_1$

3. 表示学习模型

在向量优化过程中，C&W模型希望每个正样本的打分比对应的负样本的打分高1分，即：

$$\text{score}(w_i, \text{Context}) > \text{score}(w'_i, \text{Context}) + 1$$

对于整个训练语料，C&W模型需要遍历语料中的每个 n 元组，并最小化如下目标函数：

$$\text{loss} = \sum_{(w_i, C) \in D} \sum_{w'_i \in V'} \max(0, 1 + \text{score}(w'_i, \text{Context}) - \text{score}(w_i, \text{Context}))$$

✧**问题：**上下文中的词顺序对预测结果有直接的影响；训练速度慢；固定上下文窗口范围。

3. 表示学习模型

②CBOW 模型


Tomas Mikolov, K. Chen et al . 2013. Efficient estimation of word representation in vector space. arXiv preprint arXiv: 1301.3781, 2013

✧基本思路

输入上下文词，预测中心目标词。

✧与C&W模型的区别

- 输入不再是上下文词对应词向量的拼接，直接采用所有词向量的平均；
- 省略隐层，输入层直接与输出层链接，采用 Logistic 回归的形式计算中心目标词的概率。



3. 表示学习模型

给定训练语料中任意一个 n 元组 ($n = 2C+1$) :

$$(w_i, C) = w_{i-C} \dots w_{i-1} w_i w_{i+1} \dots w_{i+C},$$

将 $WC = \boxed{w_{i-C} \dots w_{i-1}} \boxed{w_{i+1} \dots w_{i+C}}$ 作为输入, 计算上下文词的平均向量:

$$\mathbf{h} = \frac{1}{2C} \sum_{i-C \leq k \leq i+C, k \neq i} \mathbf{e}(w_k)$$

$\mathbf{h}$ 直接作为上下文的语义表示, 预测中心目标词 w_i 的概率:

$$p(w_i | WC) = \frac{\exp[\mathbf{h} \cdot \mathbf{e}(w_i)]}{\sum_{k=1}^{|V|} \exp[\mathbf{h} \cdot \mathbf{e}(w_i)]}$$

3. 表示学习模型

在CBOW模型中，词向量是唯一的神经网络参数。对于整个训练语料，模型优化词向量矩阵 L_T ，以最大化所有词的对数似然：

$$\tilde{L}_T = \arg \max_{L_T} \sum_{w_i \in V} \log p(w_i | WC)$$


3. 表示学习模型

③ Skip-gram 模型

Tomas Mikolov, K. Chen et al . 2013. Efficient estimation of word representation in vector space. arXiv preprint arXiv: 1301.3781, 2013

✧ 基本思路

用中心词预测所有的上下文词。



3. 表示学习模型

给定训练语料中任意一个 n 元组 ($n = 2C+1$) :

$$(w_i, C) = w_{i-C} \dots w_{i-1} \boxed{w_i} w_{i+1} \dots w_{i+C},$$

Skip-gram 模型直接利用中心词 w_i 的词向量 $\mathbf{e}(w_i)$ 预测上下文

$WC = w_{i-C} \dots w_{i-1} w_{i+1} \dots w_{i+C}$ 中每个词 w_j 的概率:

$$p(w_j | w_i) = \frac{\exp[\mathbf{e}(w_i) \cdot \mathbf{e}(w_j)]}{\sum_{k=1}^{|V|} \exp[\mathbf{e}(w_i) \cdot \mathbf{e}(w_k)]}$$

Skip-gram 模型的目标优化函数与CBOW模型的目标函数类似, 都是对于整个训练语料优化词向量矩阵 L_T , 以最大化所有上下文词的对数似然:

$$\tilde{L}_T = \arg \max_{L_T} \sum_{w_i \in V} \sum_{w_j \in WC} \log p(w_j | w_i)$$

3. 表示学习模型

(2) 短语的表示学习

假设短语 ph_i 由 n 个词语构成: $ph_i = w_1 w_2 \dots w_n$

①将短语视为词袋, 其表示为词向量的平均:

$$\mathbf{e}(ph_i) = \frac{1}{n} \sum_{k=1}^n \mathbf{e}(w_k)$$

或者对词向量的每一维取最大:

$$\mathbf{e}(ph_i) = \max_{k=1} \left(\mathbf{e}(w_1), \mathbf{e}(w_2), \dots, \mathbf{e}(w_n) \right)$$


或者其表示为词向量的加权平均:

$$\mathbf{e}(ph_i) = \sum_{k=1}^n v_k \cdot \mathbf{e}(w_k)$$

3. 表示学习模型

②基于递归自编码器的表示学习(recursive auto-encoder, RAE)

假设 $n = 4$



$$x_1^2 = f(W^{(1)}[x_1; x_2] + b^{(1)})$$

$$\text{从 } x_1^2 \text{ 重构: } [x'_1; x'_2] = f(W^{(2)}x_1^2 + b^{(2)})$$

$$E_{rec}([x_1; x_2]) = \frac{1}{2} \|[x_1; x_2] - [x'_1; x'_2]\|^2$$

x_1^2 与 x_3 作为输入, 得到 x_1^3 , x_1^3 与 x_4 作为输入, 得到 x_1^4 , 以此类推。


$$E_{\theta}(ph_i) = \operatorname{argmin}_{bt \in A(ph_i)} \sum_{nd \in bt} E_{rec}(nd)$$

二叉树集合

二叉树中的任意节点

3. 表示学习模型

➤ 验证：测试语义相近的短语在语义上向量空间能否聚在一起



θ 表示神经网络的参数。

假设用于训练的短语集合为 $S(ph)$, 对于一个未见的短语 ph^* , 利用短语向量之间的余弦距离度量任意两个短语之间的语义相似度, 从 $S(ph)$ 中搜索与 ph^* 相似的短语列表 $List(ph^*)$, (通常由人工) 检验 $List(ph^*)$ 与 ph^* 是否真正语义相近。

3. 表示学习模型

➤ 例如

新输入短语	RAE
military force	core force main force labor force
at a meeting	to a meeting at a rate a meeting ,
do not agree	one can accept i can understand do not want
each people in this nation	each country regards each country has its each other , and

◆ 开源工具

● Google Word2Vec / word2phrase

<http://code.google.com/p/word2vec/>

3. 表示学习模型

(3) 句子的表示学习

假设句子 s_i 由 n 个词语构成: $s_i = w_1 w_2 \dots w_n$

①将句子视为词袋, 其表示为词向量的平均:

$$\mathbf{e}(s_i) = \frac{1}{n} \sum_{k=1}^n \mathbf{e}(w_k)$$

如果考虑不用词的作用大小, 可以对每个词向量加权: $\mathbf{e}(s_i) = \frac{1}{n} \sum_{k=1}^n v_k \mathbf{e}(w_k)$

权重 v_k 可以采用 TF-IDF 值等其它度量值。

3. 表示学习模型

②PV-DM 和 PV-DBOW 模型

PV-DM 模型是在CBOW模型基础上的扩展，PV-DBOW模型则是在 Skip-gram 模型基础上的扩展。

每个句子 s_i 对应一个序号 i ，该序号可以唯一代表句子，假设句子的向量维度为 p ，训练集中所有句子的向量对应一个矩阵 $\mathbf{PV} \in \mathbb{R}^{M \times p}$ ，序号为 i 的句子对应的向量就是 $\mathbf{PV}$ 中的第 i 行向量。

$$\mathbf{PV} = \begin{bmatrix} \bullet & \bullet & \bullet & \dots & \bullet \\ \bullet & \bullet & \bullet & \dots & \bullet \\ \vdots & \vdots & \vdots & & \vdots \\ \bullet & \bullet & \bullet & \dots & \bullet \end{bmatrix} \leftarrow s_i$$

3. 表示学习模型

以 PV-DM (**P**aragraph **V**ector with sentence as **D**istributed **M**emory) 模型为例。

基本思路：以句子为单位，对于任意一个 n 元组 $(w_i, C) = w_{i-C} \dots w_{i-1} w_i w_{i+1} \dots w_{i+C}$ 和该句子的序号 SenId，将 SenId 和 $WC = w_{i-C} \dots w_{i-1} w_{i+1} \dots w_{i+C}$ 作为输入，计算其平均向量（或采用向量拼接等方式）：

$$\mathbf{h} = \frac{1}{2C+1} \left(\mathbf{e}(\text{SenId}) + \sum_{i-C \leq k \leq i+C, k \neq i} \mathbf{e}(w_k) \right)$$


中心词 w_i 的概率 $p(w_i | w_{i-C}, \dots, w_{i-1}, w_{i+1}, \dots, w_{i+C}, \text{SenId})$ 、目标函数和训练方法与 CBOW 一样。

任务相关的表示学习

3. 表示学习模型

③ Skip-Thought 模型

借鉴Skip-gram模型，它利用当前句子 D_k 预测前一个句子 D_{k-1} 和后一个句子 D_{k+1} 。其基本假设是连续出现的句子 $D_{k-1}D_kD_{k+1}$ 表达的意思比较接近或相关，因此根据句子 D_k 可以重构出前后两个句子。



3. 表示学习模型

➤ 编码器

可直接采用基于循环神经网络的语言模型，或者循环神经网络的每个神经元采用门控循环单元(gated recurrent unit, GRU)（是LSTM的简化，省去了记忆单元）；或者采用基于LSTM的语言模型。

对于句子 $D_k = w_1 w_2 \dots w_n$ ，最后一个位置（第 n 个词）的隐藏表示(h_n^k)将作为整个句子的语义编码表示。

那么，如何训练LSTM 或者GRU的参数呢？

— 通过解码前后句子。

3. 表示学习模型

➤ 解码器

以预测前一个句子为例。

每一时刻的输入包括：上一个句子的隐层表示 $\mathbf{h}_j^{k-1}$ ，已经产生的前一个句子的词语序列 $w_1^{k-1} w_2^{k-1} \cdots w_{j-1}^{k-1}$ ，当前句子 D_k 的隐层表示 $\mathbf{h}_n^k$ ，生成前一个句子的下一个词汇的概率为：

$$p\left(w_j^{k-1} \mid w_{<j}^{k-1}, \mathbf{h}_n^k\right) \propto \exp(\underbrace{\mathbf{e}(w_j^{k-1}), \mathbf{h}_j^{k-1}}_{\text{内积}})$$

目标函数：

$$\sum_{k=1}^M \left\{ \sum_{j=1}^l p\left(w_j^{k-1} \mid w_{<j}^{k-1}, \mathbf{h}_n^k\right) + \sum_{t=1}^m p\left(w_t^{k+1} \mid w_{<t}^{k+1}, \mathbf{h}_n^k\right) \right\}$$

其中， M 为训练集合中句子的数目， l 和 m 分别是前一个句子和后一个句子的长度。

3. 表示学习模型

(4) 文档的表示学习

假设文档 D_i 由 $|D_i|$ 个词语构成。

①将文档视为词袋，其表示为词向量的平均：

$$\mathbf{e}(D_i) = \sum_{k=1}^{|D_i|} v_k \mathbf{e}(w_k)$$

权重 v_k 可以采用平均值： $v_k = \frac{1}{|D_i|}$ 或者TF-IDF 值等其它度量值。

3. 表示学习模型

② 基于句子语义组合的文档表示

假设文档 $D = (D_i)_{i=1}^M$ 由 M 个句子组成，其中第 i 个句子由 n 个词汇组成：
 $S_i = w_{i,1} \cdots w_{i,n}$ 。利用LSTM可以获得句子 S_i 的分布式表示：

$$\mathbf{e}_{s_i} = \text{LSTM}(w_{i,1} \cdots w_{i,n})$$

以句子的分布式表示 $\mathbf{e}_{s_1} \cdots \mathbf{e}_{s_M}$ 作为输入，用双向LSTM分别学习每个句子 S_i 的正向（从文档第1个句子到当前位置 i ）隐层表示 $\vec{\mathbf{h}}_i$ 和逆向隐层（从最后一个句子到当前位置 i ）表示 $\overleftarrow{\mathbf{h}}_i$ ：

$$\vec{\mathbf{h}}_i = \text{LSMT}(\mathbf{e}_{s_i}, \vec{\mathbf{h}}_{i-1})$$

$$\overleftarrow{\mathbf{h}}_i = \text{LSMT}(\mathbf{e}_{s_i}, \overleftarrow{\mathbf{h}}_{i+1})$$

从文档第1个句子到第 $i-1$ 个句子的隐藏向量。

从文档最后句子到第 $i+1$ 个句子的隐藏向量。

3. 表示学习模型

将双向隐层表示拼接，形成句子 S_i 对应的隐层表示：

$$\mathbf{h}_i = [\vec{\mathbf{h}}_i; \overleftarrow{\mathbf{h}}_i]$$

那么，由文档中所有句子的隐层表示可以得到整个文档的表示：

$$\mathbf{e}_D = \sum_{i=1}^M v_i \mathbf{h}_i$$

其中， v_i 为权重。如果取平均的话， $v_i = \frac{1}{M}$ 。

也可以通过注意力机制模型学习权重。

3. 表示学习模型

③基于层次化的自编码器

✧**基本思路：**对 M 个句子的文档 $D = (s_i)_{i=1}^M$ 进行编码，获得对应的向量 $\mathbf{e}_D$ ，如果能够根据 $\mathbf{e}_D$ 重构出文档 D ，那么 $\mathbf{e}_D$ 就是文档 D 正确的分布式表示。

✧**编码：**获得句子的表示，利用 LSTM 等方法对文档中的句子序列进行建模，得到文档的表示 $\mathbf{e}_D$ ；

✧**重构：**根据文档表示重构出文档中每个句子的隐层表示，然后重构出每个句子中的所有词汇。

详见《文本数据挖掘》，第2版，
清华大学出版社，2022, pp. 53-54。



◆ 向量空间模型

特征项；特征权重

◆ 分布式词表示学习

(1) C&W 模型

(2) CBOW 模型

(3) Skip-gram 模型

◆ 短语表示学习

- 将短语视为词袋
- 自回归编码器

◆ 句子表示学习 & 文档表示



本章内容

1. 问题提出
2. 向量空间模型
3. 表示学习模型

 4. 习题

4. 习题

1. 请分析说明短语表示学习是否可以采用词语表示学习方法（如CBOW和Skip-gram模型），为什么？
2. 利用北京大学标注的汉语分词语料，或者借助爬虫工具自己从互联网上收集足够的英文语料，分别采用C&W、CBOW和Skip-gram模型得到汉语或英语的词向量，分析对比不同模型的结果差异。
3. 利用上面第2题的相同语料和Google Word2Vec 开源工具获得汉语或英语的词向量表示，并与第2题中自己实现的结果进行对比分析。

谢谢!

Thanks!

