

第8章 知识增强的大语言模型

宗成庆

中国科学院自动化研究所

cqzong@nlpr.ia.ac.cn

本章内容

- ➡ 1. 问题概述
- 2. 检索增强的生成方法
- 3. 其他改进方法
- 4. 习题

1. 问题概述

◆ 大模型存在的缺陷

➤ 幻觉

- 信息过时
- 参数化知识效率低
- 缺乏专业领域的深度知识
- 推理能力弱

◆ 实际应用需求

- 领域精准问答
- 数据频繁更新
- 生成内容可解释可溯源
- 成本可控
- 数据隐私保护

1. 问题概述

- ◆ **语境冲突性幻觉（忠实性幻觉）** LLM 现在生成的内容与之前生成的内容相冲突，或LLM 生成的内容与用户提供的输入相背离。

User Tell me something about the NBA Commissioner.

Model In the world's most popular basketball league, the NBA, Commissioner Adam Silver has long been regarded as a leader and decision-maker. Firstly, **Silver** has claimed his dedication to maintaining fairness and competitiveness in the game. Secondly, **Silver** has repeatedly emphasized his concern for player health and well-being. In this case, **Stern**'s words and actions clash with his stated goal of caring for player welfare.

User Please summarize the following content: My friend **Hill** and I love playing basketball together. We spend hours on the court, dribbling, shooting, and competing against each other. Our passion for this game brings us closer as good friends.

Model **Lucas** and I love playing basketball and this makes us good friends.



Please summarize the following news article:

Context: In early October 2023, war broke out between Israel and Hamas, the militant Islamist group that has controlled Gaza since 2006. Hamas fighters fired rockets ... civilians and taking dozens of hostages.



Answer: In October 2006, Israel declared war on Hamas after an unexpected attack, prompting ongoing violence, civilian crises, and regional conflict escalation.



Referring to “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”

“Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models”

1. 问题概述

◆与事实相冲突的幻觉 即LLM 生成的内容有悖于客观事实。



Who was the first person to walk on the moon?



Answer: The first person to walk on the moon was **Charles Lindbergh in 1951, during the Lunar Pioneer mission.** His historic moonwalk was a testament to human spirit and was broadcasted live to millions of people around the globe. ❌



Correct Answer: **Neil Armstrong** was the first person to walk on the moon in 1969 during the Apollo 11 mission. ✅

Referring to “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”

“Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models”

1. 问题概述

◆ **无中生有** 完全自己捏造。

- 在黄河流经的很多地段，尤其是中下游，河床已经高于周边地势。你认为下一次黄河改道最有可能的地方在哪里？



黄河下一次自然改道最可能发生在 **河南-山东段的地上悬河区域**（尤其是开封至东营段），这是由地质历史规律和现代水文条件共同决定的。以下是具体分析：

.....

结论

最可能改道区域：河南兰考-山东东营段（现行河道以北的古河道优先）。

时间尺度：若无重大工程干预，自然改道可能在21世纪末至22世纪初发生，但人为调控可能进一步推迟。

建议关注：黄河水利委员会的 《黄河下游河道与滩区综合治理规划》 和气候变化背景下的极端水文事件。

① 本回答由 AI 生成，内容仅供参考，请仔细甄别。

1. 问题概述

◆原因分析

- **大模型缺乏相关知识或内化错误知识（来自于数据）**
 - 将相关性（如位置接近或高度共现的关联）误解为事实知识
 - LLM 偏向于肯定测试样本，容易复制甚至放大这种幻觉行为
 - 存在一些导致幻觉的训练数据（模仿性、重复性、社会偏见、知识边界或过时等）
- **大模型有时会高估自己的能力**
 - 对于超大LLM 来说，**正确答案和错误答案的分布熵**可能是相似的
 - LLM 在生成错误答案时与生成正确答案时同样自信

1. 问题概述


➤ 有问题的对齐过程可能会误导大模型产生幻觉

- 如果LLM 在预训练阶段没有获得相关的先决知识，在训练指令时一个错误的对齐过程会促使LLM 产生幻觉;
- “谄媚”(sycophancy), LLM 可能会生成偏向用户观点的回答，而不是提供正确或真实的答案。

➤ LLM采用的生成策略

- 局部最优化（标记预测）不一定能确保全局最优化（序列预测）；
- 基于抽样的生成策略（如 $\text{top-}p$, $\text{top-}k$ 等）可能引入随机性。


1. 问题概述



Referring to “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”

“Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models”

1. 问题概述






有监督的微调
(Supervised Fine-Tuning, SFT)

Referring to “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”
“Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models”

1. 问题概述

◆ 幻觉评估

- 生成事实性陈述的判别标准是什么？
- 如何度量出大模型幻觉的具体指标？



1. 问题概述

◆数据集

Benchmark	Datasets	Data Size	Language	Attribute			Task			
				Factuality	Faithfulness	Manual	Task Type	Input	Label	Metric
TruthfulQA (Lin et al., 2022)	-	817	English	✓	✗	✓	Generative QA Multi-Choice QA	Question	Answer	LLM-Judge & Human
REALTIMEQA (Kasai et al., 2022)	-	Dynamic	English	✓	✗	✓	Multi-Choice QA Generative QA	Question	Answer	Acc EM & F1
SelfCheckGPT-Wikibio (Miao et al., 2023)	-	1,908	English	✗	✓	✗	Detection	Paragraph & Concept	Passage	AUROC
HaluEval (Li et al., 2023c)	Task-specific	30,000	English	✗	✓	✗	Detection	Query	Response	Acc
	General	5,000	English	✗	✓	✗	Detection	Task Input	Response	Acc
Med-HALT (Umapathi et al., 2023)	-	4,916	Multilingual	✓	✗	✗	Multi-Choice QA	Question	Choice	Pointwise Score & Acc
FACTOR (Muhlgay et al., 2023)	Wiki-FACTOR	2,994	English	✓	✗	✗	Multi-Choice QA	Question	Answer	likelihood
	News-FACTOR	1,036	English	✓	✗	✗	Multi-Choice QA	Question	Answer	likelihood
BAMBOO (Dong et al., 2023)	SenHallu	200	English	✗	✓	✗	Detection	Paper	Summary	P & R & F1
	AbsHallu	200	English	✗	✓	✗	Detection	Paper	Summary	P & R & F1
ChineseFactEval (Wang et al., 2023a)	-	125	Chinese	✓	✗	✓	Generative QA	Question	-	Score

1. 问题概述

◆数据集

HaluQA (Cheng et al., 2023)	Misleading	175	Chinese	✓	✗	✓	Generative QA	Question	Answer	LLM-Judge
	Misleading-hard	69	Chinese	✓	✗	✓	Generative QA	Question	Answer	LLM-Judge
	Knowledge	206	Chinese	✓	✗	✓	Generative QA	Question	Answer	LLM-Judge
FreshQA (Vu et al., 2023)	Never-changing	150	English	✓	✗	✓	Generative QA	Question	Answer	Human
	Slow-changing	150	English	✓	✗	✓	Generative QA	Question	Answer	Human
	Fast-changing	150	English	✓	✗	✓	Generative QA	Question	Answer	Human
	False-premise	150	English	✓	✗	✓	Generative QA	Question	Answer	Human
FELM (Chen et al., 2023d)	-	3,948	English	✓	✓	✗	Detection	Question	Response	Balanced Acc & F1
PHD (Yang et al., 2023)	PHD-LOW	100	English	✗	✓	✗	Detection	Entity	Response	P & R & F1
	PHD-Medium	100	English	✗	✓	✗	Detection	Entity	Response	P & R & F1
	PHD-High	100	English	✗	✓	✗	Detection	Entity	Response	P & R & F1
ScreenEval (Lattimer et al., 2023)	-	52	English	✗	✓	✗	Detection	Document	Summary	AUROC
RealHall (Friel and Sanyal, 2023)	COVID-QA	N/A	English	✗	✓	✗	Detection	Question	Answer	AUROC
	DROP	N/A	English	✗	✓	✗	Detection	Question	Answer	AUROC
	Open Assistant	N/A	English	✗	✓	✗	Detection	Question	Answer	AUROC
	TriviaQA	N/A	English	✗	✓	✗	Detection	Question	Answer	AUROC
LSum (Feng et al., 2023a)	-	6,166	English	✗	✓	✗	Detection	Document	Summary	Balanced Acc
SAC ³ (Zhang et al., 2023a)	HotpotQA	250	English	✗	✓	✗	Detection	Question	Answer	AUROC
	NQ-Open	250	English	✗	✓	✗	Detection	Question	Answer	AUROC

1. 问题概述

◆检索增强生成方法(Retrieval-Augmented Generation, RAG)

- LLM在回答问题或生成文本时，**先会从大量文档中检索出相关的信息**，然后基于这些信息来生成回答;
- RAG方法不必为每一个特定的任务重新训练整个大模型，只需要**外挂知识库**;
- RAG模型尤其适合**知识密集型的**任务。



本章内容

1. 问题概述

➡ 2. 检索增强的生成方法

3. 其他改进方法

4. 习题



外挂知识库 vs. 知识参数化

大模型优化的方式：


- 提示工程(Prompt Engineering)
- 检索增强(Retrieval-Augmented Generation) $\Rightarrow$ 用户需要特定信息
- 指令微调(Instruct / Fine-tuning) $\Rightarrow$ 模型需要掌握一种能力



RAG vs. Fine-tuning

对比因素	RAG	Fine-tuning
外部知识利用	擅长利用外部资源，适合文档或其他结构化/非结构化数据库	需要构造监督数据集以内化外部知识，不适用频繁更改的数据源
知识更新	直接更新检索知识库，适合动态数据环境	重新微调训练，保持更新需要大量资源
训练数据要求	对数据加工和处理的要求低	微调依赖高质量数据集，有限的数据集可能不会产生显著性能改善
可解释性 (可溯源性)	通常可以追溯到特定数据源的答案，从而提供更高等级的可解释性和可溯源性	微调就像黑匣子，并不总是清楚模型为何会做出这样的反应，相对较低的可解释性
可扩展性	高，可以动态衔接不同的数据源	低，扩展新知识需要重新微调训练
耗时	由于（多次）数据检索可能会有更高延迟	经过微调的 LLM 无需检索即可响应

RAG基本流程




举例说明

步骤1：构建数据索引

- ① 将文档分割成均匀的块，每个块是一段原始文本；
- ② 利用编码模型为每个文本块生成Embedding；
- ③ 将每个块的Embedding存储到向量数据库中。


Embed Sentence → Link to Expanded Window



举例说明

步骤2：检索：通过向量相似度检索和问题最相关的 k 个文档。

步骤3：生成：原始Query与检索得到的文本组合后输入大语言模型，得到最终回答。



问题讨论

检索什么？

- 词元
- 词组
- 句子
- 段落
- 实体
- 知识图谱

什么时候检索？

- 单次检索
- 每个Token
- 每 n 个Token (Phrase)
- 自适应检索

怎么使用检索的结果？

- 输入/数据层
- 模型/中间层
- 输出/预测层

什么时候增强？

- 预训练
- 指令微调
- 推理

知识检索增强方法的使用场景

- 数据长尾分布
- 知识更新频繁
- 回答需要验证追溯
- 领域专业化知识
- 数据隐私保护

问答

RETRO (Borgeaud et al, 2021)
REALM (Gu et al, 2020)
ATLAS (Izacard et al, 2023)

事实验证

RAG (Lewis et al, 2020)
ATLAS (Izacard et al, 2022)
Evi. Generator (Asai et al, 2022a)

对话

BlenderBot3 (Shuster et al, 2022)
Internet-augmented generation (Komeili et al., 2022)

自然语言推理

kNN-Prompt (Shi et al., 2022)
NPM (Min et al., 2023)

机器翻译

kNN-MT (Khandelwal et al., 2020)
TRIME-MT (Zhong et al., 2022)

代码生成

DocPrompting (Zhou et al., 2023)
Natural Prover (Welleck et al., 2022)

文摘

FLARE (Jiang et al, 2023)

常识推理

Raco (Yu et al, 2022)

情感分析

kNN-Prompt (Shi et al., 2022)
NPM (Min et al., 2023)

本章内容

1. 问题概述

2. 检索增强的生成方法

 3. 其他改进方法

4. 习题





动态知识引导的自动写作

◆ 知识表示(knowledge representation)

- 逻辑表示法：命题逻辑，谓词逻辑
- 产生式表示法：IF ... THEN ...
- 框架表示 (Frame)
- 面向对象的表示方法
- 语义网表示法  知识图谱
- 本体表示法
-

回顾：知识图谱

见第4章(3)：





知识图谱构建

- 实体识别：识别实体的边界、所属类别（人名、地名、机构.....）
- 实体消歧：消除歧义，如“迈克·乔丹 → 篮球运动员/ 教授？”“人大 → 大学/机构？”
- 关系定义和关系抽取：关系分类
- 事件抽取
 - 限定域的事件抽取
 - 开放域的事件抽取
 - 事件关系抽取



部分开源的知识图谱

● 英文：

- WikiData (<https://www.wikidata.org>)
- YAGO (<https://yago-knowledge.org>)
- DBpedia (<https://www.dbpedia.org/>)

● 中文：

- 开源社区 OpenKG (<http://openkg.cn/>)，里面包含数百个中文的各个领域的知识图谱。

●归纳推理

●演绎推理

(姚明, 出生地, 上海)


(上海, 属于, 中国)

⟹ (姚明, 属于/是, 中国人)

(姚明, 性别, 男)

(上海, 雇佣, 火箭队)

⟹ (火箭队, 属于/是, 男篮)





机器写作与人工写作

提示：埃隆·马斯克在SpaceX首次发射“星舰”(史上最强大的火箭)之前设定了较低的期望值。



GPT-3.5-turbo:

埃隆·马斯克→ SpaceX → 星舰→ 火星 → 马斯克 → 马斯克 → 马斯克 → 星舰→ SpaceX
→ 马斯克 → SpaceX



Text-Davinci-003:

SpaceX→ 埃隆·马斯克→ 星舰→ 马斯克→ 马斯克→ 星舰→ 火星→ 马斯克→ 星舰→ 德克萨
克萨斯州→ 星舰→ SpaceX→ 马斯克→ 马斯克→ 星际飞船



人撰写的文本:

NASA→ 埃隆·马斯克→ SpaceX→ SpaceX→ 星舰→ 德克萨斯州→ SpaceX→ 埃隆·马斯克→
SpaceX→ SpaceX→ 德克萨斯州→ 南帕德里岛→ SpaceX→ 南帕德里岛→ SpaceX→ 马斯克→ 星舰→
火星→ NASA→ SpaceX→ 星舰→ 月球→ 阿尔忒弥斯计划→ 地球→ 星舰→ 超重推进器→ 超重推进
器→ 星舰→ 星舰→ 地球→ SpaceX→ 德克萨斯州→ SpaceX→ SpaceX猛禽发动机→ 星舰→ 超重推
进器→ SpaceX→ 美国联邦航空局→ SpaceX→ 德克萨斯州→ 美国联邦航空局→ SpaceX

对比分析


大语言模型生成的文本往往过于关注提示中给出的实体或事件，难以包含更丰富的实体和信息。

模型	信息丰富度平均排名
人工	1.60
Text-Davinci-003 (最初GPT-3+InstT+RLHF)	2.75
GPT-3.5-turbo (API ChatGPT)	3.25
LLAMA-13B (开源)	4.00
GPT-3.5-curie (13B蒸馏版)	4.40
GPT-3-davinci (最初始GPT-3)	4.60

改进思路

在知识图谱中寻找一个子图以约束文本的生成，增强信息丰富度，且避免偏离主题。

蓝色实体表示该实体出现在输入信息中。用虚线所示的一跳关系的子图约束文本生成，子图中的实体都与输入信息实体存在直接关系，能够避免生成文本偏离主题。





评价

- 衡量生成文本质量：PPL, Dist-3, ROUGE-L, BERTScore
- 衡量信息丰富度：知识约束的实体数量 (Knowledge Constrained Entity, KC-E)

知识约束的实体数量：生成文本中与输入提示中实体存在**直接关系**的实体数量，所谓“直接关系”即在知识图谱中两个实体节点直接存在至少一条边。

评价指标	斯皮尔曼 相关性系数	肯德尔 相关性系数	皮尔森 相关性系数
实体数量	0.398	0.313	0.387
文本长度	0.487	0.396	0.479
事件数量	0.483	0.381	0.481
知识约束的实体数量	0.554	0.440	0.550

本章小结

- ◆ 大模型存在的问题分析：幻觉
- ◆ 检索增强的生成方法方法
- ◆ 示例：基于外挂知识库（知识图谱）的LLMs生成能力改进方法

本章内容

1. 问题概述
2. 检索增强的生成方法
3. 其他改进方法
-  4. 习题

4. 习题

1. 请查阅信息检索相关的文献，了解信息检索的基本原理。
2. 请阅读知识图谱相关的文献，了解知识图谱相关技术，并登录开源知识图谱网站，学习已有知识图谱的构建方法和使用方式。
3. 实验分析采用知识检索增强时，不同的索引粒度对推理结果的影响。
4. 实验分析对于同一个大语言模型采用知识检索增强时，不同的任务在不同时刻进行检索时对结果的影响。
5. 实验分析对于某个大语言模型进行外挂知识库增强时，针对不同的应用任务，如何选择不同的知识图谱？

谢谢!

Thanks!



本章部分内容参考了同济大学王昊奋教授的讲座报告，特此感谢！